Tema 2

Introducción a las Herramientas a utilizar

2.1 Material de estudio

Los materiales de estudio de este tema son: capítulo 2 y el capítulo 3 del libro Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition completos y adquirir un conocimiento inicial de la mayoría de las herramientas a usar durante el curso. Iremos detallando el uso de estos materiales en las secciones siguientes.

Sobre las ecuaciones del libro

Para la correcta visualización de las ecuaciones del libro en Chrome es necesario instalar la extensión Math Anywhere que le proporciona el soporte para MathML. En otros navegadores como FireFox, Safari y Opera este soporte ya está incluido. Para Internet Explorer, dependiendo de la versión, existe un plugin llamado MathPlayer y para Edge MathML Companion.

2.2 Índice

- Instalación de las principales herramientas.
- Introducción a Numpy
- Introducción a pandas

- Introducción a Matplotlib
- Introducción a scikit-learn
- Introducción a la metodología de los proyectos de Aprendizaje Automático

2.3 Instalación de las principales herramientas

Lo primero va a ser la instalación de casi todas las herramientas que se van a usar en la asignatura, en el tema 6 instalaremos las específicas de redes neuronales (Tensorflow y Keras). En el la sección Get the Data del capítulo 2 del libro se explica cómo usar Google Colab como principal entorno para escribir y ejecutar el código en Jupyter notebooks y también se indica cómo descargarlos localmente desde su github, aunque algunos de los enlaces que ponen a Anaconda están desactualizados, usad mejor los que ponemos a continuación. Si decidís trabajar localmente el procedimiento para preparar vuestro entorno en cualquier SO sería la instalación de Anaconda Free tier, en este enlace podéis encontrar toda la información necesaria para la instalación y uso de Anaconda Distribution y de su herramienta gráfica Anaconda Navigator.

Una interesante introducción a Python, o para consultar su programación, se puede ver en Introducing Python, 2nd Edition, con código de ejemplos descargable.

Anaconda también se puede usar para instalar paquetes de R e instala RStudio por defecto.

2.4 Introducción a las herramientas

A lo largo del capítulo 2 del libro encontraremos ejemplos del uso de las herramientas usando como entorno de programación Jupyter Notebook, que Anaconda instala por defecto y que será el que utilicemos durante el curso. En el primer tema se comentó que los dos usos principales del aprendizaje supervisado son la clasificación y la regresión. En este capítulo se da un ejemplo del uso de las herramientas para un estudio de la predicción de precios de las viviendas en California usando regresión. También el capítulo 3 del libro da ejemplos del uso de las herramientas en este caso dedicados a la clasificación de imágenes de dígitos escritos a mano.

Dos de las herramientas, Numpy y Pandas, son objeto de estudio de la asignatura Programación en Entornos de Datos por lo que aquí solo se pretende dar una pequeña introducción suficiente hasta que en dicha asignatura se estudien con profundidad.

2.4.1 Numpy

Numpy es un paquete de computación científica para Python, en esta asignatura lo usaremos básicamente para el manejo de arrays. Como introducción se recomienda leer el NumPy quickstart.

2.4.2 pandas

pandas es una biblioteca para análisis de datos en Python. En esta asignatura lo usaremos básicamente para la lectura de archivos CSV a través de los DataFrame. Como introducción se recomienda leer las sección Package overview y el tutorial 10 minutes to pandas.

2.4.3 Matplotlib

Matplotlib es una biblioteca para la generación de gráficos en Python. Como introducción se recomienda leer los tutoriales Quick start guide, Pyplot tutorial y en Plot types se tienen ejemplos de uso, haciendo click en los gráficos se accede al código que los genera.

2.4.4 scikit-learn

scikit-learn, o abreviadmente sklearn, es la herramienta fundamental de esta asignatura. Es una de las principales bibliotecas para Aprendizaje Automático en Python. La iremos estudiando en casi todos los temas de esta asignatura y una introducción interesante se da en los capítulos 2 y 3 del libro. La descripción de todos los algoritmos implementados en scikit-learn se puede ver en su User Guide, cada descripción contiene un amplio comentario sobre las características del algoritmo, su formulación matemática, enlaces a la API de scikit-learn y está acompañada de ejemplos, de uso cuyo código se puede descargar de la página correspondiente como scripts de Python o como notebooks de Jupyter.

2.4.5 Graphviz

Si queremos que se muestren gráficos de habrá que instalar en Anaconda pydot o pydotplus y pygraphviz, así como el propio Graphviz que no es un paquete Python. Esto también permite exportar los Árboles de Decisión. En Google Colab estas utilidades están instaladas.

2.5 Introducción a la metodología de los proyectos de Aprendizaje Automático

En esta sección nos referimos a la lectura de los capítulo 2 y 3 del libro completos. Como comenta en el libro para la lectura de estos capítulos no hace falta conocer los algoritmos que se emplean solo familiarizarse con el uso de las técnicas contenidas en scikit-learn y el resto de herramientas y a la metodología a emplear en los proyectos de Aprendizaje Automático. De todas formas recomendamos una lectura rápida en la User Guide de las primeras secciones correspondientes a cada algoritmo usado en los dos capítulos. Las APIs de scikit-learn de los distintos algoritmos tiene muchas características de uso en común, lo que facilita su aprendizaje y uso, como puede verse en los ejemplos del libro. Esta ha sido una de las razones, junto con su amplia disponibilidad de algoritmos y excelente documentación, para usar esta herramienta.

En estos dos capítulos se comentan técnicas para:

- La obtención de datos.
- La visualización de los datos para obtener información.
- La preparación de los datos para aplicar algoritmos y obtener mejores resultados.
- La selección y entrenamiento de modelos para tareas de regresión y clasificación y su afinación.
- El uso de medidas de rendimiento.
- La utilización práctica de los modelos obtenidos.

El espacio de aplicación de estas técnicas va más allá de su uso en esta asignatura, se utilizan en proyectos relacionados con el resto de asignaturas del máster del ámbito de la Ciencia de los Datos: Modelado Estadístico de Datos, Aprendizaje Automático II, Deep Learning, Minería de Textos, Modelos Bayesianos Jerárquicos y Minería de Datos de los Medios Sociales, así como en el TFM si se realiza en este ámbito.

2.6 Actividades autoevaluables

Realizar los ejercicios que se encuentran en la sección Exercices al final de los capítulos 2 y 3 del libro, en el notebook asociado están las soluciones.

2.7 Actividades evaluables

Este tema no tiene actividades evaluables.