Tema 4

Métodos simples de Aprendizaje Automático No-Supervisado y Semi-supervisado

4.1 Material de estudio

Los materiales de estudio de este tema son: el capítulo 9 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition, la sección In-Depth: Kernel Density Estimation del capítulo 5 de Python Data Science Handbook y adquirir un conocimiento de las herramientas que en ellos se comenta principalmente a partir de la documentación de scikit-learn. Iremos detallando el uso de estos materiales en las secciones siguientes.

Los códigos de ejemplo para este tema ya han sido descargados en temas anteriores.

4.2 Índice

En este tema vamos a dar un introducción al aprendizaje no-supervisado este tema se complementa con el tema 8 que tratará de la reducción de la dimensionalidad. Además en la asignatura Aprendizaje Automático 2 se verán otras cuestiones relacionadas con el aprendizaje no-supervisado. El aprendizaje no-supervisado se ocupa de crear modelos a partir de datos no etiquetados, no hay conocimiento a priori.

Además daremos una breve introducción al aprendizaje semi-supervisado que se ocupa de crear modelos cuando se dispone de (unos pocos) datos etiquetados y (bastantes más) datos no etiquetados.

- Técnicas de agrupamiento: K-means y DBSCAN.
- Modelos de mezclas gaussianas (GMM)
- Estimación de densidad mediante núcleos (kernel) (KDE)
- Propagación y extensión de etiquetas

4.3 Técnicas de agrupamiento

Las técnicas agrupamiento (clustering en inglés) se utilizan para crear grupos de objetos, no etiquetados, similares. La similitud puede venir dada por la distancia entre los objetos, densidad de áreas, distribuciones estadísticas, etc. En este tema veremos dos de las técnicas no probabilísticas más usadas K-Means y DBSCAN. Estas técnicas se tratan en la sección Clustering Algorithms del capítulo 9 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow, la sección comenta una serie de aplicaciones de estas técnicas. Como complemento en la documentación de scikit-learn Overview of clustering methods se da un listado de métodos, algunos de ellos se describen al final de la sección Clustering del libro Other Clustering Algorithms. Los aspectos más prácticos de las dos técnicas se pueden ver en el notebook 09_unsupervised_learning.ipynb de handson-ml3-main.

4.3.1 K-Means

La sección Clustering del libro tiene varias subsecciones dedicadas a K-Means en las que se da una introducción, se comenta el funcionamiento algoritmo, los métodos de inicialización, métodos para acelerar la ejecución, cómo encontrar el número óptimo de grupos y los límites de la técnica. En el aspecto práctico ofrece un ejemplo del uso para segmentación de imágenes. El resto de la sección: Using Clustering for Preprocessing y Using Clustering for Semi-Supervised Learning es lectura complementaria, no motivo de examen.

Para complementar el estudio de esta técnica consultar la documentación de scikit-learn 2.3.2. K-means. En el enlace se incluyen enlaces a las APIs de los 2 procedimientos (KMeans y MiniBatchKMeans) motivo de estudio que es muy conveniente conocer para su aplicación práctica. Los ejemplos incluidos al final de las secciones de las APIs son de lectura opcional, salvo Demonstration of k-means assumptions que da una idea rápida del empleo del método y alterar los datos proporcionados por make_blobs.

4.3.2 DBSCAN

La sección Clustering del libro tiene una subsección dedicadas a DBSCAN en la que se da una introducción al algoritmo. En el aspecto práctico ofrece un ejemplo del uso para agrupación de lunas creadas con make_moons.

Para complementar el estudio de esta técnica consultar la documentación de scikit-learn 2.3.7. DBSCAN. En el enlace se incluyen enlaces a la API de DBSCAN que es muy conveniente conocer para su aplicación práctica.

4.4 Modelos de mezclas gaussianas (GMM)

Los GMM son modelos probabilísticos en los que se supone que las instancias son generadas a partir de mezclas de distribuciones normales. Veremos su uso para agrupamiento, generación de datos y detección de anomalías y novedad. La primera parte de la sección Gaussian Mixtures del capítulo 9 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow comenta la teoría, su uso para agrupamiento y la generación de nuevos datos. Este método difiere de los anteriores en que es un método probabilístico y por ello puede dar las probabilidades de pertenencia a los grupos. A partir de la subsección Anomaly Detection Using Gaussian Mixtures se comenta su uso para la detección de outliers. La detección de outliers se suele usar en las etapas de análisis exploratorio de los datos para eliminar datos anómalos que puedan distorsionar los resultados de las técnicas de aprendizaje automático. Las subsecciones siguientes: Selecting the Number of Clusters y Bayesian Gaussian Mixture Models comentan técnicas para hallar el número óptimo de grupos usando los criterios de información BIC y AIC. La sección termina comentando otros algoritmos para la detección de anomalías y novedad, su estudio no es necesario, algunos de ellos serán estudiados en temas posteriores.

Para complementar el estudio de esta técnica consultar la documentación de scikit-learn 2.1. Gaussian mixture models. De esta sección es importante conocer los pros y contras de los dos métodos comentados: GaussianMixture y BayesianGaussianMixture, los aspectos teóricos de la inferencia variacional y el proceso de Dirichlet son lectura complementaria y no serán motivo de estudio. En el enlace se incluyen enlaces a las APIs de los dos métodos comentados que es muy conveniente conocer para su aplicación práctica.

Los aspectos más prácticos de GMM se pueden ver en el notebook 09_unsupervised_learning.ipynb de handson-ml3-main.

4.5 Estimación de densidad mediante núcleos (KDE)

La estimación de densidad mediante núcleos, en inglés kernel density estimation, es una técnica de estimación de funciones de densidad de probabilidad, GMM es otra. Veremos el KDE en las primeras partes de la sección In-Depth: Kernel Density Estimation del capítulo 5 de Python Data Science Handbook. En ellas se comenta la motivación del KDE, los usos prácticos y la forma de selección del parámetro bandwith, las subsecciones Example: KDE on a Sphere y Example: Not-So-Naive Bayes son lectura complementaria y no serán motivo de estudio.

Para complementar el estudio de esta técnica consultar la documentación de scikit-learn 2.8. Density Estimation el contenido es prácticamente el mismo que el del libro, aunque da una visión un poco más matemática de los que son los kernels que es conveniente conocer. De los ejemplos dos son los mismos que en el libro y en el titulado Kernel Density Estimation se ve cómo usar KDE para generar nuevas muestras, este ejemplo es también lectura complementaria.

Los aspectos más prácticos de KDE se pueden ver en el notebook 05.13-Kernel-Density-Estimation.ipynb de PythonDataScienceHandbook_master.

4.6 Propagación y extensión de etiquetas

La propagación y extensión de etiquetas será la única toma de contacto que tendremos con el aprendizaje semi-supervisado en esta asignatura, y quizás en el máster, debido a que ha sido mucho menos usado que las versiones supervisada y no-supervisada. El aprendizaje semi-supervisado puede ser usado para clasificación y regresión.

Para su estudio usaremos la documentación de scikit-learn 1.14.2. Label Propagation en ella se comentan las técnicas LabelPropagation y LabelSpreading, consultar los enlaces a sus APIs. De los ejemplos que incluye esta documentación bastará con estudiar el primero para ver una aplicación sencilla del aprendizaje semi-supervisado, el resto de ejemplo es lectura complementaria. Al principio de la documentación hay un enlace a Wikipedia en el que se puede encontrar un artículo sobre el aprendizaje semi-supervisado.

4.7 Actividades autoevaluables

4.7.1 Técnicas de agrupamiento y GMM

Realizar los ejercicios que se encuentran en la sección Exercices al final del capítulo 9 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow hasta el ejercicio 11 inclusive, salvo el 6.

4.7.2 KDE

1. ¿Qué elecciones pueden llevar a histogramas con distinta apariencia usando los mismos datos y cómo se puede evitar el problema?
2. ¿Qué es un kernel, qué parámetros tiene y cuál es su efecto?
3. ¿Cuáles son los tipos de kernel disponibles en scikit-learn?
4. Describir un procedimiento para buscar un valor apropiado para el parámetro bandwith.

4.7.3 Propagación y extensión de etiquetas

1. ¿En qué consiste el aprendizaje semi-supervisado?
2. ¿Cuáles son los modelos disponibles en scikit-learn para el aprendizaje semi-supervisado y cómo funcionan?

4.8 Actividades evaluables

Este tema no tiene actividades evaluables.

4.9 Soluciones actividades autoevaluables

4.9.1 Técnicas de agrupamiento y GMM

En el apéndice A de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow y en su correspondiente notebook, 06_decision_trees.ipynb de handson-ml3-main están las soluciones.

4.9.2 KDE

1. El tamaño y posición de los intervalos (bins). Un histograma se puede ver como pilas de bloques, uno por cada punto. Si en lugar de apilar los bloques alineados con los intervalos se alinean con los puntos que representan y se suman las alturas en de cada posición se consigue una mejor representación de los datos.

2. Un kernel es una función positiva controlada por el parámetro bandwith (ancho de banda) que especifica la forma de la distribución que se usa para suavizar la función de densidad de probabilidad que se obtiene a partir de los datos. El parámetro controla la compensación de sesgo-varianza en la estimación de la función de densidad: un ancho de banda demasiado estrecho conduce a una estimación de alta varianza (es decir, overfitting), donde la presencia o ausencia de un solo punto crea una gran diferencia. Un ancho de banda demasiado amplio conduce a una estimación de alto sesgo (es decir, underfitting) donde el núcleo ancho elimina la estructura de los datos.

3. gaussian, tophat, epanechnikov, exponential, linear, cosine.

4. Utilizando el procedimiento GridSearchCV al que se le manda el tipo de kernel, un rango de valores para el parámetro y utilizando un procedimiento de validación cruzada de manera que se obtenga el valor del parámetro que de la mejor puntuación (parámetro scoring) para la métrica elegida.

4.9.3 Propagación y extensión de etiquetas

1. El aprendizaje semi-supervisado es un tipo de aprendizaje en el que el entrenamiento se efectúa con datos etiquetados y no-etiquetados. Se hace uso de los datos adicionales sin etiquetar para capturar mejor la forma de la distribución subyacente de los datos y generalizar mejor a nuevas muestras.

2. Los modelos disponibles son LabelPropagation y LabelSpreading. Ambos construyen un grafo de similitud sobre todos los elementos del conjunto de datos de entrada, si la estructura de los datos no-etiquetados es consistente con la estructura de clases de los datos etiquetados, estas etiquetas se propagan por el árbol a los datos no-etiquetados.