Tema 7

Máquinas de vectores soporte (SVM).

7.1 Material de estudio

Los materiales de estudio de este tema son el capítulo 5 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition y adquirir un conocimiento de las herramientas que en ellos se comenta principalmente a partir de la documentación de scikit-learn. Iremos detallando el uso de estos materiales en las secciones siguientes.

Los códigos de ejemplo para este tema ya han sido descargados en temas anteriores.

7.2 Comentarios

SVM es uno de los algoritmos de Aprendizaje Automático más populares, fue introducido en 1963. Permite la clasificación, la regresión y la detección de anomalías. Originalmente es un clasificador binario aunque puede extenderse a clasificación multiclase. Está basado en encontrar el margen ("calle") más amplio que separa a las dos clases.

En el libro comienza por describir el clasificador lineal, primero el caso completamente separable (hard margin) para pasar a continuación al caso no completamente separablr (soft margin). Continúa con la clasificación no lineal, ahora la "calle" no es recta. La clasificación puede realizarse añadiendo características que son funciones no lineas de las características originales o mediante una función se similitud. Estas técnicas se implementan mediante la aplicación kernels.

A continuación se explica la regresión mediante SVM, ahora el concepto de "calle" que separa las clases se convierte en "calle" que contiene tantas muestras como sea posible. Se puede hacer regresión lineal y no lineal.

En la sección Under the Hood se describen las técnicas matemáticas en las que está fundamentado SVM, que al fin y al cabo es un problema de optimización cuadrática. Se describen las optimizaciones para hard y soft margin, las funciones de decisión y predicción, el problema dual, las ecuaciones de los kernels más comunes y la forma de entrenar SVM incrementalmente (on-line).

Para completar los contenidos del libro tenemos la documentación de scikit-learn 1.4. Support Vector Machines. En esta documentación se comentan ventas y desventajas del uso de SVM.

Se describen las clases para clasificación SVC, NuSVC y LinearSVC, esto enlaces llevan a las APIs de las clases que hay que conocer para su uso. También se comenta como usar SVM para la clasificación multiclase, un ejemplo lo tenemos en el ejercicio 10 del libro. SVM es un método de clasificación discriminativo, no aporta probabilidades de pertenencia a las clases, pero SVC y NuSVC disponen de una opción para proporcionarlas usando validación cruzada. También se comenta cómo usar las clases proporcionadas por scikit-learn en problemas no balanceados.

Las clases para regresión son SVR, NuSVR y LinearSVR.

Para detección de anomalías (outliers) scikit-learn dispone de OneClassSVM.

La documentación también comenta la complejidad computacional de los distintos procedimientos y da consejos para el uso práctico. Como lectura opcional se puede ver cómo crear kernel personalizados. El resto de secciones de la documentación, la formulación matemática, ya se han visto en el libro.

7.3 Actividades autoevaluables

Realizar los 10 ejercicios que se encuentran en la sección Exercices del capítulo 5 Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow. En el notebook 05_support_vector_machines.ipynb están las soluciones.

7.4 Actividades evaluables

La actividad evaluable asociada a este tema y al módulo 3 de la asignatura va a constituir en un ejercicio de clasificación y otro de regresión usando los datos de los alquileres vacacionales ofrecidos en la plataforma AirBnB que ya se usaron en la actividad del tema 3, ver sección **??**. Para ello habrá que crear un notebook con celdas de tipo code y de tipo

markdwon, en las de este último tipo se incluirán comentarios de lo que se esté haciendo en las de tipo code o sobre los resultados.

Para el estudio estadístico y limpieza de datos, ver subsección **??**, se pueden tomar lo que ya se hiciera en la actividad del tema 3.

La fecha de entrega de la actividad aparece en la plataforma.

7.4.1 Clasificación

La tarea de clasificación consistirá en clasificar los datos según el tipo de alojamiento, definido en el campo room_type, a partir del resto de características. Es decir, en room_type estarán codificadas las clases y en el resto de campos los atributos.

Para el estudio estadístico y limpieza de datos, ver subsección **??**, se puede tomar lo que ya se hiciera en la actividad del tema 3.

La clasificación se realizará usando LinearSVC y SVC con sus parámetros por defecto, para el entrenamiento y validación se seguirá lo descrito en los dos primeros puntos de la subsección **??**, teniendo en cuenta que ahora son dos modelos. En cuanto al punto 3, afinación de hiperparámetros, se realizará para SVC, usando el kernel RBF, buscando los mejores valores para γ y C usando GridSearchCV. En este caso no se van a dar sugerencias del rango de valores a probar, por lo que hay que realizar búsquedas de manera que cada una refine la anterior. Proponemos seguir las indicaciones de la sección 3.2 de A Practical Guide to Support Vector Classification, bastará con dos búsquedas. Para crear las listas de parámetros se puede hacer a mano o usando numpy.logspace. Las listas están equiespaciadas en escala logarítmica, si se realizara una tercera búsqueda se podría usar una escala lineal. La idea es escala logarítmica para rangos elevados y lineal para rangos no elevados.

7.4.2 Regresión

La tarea de regresión consistirá en considerar el precio por noche como variable dependiente, y el resto de campos como variables independientes. Es decir, se tratará de predecir los valores del campo price a partir de todos los demás. Convendrá repasar el capítulo 2 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition.

Puntos a tener en cuenta:

- Convendrá estudiar estadísticamente las variables price, minimun_nights y calculated_host_listings_count para ver si hay outliers que posiblemente sea conveniente eliminar.

- Probar con LinearSVR y SVR con parámetros por defecto, realizando el entrenamiento para cada caso usando todas las variables independientes y todas las independientes excepto neighbourhood, ya que esta variable es categórica y tiene muchos valores, lo que podría afectar a los resultados. Si los resultados aconsejan eliminar neighbourhood el siguiente punto se realizará sin tener en cuenta dicha variable.
- Para el algoritmo que mejor resultado haya dado en el punto anterior realizar una afinación de hiperparámetros como se comentó en el apartado de clasificación:
  - C si fuera LinearSVR, realizando 3 búsquedas.
  - γ y C si fuera SVR, realizando 2 búsquedas.

7.4.3 Valoración

Se valorará la creación del código que realice los requisitos enumerados, la presencia de comentarios de lo que hace el código y sus resultados y las comparaciones entre los resultados obtenidos por los distintos algoritmos, así como algún gráfico que muestre los resultados. Para terminar incluir un apartado de conclusiones. Tanto los comentarios como las conclusiones no es necesario que sea extensos, sino que describan de forma concisa.

7.5 Otras actividades opcionales

Leer los artículos que se citan en el libro y en las notas al final del capítulo. Leer el apéndice C de la segunda edición libro sobre el problema dual de SVM.