Tema 8

Selección de variables y reducción de la dimensionalidad.

8.1 Material de estudio

Los materiales de estudio de este tema son el capítulo 8 de Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition y adquirir un conocimiento de las herramientas que en ellos se comenta principalmente a partir de la documentación de scikit-learn. Iremos detallando el uso de estos materiales en las secciones siguientes.

Los códigos de ejemplo para este tema ya han sido descargados en temas anteriores.

8.2 Comentarios

La selección de variables y reducción de dimensionalidad es un conjunto de técnicas para disminuir el número de características a considerar en un problema de Aprendizaje Automático.

En el capítulo 8 del libro se da primero una introducción a estas cuestiones.

Primero se comenta con ejemplos el problema de la maldición de la dimensionalidad y a continuación se ven los principales enfoques: la proyección y el manifold learning, que se podría traducir como aprendizaje de variedades.

A continuación se pasa a estudiar la técnica conocida como Análisis de Componentes Principales (PCA) que es una técnica de aprendizaje nosupervisado. Esta técnica está basada en la descomposición de una matriz en sus componentes principales, si se quiere profundizar en los aspectos matemáticos de SVD consultar el capítulo 58 de Handbook

of Linear Algebra, second edition. El libro comenta las implementaciones disponibles en scikit-learn, ver en su documentación 2.5. Decomposing signals in components (la primera sección 2.5.1) y 6.5. Unsupervised dimensionality reduction, así como los enlaces en estas páginas a las APis (PCA, IncrementalPCA y KernelPCA) y ejemplos de las clases comentadas en el libro.

La siguiente técnica comentada en el libro es Locally Linear Embedding (LLE) que es una técnica no lineal. La documentación de scikit-learn de esta técnica y de algunas de las las comentadas en la siguiente sección del libro, Other Dimensionality Reduction Techniques, se hallan en 2.2. Manifold learning y en los enlaces a sus APis (LLE, MDS, Isomap y t-SNE).

Termina el capítulo comentado otras técnicas, varias de las cuales se han enumerado en el párrafo anterior y además LDA y 6.6. Random Projection, estas última es material complementario no evaluable.

Como ampliación, no evaluable, se pueden leer el resto de secciones de 2.5. Decomposing signals in components, de la 2.5.2 a la 2.5.7.

8.3 Actividades autoevaluables

Realizar los ejercicios que se encuentran en la sección Exercices del capítulo 8 Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow. En el notebook 08_dimensionality_reduction.ipynb están las soluciones.

8.4 Actividades evaluables

La actividad evaluable va a consistir principalmente en la comparación de clasificaciones realizadas empleando técnicas de reducción de dimensionalidad.

Se suministra el notebook load_faces.ipynb, disponible en la carpeta code de los documentos de Alf, en el que se cargan las imágenes de caras obtenidas con el método de scikit-learn fetch_olivetti_faces. En el notebook se carga el dataset y se hace uso de display(Markdown(faces.DESCR)) para mostrar la documentación asociada al dataset, esta documentación es la misma que aparece en el enlace anterior, utilizar este método puede proporcionar información interesante si los creadores del dataset se han preocupado en proporcionarla. En las celdas siguientes las imágenes se centran y se define un método para mostrar algunas de ellas.

La actividad consiste en:

1. Comprimir las imágenes aplicando PCA de manera que se preserve el 95% de la varianza y mostrar las 8 primeras imágenes originales y descomprimidas. Crear un nuevo dataset con las imágenes comprimidas. ¿Qué número de píxeles quedan al comprimir?

2. Lo mismo que en 1. usando LDA.

3. Dividir los datos en conjunto de entrenamiento y test de manera que el conjunto de test sea un 20% del total, tanto para los datos originales como para los comprimidos con PCA y LDA. Repasar la documentación de scikit-learn referida a SVM para ver si es conveniente aplicar transformaciones a los datos.

4. Realizar una afinación de hiperparámetros para LinearSVC y SVC con kernel 'rbf' para la clasificación de los datos originales, realizando la búsqueda de parámetros como se comentó en las subsecciones **??** y **??** (cambiando SVR por SVC). Usar para el parámetro 'cv' de GridSearchCV el valor 10. Medir los tiempos en milisegundos de las dos ejecuciones de GridSearchCV. Se recomienda usar multiproceso.

5. Realizar 4. usando los datos comprimidos mediante PCA.

6. Realizar 4. usando los datos comprimidos mediante LDA.

7. Comparar los parámetros resultantes para los mejores estimadores obtenidos en 4., 5. y 6. así como sus accuracies y los tiempos de ejecución totales de las búsquedas y la media de las búsquedas de cada GridSearchCV teniendo en cuenta el número de valores de los parámetros en cada GridSearchCV.

8.4.1 Valoración

Se valorará la creación del código que realice los requisitos enumerados, la presencia de comentarios de lo que hace el código y sus resultados y las comparaciones entre los resultados obtenidos, así como una tabla que muestre los resultados. Para terminar incluir un apartado de conclusiones. Tanto los comentarios como las conclusiones no es necesario que sea extensos, sino que describan de forma concisa.