EXAMEN FEBRERO 2025

1. ¿Qué significa que Hadoop es distribuido?

Distribuye la carga de trabajo y los datos entre varios nodos del clúster, lo que permite un procesamiento paralelo y escalable.

2. ¿Cuál de las siguientes afirmaciones describe mejor una característica clave de HDFS?

HDFS divide los archivos en bloques de tamaño fijo y los distribuye en varios nodos del cluster para un almacenamiento eficiente y paralelo.

3. Elije la opción FALSA (si todas las opciones son correctas, selecciona la opción "d. Ninguna de las restantes'):

Los DataNodes no almacena los datos en sí, solo los metadatos que rastrean los datos almacenados en los BlockNode.

4. Dado el siguiente código, ¿qué significa que una tabla esté definida como EXTERNAL y que tenga una ubicación especifica en el sistema de archivos?

```
CREATE EXTERNAL TABLE aeropuertos(
airportID int, name string,
city string, country string,
)
STORED AS parquet
LOCATION '/data/airports/
```

Los datos de la tabla se almacenan en una ubicación externa fuera del almacén de datos de Hive y no se eliminan automáticamente cuando se elimina la tabla.

5. ¿Cuál es la diferencia principal entre particiones y buckets en Hive?

6. ¿Cuál de las siguientes opciones es correcta?

I. Flume solo es compatible con la ingesta de datos desde fuentes locales en un sistema de archivos y no puede integrarse con sistemas de mensajeria como Kafka o sistemas de bases de datos.

II. Avro es una tecnologia de serializacién/deserializacién, que utiliza almacenamiento en forma de columnas.

I. Falsa. II. Falsa. Flume si permite integrarse con Kafka y Avro es en forma de filas.

7. ¿Qué podemos decir de los siguientes pares extraídos de un programa contador de palabras de MapReduce?

<perro, 1>
<perro, 1>
<gato, 1>
<perro, 1>
<gato, 1>
<perro, 1>

I. Sabemos que fueron generados por el mismo proceso.

II. Sabemos que serán procesados por el mismo proceso.

II. Falsa, los procesos reduce procesan solo una única clave y en este caso hay dos, aunque se puede configurar para que solo haya un solo proceso reduce;

I. Falsa. Hay tantos procesos map como nodos en el clúster, por lo que es posible que cada par haya sido generado por un proceso map diferente, o quizás por el mismo.

8. ¿Qué hace la siguiente orden de HDFS? hdfs dfs -put -p /home/file1 /Hadoop

Copia el fichero 'file1' del sistema de ficheros local a HDFS. Mantiene los tiempos de acceso, de modificación y propietario original (opción -p).

9. Sobre HDFS:

Todas falsas. Está basado en Java, los ficheros se dividen en bloques del mismo tamaño, no tienen que almacenarse los metadatos a no ser que se indique la opción -p.

10. Indicar cuál de las siguientes opciones identifica la razón por la que ejecución de cargas analíticas Spark es más rápida que en MapReduce.

Motor de ejecución basado en grafos (DAG) y computación en memoria

11. Indicar cuantas tareas ejecuta Spark en cada una de las particiones

Una por partición

12. Indicar cuál de las siguientes opciones NO se puede considerar como una propiedad/caracteristica de Apache Spark

Es muy eficiente en cuanto a coste económico

13. Indicar cual de las siguientes opciones/métodos de los RDD no es una transformación

Reduce(). Es una acción.

14. ¿Cómo podemos crear un RDD a partir de un fichero de texto? PD: sc es el nombre de una variable del tipo SparkContext. sc.broadcast() sc.emptyRDD() sc. textFile() sc.parallelize().

sc.textFile

15. Señala si las siguientes afirmaciones son verdaderas o falsas respecto a Spark Streaming.

I. Monitorizar el número de usuarios únicos que se han conectado a un servidor en el último minuto, con una frecuencia de cada minuto, es un caso de uso que se puede implementar sin aplicar windowing.

II. Una aplicación Spark Streaming con checkpointing puede ser detenida para solucionar un error y vuelta a lanzar sin que se provoquen fallos.

I es verdadera; II falsa, se producirán fallos ya que también se guardan metadatos

16. En Spark Streaming, indicar cuál de las siguientes entradas de datos se corresponde con una secuencia de RDDs de tal forma que cada RDD se trata como un batch simple.

queueStream()

17. Una de las maneras más habituales de evaluar el rendimiento de un modelo de flujo de datos es mediante: (Nota: si no hubiera respuesta correcta, marque "Todas las respuestas son falsas")

La metodologia test-then-train

18. Amazon S3 almacena la información en unidades de organización que "contienen" esa información y que definen una estructura organizativa del espacio. Indicar cual de estas opciones define a esa unidad.

Se almacena en buckets.

19. Un clúster Hadoop instanciado con Amazon EMR usa otro servicio de Amazon para definir las máquinas de ejecuci6n que se corresponden con el conjunto de nodos de ejecución de dicho clúster. Indicar cuál de las siguientes opciones identifica a ese servicio.

Elastic Container Computers (EC2)

20. Si se quiere configurar un cluster Apache Spark gestionado, qué servicio se debe configurar

Cloud Dataproc

EXAMEN SEPTIEMBRE 2025

1. ¿Qué papel cumple YARN en el ecosistema Hadoop?

Administra recursos y planificacion de tareas.

2. ¿Cuál es la unidad minima de almacenamiento en HDFS?

Bloque (los ficheros se dividen en bloques)

3. ¿Qué ocurre si falla un DataNode en HDFS?

Los bloques se recuperan desde otras réplicas.

4. Disponemos de un dataset consistente en un conjunto de transacciones de compra de una tienda online, donde cada linea representa una transacci6n, y donde en una transacción se puede comparar más de un ejemplar de un unico producto (por ejemplo, no hay transacciones donde un cliente compre 3 ratones y 2 portatiles). El formato del dataset es el siguiente: cliente id, producto, cantidad, precio unitario C001, Portatil,1,1200 C002, Libro, 2, 20 COO1, Ratén, 2,25 C003, Portatil,1,1100 Desarrollamos el código MapReduce para calcular el gasto total de cada cliente (cliente_id). gCual es la clave que genera el mapper en este ejemplo?

cliente_id.

5. Continuando con elejercicio anterior, ¿cuál de las siguientes opciones representa mejor el valor emitido por el mapper?

Total gastado en la transacción (calculado como cantidad * precio_unitario).

6. Continuando con el ejercicio anterior, ¿qué operación realiza el reducer?

Suma los valores agrupados por cliente

7. Continuando con el ejercicio anterior, ¿por qué se necesita la etapa de shuffle & sort?

Para agrupar las claves iguales antes de reducir.

8. ¿Qué ocurre al eliminar una tabla interna en Hive?

Se eliminan el esquema y los datos en HDFS

9. Indicar cual de las siguientes opciones es una caracteristica de los RDDs de Spark. PD: Solo hay una respuesta correcta, por lo que si hay mas de una opcion correcta, se marcara la opción “Dos o mas del resto de respuestas son ciertas”

Tolerancia a fallos, evaluación diferida y computación distribuida

10. ¿Qué podemos hacer con la operación coalesce()?

Reducir el número de particiones creadas en el RDD.

11. ¿Cuál de las siguientes instrucciones es una acción?

take(n). selecciona las primera n filas del RDD.

12. ¿Qué libreria es recomendable usar para implementar soluciones de Machine Learning en Spark?

MLlib

13. ¿Qué es el DAG de un RDD?

Es el diagrama que muestra la secuencia de operaciones que se realizan en un RDD.

15. ¿Cuál es el principal mecanismo orientado a proporcionar tolerancia a fallos en Apache Kafka?

La replicacion de particiones

16. Indique si las siguientes afirmaciones son ciertas.

I. La aproximaci6én implementada por Spark Streaming para el procesamiento de datos en tiempo real se denomina mini-batch.

II. La técnica de checkpointing en Spark Streaming permite restaurar valores de operaciones internas stateful como updateStateByKey

Las dos son verdaderas

17. Indicar cuál de las siguientes funciones disponibles en Spark Streaming requiere una función como parámetro.

UpdateStateByKey. Window, Repartition y Broadcast no llevan función.

18. Indicar cual de las siguientes afirmaciones es cierta:

I. El servicio equivalente en GCP (Google Cloud Platform) para Azure Storage se denomina Google Cloud Storage

II. El servicio equivalente en GCP (Google Cloud Platform) para Amazon EMR se denomina Google Cloud DataProc

Verdad los dos

19. Un cluster Hadoop instanciado con Amazon EMR usa otro servicio de Amazon para definir las maquinas de ejecución que se corresponden con el

conjunto de nodos de ejecución de dicho cluster. Indicar cuál de las siguientes opciones identifica a ese servicio.

Elastic Compute Cloud.

20. El servicio Azure Stream Analytics permite gestionar la ingestión/recolección de datos procedentes de fuentes de datos en "tiempo real". Indicar cual de esos componentes esta especialmente pensado para gestionar eventos de dispositivos IoT.

Azure IoT Hub

EXAMEN FEBRERO 2024

1. ¿Cuál de las siguientes afirmaciones representa un mapeo correcto entre entidades de YARN y su funcionalidad?

NodeManager: Crea los contenedores que ejecutan las aplicaciones en el nodo.

2. ¿Cuál de las siguientes órdenes calcula cuánto espacio libre y ocupado tenemos en el sistema de archivos HDFS?

hadoop fs -df -h. Se puede especificar una ruta

3. ¿Cuál de las siguientes órdenes devuelve cuántos archivos y carpetas hay en la carpeta /tmp en HDFS?

hadoop fs -count /tmp/

4. Partimos de la siguiente definición de una tabla en Hive:

CREATE TABLE IF NOT EXISTS happiness (rank INT, country STRING, score FLOAT, year INT)

COMMENT 'Ranking paises segun felicidad'

PARTITIONED BY (year INT)

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\,"

TBLPROPERTIES ('Autor' = 'Bigdata', 'Fecha' = '01/02/2021');

¿Cuál de las siguientes afirmaciones es cierta sobre esta tabla?

I Es correcto particionar la tabla por uno de los campos que están incluidos dentro de la definición de la tabla (en este caso el campo year).

II. Es una tabla externa.

I es verdadero y II es falso.

6. En el caso de que un datanode en HDFS deje de funcionar ...

I. El sistema deja de funcionar.

II. Se pierden los datos que se almacenaban en dicho datanode.

I es falso y II es falso.

7. El NameNode de HDFS...

Almacena los metadatos de los archivos almacenados en el cluster HDFS.

9. Indicar cuál de las siguientes opciones se emplea como componente/librería específica para dar soporte al procesamiento

estructurado de datos (Structured data processing) sobre el que se fundamenta el uso de Dataframes/Datasets

Spark SQL

10. Dstream se puede considerar como un:

Flujo continuo de RDD.

11. El paradigma de programación usado en Spark se corresponde con aplicaciones

Generalista

12. Indicar cuál de los siguientes términos no es usado en la terminología asociada a Spark

Datastream

14. Indicar que tipo de semántica de entrega permite una latencia más reducida.

At-most-once. No se espera recibir el ACK desde el receptor.

15. Indicar qué transformaciones semánticas (independientemente de si se pueden aplicar o no en un contexto concreto) se contemplan para pasar de un sistema "At-least-once" a uno "Exactly-once".

Deduplicación de mensajes e idempotencia.

16. Indicar cuál es el principal mecanismo orientado a proporcionar tolerancia a fallos en Apache Kafka.

La replicación de particiones.

17. Señale si las siguientes afirmaciones son verdaderas o falsas respecto a un sistema de streaming basado en Apache Kafka.

I. Durante las iteraciones de lectura en Kafka se almacena información sobre quién ha leído el mensaje, reduciendo el número posible de consumidores.

II. En la operación de escritura en Kafka los eventos se distribuyen entre las particiones, y cada evento es tratado sólo por una partición.

I. es falsa, se almacena cuantos no quién; II verdadero

18. Indicar que tipo de servicio de almacenamiento proporciona Amazon Atenea

Almacén de estructuras relacionales (basado en SQL)

20. Indicar cuál de las siguientes tecnologías de almacenamiento en AWS se puede considerar como un "disco duro virtual" en la nube.

Amazon EBS. Almacenamiento a nivel de bloque.

EXAMEN FEBRERO 2023

3. Si ejecutamos la siguiente orden, ¿qué información obtendremos?
hdfs dfsadmin -report

Visualizaremos la información del clúster.

5. ¿Qué sabemos a partir de la siguiente orden?

mapred streaming

-D mapreduce.job.reduces=2

-input/user/root/input/texto.txt

-output/user/root/output

-file ./reducer.py

-file ./mapper.py

-mapper mapper.py

-reducer reducer.py

I. Hay una única tarea reduce.

II. Los ficheros reducer.py y mapper.py se guardan en los nodos del cluster.

I es falso, porque se indica mapreduce.job.reduces=2; II es verdad por -file.

6. Partimos de la siguiente definición de una tabla en Hive:

create table datacleaninternalB(

idref STRING,

ident STRING,

gsm19023 FLOAT,

gsd19024 FLOAT,

gsd19025 FLOAT,

gsd19026 FLOAT,

genetitle STRING,

genesymbol STRING,

geneID SMALLINT,

uniGenetitle STRING,

uniGenesymbol STRING,

uniGeneID STRING,

NucleotideTitle STRING)

ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t';

¿Cuál de las siguientes afirmaciones es cierta sobre esta tabla?

El separador de los campos es el tabulador.

7. ¿Qué se obtiene tras ejecutar la siguiente orden en Hive? CREATE TABLE like_datacleaninternalB LIKE datacleaninternalB;

Se crea una tabla idéntica pero vacía.

9. ¿Cuál de las siguientes opciones se emplea como componente/librería específica para dar soporte al uso de algoritmos de minería de datos en Spark?

MLlib

10. ¿Cuál de las siguientes instrucciones es una acción?

takeOrdered()

11. Indicar cuál de las siguientes opciones no es una característica de los RDDs de Spark.

Computación incremental. Los RDD son inmutables.

12. ¿Cuál de las siguientes acciones es una transformación?

reduceByKey()

13. ¿En qué estructura de datos de Spark podemos realizar consultas a través del nombre de una columna?

DataFrame

14. Indica que característica no define un flujo de datos

Los datos llegan a lo largo del tiempo.

15. La memoria es un elemento dentro del análisis de flujo que

Permite almacenar a modo de buffer los datos provenientes del stream

16. Indica la respuesta correcta respecto a ventanas de tipo landmak:

Corre el riesgo de saturar la memoria. Acumulan desde el inicio.

17. Una consecuencia de que se produzca el cambio de concepto es:

Los algoritmos entrenados dejan de ser válidos

18. Amazon S3 almacena la información en unidades indivisibles a las cuales se les puede aplicar un conjunto de directivas (seguridad, permisos, visibilidad, etc.). Indicar cuál de estas opciones define a esa unidad.

Los almacena en buckets, que son Contenedores.

19. Indicar que tipo de servicio de almacenamiento proporciona de manera automática el servicio Amazon Kinesis

Kinesis es para streaming.

20. Indicar cuál de las siguientes afirmaciones es cierta.

I. de El servicio Azure Machine Learning dispone de una herramienta especifica que permite diseñar redes neuronales profundas manera visual (No code)

II. Azure Machine Learning Studio no dispone de redes neuronales convolucionales pre-entrenados (Resnet, etc.) en su catálogo de algoritmos integrados.

I es verdad; II es falso, sí dispone de modelos preentrenados (Resnet por ejemplo)

EXAMEN FEBRERO 2022

1. Indicar cuál de los siguientes términos no es específico del funcionamiento (desarrollo/ejecución/tuning) de una aplicación en la terminología asociada a Spark

Python

2. Indicar cual de las siguientes funciones de un RDD se puede usar para recorrer el RDD y aplicar una función cualquiera sobre cada elemento (del propio API de Spark o una función definida por el usuario) para generar un nuevo RDD del mismo tamaño que el original.

map()

4. ¿Qué hace la siguiente orden de Hadoop? hadoop fs -copyFromLocal /dataset/texto.txt /user/root/input

Copiamos el archivo texto.txt desde la carpeta local /dataset/ a la carpeta de HDFS /user/root/

5. ¿Cuál de las siguietnes afirmaciones es cierta sobre Avro?

I. Los esquemas de Avro se definen en formato XSLT.

II. El campo Sync Marker es el que permite que un archivo sea dividido en bloques para su procesamiento en el cluster Hadoop.

I es falsa, se definen en JSON; II es verdad.

6. Indicar cuál de las siguientes abstracciones de ML Pipelines de Spark implementa el método fit()

Pipeline

8. Indicar a cuál de las siguientes opciones define mejor en que consiste de manera básica un Dstream en Spark Streaming

Flujo continuo de RDD

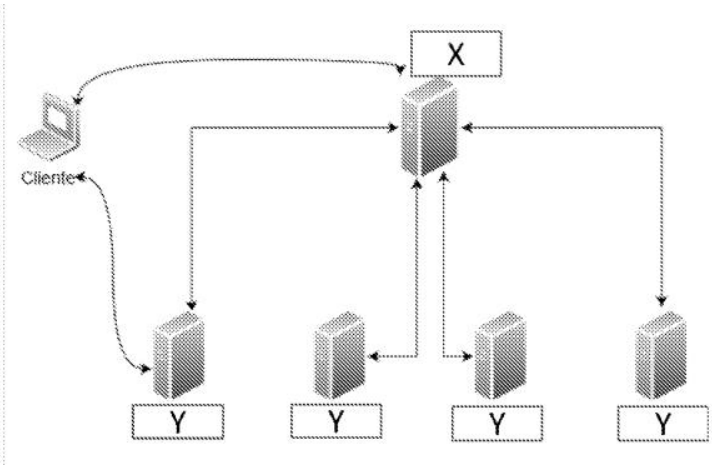
9. ¿Cuál de las siguientes afirmaciones es cierta sobre la siguiente orden? mapred streaming\ -D mapreduce.job.reduces=2\ -input /user/root/input/texto.txt\ -output/user/root/output\ -file./reducer.py\ -file ./mapper.py\ -mapper mapper.py\ -reducer reducer.py

Es un programa mapreduce que se ha ejecutado con éxito.

10. En la siguiente figura que representa un cluster HDFS, ¿cuál de las siguientes afirmaciones es cierta?

I. El componente marcado con X es el datanode y se encarga de almacenar metadatos de los archivos almacenados en nuestro cluster.

II. El componente marcado con Y es el namenode y hay uno en cada nodo del cluster.



Los dos falsos, Datanode y Namenode está al revés.

11. La interface de usuario de Spark (Spark UI) permite monitorizar visualmente la ejecución de las aplicaciones Spark y el propio rendimiento del clúster (nodo master y nodos esclavos si hay). Indicar cual de las siguientes afirmaciones es cierta respecto de Spark UI

I. Emplea por defecto el puerto 8080.

II. En la pestaña de Entorno (Enviroment) se pueden modificar las variables de entorno de Spark.

I. es verdad; II. Es falso, solo se puede ver

12. Los datos en Kafka

I.- Se pueden distribuir en el sistema para garantizar protección contra fallos

II.-Se almacenan de forma duradera

I es verdad; II es verdad

13. Si comparamos una arquitectura de stream process con la gestión tradicional de un sistema de gestión de bases de datos. Podemos afirmar:

I. Un stream process está orientado a eventos inmutables.

II. En una base de datos tradicional se permite la actualización de datos

I es verdad; II es verdad

14. Indicar cuál de las siguientes opciones no representa una transformación en Spark.

reduce()

15. En Kafka

I. Los mensajes son escritos en modo sobre-escritura y leídos desde el final.

II. Las particiones son los elementos que se usan para garantizar redundancia y escalabilidad.

I. es falsa, es append-only; II. es verdad

16. Indicar que tipo de servicio de almacenamiento proporciona Amazon Kinesis

Amazon Kinesis no proporciona un servicio de almacenamiento, sino de streaming.

17. Indicar cual de estas opciones identifica al servicio de Azure que permite implementar analítica en tiempo real, específicamente para aplicaciones loT (Internet of Things).

Azure Stream Analytics

18. Un clúster Hadoop instanciado con Amazon EMR usa otro servicio de Amazon para definir las máquinas de ejecución que se corresponden con el conjunto de nodos de ejecución de dicho clúster. Indicar cuál de las siguientes opciones identifica a ese servicio.

Elastic Compute Cloud. Compute engine es el equivalente en Google. Virtual Machines es de Azure.

19. Indicar cuál de las siguientes afirmaciones es cierta.

I. Googel DataFlow es un servicio basado en Apache Beam, personalizado para la estructura de Google Cloud.

II. Google Dataflow no permite gestionar datos en modo Batch y solo está pensado para gestionar datos en formato Streaming.

I es correcta; II es falsa, sí se puede por batch de forma nativa.

20. Si tenemos una arquitectura lambda

I Es compleja y difícil de mantener, debemos mantener dos versiones del mismo código.

II Se considera que los datos son inmutables.

I es verdad, II es verdad

EXAMEN FEBRERO 2020

1. ¿Cuál de las siguientes opciones representa componentes de YARN junto a su cardinalidad?

I. ResourceManager, uno por cluster.

II. NodeManager, uno por aplicación.

I es verdad; II es falso, uno por nodo.

2. En el caso de que un datanode en HDFS deje de funcionar ...

a. Se pierden los datos que se almacenaban en dicho datanode.

b. El sistema deja de funcionar.

a es falsa. Esos datos están duplicados en otros datanodes; b es falsa, hay otros datanodes con su información.

3. El NameNode de HDFS...

Almacena los metadatos de los archivos almacenados en el cluster HDFS.

4. Sea el nodo n1, del rack r1, del datacenter d1 (representado como /d1/r1/n1). En este escenario, ¿cuál de las siguientes afirmaciones es cierta?

distancia(/d1/r1/n1,/d2/r3/n4) = 6. Cada salto es 1 n1 -> r1 -> d1 -> ROOT -> d2 -> r3 -> n4

5. ¿Cuál de las siguientes opciones es el comando de HDFS para mostrar el final de un archivo almacenado en HDFS?

hdfs dfs -tail archivo

6. Disponemos de un archivo de datos que contiene animales de compaña (perro, perro, gato, elefante, gato, perro, ...) sobre el que se desea ejecutar un contador de palabras con MapReduce. En este escenario, el nodo reducer que procese los perros estará sobrecargado mientras que el que procese los elefantes estará infrautilizado. ¿Cómo podemos equilibrar la carga de trabajo de ambos procesos reduce?

Implementando un combiner

7. ¿Cuál de las siguientes opciones es cierta sobre la consulta de Hive siguiente? create database BD1:

I. Interactúa con el Metastore DB.

II. Se ejecuta un proceso MapReduce.

I. es verdad; II es falso

9. Indica cuál de las siguientes opciones define mejor en qué consiste de manera básica un Dstream en Spark Streaming

Flujo continuo de RDDs.

10. Indica cuál sería el paradigma de programación usado/soportado en Spark para el desarrollo de aplicaciones de analítica/machine learning.

Generalista, sin paradigma específico.

11. Indica cuál de los siguientes términos no se usa en la terminología asociada a Spark

Datastream

12. Indica cuál de las siguientes opciones define el valor por defecto para el nivel de almacenamiento de la función cache():

MEMORY_ONLY

14. Indica cuál de las siguientes opciones NO pertenece al ecosistema Spark (núcleo y librerías):

Scoop. Mlib, GrapFrames y Catalyst sí pertenece

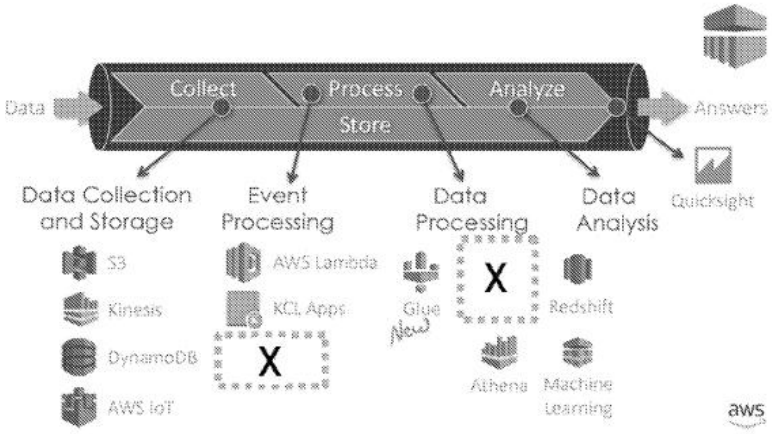
15. Queremos diseñar un sistema que procese las visitas que se produzcan a una página web y vaya mostrando una gráfica de la media de visitas en el último minuto, actualizada cada segundo. Desde el punto de vista de un sistema de streaming, ¿cuál crees que es la estrategia más oportuna (y eficiente) para el procesamiento de los datos que debería implementarse?

Processing-time windowing, con ventanas deslizantes.

17. En la interfaz de línea de comandos de Kafka, el comando $> bin/kafka-topics.sh --describe --bootstrap-server localhost:9092 --topic topic-test genera la siguiente salida: Topic:topic-test PartitionCount:1 ReplicationFactor:3 Configs: Topic: topic-test Partition: 0 Leader: 1 Replicas: 1,2,0 Isr: 1,2,0 ¿Cuál es su significado?

El topic "topic-test" está almacenado en 1 partición gestionada por 3 brokers, de los cuáles el nodo 1 es responsable de lecturas y escrituras, y los nodos 0 y 2 son réplicas.

18. En la figura siguiente se muestra un esquema de servicios de AWS agrupados por funcionalidades. Indica a qué producto/servicio se puede asociar el elemento X de la figura.



EMR

19. Indica cuál de las siguientes afirmaciones es cierta:

I. El servicio equivalente en GCP (Google Cloud Platform) para Amazon S3 se denomina Google Dataproc.

II. El servicio equivalente en GCP (Google Cloud Platform) para Amazon Kinesis se denomina Google Pubsub.

I. es falso, sería Google Cloud Storage; II. es verdad