Práctica 1

Manuel Suano Gallardo

Pregunta 1

Para esta pregunta se ha utilizado Gemini 3 Pro. La conversación se encuentra en el Anexo 1. Además, se ha hecho uso de la pregunta 1 de la práctica de febrero de 2022.

Por un lado, podríamos decir que un estudio es "clínicamente relevante" si los resultados que ofrece aportan nuevo conocimiento con notable transcendencia o si permite establecer una nueva ruta de investigación hacia dicho conocimiento, en este caso, médico.

Mientras que, por otro lado, por lo que podemos leer en esta página de IBM, aquello estadísticamente significativo quiere decir que el resultado obtenido no parece ser producto del azar, sino causal, aunque sin llegar a afirmarlo rotundamente.

El ejemplo que proporciona Gemini es muy ilustrativo para observar dicha diferencia: un fármaco que consigue reducir muy poco peso. El siguiente código generado por Gemini (el código completo está en el anexo, aquí solo me he quedado con lo que me interesa para el ejemplo) nos muestra en detalle como el p-valor obtenido usando el test t de Student de diferencia de dos medias nos da un valor muy cercano a 0:

```
n <- 10000

control <- rnorm(n, mean = 2.00, sd = 1.5)
farmaco <- rnorm(n, mean = 2.15, sd = 1.5)

datos <- data.frame(
  pérdida = c(control, farmaco),
  grupo = rep(c("Control", "Fármaco"), each = n)
)

t_test_resultado <- t.test(control, farmaco)

cat("P-valor:", t_test_resultado$p.value, "\n")
```

Este código realiza:

1. Creación de las dos proporciones: las del grupo de control, asociado a la dieta, y la del grupo del fármaco, que es el que lo ha consumido.
2. Agrupa los datos en un data frame con dos columnas: los kilos perdidos y el método usado.

3. Se realiza el test t de Student y se obtiene el p-valor. Al ejecutar ese código me ha salido un resultado de $6.673575x10^{-8}$. Cambiará en cada ejecución debido a que no se está restableciendo la semilla.

Como se puede ver el p-valor es bastante cercano al cero, por lo que se puede considerar que el estudio es estadísticamente significativo, pero no es clínicamente relevante, pues solo se pierde, de media, 150 gramos más que si se sigue un método natural (ajustar la dieta) para perder peso.

Pregunta 2

Tenemos la variable aleatoria X y la transformación indicada: $h(x) = \text{arcsen}(\sqrt{X})$. Se sabe que:

$$V[h(X)] \approx V[X] \cdot \left(h'(E[X])\right)^2$$

Por un lado, la derivada del arco seno se la raíz sería:

$$h'(x) = \frac{\frac{1}{2\sqrt{x}}}{\sqrt{1-\left(\sqrt{x}\right)^2}} = \frac{1}{2\sqrt{x(1-x)}}$$

Por lo que para $E[X]$, teniendo en cuenta que $E[X] = \pi$, el valor de la derivada sería:

$$h'(E[X]) = h'(\pi) = -\frac{1}{2\sqrt{\pi(1-\pi)}}$$

Por otro lado, $V[X] = E[(X - E[X])^2] = E[X^2] - E^2[X] = \pi(1-\pi)\frac{1}{n}$, con n el tamaño muestral. Por tanto:

$$V\left[arcsen\left(\sqrt{X}\right)\right] \approx \left(\pi(1-\pi)\frac{1}{n}\right) \cdot \left(\frac{1}{2\sqrt{\pi(1-\pi)}}\right)^2 = \frac{\pi(1-\pi)}{n \cdot 4 \cdot \pi(1-\pi)} = \frac{1}{4n}$$

Por lo que la varianza queda en fusión del tamaño muestras y la afirmación es **verdadera**.

Pregunta 3

Para esta pregunta he utilizado Gemini 3 Pro. La pregunta hecha está en el Anexo 3.

La afirmación es **falsa**. Expongo el razonamiento con un caso donde la curva ROC queda por debajo de la diagonal.

Según la definición del modelo binormal, se supone que la media de aquellas instancias que se considera "señal" (π_1) es mayor que la media de aquellas instancias que se considera "ruido" (π_0). A partir de esta suposición, se debe decidir un umbral para decidir que se trata como ruido (izquierda del umbral y, por tanto,

valores bajos de la variable explicativa) y qué se trata como señal (derecha del umbral y, por tanto, valores altos de la variable explicativa), de forma que la curva ROC quede lo más cercada posible al punto (0,1), la esquina noroeste.

Es decir, aquellos valores de X que sean mayores del umbral serán clasificados como positivos ($\hat{Y} = 1$), mientras que los que sean menores serán clasificados como negativos ($\hat{Y} = 0$).

Bajo este comportamiento, si se tiene una variable respuesta Y y una variable explicativa X, donde se da el caso de que cuando $Y = 1$, la media de X es menor que la media de X cuando $Y = 0$, es decir, que la media de la señal es menor que la media del ruido. Al usar el modelo binormal se clasificará que todo X superior al umbral decidido se etiquetará como señal, cuando realmente la probabilidad de que sea ruido en ese punto puede que sea mayor. Esto provocará que los falsos positivos y los verdaderos positivos queden con los valores alterados, pues se puede estar clasificando como $Y = 0$ aquellos casos que realmente son $Y = 1$.

Por tanto, la curva ROC, al estar definida en función de estas dos fracciones, podrá quedar por debajo de la diagonal, pues puede estar clasificando inversamente, pero no por un comportamiento erróneo del modelo, sino por una mal etiquetado de los datos.

Pregunta 4

A partir del modelo completo definido por:

```
modelo_completo <- lm(mpg ~ cyl + disp + hp + drat + wt + qsec + vs + am + gear + carb, data = mtcars)
```

Primero analizamos la multicolinealidad usando el factor de inflación de la varianza (VIF), tal y como se hace en el ejercicio 5 de la práctica de febrero del curso pasado.

vif(modelo_completo)

Según la salida, las variables que tiene un valor de VIF superior a 10 son: cyl, disp y wt. Estas variables lo recomendable es eliminarlas, ya que el valor VIF es bastante alto.

```
modelo_reducido <- lm(mpg ~ hp + drat + qsec + vs + am + gear + carb, data = mtcars)
```

A partir de este modelo reducido se puede utilizar el procedimiento stepwise para reducir, si es posible, el conjunto de características utilizadas:

```
modelo_final <- step(modelo_reducido, direction = "backward")
```

Tras realizar la ejecución, el modelo final queda en función de las variables hp, am, gear y carb.

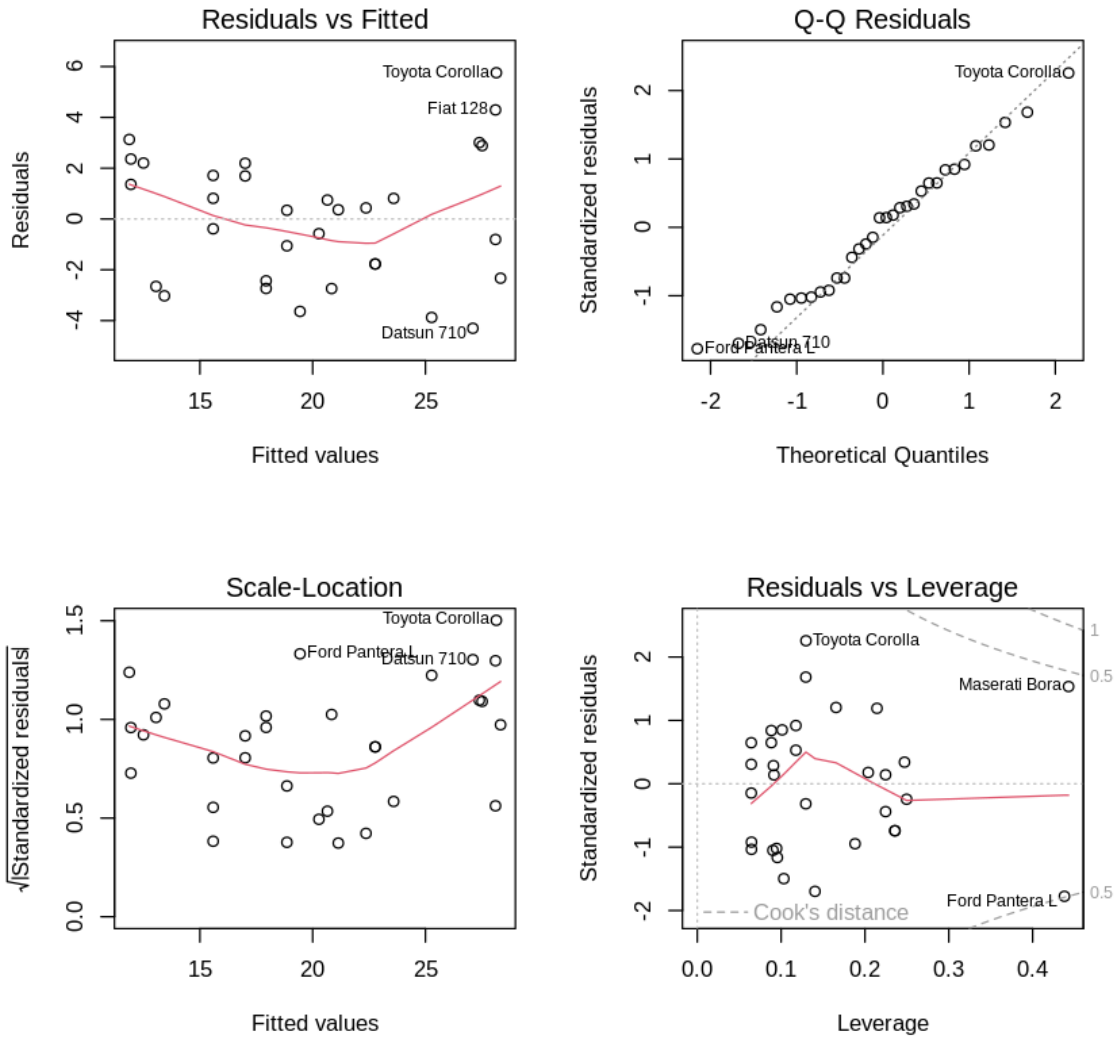
Pasamos a realizar el análisis de los residuos del modelo final. Para esto se ha utilizado Gemini 3 Pro para realizar la interpretación de los resultados. La conversación completa se encuentra en el Anexo 4.

Primero usamos:

```
par(mfrow = c(2, 2))
plot(modelo_final)
```

para obtener las gráficas de los residuos vs los ajustados, el gráfico Q-Q Normal, la escala-ubicación y los residuos vs apalancamiento.

Las gráficas obtenidas son:



A partir de estas gráficas tenemos que:

- La gráfica de los residuos vs los ajustados indica que la relación entre las variables podría no ser lineal, pudiendo ser útil un ajuste cuadrático para una mejor regresión.
- El gráfico Q-Q Normal indica los datos siguen una distribución normal, pero por los extremos (más por el extremo bajo) al verse valores más separados de la diagonal, significa que tiene más valores extremos de los que se espera en una distribución normal.
- El gráfico Escala-Ubicación nos muestra que los datos se encuentran distribuidos de relativamente uniformes, salvo por el lado derecho que tiende un poco más a la dispersión.
- Por último, la gráfica residuos vs apalancamiento, se puede ver que los modelos de coches que más problemas dan para realizar la predicción son el Maserati y el Ford. El primero tiene gran apalancamiento, probablemente por ser diferente al resto de coches. El segundo, por otro lado, tiene cierto apalancamiento y un residuo bastante grande.

Pregunta 5

El procedimiento stepwise[1] consiste en seleccionar a partir de un conjunto de variables explicativas aquellas que son capaces de determinar de forma óptima el comportamiento de una variable respuesta.

Se puede demostrar que un proceso stepwise en un modelo de regresión lineal escoge variables explicativas irrelevantes si se usa un conjunto de variables generadas de forma aleatoria, tanto las explicativas como la respuesta.

Primero definimos el número de instancias, n, y el número de características, p.

```
n <- 100
```

```
p <- 10
```

Generamos las 100 variables de 10 características con valores aleatorios.

```
x_explicativa <- matrix(rnorm(n * p), nrow = n, ncol = p)
```

Nombre de las columnas, se llamarán `explicativa_[0,…,10]`.

```
colnames(x_explicativa) <- paste0("explicativa_", 1:p)
```

Generamos ahora la variable respuesta.

```
y <- rnorm(n)
```

Agrupamos los datos en un data frame.

```
datos <- data.frame(y, x_explicativa)
```

[1] https://doi.org/10.1016/j.neucom.2021.08.150

Generamos el modelo lineal haciendo que la variable respuesta depende de todas las características de las variables explicativas.

```
modelo <- lm(y ~ ., data = datos)
```

Usamos el procedimiento stepwise, en dirección backward para que se vayan eliminando aquellas que se consideren irrelevantes.

```
modelo_final <- step(modelo, direction = "backward")
```

En el Anexo 5 se encuentra la ejecución del procedimiento stepwise. Para los valores pseudoaleatorios generados, se selecciona la característica 10.

Pregunta 6

Para esta pregunta, además de usar Gemini 3 Pro y ChatGPT, se han usado las siguientes fuentes:

- https://afectadoscancerdepulmon.com/ensayos-clinicos/
- https://www.gtt-vih.org/aprende-categoria/participar-en-ensayos-clinicos/que-es-un-ensayo-clinico/
- https://www.nhlbi.nih.gov/es/investigacion/ensayos-clinicos/como-funcionan

En función de todo esto, las principales características que deben tener un ensayo clínico:

- Una de ellas sería **tener un grupo de control**. De la muestra seleccionada para realizar el ensayo, un subconjunto no recibiría el fármaco, sino un placebo generalmente. De esta forma se puede hacer la comparativa entre el grupo de control y el grupo que recibe el tratamiento y determinar si el tratamiento es estadísticamente significativo. También está la posibilidad de tener otro grupo más que reciba un tratamiento convencional. Para todo esto es necesario tener una muestra lo suficientemente grande.
- También es importante la **aleatorización** a la hora de asignar el tratamiento para que en los grupos haya individuos que incluyan diferentes características. Al asignar de forma aleatoria el tratamiento se consigue que los grupos sean comparables entre sí.
- El **enmascaramiento** es otra característica importante de los ensayos clínicos, pues se puede evitar la aparición de sesgos. Este enmascaramiento se puede hacer o bien sin decirle al paciente qué está tomando, o bien ocultándoselo incluso al médico que participa en el ensayo.
- Por último, todo esto se debe realizar mediante una **intervención controlada**. Es necesario llevar un estricto control del diseño del ensayo, de

los fármacos, los participantes y los resultados para asegurarse que los resultados que se obtengan son válidos para inferir conclusiones poblacionales.

Anexo 1

YO:

> Considerando que lo "clínicamente relevante" es aquello que es importante por tener conocimiento en la materia, influye en el cálculo del tamaño muestral o porque tiene un efecto de gran magnitud; y lo "estadísticamente significado" es aquello que es importante según las técnicas estadísticas, ¿podrías dar un ejemplo de un conjunto de datos que ilustre la diferencia entre ambos términos?

Respuesta:

> Esta es una distinción fundamental en la investigación científica. A menudo, los investigadores o lectores de estudios confunden un "p-valor pequeño" con un "efecto grande".
>
> Para ilustrar esto, imaginemos un escenario en el que la **"Significación Estadística"** (dependiente del tamaño de la muestra) choca con la **"Relevancia Clínica"** (dependiente de la magnitud del efecto).
>
> Aquí tienes el ejemplo clásico: **El estudio de un nuevo fármaco para adelgazar.**
>
> ---
>
> **Escenario: El Fármaco "SlimFast-X"**
>
> Imagina que una farmacéutica quiere probar si su nuevo medicamento ayuda a perder peso mejor que una dieta estándar sola. Realizan un ensayo clínico masivo con un presupuesto enorme.
>
> **1. Los Datos del Estudio**
>
> Diseñan un estudio con una muestra gigantesca para asegurarse de detectar cualquier diferencia, por mínima que sea.
>
> - **Muestra Total (N):** 20.000 pacientes.
> - **Grupo A (Control/Dieta sola):** 10.000 pacientes.
> - **Grupo B (Fármaco "SlimFast-X"):** 10.000 pacientes.
> - **Duración:** 6 meses.
>
> **Resultados obtenidos (pérdida de peso media):**

Grupo	Media de pérdida de peso	Desviación Estándar
Grupo A (Control)	2.00 kg	1.5 kg
Grupo B (Fármaco)	**2.15 kg**	1.5 kg

Diferencia observada: El grupo del fármaco perdió **0.15 kg (150 gramos)** más que el grupo de control después de 6 meses.

---

2. Análisis: El Conflicto

Aquí es donde aplicamos tus definiciones para ver la discrepancia.

A. ¿Es Estadísticamente Significativo? (La Matemática)

SÍ.

Debido a que el tamaño de la muestra es enorme ($N = 20.000$), el error estándar se vuelve minúsculo. Las pruebas estadísticas (como una *t-student*) detectarán que esa diferencia de 0.15 kg **no es producto del azar**.

El resultado arrojaría algo como:

$$p < 0.001$$

Según la estadística, es un éxito rotundo. Podemos afirmar con un 99.9% de confianza que el fármaco reduce el peso más que el placebo.

B. ¿Es Clínicamente Relevante? (La Realidad)

NO.

Aquí entra el juicio clínico. Preguntémonos:

- ¿Tiene un impacto real en la salud del paciente perder 150 gramos extra en 6 meses? **No.**
- ¿Justifica esa diferencia el costo del fármaco y los posibles efectos secundarios? **No.**
- ¿Es una magnitud de efecto grande? **No, es trivial.**

Conclusión del ejemplo: Tenemos un resultado **estadísticamente muy significativo**, pero **clínicamente irrelevante**.

---

3. Matriz de Decisiones

Para visualizarlo mejor, podemos clasificar los resultados de cualquier investigación en cuatro cuadrantes. Lo ideal es caer en el cuadrante 1, pero el peligro suele estar en el cuadrante 2 (nuestro ejemplo anterior).

	Estadísticamente Significativo (p<0.05)	**NO Estadísticamente Significativo (p>0.05)**
Clínicamente Relevante	**1. El Ideal:** El tratamiento funciona, el efecto es grande y los datos lo respaldan.	**3. El Falso Negativo:** El tratamiento es excelente, pero la muestra (N) fue muy pequeña (falta de potencia estadística).
Clínicamente IRRELEVANTE	**2. El Engaño de la Muestra Grande:** (Ejemplo SlimFast-X). La diferencia es real pero inútil.	**4. El Fracaso Claro:** El tratamiento no funciona ni estadística ni clínicamente.

Resumen de la diferencia

- **Significación Estadística:** Responde a la pregunta *"¿Es probable que esta diferencia se deba al azar?"*. Es muy sensible al tamaño de la muestra (a mayor N, más fácil es obtener una p significativa).
- **Relevancia Clínica:** Responde a la pregunta *"¿Le importa esto al paciente o al médico?"*. Se mide a través del tamaño del efecto (ej. *d de Cohen*, reducción de riesgo relativo) y el conocimiento experto.

Nota: La imagen anterior ilustraría cómo, aunque las medias de los dos grupos (Control vs Fármaco) son distintas estadísticamente, las curvas de distribución se superponen casi totalmente, demostrando que el efecto es despreciable.

¿Te gustaría que calculemos el tamaño del efecto (*d de Cohen*) para el ejemplo de los datos de arriba para ver matemáticamente por qué es irrelevante?

***YO*:**

¿Podrías hacer el ejemplo en código R?

Respuesta:

¡Claro! Vamos a llevar el ejemplo teórico del fármaco "SlimFast-X" a la práctica usando R.

El siguiente código simula el escenario donde:

1. Tenemos una **muestra masiva** ($N=20,000$).
2. La diferencia real es **diminuta** (0.15 kg).
3. El **P-valor sale significativo**, pero el **tamaño del efecto (Cohen's d) es despreciable**.

Puedes copiar y pegar este código directamente en tu consola de R o RStudio.

Código R: Significancia Estadística vs. Relevancia Clínica

R

```
# 1. Preparación de datos ----------------------------------
------------------

# Fijamos la semilla para reproducibilidad

set.seed(123)


# Definimos una muestra muy grande (La clave de la
significación estadística)

n <- 10000


# Generamos datos aleatorios (Distribución Normal)

# Grupo Control: Media de pérdida = 2.0 kg, SD = 1.5

control <- rnorm(n, mean = 2.00, sd = 1.5)


# Grupo Fármaco: Media de pérdida = 2.15 kg, SD = 1.5

# Nota: La diferencia real es de solo 0.15 kg (150 gramos)

farmaco <- rnorm(n, mean = 2.15, sd = 1.5)


# Creamos un Data Frame para visualizarlo luego

datos <- data.frame(
```

```
  pérdida = c(control, farmaco),
  grupo = rep(c("Control", "Fármaco"), each = n)
)

# 2. Análisis Estadístico (El P-Valor) ----------
t_test_resultado <- t.test(control, farmaco)

# 3. Análisis de Relevancia Clínica (Tamaño del Efecto) ---
# Calculamos la d de Cohen manualmente (Diferencia de medias / Desviación estándar combinada)
media_diff <- mean(farmaco) - mean(control)
sd_pooled <- sqrt((sd(control)^2 + sd(farmaco)^2) / 2)
cohen_d <- media_diff / sd_pooled

# 4. Resultados ---------------------------------------
cat("=== RESULTADOS DEL ESTUDIO ===\n")
cat("Tamaño de la muestra por grupo:", n, "\n")
cat("Diferencia de medias observada:", round(media_diff, 4), "kg\n\n")

cat("--- A. SIGNIFICACIÓN ESTADÍSTICA ---\n")
cat("P-valor:", t_test_resultado$p.value, "\n")
if(t_test_resultado$p.value < 0.05) {
  cat("CONCLUSIÓN: ¡Es Estadísticamente Significativo! (p < 0.05)\n\n")
} else {
  cat("CONCLUSIÓN: No es significativo.\n\n")
}

cat("--- B. RELEVANCIA CLÍNICA (Tamaño del efecto) ---\n")
cat("d de Cohen:", round(cohen_d, 4), "\n")
if(cohen_d < 0.2) {
  cat("CONCLUSIÓN: Efecto DESPRECIABLE (Irrelevante clínicamente)\n")
```

```
} else if(cohen_d < 0.5) {
  cat("CONCLUSIÓN: Efecto PEQUEÑO\n")
} else {
  cat("CONCLUSIÓN: Efecto MEDIO/GRANDE\n")
}


# 5. Visualización ----------------------------------------
-----------------
# Usamos ggplot2 si está instalado, si no, usamos base R
if(require(ggplot2)){
  grafico <- ggplot(datos, aes(x = pérdida, fill = grupo))
+
    geom_density(alpha = 0.5) +
    labs(title = "Superposición de Grupos: Control vs
Fármaco",
         subtitle = paste("P-valor < 0.001 pero d de Cohen
=", round(cohen_d, 2)),
         x = "Pérdida de Peso (kg)",
         y = "Densidad") +
    theme_minimal()
  print(grafico)
} else {
  # Versión básica si no tienes ggplot2
  plot(density(farmaco), col="blue", main="Superposición de
Grupos", xlab="Kg perdidos")
  lines(density(control), col="red")
  legend("topright", legend=c("Fármaco", "Control"),
fill=c("blue", "red"))
}
```

Interpretación de la salida del código

Al ejecutar el código, obtendrás algo muy similar a esto en la consola:

1. **El P-valor es minúsculo (ej. 2.3×10^{-13}):** La prueba estadística "grita" que los grupos son diferentes. Si solo miras esto, publicarías que el fármaco es un éxito.

2. **La d de Cohen es aprox 0.10:** Este valor es la medida de la relevancia.
    - Generalmente, una $d = 0.2$ se considera "pequeña".
    - Una $d = 0.1$ es **trivial**.
3. **El Gráfico:** Si miras el gráfico generado (ggplot o plot), verás dos curvas (una roja y una azul) que están casi **perfectamente superpuestas**.

Lo que nos enseña el gráfico: A pesar de que la estadística matemática dice "son diferentes" (debido a la potencia de los 20.000 pacientes), visualmente y clínicamente los pacientes del grupo fármaco son indistinguibles de los del grupo control.

¿Te gustaría que modifiquemos el código para ver el caso contrario: una muestra pequeña con un efecto grande (el problema de la falta de potencia)?

Anexo 3

Primera pregunta (recortada):

YO: Explícame el modelo binormal.

RESPUESTA: El **Modelo Binormal** es una herramienta estadística fundamental utilizada principalmente en la **Teoría de Detección de Señales** y en el análisis de **Curvas ROC** (Receiver Operating Characteristic).

En términos sencillos, es un modelo matemático que nos ayuda a entender qué tan bien un sistema (como una prueba médica, un algoritmo de IA o un ser humano) puede distinguir entre dos situaciones diferentes (por ejemplo: "Sano vs. Enfermo" o "Ruido vs. Señal").

Aquí tienes un desglose claro de cómo funciona.

---

1. El Concepto Fundamental: Dos Campanas

El nombre "Binormal" viene de la suposición de que los datos de los dos grupos que intentamos separar siguen una **distribución normal** (la famosa curva de campana o Gaussiana).

Imagina que tenemos una prueba de sangre para detectar una enfermedad:

1. **Distribución de Ruido (o Sano):** La población sana tendrá unos valores que se agrupan en una curva normal (N_0).
2. **Distribución de Señal (o Enfermo):** La población enferma tendrá valores que se agrupan en otra curva normal (N_1).

[imagen de ambas distribuciones]

La Clave: En el mundo real, estas dos curvas casi siempre se **superponen**. Esa zona de superposición es donde ocurren los errores de diagnóstico (falsos positivos o falsos negativos).

2. Cómo funciona el modelo

El modelo binormal asume que hay una variable latente continua (un "eje de decisión") donde se sitúan estas dos distribuciones.

- **La media (μ):** Indica dónde está el centro de cada curva. Si las medias están muy separadas, es fácil distinguir los grupos.

- **La desviación estándar (σ):** Indica qué tan ancha es la campana. Si una es más ancha que la otra, significa que los datos de ese grupo son más variables.

El Umbral de Decisión (Cutoff)

Para tomar una decisión (decir si alguien está "sano" o "enfermo"), trazamos una línea vertical en algún punto de estas curvas. Todo lo que esté a la derecha es "positivo" y lo que esté a la izquierda es "negativo".

- Al mover esta línea, cambias el equilibrio entre **Sensibilidad** (detectar a los enfermos) y **Especificidad** (no alarmar a los sanos).

[...]

Anexo 4

YO:

Cómo se interpreta estas gráficas

Respuesta:

Estas cuatro gráficas son el estándar generado por el software estadístico **R** para diagnosticar un modelo de **regresión lineal**. Su objetivo es verificar si los datos cumplen con las suposiciones necesarias para que el modelo sea válido (linealidad, normalidad, homocedasticidad e independencia).

Aquí tienes la interpretación detallada de cada una:

---

1. Residuals vs Fitted (Residuos vs. Valores Ajustados)

- **¿Qué evalúa?** La **linealidad**. Verifica si existe una relación lineal entre las variables.
- **El escenario ideal:** Deberías ver una distribución aleatoria de puntos alrededor de la línea horizontal (en el 0), sin ningún patrón claro. La línea roja debería ser casi recta y horizontal.
- **Interpretación de tu gráfica:**
    - La línea roja tiene una ligera curvatura (baja, sube un poco). Esto sugiere que la relación entre tus variables podría no ser perfectamente lineal; quizás falte un término cuadrático o una transformación de variables.
    - Los puntos etiquetados (**Toyota Corolla, Fiat 128, Datsun 710**) son "outliers" o valores atípicos que se alejan de lo esperado.

2. Normal Q-Q (Gráfico Q-Q Normal)

- **¿Qué evalúa?** La **normalidad** de los residuos. Verifica si los errores del modelo siguen una distribución normal.
- **El escenario ideal:** Todos los círculos deberían caer exactamente sobre la línea punteada diagonal.
- **Interpretación de tu gráfica:**
    - El ajuste es bastante bueno en el centro.

    - Sin embargo, en los extremos (las "colas"), los puntos se desvían de la línea (especialmente el **Toyota Corolla** arriba a la derecha y el **Ford Pantera L** abajo a la izquierda). Esto indica que la distribución de los errores tiene colas un poco más "pesadas" de lo que tendría una distribución normal perfecta, pero no parece ser un problema grave.

3. Scale-Location (Escala-Ubicación)

- **¿Qué evalúa?** La **homocedasticidad**. Verifica si la varianza de los errores es constante a lo largo de los datos.
- **El escenario ideal:** La línea roja debería ser horizontal y los puntos deberían estar dispersos aleatoriamente a lo ancho de la gráfica, sin formar embudos (no deberían abrirse ni cerrarse en forma de abanico).
- **Interpretación de tu gráfica:**
    - La línea roja tiene una ligera curva, pero no es drástica.
    - Los puntos parecen estar distribuidos de manera razonablemente uniforme, aunque hay un poco más de dispersión en el lado derecho. En general, las suposiciones de varianza constante se sostiene aceptablemente, aunque esos tres puntos etiquetados siguen molestando un poco.

4. Residuals vs Leverage (Residuos vs. Apalancamiento)

- **¿Qué evalúa?** Los **casos influyentes**. Identifica puntos que tienen un impacto exagerado en la línea de regresión (si quitaras ese punto, el modelo cambiaría drásticamente).
- **El escenario ideal:** No queremos ver puntos en las esquinas superior o inferior derecha, fuera de las líneas punteadas rojas (que representan la "Distancia de Cook").
- **Interpretación de tu gráfica:**
    - Fíjate en el eje X ("Leverage" o Apalancamiento). El **Maserati Bora** está muy a la derecha. Esto significa que tiene valores inusuales en las variables predictoras (es un coche muy diferente al resto en cuanto a características).
    - Aunque el Maserati tiene alto apalancamiento, su residuo es cercano a 0 (está cerca de la línea punteada central), por lo que el modelo lo predice bien.

- El **Ford Pantera L** es preocupante porque tiene cierto apalancamiento y un residuo negativo grande.
- **Distancia de Cook:** Las líneas punteadas grises (apenas visibles en las esquinas) marcan los límites de peligro (0.5 y 1). Ningún punto parece cruzar la línea de "1", lo cual es bueno, pero el Maserati y el Ford Pantera son puntos que deberías revisar para decidir si mantenerlos o excluirlos del modelo.

Resumen del diagnóstico

El modelo es **aceptable pero no perfecto**.

1. **Linealidad:** Hay una ligera no-linealidad.
2. **Outliers:** Tienes 3 o 4 coches (Toyota Corolla, Fiat 128, Maserati Bora) que se comportan de forma diferente al resto de la muestra.

¿Te gustaría que te explique cómo eliminar esos "outliers" en R para ver si mejora el modelo?

Anexo 5

```
Start:  AIC=21.52

y ~ explicativa_1 + explicativa_2 + explicativa_3 + explicativa_4
+ explicativa_5 + explicativa_6 + explicativa_7 + explicativa_8 +
explicativa_9 + explicativa_10

                 Df Sum of Sq     RSS    AIC

- explicativa_5   1   0.00164  99.520 19.519

- explicativa_2   1   0.05817  99.576 19.576

- explicativa_6   1   0.06682  99.585 19.584

- explicativa_3   1   0.07363  99.592 19.591

- explicativa_7   1   0.10375  99.622 19.621

- explicativa_8   1   0.14867  99.667 19.666

- explicativa_9   1   0.66678 100.185 20.185

- explicativa_4   1   1.04956 100.568 20.566

- explicativa_1   1   1.30573 100.824 20.821

<none>                         99.518 21.517

- explicativa_10  1   3.02004 102.538 22.507

Step:  AIC=19.52

y ~ explicativa_1 + explicativa_2 + explicativa_3 + explicativa_4
+ explicativa_6 + explicativa_7 + explicativa_8 + explicativa_9 +
explicativa_10

                 Df Sum of Sq     RSS    AIC

- explicativa_2   1   0.05947  99.579 17.578

- explicativa_6   1   0.06975  99.590 17.589

- explicativa_3   1   0.07308  99.593 17.592

- explicativa_7   1   0.10529  99.625 17.625

- explicativa_8   1   0.14754  99.667 17.667

- explicativa_9   1   0.67169 100.192 18.191

- explicativa_4   1   1.04794 100.568 18.566

- explicativa_1   1   1.30863 100.829 18.825

<none>                         99.520 19.519

- explicativa_10  1   3.07697 102.597 20.564

Step:  AIC=17.58

y ~ explicativa_1 + explicativa_3 + explicativa_4 + explicativa_6
+ explicativa_7 + explicativa_8 + explicativa_9 + explicativa_10
```

```
                 Df Sum of Sq     RSS    AIC
- explicativa_6   1   0.07276  99.652 15.652
- explicativa_3   1   0.07744  99.657 15.656
- explicativa_7   1   0.09793  99.677 15.677
- explicativa_8   1   0.18175  99.761 15.761
- explicativa_9   1   0.78942 100.369 16.368
- explicativa_4   1   1.01692 100.596 16.595
- explicativa_1   1   1.27165 100.851 16.847
<none>                        99.579 17.578
- explicativa_10  1   3.03279 102.612 18.579

Step:  AIC=15.65

y ~ explicativa_1 + explicativa_3 + explicativa_4 + explicativa_7
+ explicativa_8 + explicativa_9 + explicativa_10

                 Df Sum of Sq     RSS    AIC
- explicativa_7   1    0.0918  99.744 13.744
- explicativa_3   1    0.1206  99.773 13.773
- explicativa_8   1    0.1952  99.847 13.847
- explicativa_9   1    0.8245 100.477 14.476
- explicativa_4   1    1.0715 100.724 14.721
- explicativa_1   1    1.2396 100.892 14.888
<none>                        99.652 15.652
- explicativa_10  1    3.1865 102.839 16.799

Step:  AIC=13.74

y ~ explicativa_1 + explicativa_3 + explicativa_4 + explicativa_8
+ explicativa_9 + explicativa_10

                 Df Sum of Sq     RSS    AIC
- explicativa_3   1    0.1134  99.857 11.857
- explicativa_8   1    0.1994  99.943 11.943
- explicativa_9   1    0.9048 100.649 12.647
- explicativa_4   1    1.0353 100.779 12.776
- explicativa_1   1    1.2124 100.956 12.952
<none>                        99.744 13.744
- explicativa_10  1    3.2027 102.947 14.904

Step:  AIC=11.86
```

```
y ~ explicativa_1 + explicativa_4 + explicativa_8 + explicativa_9
+ explicativa_10
                 Df Sum of Sq     RSS    AIC
- explicativa_8   1   0.19536 100.053 10.053
- explicativa_9   1   0.86058 100.718 10.715
- explicativa_4   1   1.19631 101.054 11.048
- explicativa_1   1   1.30295 101.160 11.154
<none>                         99.857 11.857
- explicativa_10  1   3.09855 102.956 12.913
Step:  AIC=10.05
y ~ explicativa_1 + explicativa_4 + explicativa_9 + explicativa_10
                 Df Sum of Sq    RSS     AIC
- explicativa_9   1   0.96118 101.01  9.0088
- explicativa_4   1   1.07441 101.13  9.1208
- explicativa_1   1   1.24595 101.30  9.2903
<none>                        100.05 10.0527
- explicativa_10  1   3.12751 103.18 11.1307
Step:  AIC=9.01
y ~ explicativa_1 + explicativa_4 + explicativa_10
                 Df Sum of Sq    RSS     AIC
- explicativa_4   1    1.0317 102.05  8.0250
- explicativa_1   1    1.3199 102.33  8.3070
<none>                        101.01  9.0088
- explicativa_10  1    3.2582 104.27 10.1834


Step:  AIC=8.02
y ~ explicativa_1 + explicativa_10
                 Df Sum of Sq    RSS    AIC
- explicativa_1   1    1.1087 103.15 7.1056
<none>                        102.05 8.0250
- explicativa_10  1    4.0977 106.14 9.9620
Step:  AIC=7.11
y ~ explicativa_10
                 Df Sum of Sq    RSS    AIC
<none>                        103.15 7.1056
```

```
- explicativa_10  1    4.1862 107.34 9.0836
```

Anexo 6

Pregunta a Gemini:

YO:

> ¿Cuáles son las características fundamentales de los Ensayos Clínicos? ¿Cómo se podrían relacionar con la estadística?

Respuesta:

> Un Ensayo Clínico es la metodología más rigurosa que tenemos en medicina para validar si un tratamiento (fármaco, terapia, dispositivo) funciona y es seguro. No es simplemente "probar algo"; es un experimento controlado y diseñado matemáticamente.
>
> Aquí tienes un desglose de sus características y su profunda relación con la estadística.
>
> ---
>
> **1. Características Fundamentales de los Ensayos Clínicos**
>
> Lo que diferencia a un ensayo clínico de otros estudios médicos (como los observacionales) es que **el investigador interviene activamente**: administra el tratamiento bajo condiciones controladas.
>
> - **Intervención Controlada:** A diferencia de observar qué pasa en la vida real, aquí se asigna una intervención específica según un protocolo estricto.
> - **Grupo Control:** Es el estándar de comparación. Un grupo recibe el tratamiento nuevo y otro (el grupo control) recibe el tratamiento estándar actual o un **placebo** (una sustancia inactiva). Esto permite saber si la mejora se debe al fármaco o simplemente al efecto psicológico de ser tratado (Efecto Placebo).
> - **Aleatorización (Randomization):** Los pacientes no eligen su tratamiento, ni tampoco lo elige el médico. Se asignan al azar. Esto asegura que los grupos sean comparables y que las diferencias en los resultados se deban al tratamiento y no a que un grupo estaba "más sano" que el otro desde el principio.
> - **Enmascaramiento (Cegamiento):** Para evitar sesgos (prejuicios), a menudo se oculta quién recibe qué:
>   - *Simple ciego:* El paciente no sabe qué toma.

    - *Doble ciego:* Ni el paciente ni el médico saben qué se está administrando.

- **Fases de Investigación:** Se realizan en etapas secuenciales para garantizar la seguridad antes de exponer a grandes poblaciones.

Fase	Objetivo Principal	Población Típica
Fase I	Seguridad y Dosis	Pocos voluntarios sanos (20-80)
Fase II	Eficacia preliminar	Pacientes con la enfermedad (100-300)
Fase III	Confirmación de eficacia	Miles de pacientes (multicéntrico)
Fase IV	Farmacovigilancia	Población general (post-comercialización)

---

2. ¿Cómo se relacionan con la Estadística?

La estadística no es solo una herramienta de cálculo al final del estudio; es el **esqueleto estructural** de todo el ensayo clínico. Sin estadística, un ensayo clínico es anecdótico, no evidencia científica.

A. En el Diseño (Antes de empezar)

- **Cálculo del Tamaño Muestral:** La estadística responde a la pregunta: *"¿Cuántos pacientes necesito?"*. Si usas muy pocos, podrías no detectar un medicamento que sí funciona (Error Tipo II). Si usas demasiados, es éticamente cuestionable y costoso. Se calcula basándose en el **Poder Estadístico** (generalmente 80% o 90%).
- **Aleatorización:** La estadística provee los algoritmos para asignar pacientes a los grupos de forma verdaderamente aleatoria, equilibrando variables desconocidas.

B. En el Análisis (Durante y después)

Una vez recolectados los datos, la estadística determina si los resultados son reales o fruto del azar.

- **Pruebas de Hipótesis:** Todo ensayo parte de una "Hipótesis Nula" (H_0), que asume que el nuevo tratamiento **no tiene efecto** (es igual al placebo). El objetivo es acumular suficiente evidencia matemática para rechazar esta idea en favor de la "Hipótesis Alternativa" (H_1).
- **El Valor-P (P-value):** Es la métrica más famosa. Si obtienes un $p < 0.05$, significa que hay menos de un 5% de probabilidad de que tus resultados positivos sean pura casualidad. Se considera "estadísticamente significativo".
- **Intervalos de Confianza (IC):** En lugar de dar un solo número, la estadística nos da un rango. Por ejemplo: *"El fármaco reduce el riesgo de infarto un 20%, pero estamos 95% seguros de que la reducción real está entre el 15% y el 25%"*.

C. Conceptos Clave de Bioestadística

- **Riesgo Relativo (RR) y Hazard Ratio (HR):** Miden cuánto más probable es un evento (como curarse o tener un efecto secundario) en un grupo comparado con el otro.
- **Análisis de Supervivencia (Curvas de Kaplan-Meier):** Se usa para medir el tiempo que transcurre hasta que sucede algo (por ejemplo, cuánto tiempo sobrevive un paciente con cáncer con el nuevo fármaco vs. el anterior).

Resumen de la relación

La clínica propone la pregunta (¿Funciona este fármaco?), **el diseño metodológico minimiza los errores** (sesgos), y **la estadística cuantifica la incertidumbre** de la respuesta.

¿Te gustaría que profundicemos en cómo se calcula el tamaño de la muestra o prefieres ver un ejemplo de cómo se interpreta un "Hazard Ratio" en un estudio real?

Pregunta a ChatGPT.

YO:

¿Cuáles son las características fundamentales de los Ensayos Clínicos? ¿Cómo se podrían relacionar con la estadística?

Respuesta:

A continuación tienes una explicación clara y completa sobre **las características fundamentales de los Ensayos Clínicos** y **cómo se relacionan con la estadística**:

✅ Características fundamentales de los Ensayos Clínicos

Un **Ensayo Clínico (EC)** es un estudio experimental que evalúa la eficacia y seguridad de intervenciones médicas (fármacos, procedimientos, dispositivos, programas preventivos, etc.). Sus características clave son:

1. Intervención controlada

Se administra una intervención (por ejemplo, un fármaco) y se compara con:

- placebo
- tratamiento estándar
- otra intervención

Esto permite medir efectos de forma objetiva.

2. Asignación aleatoria (randomización)

Los participantes se asignan al azar a los grupos del estudio.
Objetivos:

- evitar sesgos de selección
- distribuir factores de confusión de forma equilibrada

3. Grupo de control

Un grupo sirve como comparación para evaluar si la intervención realmente produce un efecto.

4. Cegamiento (enmascaramiento)

Elimina influencias subjetivas:

- **simple ciego:** el paciente no sabe qué recibe
- **doble ciego:** paciente e investigador desconocen la asignación
- **triple ciego:** incluye a quien analiza los datos

5. Protocolos definidos previamente

Incluye:

- criterios de inclusión/exclusión
- dosis
- duración
- medidas de resultado (endpoints)

Garantiza consistencia y reproducibilidad.

6. Seguimiento sistemático

Se monitorizan los resultados, efectos adversos y eventos clínicos de forma estructurada.

7. Ética y consentimiento informado

Todo ensayo debe aprobarse por un comité ético y garantizar la protección de los participantes.

📊 Relación de los Ensayos Clínicos con la Estadística

La estadística es esencial en todas las fases del ensayo. Ejemplos:

1. Diseño del estudio

La estadística ayuda a determinar:

- **tamaño muestral**
- **nivel de significación (α)**
- **potencia del estudio (1−β)**
- **tipo de diseño** (paralelo, cruzado, factorial)

Un cálculo incorrecto puede invalidar los resultados.

2. Randomización

Se utilizan técnicas estadísticas para:

- generar secuencias aleatorias
- controlar estratos (edad, sexo, severidad, etc.)
- equilibrar covariables

3. Análisis de resultados

Se aplican pruebas estadísticas para evaluar diferencias entre grupos:

- t de Student

- chi-cuadrado
- ANOVA
- regresión logística
- análisis de supervivencia (Kaplan-Meier, Cox)

Esto determina si los efectos observados son **estadísticamente significativos** y no producto del azar.

4. Control de sesgos y confusión

Se usan modelos multivariables para ajustar por variables que puedan distorsionar el efecto real.

5. Inferencia y generalización

La estadística permite:

- estimar intervalos de confianza
- calcular riesgos relativos, odds ratios, diferencias de medias
- evaluar la precisión y validez externa

6. Manejo de datos faltantes o pérdidas de seguimiento

Técnicas como:

- imputación múltiple
- análisis por intención de tratar (ITT)
- análisis por protocolo

📌 **En resumen**

Los ensayos clínicos y la estadística están profundamente interconectados:

Los ensayos clínicos proporcionan los datos y la estadística provee las herramientas para diseñarlos, analizarlos y extraer conclusiones válidas.

Sin estadística no habría forma confiable de saber si un tratamiento funciona.

Si quieres, puedo también:

✅ hacer un esquema resumido

✅ preparar una explicación para examen

✅ comparar tipos de ensayos clínicos

💡 ¿Te gustaría alguna de esas opciones?