Principales técnicas estadísticas

(ver 7: 2025-2026)



Emilio Letón y Elisa M. Molanes-López

01-Oct-2025

Página legal

PRINCIPALES TÉCNICAS ESTADÍSTICAS
©Emilio Letón y Elisa M. Molanes-López
Madrid, ver 1: 2019-2020
Madrid, ver 2: 2020-2021
Madrid, ver 3: 2021-2022
Madrid, ver 4: 2022-2023
Madrid, ver 5: 2023-2024
Madrid, ver 6: 2024-2025
Madrid, ver 7: 2025-2026

Quedan rigurosamente prohibidas, sin la autorización escrita de los titulares del Copyright, bajo las sanciones establecidas en las leyes, la reproducción total o parcial de esta obra por cualquier medio o procedimiento, comprendidos la reprografía y el tratamiento informático, y la distribución de ejemplares de ella mediante alquiler o préstamo público.
ISBN electrónico: xxx.
Edición digital (epub): xxx.

Índice general

Prefacio **1**

1. Conceptos básicos de inferencia estadística **3**
1.1. Consideraciones previas 3
1.2. Intervalo de confianza 9
1.3. Contraste de hipótesis 13

2. Respuesta dicotómica **17**
2.1. z de diferencia de dos proporciones 17
2.2. Fisher 22

3. Respuesta continua **27**
3.1. t de Student de diferencia de dos medias 27
3.2. ANOVA de un factor 32

4. Respuesta nominal **39**
4.1. χ^2 de homogeneidad 39
4.2. Freeman-Halton 41

5. Respuesta ordinal **45**
5.1. U de Mann-Whitney 45
5.2. W de Wilcoxon 49
5.3. H de Kruskal-Wallis 52

Autoevaluación **59**

Referencias **85**

Glosario **87**

Acerca de **91**
Emilio Letón 91
Elisa M. Molanes-López 91

Índice de figuras

5.1. Box-Plot para los datos observados del esquema $O \leftarrow D$ 48
5.2. Box-Plot para los datos observados del esquema $O \leftarrow N$ 55
5.3. Emilio Letón 91
5.4. Elisa M. Molanes-López 92

Índice de tablas

1.1. Distintas clasificaciones según los tipos de variables 5
1.2. Datos genéricos de una variable dicotómica 6
1.3. Datos de 20 proporciones muestrales 8
1.4. Simulación del $IC_{95\,\%}$ de una proporción poblacional basada en 20 muestras . 12
1.5. Simulaciones de 20 muestras para el CH de una proporción poblacional . . . 16

2.1. Datos genéricos del esquema $D \leftarrow D$ 18
2.2. Datos observados del esquema $D \leftarrow D$, $n = 90$ 20
2.3. Tabla con datos genéricos del esquema $D \leftarrow D$ 22
2.4. Datos observados del esquema $D \leftarrow D$, $n = 42$ 23
2.5. Tabla con datos observados del esquema $D \leftarrow D$, $n = 42$ 24
2.6. Tablas variando a' en el esquema $D \leftarrow D$, $n = 42$ 24

3.1. Datos genéricos del esquema $C \leftarrow D$ 28
3.2. Datos observados del esquema $C \leftarrow D$ 31
3.3. Datos genéricos del esquema $C \leftarrow N$ 33
3.4. Tabla ANOVA con datos genéricos del esquema $C \leftarrow N$ 34
3.5. Datos observados del esquema $C \leftarrow N$ 35
3.6. Tabla ANOVA con datos observados del esquema $C \leftarrow N$ 36

4.1. Datos genéricos del esquema $N \leftarrow N$ 42
4.2. Tabla con datos genéricos del esquema $N \leftarrow N$ 43
4.3. Tabla con datos observados del esquema $N \leftarrow N$ 43
4.4. Tabla con datos esperados del esquema $N \leftarrow N$ 43

5.1. Datos genéricos del esquema $O \leftarrow D$ 46
5.2. Datos observados del esquema $O \leftarrow D$ 47
5.3. Rangos para los datos observados del esquema $O \leftarrow D$ 51
5.4. Datos genéricos del esquema $O \leftarrow N$ 53
5.5. Datos observados del esquema $O \leftarrow N$ 54
5.6. Rangos para los datos observados del esquema $O \leftarrow N$ 56
5.7. Tabla con datos observados del esquema N “Tipo de enfermedad” $\leftarrow N$ . . . 75
5.8. Datos observados del esquema O “Grado de ansiedad” $\leftarrow D$ 80

5.9. Datos observados del esquema O "Grado de mejoría" $\leftarrow D$ 81
5.10. Datos observados del esquema O "Grado de severidad" $\leftarrow D$ 81
5.11. Datos observados del esquema O "Grado de satisfacción" $\leftarrow D$ 82
5.12. Datos observados del esquema O "Grado de dependencia" $\leftarrow D$ 83
5.13. Datos observados del esquema O "Grado de autonomía" $\leftarrow D$ 83

Prefacio

Este material está diseñado con el paradigma que propone el grupo de innovación docente miniXmodular de generar material en formato mini y modular, según se puede ver en la página web `www.minixmodular.ia.uned.es`, donde se introduce, entre otros, el concepto de mini-libro electrónico modular.

En este mini-libro se explican las principales técnicas estadísticas básicas que se utilizan en la práctica. Para ello, en primer lugar, se describen de forma resumida los conceptos básicos de inferencia estadística necesarios para entender los mini-capítulos siguientes. En dicho primer mini-capítulo se hace especial énfasis en los principales tipos de variables, así como los distintos propósitos de las mismas (respuesta o explicativa).

Con la ayuda del primer mini-capítulo se estructuran el resto atendiendo a distintos tipos de variable respuesta (dicotómica, continua, nominal y ordinal).

Para poder seguir este mini-libro es conveniente haber estudiado previamente una asignatura básica de grado de Estadística y tener asumidos los conceptos estadísticos básicos tratados en ella (ver, por ejemplo, Peña [2014] o Ramos et al. [2019]). Aunque se ha hecho un esfuerzo de síntesis en el primer mini-capítulo para nivelar conocimientos, no se puede condensar una asignatura de grado en unas pocas páginas. No obstante, en el glosario aparecen algunos de dichos conceptos.

Por último, conviene mencionar que a lo largo de este mini-libro se presenta código en el lenguaje R (R Core Team [2017]) para realizar los cálculos estadísticos. Existen numerosas páginas web y libros que introducen este lenguaje; dos referencias clásicas que combinan Estadística y R son Davies [2016] y García-Pérez [2010]. No obstante, conviene señalar que el código que se utiliza en este mini-libro es muy sencillo y autoexplicativo.

Mini-capítulo 1

Conceptos básicos de inferencia estadística

En este mini-capítulo se describen de forma resumida los conceptos básicos de inferencia estadística. En primer lugar, se realizan una serie de consideraciones previas y, a continuación, se tratan los conceptos básicos de intervalo de confianza y contraste de hipótesis.

1.1. Consideraciones previas

Antes de describir los conceptos básicos propiamente de la inferencia estadística, conviene tener presente una serie de consideraciones previas sobre los conceptos de población, muestra, casos, variables, datos, tipos de variables, clasificación de las variables, propósito de las variables, estadística descriptiva y cálculo de probabilidades.

Población, muestra, casos, variables y datos

Ante la necesidad de conocer un fenómeno concreto, hay que establecer, en primer lugar, una población (universo) de interés, que es un conjunto de elementos (individuos, pacientes, objetos, unidades experimentales, ordenadores, neumáticos, etc.) que poseen una o más características observables en común, que se denominan criterios de definición de la población.

En la práctica, el estudio de todos los elementos de la población es prácticamente inabordable o directamente inabordable, por lo que es habitual trabajar con un conjunto de elementos extraídos de la población, que se denomina muestra. Para que una muestra sirva para generalizar conclusiones a su población correspondiente, la muestra tiene que ser representativa de su población. Esto se consigue mediante un cálculo del tamaño muestral adecuado y un correcto procedimiento para su extracción aleatoria de la población. Una vez definida la población y extraída la muestra, se recoge información de ésta susceptible de poderse organizar en filas (casos) y columnas (variables). A un nivel básico, se podría decir que los casos (individuos o unidades experimentales) son los elementos de la muestra sobre

los que se recoge información y que variable es la forma de recoger una característica de interés de los casos (es decir, todo aquello que se recoja de un caso). Una variable puede tomar distintos valores (aleatorios) para cada caso; lo contrario a una variable es una constante (no varía). Los datos son los valores observados de las variables para cada caso: son las realizaciones de las variables para los casos.

Tipos, clasificación y propósito de las variables

Los valores que puede tomar una variable constituyen el rango de dicha variable. La naturaleza de este rango es lo que determina el tipo de variable. La importancia de distinguir apropiadamente los tipos de variables radica en que el uso correcto de las técnicas estadísticas está condicionado por la naturaleza de las variables. Los principales tipos de variables son los siguientes (ver, también tabla 1.1 donde se recogen otras clasificaciones dadas en la literatura):

- Dicotómica o binaria: tiene dos valores posibles. Por ejemplo, la variable `Curación` (Sí/No), `Ejercicio físico` (Sí/No), `Tratamiento` (A/B) o `Fumar` (Sí/No).
- Nominal: tiene varios valores posibles sin orden entre ellos. Por ejemplo, la variable `Tipo enfermedad` (A/B/C), `Hospital` (A/B/C/D), `Estado civil` (Casado/Soltero/Otros) o `Fumar tipo` (Cigarrillos/Puros/Otros/No fuma).
- Ordinal: tiene varios valores posibles con un orden entre ellos. Por ejemplo, la variable `Horas semanales ejercicio físico` (0/más de 0 y menor o igual a 2/más de 2), `Tamaño tumor` (Pequeño/Mediano/Grande) o `Fumar nivel` (Consumo alto/Moderado/Nulo).
- Numérica discreta: tiene, en teoría, un número de valores discretos (enteros) posibles. Por ejemplo, la variable `Número cefaleas mes` (0/1/2/...), `Número hijos` (0/1/2/...) o `Número cigarrillos día` (0/1/2/...).
- Numérica continua o simplemente continua: tiene, en teoría, un número infinito de valores continuos posibles. Por ejemplo, la variable `Tensión arterial`, `Colesterol` o `Nicotina en sangre`.

En la mayoría de los estudios suele haber variables explicativas y variables respuesta. Las variables respuesta (también llamadas dependientes, resultado u objetivo) son las variables que se pretende explicar o analizar. Las variables explicativas (también llamadas independientes) son las variables candidatas a servir de explicación de las variables respuesta. Un ejemplo de variable explicativa genérica puede ser `Tipo` (tipo de fármaco, tipo de motor, tipo de técnica pedagógica, etc.) y de variable respuesta genérica puede ser `Medida` (medida del

Tipo	Clasificación 1	Clasificación 2	Clasificación 3
Dicotómica	Cualitativa	Categórica	Discreta finita
Nominal	Cualitativa	Categórica	Discreta finita
Ordinal	Cualitativa	Categórica	Discreta finita
Numérica discreta	Cuantitativa	Numérica discreta	Discreta infinita
Continua	Cuantitativa	Continua	Continua

Tabla 1.1: Distintas clasificaciones según los tipos de variables

éxito o no de un fármaco, medida del número de horas que funciona un motor hasta romperse, medida del grado de mejoría cuando se aplica una determinada técnica pedagógica, etc.). En el caso de dos variables X (explicativa) e Y (respuesta) se suele escribir de forma esquemática como $Y \leftarrow X$ para indicar que se está ante un modelo estadístico que establece que se está intentando explicar Y a través de X.

Estadística descriptiva

El propósito de la Estadística es conocer una población. Este propósito se realiza estudiando en primer lugar una muestra de ella a través de la estadística descriptiva y, gracias al cálculo de probabilidades, dando el salto a la población a través de la estadística inferencial.

El objetivo de la estadística descriptiva es procesar, describir, resumir la información recogida en la muestra a través de unos índices que reciben el nombre de estadísticos y que se calculan a partir de los datos experimentales. Por ejemplo, en el caso de que se esté interesado en conocer el impacto de una enfermedad en una población, se podría hacer un estudio recogiendo una muestra de ella de n individuos y registrando si tienen o no la enfermedad. Este ejemplo correspondería a estudiar una variable dicotómica, dada por `Enfermedad` (Sí/No) y que se podría denotar por Y (1/0). En esta situación los datos experimentales tendrían el patrón dado en la tabla 1.2, donde el número de individuos 1 es r_1, el número de individuos 0 es r_0 y el número total de individuos es $n = r_1 + r_0$. En este caso de una variable dicotómica, el estadístico descriptivo por excelencia es la proporción muestral dada por $\frac{r_1}{n}$ que es un número entre 0 y 1. En la práctica se suele presentar en forma de porcentaje multiplicando por 100. En el contexto médico, a la proporción muestral de enfermedad se la denomina prevalencia muestral y representa la probabilidad muestral de estar enfermo. Es interesante observar que si se denota en general por y_i al valor del individuo i en la variable Y, al haber codificado esta variable Y con 1/0 se tiene en este caso, que

$$\frac{r_1}{n} = \frac{1}{n}\sum_{i=1}^{n} y_i,$$

donde $\sum_{i=1}^{n} y_i$ indica $y_1 + \ldots + y_n$, ya que $\sum_{i=1}^{n} y_i = \underbrace{1 + \ldots + 1}_{r_1} + \underbrace{0 + \ldots + 0}_{r_0} = r_1$, por lo que en

este contexto la proporción muestral es la media muestral $\overline{y}$, dada por $\overline{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$. Así, si en una muestra de $n = 50$ unidades, hubiera $r_1 = 17$ con dicha enfermedad, la estadística descriptiva afirmaría que en dicha muestra el porcentaje de enfermedad es del 34 %. ¿Y en la población? Esta es una pregunta que no puede responder la estadística descriptiva, hay que esperar a la estadística inferencial.

Y
1
1
...
1
0
0
...
0

Tabla 1.2: Datos genéricos de una variable dicotómica

Cálculo de probabilidades

El cálculo de probabilidades es la parte más matemática de la Estadística y suministra las herramientas (por ejemplo, el teorema central del límite) para poder conocer la población a partir de una muestra representativa de ella (para poder pasar a lo general partiendo de lo concreto o particular). En este proceso es clave el concepto de parámetro y de distribución muestral de un estadístico.

En la Estadística clásica (también llamada frecuentista) se está interesado en conocer una población a través de un parámetro poblacional θ que es una constante desconocida y que se desea saber su valor. Así, por ejemplo, si se está interesado en conocer el impacto de una enfermedad en una población, sería interesante conocer el parámetro proporción poblacional de dicha enfermedad (en este caso, también denominada, prevalencia poblacional de enfermedad), que se podría denotar por la proporción poblacional π y que representa la probabilidad poblacional de enfermedad, es decir $\pi = P(Y = 1)$. Siempre que se pueda, existe el convenio de denotar con letras griegas a los parámetros poblacionales; en este caso conviene señalar que π no tiene nada que ver con el valor 3.14159265... Para conocer π se cuenta con la ayuda de la proporción muestral, que se podría denotar por $\widehat{\pi}$ dado por $\widehat{\pi} = \frac{r_1}{n}$ (en otros textos se denota a la proporción muestral por p para hacer énfasis en que se utilizan letras latinas para los valores muestrales; en este mini-libro se prefiere la utilización del "gorro" $\widehat{\ }$ o acento circunflejo para indicar que $\widehat{\pi}$ es un valor estimado de π). Conviene mencionar que para los datos de la tabla 1.2 se puede calcular además de la proporción

muestral $\widehat{\pi} = \frac{r_1}{n}$, la desviación típica muestral dada por

$$\begin{aligned}\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-\overline{y})^2} &= \sqrt{\frac{1}{n}\left[\left(1-\frac{r_1}{n}\right)^2 r_1 + \left(0-\frac{r_1}{n}\right)^2 r_0\right]} = \sqrt{\frac{1}{n}\frac{(n-r_1)^2}{n^2}r_1 + \frac{1}{n}\frac{r_1^2}{n^2}r_0} \\ &= \sqrt{\frac{1}{n}\frac{r_0^2}{n^2}r_1 + \frac{1}{n}\frac{r_1^2}{n^2}r_0} = \sqrt{\frac{r_0 r_1}{n}\left(\frac{r_0}{n^2}+\frac{r_1}{n^2}\right)} = \sqrt{\frac{r_0 r_1}{n}\frac{n}{n^2}} \\ &= \sqrt{\frac{r_1}{n}\left(1-\frac{r_1}{n}\right)} = \sqrt{\widehat{\pi}(1-\widehat{\pi})}.\end{aligned}$$

Desde un punto de vista formal (ver, por ejemplo, Peña [2014] o Ramos et al. [2019]), el marco teórico poblacional que está generando los datos experimentales de la tabla 1.2 es el que especifica que Y es una variable aleatoria (v.a.) Bernoulli, por lo que la media téorica de Y, que se denota por $E[Y]$ (esperanza matemática), viene dada por

$$E[Y] = 1 \cdot P(Y=1) + 0 \cdot P(Y=0) = 1 \cdot \pi + 0 \cdot (1-\pi) = \pi,$$

la varianza teórica de Y, que se denota por $V[Y]$, viene dada por

$$V[Y] = E[(Y-E[Y])^2] = E[Y^2] - E^2[Y] = 1^2 \cdot P(Y=1) + 0^2 \cdot P(Y=0) - \pi^2 = \pi(1-\pi)$$

y la desviación típica teórica de Y, que se denota por $D[Y]$, viene dada por

$$D[Y] = \sqrt{V[Y]} = \sqrt{\pi(1-\pi)}.$$

Ahora se trata de extrapolar (pasar) de la muestra a la población, algo que a priori parece imposible. Esto sólo se consigue con el concepto de distribución muestral de un estadístico. La idea es la siguiente. En la muestra que se está analizando, la proporción muestral tiene un determinado valor, por ejemplo, 0.34. Si se hubiese tomado otra muestra representativa, la proporción muestral tomaría seguramente otro valor, por ejemplo, 0.56 y si se hubiese tomado otra, quizás 0.52, etc. Si este proceso de tomar muestras representativas se repitiese varias veces, se podría construir una columna de datos con los valores de todas las proporciones muestrales obtenidas, similar a la tabla 1.3 donde dichos valores varían de unos a otros (hay una cierta variabilidad). En la tabla 1.3 se ha nombrado a la columna con $\widehat{\Pi}$ para indicar que se está ante una nueva variable aleatoria (por eso en mayúscula) que es la variable aleatoria asociada al estadístico proporción muestral. Esta variable tendrá un histograma asociado y, por tanto, tamnién un modelo de probabilidad continuo asociado. Este histograma o modelo asociado representa la distribución muestral del estadístico proporción muestral. En este caso, el teorema central del límite afirma que tiene forma de campana de Gauss (es una v.a. Normal). Desde un punto de vista formal (ver, por ejemplo, Peña [2014] o Ramos et al. [2019]), si se considera Y_i la v.a. Y asociada al individuo i, se tiene que el estadístico $\widehat{\Theta}$ dado por la v.a. proporción muestral $\widehat{\Pi}$ es

$$\widehat{\Theta} = \widehat{\Pi} = \overline{Y} = \frac{1}{n}\sum_{i=1}^{n} Y_i$$

$\widehat{\Pi}$
0.34
0.56
0.52
0.48
0.52
0.48
0.36
0.34
0.40
0.30
0.44
0.30
0.34
0.34
0.38
0.36
0.48
0.52
0.40
0.44

Tabla 1.3: Datos de 20 proporciones muestrales

con lo que la media teórica de $\widehat{\Pi}$ viene dada por

$$E[\widehat{\Pi}] = E[\overline{Y}] = E\Big[\frac{1}{n}\sum_{i=1}^{n} Y_i\Big] = \frac{1}{n}E\Big[\sum_{i=1}^{n} Y_i\Big] = \frac{1}{n}n\pi = \pi$$

y, al ser las Y_i independientes, son incorreladas, por lo que la varianza teórica de $\widehat{\Pi} = \overline{Y}$ viene dada por

$$V[\widehat{\Pi}] = V[\overline{Y}] = V\Big[\frac{1}{n}\sum_{i=1}^{n} Y_i\Big] = \frac{1}{n^2}V\Big[\sum_{i=1}^{n} Y_i\Big] \overset{incorr.}{=} \frac{1}{n^2}n\pi(1-\pi) = \pi(1-\pi)\frac{1}{n}.$$

La raíz cuadrada de la varianza teórica del estadístico proporción muestral $\widehat{\Pi}$ se denomina error estándar del estadístico proporción muestral, $EE[\widehat{\Pi}]$, y representa una medida de la dispersión del estadístico proporción muestral. Su expresión viene dada por

$$EE[\widehat{\Pi}] = \sqrt{V[\widehat{\Pi}]} = \sqrt{\pi(1-\pi)\frac{1}{n}}.$$

Con estos elementos y la ayuda de la estadística inferencial se puede inferir qué ocurre con el parámetro proporción poblacional π, dando el salto de la muestra a la población. Dentro de la estadística inferencial se distingue la inferencia mediante un intervalo de confianza (IC) y la inferencia mediante un contraste de hipótesis (CH).

1.2. Intervalo de confianza

A un nivel intuitivo el IC de un parámetro poblacional θ proporciona (infiere) un rango plausible de valores para dicho parámetro a nivel poblacional. En el caso del parámetro poblacional π su IC viene dado por

$$IC_{1-\alpha}(\pi) = \Big(E[\widehat{\Pi}] - z_{1-\alpha/2}EE[\widehat{\Pi}], E[\widehat{\Pi}] + z_{1-\alpha/2}EE[\widehat{\Pi}]\Big),$$

donde $1-\alpha$ representa el nivel de confianza que se tiene en que dicho intervalo cubra (incluya) de verdad al parámetro poblacional. Usualmente, se toma $\alpha = 0.05$ con lo que la confianza habitual es del 95 %, aunque en ocasiones también se utiliza $\alpha = 0.01$ y por tanto una confianza del 99 %. El valor $z_{1-\alpha/2}$ representa el valor de la abscisa en la curva de una densidad normal tipificada que deja a su izquierda un área de $1-\alpha/2$ y a su derecha un área de $\alpha/2$. Este valor $z_{1-\alpha/2}$ se encuentra tabulado, de forma que para $\alpha = 0.05$ es $z_{1-0.05/2} = 1.96$ y para $\alpha = 0.01$ es $z_{1-0.01/2} = 2.58$. En la expresión anterior del IC para π aparecen los términos $E[\widehat{\Pi}] = \pi$ y $EE[\widehat{\Pi}] = \sqrt{\pi(1-\pi)\frac{1}{n}}$ que, al depender de π, son desconocidos y se estiman por $\widehat{E}[\widehat{\Pi}] = \widehat{\pi} = \frac{r_1}{n}$ y $\widehat{EE}[\widehat{\Pi}] = \sqrt{\widehat{\pi}(1-\widehat{\pi})\frac{1}{n}} = \sqrt{\frac{r_1}{n}(1-\frac{r_1}{n})\frac{1}{n}}$, respectivamente.

El nivel de confianza, si se expresa en tanto por ciento, está comprendido entre 0 y 100. Técnicamente, no se puede decir, si se trabaja por ejemplo con un 95 % de confianza, que el parámetro está en el $IC95\,\%$ con una probabilidad del 95 %, sino que si se repitiese el estudio 100 veces con 100 muestras distintas y se construyesen 100 $IC95\,\%$ utilizando la fórmula anterior, un 95 % de ellos cubrirían realmente al parámetro desconocido. En la práctica, sólo se realizará un estudio y sólo se construirá un $IC95\,\%$ y nunca se sabrá si el parámetro está o no está en él, pero al menos se tendrá la seguridad de que el método de construcción del intervalo se realiza con una confianza dada. Dicho de otra forma, los IC no calculan la probabilidad de que θ esté comprendido entre dos valores porque el parámetro no es una v.a., es una constante (desconocida, pero constante y está o no está en el IC). Ahora bien, dado que los extremos del IC son v.a., sí se puede hablar de la probabilidad de que dichos valores cubran a θ.

Otro concepto importante en el intervalo de confianza es la imprecisión, que está asociada a la anchura del IC y que viene dada en las mismas unidades que el parámetro que se pretende estimar. Existe un símil algo poético en el que se considera que el centro de una diana es el parámetro desconocido y un lanzador de hacha es la estadística inferencial. En dicho símil,

la confianza está representada por la habilidad del lanzador del hacha y la imprecisión por la longitud del filo del hacha.

Sobre los conceptos que intervienen en un IC, se tiene que:

- Una mayor confianza conlleva una mayor imprecisión, ya que, por ejemplo, para $\alpha = 0.05$ es $z_{1-0.05/2} = 1.96$ y para $\alpha = 0.01$ es $z_{1-0.01/2} = 2.58$, lo que se traduce en un IC más ancho.
- Un mayor tamaño muestral conlleva una mayor precisión, es decir un IC más estrecho.
- Si se quisiera tener una confianza del 100 %, el $IC100\,\%$ sería todo el rango posible de valores que puede tomar θ. Por ejemplo si θ es una proporción π, el $IC100\,\%$ sería todo el intervalo $[0, 1]$ con una imprecisión máxima.
- Si se quisiera tener confianza nula, el $IC0\,\%$ sería la estimación puntual del parámetro dada por el valor del estadístico muestral correspondiente, con una precisión máxima, pero generabilidad nula a la población.

Por último, cabe señalar como recomendación práctica, que el cálculo del IC para una proporción según la fórmula dada requiere que el valor $n\widehat{\pi}$ sea mayor que 5 lo que, intuitivamente, corresponde a un tamaño muestral lo suficientemente grande y una proporción no demasiado extrema.

Ejemplo

1. Se desea estimar por IC el verdadero valor de una proporción poblacional. Después de tomar una muestra representativa de $n = 50$, se observa que en dicha muestra 17 individuos presentan la característica de interés. ¿Cuál es el $IC95\,\%$?

   SOLUCIÓN:

   El $IC95\,\%(\pi)$ viene dado por

$$\begin{aligned} IC95\,\%(\pi) &= \left(\widehat{\pi} \mp 1.96\sqrt{\widehat{\pi}(1-\widehat{\pi})\frac{1}{n}}\right) \\ &= \left(\frac{r_1}{n} \mp 1.96\sqrt{\frac{r_1}{n}\Big(1-\frac{r_1}{n}\Big)\frac{1}{n}}\right) = \left(\frac{17}{50} \mp 1.96\sqrt{\frac{17}{50}\Big(1-\frac{17}{50}\Big)\frac{1}{50}}\right) \\ &= (0.21, 0.47). \end{aligned}$$

2. Se pide ilustrar con R el concepto de intervalo de confianza mediante simulaciones. Para ello se supone conocida la proporción poblacional, por ejemplo, se supone $\pi = 0.40$, pero se procede como si no se supiese. Se toman 20 muestras de dicha población, cada una de tamaño 50, y se construyen 20 $IC95\,\%$ observando empíricamente cuántos cubren al verdadero parámetro poblacional.

SOLUCIÓN:

En primer lugar, se muestra la sintaxis en R para la generación de una muestra de tamaño 50 de una población con proporción poblacional $\pi = 0.40$ y del cálculo del $IC95\,\%$.

```
rm(list=ls())

muestra=1*(runif(50,0,1)<0.40)
muestra

pi_muestral=sum(muestra)/50
pi_muestral

IC95inf=pi_muestral-1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95inf

IC95sup=pi_muestral+1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95sup
```

Dicha sintaxis produce un resultado distinto cada vez que se ejecuta. A la hora de escribir este mini-capítulo se obtuvo

$$\begin{aligned} \widehat{\pi} &= 0.34 \\ IC95\,\%(\pi) &= (0.21, 0.47). \end{aligned}$$

En este caso, se observa que el $IC95\,\%(\pi)$ cubre al verdadero parámetro poblacional $\pi = 0.40$ (era de esperar, ya que sólo 5 de cada 100 veces, o si se prefiere 1 de cada 20 no lo cubriría).

En segundo lugar, se muestra la sintaxis en R para la generación de 19 muestras de tamaño 50 de la misma población con proporción poblacional $\pi = 0.40$ y del cálculo del $IC95\,\%$ para cada muestra. En esta ocasión se utiliza una sintaxis más compacta:

```
rm(list=ls())

pi_muestral=replicate(19,sum(1*(runif(50,0,1)<0.40))/50)
pi_muestral

IC95inf=pi_muestral-1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95inf

IC95sup=pi_muestral+1.96*sqrt(pi_muestral*(1-pi_muestral)/50)
IC95sup
```

Dicha sintaxis produce un resultado distinto cada vez que se ejecuta. A la hora de escribir este mini-capítulo y, teniendo en cuenta la primera muestra, se obtuvieron los valores dados en la tabla 1.4.

pi_muestral	IC95inf	IC95sup
0.34	0.21	0.47
0.56	0.42	0.70
0.52	0.38	0.66
0.48	0.34	0.62
0.52	0.38	0.66
0.48	0.34	0.62
0.36	0.23	0.49
0.34	0.21	0.47
0.40	0.26	0.54
0.30	0.17	0.43
0.44	0.30	0.58
0.30	0.17	0.43
0.34	0.21	0.47
0.34	0.21	0.47
0.38	0.25	0.51
0.36	0.23	0.49
0.48	0.34	0.62
0.52	0.38	0.66
0.40	0.26	0.54
0.44	0.30	0.58

Tabla 1.4: Simulación del $IC_{95\,\%}$ de una proporción poblacional basada en 20 muestras

En la tabla 1.4 se observa que hay un IC (el segundo) de los 20 dado por $(0.42, 0.70)$ que NO cubre al verdadero parámetro poblacional. Si esa segunda muestra fuera la muestra obtenida en el estudio, el IC no cumpliría su misión y NADIE lo sabría.

Además, con la ayuda de la tabla 1.4, se puede comprobar que la media muestral de todas las proporciones muestrales es 0.414, muy similar al valor teórico dado por $E[\widehat{\Pi}] = \pi = 0.40$, y que la desviación típica muestral de todas las proporciones muestrales es 0.079, muy similar al valor teórico dado por $D[\widehat{\Pi}] = \sqrt{V[\widehat{\Pi}]} = \sqrt{\pi(1-\pi)/50} = 0.069$.

1.3. Contraste de hipótesis

A un nivel intuitivo el CH permite tomar (inferir) una decisión acerca de las poblaciones en base a lo que se ha observado en la muestra. Se puede decir también, que cuantifica si el azar puede explicar o no lo observado en la muestra. En definitiva, si se puede inferir que lo observado en la muestra también ocurre en la población.

En el CH intervienen dos hipótesis que se enfrentan entre sí: la hipótesis nula H_0 (usualmente de igualdad: no hay diferencias) y la hipótesis alternativa H_1 (usualmente de no igualdad: sí hay diferencias). Se trata de decidir, en base a la construcción de un estadístico de contraste experimental (basado en la muestra) entre esas dos hipótesis. En dicha decisión, existen dos posibles riesgos:

- El riesgo α (o probabilidad de error de tipo I) que aparece cuando se rechaza la hipótesis H_0 siendo ésta verdadera. En plan intuitivo, el error de tipo I sería "pasarse de listo", es decir, decretar que hay diferencias cuando en realidad no las hay (falso positivo). En términos técnicos $\alpha = P(H_1|H_0)$, es decir,

  $$\alpha = P(\text{concluir } H_1|\text{en realidad es cierta } H_0)$$

  (conviene recordar que la barra vertical se lee como "sabiendo que").

- El riesgo β (o probabilidad de error de tipo II) que aparece cuando no se rechaza la hipótesis H_0 siendo ésta falsa. En plan intuitivo, el error de tipo II sería "ser cegato ante la realidad", es decir, no decretar que hay diferencias cuando en realidad las hay (falso negativo). En términos técnicos $\beta = P(H_0|H_1)$, es decir,

  $$\beta = P(\text{aceptar } H_0|\text{en realidad es cierta } H_1).$$

Estos riesgos que se admite que siempre van a existir al tomar una decisión, se intentan controlar fijando unos valores asumibles. Para el riesgo α se considera 0.05 que es el valor usual del nivel de significación, a partir del cual se va a decretar o no la existencia de diferencias estadísticamente significativas. Para el riesgo β se suele considerar 0.10, que es el valor que corresponde a una potencia del 90 %. Estos valores asumidos para α y β intervienen en las fórmulas del cálculo del tamaño muestral. A la hora de la decisión, se asocia al estadístico de contraste un valor llamado p-valor, que cuantifica el peso del azar, tomando valores entre 0 y 1. Este p-valor técnicamente se define como la probabilidad, suponiendo que H_0 es cierta, de que el estadístico de contraste tome un valor tanto o más extremo que el observado o experimental. Si dicho p-valor es menor que el nivel de significación, se rechaza H_0 (se decreta la existencia de diferencias estadísticamente significativas, ya que el peso del azar es pequeño y el azar no puede explicar las diferencias muestrales observadas) y se concluye H_1, en caso contrario no se rechaza H_0, se dice que no hay evidencia suficiente para rechazar H_0 (se decreta que no hay diferencias estadísticamente significativas, ya que

el peso del azar es grande y el azar sí puede explicar las diferencias muestrales observadas) y en la práctica se "acepta" H_0.

Para fijar ideas, se presenta el CH para el parámetro proporción poblacional π dado por

$$H_0 : \pi = \pi_t$$
$$H_1 : \pi \neq \pi_t$$

donde se trata de decidir si en la población, el parámetro proporción poblacional π toma un valor concreto π_t teórico de referencia o si no lo toma. En este caso, el estadístico de contraste "experimental" Z está dado por

$$Z = \frac{\widehat{\Pi} - \pi_t}{EE[\widehat{\Pi}]}$$

y se demuestra, utilizando el teorema central del límite, que sigue una $N(0,1)$ bajo H_0 (es decir, suponiendo que H_0 es cierta). Para la muestra en estudio, dicho estadístico de contraste toma el valor

$$z_{exp} = \frac{\frac{r_1}{n} - \pi_t}{\sqrt{\pi_t(1-\pi_t)\frac{1}{n}}}.$$

Se observa que en el numerador de z_{exp} aparece la proporción muestral y que en el denominador aparece la cuantificación de la variabilidad de la proporción muestral. En concreto, el denominador representa la estimación de $EE[\widehat{\Pi}] = \sqrt{\pi(1-\pi)\frac{1}{n}}$ bajo la hipótesis nula (con lo que $\pi = \pi_t$), que se podría denotar por $\widehat{EE}_0[\widehat{\Pi}] = \sqrt{\pi_t(1-\pi_t)\frac{1}{n}}$. Dado que H_1 está formulada como $\pi \neq \pi_t$ se contempla tanto que $\pi < \pi_t$ como que $\pi > \pi_t$. Por este motivo se habla de hipótesis bilateral. Asociado al valor del estadístico de contraste z_{exp} estaría el p-valor bilateral $= P(|Z| \geq |z_{exp}|) = P(Z \leq -|z_{exp}|) + P(Z \geq |z_{exp}|)$ con $Z \sim N(0,1)$. Al ser Z simétrica en torno al 0, se tiene que $P(Z \leq -|z_{exp}|) = P(Z \geq |z_{exp}|)$, por lo que el p-valor bilateral también se puede calcular como $2P(Z \geq |z_{exp}|)$. Por lo tanto, si p-valor bilateral $< \alpha$, equivalentemente, si $|z_{exp}| > z_{1-\alpha/2}$, se rechaza H_0.

Existen versiones unilaterales del CH anterior. Por una parte, el CH unilateral por la izquierda viene dado por

$$H_0 : \pi \geq \pi_t$$
$$H_1 : \pi < \pi_t$$

con el mismo estadístico de contraste z_{exp}, pero con p-valor unilateral izquierdo dado por p-valor unilateral izquierdo$= P(Z \leq z_{exp})$. Por otra parte, el CH unilateral por la derecha viene dado por

$$H_0 : \pi \leq \pi_t$$
$$H_1 : \pi > \pi_t$$

con el mismo estadístico de contraste z_{exp}, pero con p-valor unilateral derecho dado por p-valor unilateral derecho $= P(Z \geq z_{exp})$.

Es importante notar que, en ningún caso, el p-valor representa la probabilidad de que la H_0 sea correcta, sino la probabilidad de que siendo correcta la H_0 se presente un resultado del estadístico de contraste tanto o más extremo que el observado en el sentido que marca la H_1. Además, el hecho de denotar con el subíndice *exp* al estadístico de contraste experimental es por motivos pedagógicos para hacer hincapié en que depende de los datos experimentales, pero no se suele especificar en la literatura.

Como recomendación práctica, la asunción del test z de una proporción es que el valor $n\widehat{\pi}$ sea mayor que 5 lo que, intuitivamente, corresponde a un tamaño muestral lo suficientemente grande y una proporción no demasiado extrema.

Ejemplo

1. Se desea contrastar si el verdadero valor de una propoción poblacional es 0.40. Después de tomar una muestra representativa de $n = 50$, se observa que en dicha muestra 17 individuos presentan la característica observada. ¿Cuál es la decisión en relación al CH bilateral sobre el valor teórico?

   SOLUCIÓN:

   El CH planteado es

   $$H_0 : \pi = 0.40$$
   $$H_1 : \pi \neq 0.40$$

   donde para la muestra en estudio el estadístico de contraste toma el valor

   $$z_{exp} = \frac{\frac{17}{50} - 0.40}{\sqrt{0.40(1-0.40)\frac{1}{50}}} = -0.8660,$$

   con un p-valor asociado igual a `2*(1-pnorm(abs(-0.8660))`$= 0.3865$. Dado que el p-valor es mayor que el nivel de significación habitual de 0.05, se concluye que no hay motivos para rechazar H_0, que el valor observado para la proporción muestral de 0.34 no es estadísticamente distinto de forma significativa del valor de referencia de 0.40, que el azar puede explicar la diferencia observada entre 0.34 y 0.40.

2. Se pide ilustrar con R el concepto de CH mediante simulaciones. Para ello se supone conocida la proporción poblacional, por ejemplo se supone $\pi = 0.40$, pero se procede como si no se supiese. Se toman 20 muestras de dicha población, cada una de tamaño 50, y se construyen 20 CH con valor de referencia precisamente el valor de 0.40, observando empíricamente cuántos de ellos rechazan H_0 de forma incorrecta.

   SOLUCIÓN:

Aprovechando el ejercicio de simulación de los IC, se construye la tabla 1.5 pero con las columnas de z_{exp} y del p-valor.

pi_muestral	z_{exp}	p-valor
0.34	-0.8660	0.3865
0.56	2.3094	0.0209
0.52	1.7321	0.0833
0.48	1.1547	0.2482
0.52	1.7321	0.0833
0.48	1.1547	0.2482
0.36	-0.5774	0.5637
0.34	-0.8660	0.3865
0.40	0.0000	1.0000
0.30	-1.4434	0.1489
0.44	0.5774	0.5637
0.30	-1.4434	0.1489
0.34	-0.8660	0.3865
0.34	-0.8660	0.3865
0.38	-0.2886	0.7728
0.36	-0.5774	0.5637
0.48	1.1547	0.2482
0.52	1.7321	0.0833
0.40	0.0000	1.0000
0.44	0.5774	0.5637

Tabla 1.5: Simulaciones de 20 muestras para el CH de una proporción poblacional

En la tabla 1.5 se muestran, por tanto, 20 estudios hipotéticos con 20 posibles resultados (aunque conviene recordar que en la práctica sólo se hace uno). Si el único estudio realizado fuera el primero, se tendría que al ser el p-valor=0.3865>0.05 no se rechazaría la H_0. Es decir, los resultados experimentales (proporción muestral de 0.34) serían compatibles con la H_0 (proporción teórica de 0.40). Sin embargo, se observa que si el único estudio realizado fuera el segundo, se tendría que al ser el p-valor=0.0209<0.05 se rechazaría la H_0 de forma incorrecta, ya que los datos estaban simulados con 0.40 como verdadero parámetro poblacional. Si el único estudio fuera cualquiera, a excepción del segundo, se tendría de nuevo la misma conclusión que la ya comentada para el primero, lo cual concuerda con la teoría de que el error α es 0.05 (5 veces de cada 100, o lo que es lo mismo una vez de cada 20, se obtiene un error falso positivo). Es importante notar la equivalencia entre CH e IC, aunque dicha equivalencia no es total porque difieren en la forma de estimación del EE.

Mini-capítulo 2

Respuesta dicotómica

En este mini-capítulo se contemplan el test z de diferencia de dos proporciones y el test exacto de Fisher, que están enmarcados en el esquema $D \leftarrow D$ que indica que se está intentando explicar la variable respuesta Y dicotómica a través de la variable explicativa X dicotómica.

Esta situación se da, por ejemplo, cuando se quiere estudiar si la curación de una enfermedad está influida por el hecho de dar un tratamiento u otro. Para ello se realiza un estudio en n individuos a los que se les administra el tratamiento 1 (codificado con 1 en la variable tratamiento) a n_1 individuos y el tratamiento 2 (codificado con 2 en la v.a. tratamiento) a n_2 individuos con $n = n_1 + n_2$ y se observa quién se cura (codificándolo con 1 en la variable respuesta) y quién no (codificándolo con 0 en la variable respuesta). En esta situación, los datos experimentales tendrán el patrón dado en la tabla 2.1, donde el número de individuos con perfil $Y = 1$ y $X = 1$ es a_1, con perfil $Y = 0$ y $X = 1$ es $n_1 - a_1$, con perfil $Y = 1$ y $X = 2$ es a_2 y con perfil $Y = 0$ y $X = 2$ es $n_2 - a_2$.

La pregunta de si X influye en Y se traduce en comparar la proporción poblacional de curaciones con el tratamiento 1 (que se denota por π_1) y la propoción poblacional de curaciones con el tratamiento 2 (que se denota por π_2).

2.1. z de diferencia de dos proporciones

El test z de diferencia de dos proporciones está enmarcado en el esquema $D \leftarrow D$ y está indicado para tamaños muestrales grandes. En este caso, el parámetro poblacional θ de interés es la diferencia entre las proporciones poblacionales, π_1 y π_2, es decir, $\theta = \pi_1 - \pi_2$. Para ello se considera el estadístico $\widehat{\Theta}$ dado por la v.a. $\widehat{\Pi}_1 - \widehat{\Pi}_2$, es decir, $\widehat{\Theta} = \widehat{\Pi}_1 - \widehat{\Pi}_2$, siendo $\widehat{\Pi}_1$ y $\widehat{\Pi}_2$ las proporciones muestrales entendidas como v.a. ya que variarán de muestra a muestra. Es sabido, utilizando el teorema central del límite, que $\widehat{\Pi}_1$ y $\widehat{\Pi}_2$ siguen sendas distribuciones normales y, por lo tanto, la diferencia $\widehat{\Pi}_1 - \widehat{\Pi}_2$ también será normal. Además,

Y	X
1	1
...	...
1	1
0	1
...	...
0	1
1	2
...	...
1	2
0	2
...	...
0	2

Tabla 2.1: Datos genéricos del esquema $D \leftarrow D$

es fácil ver que la media teórica de $\widehat{\Pi}_1 - \widehat{\Pi}_2$ está dada por

$$E[\widehat{\Pi}_1 - \widehat{\Pi}_2] = E[\widehat{\Pi}_1] - E[\widehat{\Pi}_2] = \pi_1 - \pi_2$$

y la varianza teórica de $\widehat{\Pi}_1 - \widehat{\Pi}_2$ está dada por

$$V[\widehat{\Pi}_1 - \widehat{\Pi}_2] = V[\widehat{\Pi}_1] + V[\widehat{\Pi}_2] - 2Cov(\widehat{\Pi}_1, \widehat{\Pi}_2) = \frac{\pi_1(1-\pi_1)}{n_1} + \frac{\pi_2(1-\pi_2)}{n_2},$$

ya que independencia implica incorrelación que equivale a covarianza nula, con lo que el error estándar de $\widehat{\Pi}_1 - \widehat{\Pi}_2$ es

$$EE[\widehat{\Pi}_1 - \widehat{\Pi}_2] = \sqrt{\frac{\pi_1(1-\pi_1)}{n_1} + \frac{\pi_2(1-\pi_2)}{n_2}}.$$

Con la información anterior se define un nuevo estadístico dado por

$$\frac{\widehat{\Pi}_1 - \widehat{\Pi}_2 - E[\widehat{\Pi}_1 - \widehat{\Pi}_2]}{EE[\widehat{\Pi}_1 - \widehat{\Pi}_2]} = \frac{\widehat{\Pi}_1 - \widehat{\Pi}_2 - (\pi_1 - \pi_2)}{\sqrt{\pi_1(1-\pi_1)\frac{1}{n_1} + \pi_2(1-\pi_2)\frac{1}{n_2}}}$$

que sigue una $N(0,1)$ y que servirá para construir un intervalo de confianza y un contraste de hipótesis para $\pi_1 - \pi_2$.

En el caso del intervalo de confianza hay que estimar $EE[\widehat{\Pi}_1 - \widehat{\Pi}_2]$ a través de

$$\widehat{EE}[\widehat{\Pi}_1 - \widehat{\Pi}_2] = \sqrt{\widehat{\pi}_1(1-\widehat{\pi}_1)\frac{1}{n_1} + \widehat{\pi}_2(1-\widehat{\pi}_2)\frac{1}{n_2}}$$

con $\widehat{\pi}_1 = \frac{a_1}{n_1}$ y $\widehat{\pi}_2 = \frac{a_2}{n_2}$, con lo que el intervalo de confianza al nivel de confianza $1-\alpha$ está dado por

$$\begin{aligned} IC_{1-\alpha}(\pi_1-\pi_2) &= \Big(\widehat{\pi}_1-\widehat{\pi}_2 \mp z_{1-\alpha/2}\sqrt{\widehat{\pi}_1(1-\widehat{\pi}_1)\frac{1}{n_1}+\widehat{\pi}_2(1-\widehat{\pi}_2)\frac{1}{n_2}}\Big) \\ &= \Big(\frac{a_1}{n_1}-\frac{a_2}{n_2} \mp z_{1-\alpha/2}\sqrt{\frac{a_1}{n_1}\Big(1-\frac{a_1}{n_1}\Big)\frac{1}{n_1}+\frac{a_2}{n_2}\Big(1-\frac{a_2}{n_2}\Big)\frac{1}{n_2}}\Big). \end{aligned}$$

En el caso del contraste de hipótesis

$$\begin{aligned} H_0 &: \pi_1-\pi_2 = 0 \\ H_1 &: \pi_1-\pi_2 \neq 0 \end{aligned}$$

hay que estimar $EE[\widehat{\Pi}_1-\widehat{\Pi}_2]$ bajo H_0. Dado que bajo H_0, $\pi_1=\pi_2$, se suponen igual a un valor común π_c estimado por $\widehat{\pi}_c = \dfrac{n_1\widehat{\pi}_1+n_2\widehat{\pi}_2}{n_1+n_2} = \dfrac{a_1+a_2}{n_1+n_2}$ y, por tanto, $EE[\widehat{\Pi}_1-\widehat{\Pi}_2]$ se estima a través de

$$\begin{aligned} \widehat{EE}_0[\widehat{\Pi}_1-\widehat{\Pi}_2] &= \sqrt{\widehat{\pi}_c(1-\widehat{\pi}_c)\frac{1}{n_1}+\widehat{\pi}_c(1-\widehat{\pi}_c)\frac{1}{n_2}} \\ &= \sqrt{\widehat{\pi}_c(1-\widehat{\pi}_c)\Big(\frac{1}{n_1}+\frac{1}{n_2}\Big)} = \sqrt{\frac{a_1+a_2}{n_1+n_2}\Big(1-\frac{a_1+a_2}{n_1+n_2}\Big)\Big(\frac{1}{n_1}+\frac{1}{n_2}\Big)} \end{aligned}$$

y el contraste de hipótesis al nivel de significación α se realiza a través del estadístico de contraste "experimental" Z dado por

$$Z = \frac{\widehat{\Pi}_1-\widehat{\Pi}_2-(\pi_1-\pi_2)}{EE[\widehat{\Pi}_1-\widehat{\Pi}_2]}$$

que se demuestra por el teorema central del límite que sigue una $N(0,1)$ bajo H_0. Para la muestra en estudio dicho estadístico de contraste toma el valor

$$z_{exp} = \frac{\frac{a_1}{n_1}-\frac{a_2}{n_2}-0}{\sqrt{\frac{a_1+a_2}{n_1+n_2}\Big(1-\frac{a_1+a_2}{n_1+n_2}\Big)\Big(\frac{1}{n_1}+\frac{1}{n_2}\Big)}}.$$

Asociado al valor del estadístico de contraste z_{exp} estaría el p-valor bilateral $= P(|Z| \geq |z_{exp}|) = P(Z \leq -|z_{exp}|) + P(Z \geq |z_{exp}|) = 2P(Z \geq |z_{exp}|)$. Por lo tanto, si dicho p-valor es menor que α (de forma equivalente, si $|z_{exp}| > z_{1-\alpha/2}$) se rechaza la hipótesis H_0.

Como recomendación práctica, las asunciones del test z de diferencia de dos proporciones son que todos los valores $n_1\widehat{\pi}_1$, $n_1(1-\widehat{\pi}_1)$, $n_2\widehat{\pi}_2$ y $n_2(1-\widehat{\pi}_2)$ sean mayores que 5 lo que, intuitivamente, corresponde a tamaños muestrales suficientemente grandes y proporciones no demasiado extremas.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta dicotómica. Han participado en el estudio 90 individuos. Los datos experimentales se dan en la tabla 2.2, donde el número de individuos con perfil $rta = 1$ y $exp = 1$ es 8, con perfil $rta = 1$ y $exp = 2$ es 14, con perfil $rta = 0$ y $exp = 1$ es 42 y con perfil $rta = 0$ y $exp = 2$ es 26.

rta	exp
1	1
...	...
1	1
1	2
...	...
1	2
0	1
...	...
0	1
0	2
...	...
0	2

Tabla 2.2: Datos observados del esquema $D \leftarrow D$, $n = 90$

SOLUCIÓN:

En primer lugar, se muestran los cálculos detallados para el intervalo de confianza al 95 % dado por

$$\begin{aligned} IC95\,\%(\pi_1 - \pi_2) &= \Big(\frac{8}{50} - \frac{14}{40} \mp 1.96\sqrt{\frac{8}{50}\Big(1 - \frac{8}{50}\Big)\frac{1}{50} + \frac{14}{40}\Big(1 - \frac{14}{40}\Big)\frac{1}{40}}\Big) \\ &= (0.16 - 0.35 \mp 1.96 \cdot 0.0915) \\ &= (-0.3694, -0.0106) \end{aligned}$$

y para el contraste de hipótesis dado por

$$z_{exp} = \frac{\frac{8}{50} - \frac{14}{40}}{\sqrt{\frac{8+14}{50+40}\Big(1 - \frac{8+14}{50+40}\Big)\Big(\frac{1}{50} + \frac{1}{40}\Big)}} = -2.0841$$

con lo que al ser $|z_{exp}| = 2.0841 > 1.96$ se rechaza la hipótesis nula de igualdad de proporciones y se concluye que la variable explicativa influye en la variable respuesta de forma significativa con un p-valor asociado igual a `2*(1-pnorm(abs(-2.0841))`$=$ 0.0371.

En segundo lugar, se muestra la sintaxis en R para el cálculo del IC y del p-valor del test z de diferencia de dos proporciones. Si se supone que los datos sin agrupar están en el fichero d_d_1.txt, la sintaxis es

```
rm(list=ls())

datos=read.table('d_d_1.txt',header=T)
attach(datos)

tabla=table(-rta,exp); tabla

ind1=which(exp==1);
ind2=which(exp==2);
ind11=which(rta==1 & exp==1);
ind12=which(rta==1 & exp==2);
a1=length(rta[ind11]); a1
a2=length(rta[ind12]); a2
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2

alfa=0.05
pi1=a1/n1
pi2=a2/n2

ee=sqrt(pi1*(1-pi1)*(1/n1)+pi2*(1-pi2)*(1/n2)); ee

ic1=pi1-pi2-qnorm(1-alfa/2)*ee; ic1
ic2=pi1-pi2+qnorm(1-alfa/2)*ee; ic2

pit=(a1+a2)/(n1+n2); pit

ee0=sqrt(pit*(1-pit)*(1/n1+1/n2))
z=(pi1-pi2)/ee0; z
z*z

p_valor= 2*(1-pnorm(abs(z))); p_valor

a=c(a1,a2); a
n=c(n1,n2); n
prop.test(a,n,correct=F)
```

y si se supone que se introducen los datos agrupados directamente, hay que sustituir las primeras líneas de la sintaxis anterior por

```
rm(list=ls())

a1=8; n1=50
a2=14; n2=40
```

Es importante notar que el test z de diferencia de dos proporciones, además de la versión bilateral explicada, tiene versiones unilaterales que en R se consiguen con

```
prop.test(a,n,correct=F,alternative="greater")
prop.test(a,n,correct=F,alternative="less")
```

2.2. Fisher

El test exacto de Fisher está enmarcado en el esquema $D \leftarrow D$ y está indicado para tamaños muestrales pequeños donde no se cumplen las asunciones del test z de diferencia de dos proporciones. A partir de los datos experimentales se construye la tabla de datos cruzados genérica dada en la tabla 2.3.

	$X=1$	$X=2$	
$Y=1$	a	b	$r_1 = a+b$
$Y=0$	c	d	$r_2 = c+d$
	n_1	n_2	n

Tabla 2.3: Tabla con datos genéricos del esquema $D \leftarrow D$

En el caso del contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 \neq 0$$

se construye un estadístico de contraste A que sigue una distribución hipergeométrica de parámetros $(n, a+c, a+b)$. Bajo este modelo se verifica que

$$p_a = P(A=a) = \frac{\binom{a+c}{a}\binom{b+d}{b}}{\binom{n}{a+b}} = \frac{\frac{(a+c)!}{a!c!}\frac{(b+d)!}{b!d!}}{\frac{n!}{(a+b)!(c+d)!}} = \frac{r_1!r_2!n_1!n_2!}{n!a!b!c!d!},$$

$$E[A] = \frac{(a+b)(a+c)}{n},$$

donde $x!$ indica el factorial de x que se calcula como $x \cdot (x-1) \cdot (x-2) \cdot \ldots \cdot 1$ (por ejemplo, $5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120$). Para esta v.a. A, el p-valor bilateral asociado es

$$\begin{aligned} p\text{-valor bilateral} &= P(|A - E[A]| \geq |a - E[A]|) \\ &= P(A - E[A] \leq -|a - E[A]|) + P(A - E[A] \geq |a - E[A]|). \end{aligned}$$

Para llever a cabo dicho contraste conviene construir, a partir de la tabla 2.3, todas las tablas posibles 2x2 con celdas a', b', c' y d' siendo:

- $0 \leq a' \leq \min\{n_1, r_1\}$.
- $b' = r_1 - a'$.
- $c' = n_1 - a'$.
- $d' = r_2 - c'$.

A continuación, a partir de dichas tablas, se calcula

$$p_{a'} = \frac{r_1! r_2! n_1! n_2!}{n! a'! b'! c'! d'!}$$

y el p-valor bilateral se obtiene como p-valor$= \sum_{p_{a'} \leq p_a} p_{a'}$.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta dicotómica. Han participado en el estudio 42 individuos. Los datos experimentales se dan en la tabla 2.4, donde el número de individuos con perfil $rta = 1$ y $exp = 1$ es 4, con perfil $rta = 1$ y $exp = 2$ es 1, con perfil $rta = 0$ y $exp = 1$ es 16 y con perfil $rta = 0$ y $exp = 2$ es 21.

rta	exp
1	1
...	...
1	1
1	2
...	...
1	2
0	1
...	...
0	1
0	2
...	...
0	2

Tabla 2.4: Datos observados del esquema $D \leftarrow D$, $n = 42$

SOLUCIÓN:

	$exp = 1$	$exp = 2$	
$rta = 1$	4	1	5
$rta = 0$	16	21	37
	20	22	42

Tabla 2.5: Tabla con datos observados del esquema $D \leftarrow D$, $n = 42$

En primer lugar, se muestran los cálculos intermedios detallados que toman como referencia la tabla 2.5 y que sirven para construir la tabla 2.6. Además hay que tener en cuenta que

$$E[A] = \frac{(a+b)(a+c)}{n} = \frac{(4+1)(4+16)}{42} = 2.3810.$$

a'	b'	c'	d'	n	$p_{a'}$
0	5	20	17	42	0.0310
1	4	19	18	42	0.1720
2	3	18	19	42	0.3440
3	2	17	20	42	0.3096
4	1	16	21	42	0.1253
5	0	15	22	42	0.0182

Tabla 2.6: Tablas variando a' en el esquema $D \leftarrow D$, $n = 42$

Utilizando la tabla 2.6, el cálculo del p-valor bilateral es igual a

$$\begin{aligned}
& P(A - 2.3810 \leq -|4 - 2.3810|) + P(A - 2.3810 \geq |4 - 2.3810|) \\
= \; & [P(A - 2.3810 \leq -1.6190)] + [P(A - 2.3810 \geq 1.6190)] \\
= \; & [P(A \leq 0.7620)] + [P(A \geq 4)] \\
= \; & P(A = 0) + P(A = 4) + P(A = 5) \\
= \; & 0.0310 + 0.1253 + 0.0182 = 0.1745.
\end{aligned}$$

Dado que el p-valor bilateral es mayor que 0.05 se tiene que no hay evidencia para concluir que la variable explicativa influya en la variable respuesta de forma significativa. Se observa que el p.valor bilateral corresponde efectivamente a que el estadístico de contraste tome un valor tanto o más extremo que el observado tanto a la derecha como a la izquierda, dado por p-valor$= \sum_{p_{a'} \leq p_a} p_{a'}$.

En segundo lugar, se muestra la sintaxis en R para el cálculo del p-valor del test exacto de Fisher. Si se supone que los datos sin agrupar están en el fichero d_d_2.txt, la sintaxis es

```
rm(list=ls())

datos=read.table('d_d_2.txt',header=T)
attach(datos)

tabla=table(rta,exp)

fisher.test(x=tabla,alternative="two.sided")
```

y si se supone que los datos se introducen directamente agrupados, la sintaxis es

```
rm(list=ls())

tabla <- matrix(c(4,1,16,21),ncol=2,byrow=TRUE)
colnames(tabla) <- c("exp=1","exp=2")
rownames(tabla) <- c("rta=1","rta=0")
tabla <- as.table(tabla); tabla
fisher.test(x=tabla,alternative="two.sided")
```

Es importante notar que el test exacto de Fisher, además de la versión bilateral explicada, tiene versiones unilaterales que en R se consiguen con

```
fisher.test(x=tabla,alternative="greater")
fisher.test(x=tabla,alternative="less")
```

y que corresponden, respectivamente, a

- p-valor unilateral derecho

$$P(A - E[A] \geq a - E[A]) = P(A - 2.3810 \geq 1.6190) =$$
$$P(A \geq 4) = P(A = 4) + P(A = 5) = 0.1253 + 0.0182 = 0.1435.$$

- p-valor unilateral izquierdo

$$P(A - E[A] \leq a - E[A]) = P(A - 2.3810 \leq 1.6190) = P(A \leq 4) =$$
$$P(A = 0) + P(A = 1) + P(A = 2) + P(A = 3) + P(A = 4) =$$
$$0.0310 + 0.1720 + 0.3440 + 0.3096 + 0.1253 = 0.9818.$$

Se oberva que el p-valor unilateral derecho corresponde efectivamente a que el estadístico de contraste tome un valor tanto o más extremo que el observado hacia la derecha dado por $\sum_{a' \geq a} p_{a'}$ y que el p-valor unilateral izquierdo corresponde, de forma análoga, a $\sum_{a' \leq a} p_{a'}$.

Mini-capítulo 3

Respuesta continua

En este mini-capítulo se contemplan el test t de Student de diferencia de dos medias y el test ANOVA de un factor (ANOVA significa "ANalysis Of VAriance"; a veces, por ejemplo en Peña [2014], se utilizan las siglas de su traducción al español "Análisis DE la VArianza", ADEVA). El test t de Student está enmarcado en el esquema $C \leftarrow D$ que indica que se está intentando explicar la variable respuesta Y continua a través de la variable explicativa X dicotómica y el test ANOVA de un factor está enmarcado en el esquema $C \leftarrow N$ que indica que se está intentando explicar la variable respuesta Y continua a través de la variable explicativa X nominal.

3.1. t de Student de diferencia de dos medias

El test t de Student de diferencia de dos medias está enmarcado en el esquema $C \leftarrow D$ y está indicado para variables Y normales en cada categoría de la variable dicotómica X. Esta situación se da, por ejemplo, cuando se quiere estudiar si una variable bioquímica está influida por el hecho de recibir un tipo de tratamiento u otro. Para ello se realiza un estudio en n individuos a los que se les asigna el tratamiento 1 (codificado con 1 en la variable tratamiento) a n_1 individuos y el tratamiento 2 (codificado con 2) a n_2 individuos con $n = n_1 + n_2$ y se observa qué valor continuo tienen en una determinada variable bioquímica. En esta situación los datos experimentales tendrán el aspecto dado en la tabla 3.1, donde el número de individuos con $X = 1$ es n_1 y con $X = 2$ es n_2.

La pregunta de si X influye en Y se traduce en comparar la media poblacional de la variable bioquímica al recibir la dieta 1, que se denota por μ_1, con la media poblacional de la variable bioquímica bajo la dieta 2, que se denota por μ_2. En este caso, el parámetro poblacional θ de interés es la diferencia de medias poblacionales, entre μ_1 y μ_2, es decir, $\theta = \mu_1 - \mu_2$. Para ello se considera el estadístico $\widehat{\Theta}$ dado por la v.a. $\overline{Y}_1 - \overline{Y}_2$, es decir, $\widehat{\Theta} = \overline{Y}_1 - \overline{Y}_2$, siendo $\overline{Y}_1$ y $\overline{Y}_2$ las medias muestrales entendidas como v.a. ya que variarán de muestra a muestra. Es sabido, utilizando que cualquier combinación lineal de normales

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2

Tabla 3.1: Datos genéricos del esquema $C \leftarrow D$

es normal, que $\overline{Y}_1$ y $\overline{Y}_2$ siguen sendas distribuciones normales y, por lo tanto, la diferencia $\overline{Y}_1 - \overline{Y}_2$ será normal. Además, es fácil ver que la media teórica de $\overline{Y}_1 - \overline{Y}_2$ está dada por

$$E[\overline{Y}_1 - \overline{Y}_2] = E[\overline{Y}_1] - E[\overline{Y}_2] = \mu_1 - \mu_2$$

y la varianza teórica de $\overline{Y}_1 - \overline{Y}_2$ está dada por

$$V[\overline{Y}_1 - \overline{Y}_2] = V[\overline{Y}_1] + V[\overline{Y}_2] - 2Cov(\overline{Y}_1, \overline{Y}_2) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2},$$

ya que independencia implica incorrelación que equivale a covarianza nula, con lo que el error estándar de $\overline{Y}_1 - \overline{Y}_2$ es

$$EE[\overline{Y}_1 - \overline{Y}_2] = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}.$$

Con la información anterior se define un nuevo estadístico dado por

$$\frac{\overline{Y}_1 - \overline{Y}_2 - E[\overline{Y}_1 - \overline{Y}_2]}{EE[\overline{Y}_1 - \overline{Y}_2]} = \frac{\overline{Y}_1 - \overline{Y}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

que sigue una $N(0,1)$ y que servirá para construir un intervalo de confianza y un contraste de hipótesis para $\mu_1 - \mu_2$.

En el caso del intervalo de confianza hay que estimar $EE[\overline{Y}_1 - \overline{Y}_2]$. Hay dos situaciones posibles:

- Que se pueda asumir $\sigma_1^2 = \sigma_2^2$ (homocedasticidad), en cuyo caso se suponen igual a un valor común σ_c^2 y que se estima por

  $$\widehat{s}_c^2 = \frac{(n_1 - 1)\widehat{s}_1^2 + (n_2 - 1)\widehat{s}_2^2}{(n_1 - 1) + (n_2 - 1)},$$

  con $\widehat{s}_1^2$ y $\widehat{s}_2^2$ las cuasivarianzas muestrales en cada grupo. En este supuesto

  $$\widehat{EE}[\overline{Y}_1 - \overline{Y}_2] = \sqrt{\widehat{s}_c^2\Big(\frac{1}{n_1} + \frac{1}{n_2}\Big)}$$

y el intervalo de confianza al nivel de confianza $1-\alpha$ está dado por

$$IC_{1-\alpha}(\mu_1-\mu_2)=\Big(\widehat{y}_1-\widehat{y}_2\mp t_{1-\alpha/2,n_1+n_2-2}\sqrt{\widehat{s}_c^2\Big(\frac{1}{n_1}+\frac{1}{n_2}\Big)}\Big).$$

El valor $t_{1-\alpha/2,n_1+n_2-2}$ representa el valor de la abscisa en la curva de una densidad t de Student con grados de libertad dados por $gl=(n_1-1)+(n_2-1)=n_1+n_2-2$ que deja a su izquierda un área de $1-\alpha/2$ y a su derecha un área de $\alpha/2$. Este valor $t_{1-\alpha/2,n_1+n_2-2}$ se encuentra tabulado, de forma que para $\alpha=0.05$ y, por ejemplo, $n_1=7$ y $n_2=10$, es $t_{1-0.05/2,15}=2.1315$ y en R se obtiene usando `qt(1-0.05/2,15)`.

- Que no se pueda asumir $\sigma_1^2=\sigma_2^2$ (heterocedasticidad). En este supuesto, hay que utilizar la aproximación de Welch publicada en 1938 y que está dada por

$$\widehat{EE}[\overline{Y}_1-\overline{Y}_2]=\sqrt{\frac{\widehat{s}_1^2}{n_1}+\frac{\widehat{s}_2^2}{n_2}}$$

y el intervalo de confianza al nivel de confianza $1-\alpha$ está dado por

$$IC_{1-\alpha}(\mu_1-\mu_2)=\left(\widehat{y}_1-\widehat{y}_2\mp t_{1-\alpha/2,gl}\sqrt{\frac{\widehat{s}_1^2}{n_1}+\frac{\widehat{s}_2^2}{n_2}}\right),$$

con

$$gl=\frac{\widehat{EE}^4[\overline{Y_1}-\overline{Y}_2]}{\frac{1}{n_1-1}\widehat{EE}^4[\overline{Y_1}]+\frac{1}{n_2-1}\widehat{EE}^4[\overline{Y_2}]}.$$

En el caso del contraste de hipótesis

$$H_0:\mu_1-\mu_2=0$$
$$H_1:\mu_1-\mu_2\neq 0$$

hay que considerar también los supuestos de homocedasticidad y heterocedasticidad.

- En el caso de homocedasticidad, la estimación de $EE[\overline{Y}_1-\overline{Y}_2]$ viene dada por

$$\widehat{EE}[\overline{Y}_1-\overline{Y}_2]=\sqrt{\widehat{s}_c^2\Big(\frac{1}{n_1}+\frac{1}{n_2}\Big)}$$

y el contraste de hipótesis al nivel de significación α se realiza a través del estadístico de contraste T dado por

$$T=\frac{\overline{Y}_1-\overline{Y}_2-(\mu_1-\mu_2)}{EE[\overline{Y}_1-\overline{Y}_2]}$$

que se demuestra que bajo H_0 sigue una t de Student con $gl=(n_1-1)+(n_2-1)=n_1+n_2-2$ grados de libertad. Para la muestra en estudio, dicho estadístico de contraste toma el valor experimental

$$t_{exp}=\frac{\overline{y}_1-\overline{y}_2-0}{\sqrt{\widehat{s}_c^2\Big(\frac{1}{n_1}+\frac{1}{n_2}\Big)}}.$$

- En el caso de heterocedasticidad, la estimación del $EE[\overline{Y}_1 - \overline{Y}_2]$ viene dada por

$$\widehat{EE}[\overline{Y}_1 - \overline{Y}_2] = \sqrt{\frac{\widehat{s}_1^2}{n_1} + \frac{\widehat{s}_2^2}{n_2}}$$

y el contraste de hipótesis al nivel de significación α se realiza a través del estadístico de contraste T de Welch dado por

$$T = \frac{\overline{Y}_1 - \overline{Y}_2 - (\mu_1 - \mu_2)}{EE[\overline{Y}_1 - \overline{Y}_2]}$$

que se demuestra que bajo H_0 sigue una t de Student con

$$gl = \frac{\widehat{EE}^4[\overline{Y_1} - \overline{Y}_2]}{\frac{1}{n_1-1}\widehat{EE}^4[\overline{Y_1}] + \frac{1}{n_2-1}\widehat{EE}^4[\overline{Y_2}]}$$

grados de libertad. Para la muestra en estudio, dicho estadístico de contraste toma el valor experimental

$$t_{exp} = \frac{\overline{y}_1 - \overline{y}_2 - 0}{\sqrt{\frac{\widehat{s}_1^2}{n_1} + \frac{\widehat{s}_2^2}{n_2}}}.$$

En ambos casos, asociado al valor del estadístico de contraste t_{exp} está el p-valor bilateral

$$P(|T| \geq |t_{exp}|) = P(T \leq -|t_{exp}|) + P(T \geq |t_{exp}|).$$

Al ser T simétrica en torno al cero, se tiene que $P(T \leq -|t_{exp}|) = P(T \geq |t_{exp}|)$, por lo que el p-valor bilateral también se puede expresar como $2P(T \geq |t_{exp}|)$. Por lo tanto, si dicho p-valor es menor que α (de forma equivalente, $|t_{exp}| > t_{1-\alpha/2,gl}$) se rechaza la hipótesis H_0.

Por último, como recomendaciones prácticas, conviene explicitar que las asunciones de normalidad y homocedasticidad en la t de Student se contrastan con el test de Shapiro-Wilk y el test de Levene, respectivamente.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta continua. Han participado en el estudio 17 individuos. Los datos experimentales se dan en la tabla 3.2. ¿Influye la variable explicativa en la variable respuesta?

   SOLUCIÓN:

   En primer lugar, se realiza una estadística descriptiva numérica básica de los datos con la sintaxis siguiente

rta	*exp*
15	1
15	1
25	1
25	1
25	1
33	1
43	1
15	2
16	2
16	2
25	2
28	2
28	2
28	2
28	2
35	2
43	2

Tabla 3.2: Datos observados del esquema $C \leftarrow D$

```
rm(list=ls())

datos=read.table('c_d_1.txt',header=T)
attach(datos)

ind1=which(exp==1)
ind2=which(exp==2)
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2
tapply(rta,exp,mean)
tapply(rta,exp,sd)
```

que proporcionan los estadísticos:

$$n_1 = 7 \quad ; \quad n_2 = 10$$

$$\overline{y}_1 = \frac{1}{n_1}\sum_{i_1=1}^{n_1} y_{1i_1} = \frac{181}{7} = 25.8571 \quad ; \quad \overline{y}_2 = \frac{1}{n_2}\sum_{i_2=1}^{n_2} y_{2i_2} = \frac{262}{10} = 26.2000$$

$$\widehat{s}_1 = \sqrt{\frac{1}{n_1-1}\sum_{i_1=1}^{n_1}(y_{1i_1}-\overline{y}_1)^2} = 9.8561 \quad ; \quad \widehat{s}_2 = \sqrt{\frac{1}{n_2-1}\sum_{i_2=1}^{n_2}(y_{2i_2}-\overline{y}_2)^2} = 8.8669$$

En segundo lugar, se contrasta la normalidad de la variable respuesta en cada grupo y la homocedasticidad entre grupos con la sintaxis siguiente

```
shapiro.test(rta[ind1])
shapiro.test(rta[ind2])

install.packages("lawstat")
library(lawstat)
levene.test(rta,exp,location="mean")
```

que proporciona, en cuanto a la normalidad, para el grupo 1 un p-valor=0.3300 y para el grupo 2 un p-valor=0.2268, por lo que se asume normalidad de la respuesta en cada grupo, y en cuanto a la homocedasticidad, un p-valor=0.8982 por lo que se asume homocedasticidad.

Por último, dado que se cumplen las condiciones de aplicabilidad del test t de Student, se calcula el estadístico de contraste y su p-valor asociado con la sintaxis

```
t.test(rta[ind1],rta[ind2],var.equal=TRUE)
```

que proporciona

$$t_{exp} = \frac{\overline{y}_1 - \overline{y}_2}{\sqrt{\widehat{s}_c^2\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} = \frac{25.8571 - 26.2000}{\sqrt{86.0305\left(\frac{1}{7} + \frac{1}{10}\right)}} = -0.0750,$$

con $gl = 7+10-2 = 15$ y un p-valor asociado igual a `2*(1-pt(abs(-0.0750),n1+n2-2))`$= 0.9412 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de medias con lo que la variable explicativa no influye en la respuesta (no hay diferencias estadísticamente significativas entre $\overline{y}_1 = 25.8571$ y $\overline{y}_2 = 26.2000$).

Conviene observar que también sería válida la sintaxis `t.test(rta~exp,var.equal=TRUE)` y la sintaxis `t.test(rta~factor(exp),var.equal=TRUE)`. Sin embargo, sería incorrecta la sintaxis `t.test(rta,exp,var.equal=TRUE)`.

3.2. ANOVA de un factor

El test ANOVA de un factor está enmarcado en el esquema $C \leftarrow N$ y está indicado para variables Y normales con igual varianza (homocedasticidad) en cada categoría de la variable nominal X. La situación de $C \leftarrow N$ se da, por ejemplo, cuando se quiere estudiar si la variable pérdida de peso (medida en g) está influida por el hecho de recibir un tipo de dieta u otro. Para ello se realiza un estudio en n individuos a los que se les asigna la dieta 1 (codificada con 1 en la variable dieta) a n_1 individuos, la dieta 2 (codificada con 2) a n_2 individuos y la dieta 3 (codificada con 3) a n_3 individuos con $n = n_1 + n_2 + n_3$ y se observa qué valor tienen en la variable pérdida de peso. En esta situación, los datos experimentales

tendrán el aspecto dado en la tabla 3.3, donde el número de individuos con $X = 1$ es n_1, con $X = 2$ es n_2 y con $X = 3$ es n_3.

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2
y_{31}	3
$\dots$	$\dots$
y_{3n_3}	3

Tabla 3.3: Datos genéricos del esquema $C \leftarrow N$

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : \mu_1 = \mu_2 = \mu_3$$
$$H_1 : \text{Hay alguna } \mu_i \text{ distinta}$$

El ANOVA de un factor se basa en el estadístico de contraste F cuyo cálculo se realiza a través de la tabla ANOVA que se muestra en la tabla 3.4, siendo SCE la suma de cuadrados explicada (por la variable explicativa), SCR la suma de cuadrados residual (la que queda sin explicar por la variable explicativa), SCT la suma de cuadrados total, gle los grados de libertad de la parte explicada, glr los grados de libertad de la parte residual, glt los grados de libertad total, CME el cuadrado medio explicado, CMR el cuadrado medio residual y

CMT el cuadrado medio total, que se calculan como

$$\begin{aligned} SCE &= \sum_{m=1}^{r} n_m(\overline{y}_{m.} - \overline{y}_{..})^2 \\ SCR &= \sum_{m=1}^{r}\sum_{i=1}^{n_m}(y_{mi} - \overline{y}_{m.})^2 \\ SCT &= \sum_{m=1}^{r}\sum_{i=1}^{n_m}(y_{mi} - \overline{y}_{..})^2 \\ gle &= r-1 \\ glr &= n-r \\ glt &= gle + glr \\ CME &= \frac{SCE}{gle} \\ CMR &= \frac{SCR}{glr} \\ F_{exp} &= \frac{CME}{CMR} \end{aligned}$$

con $\overline{y}_{m.}$ la media muestral de la variable respuesta en el grupo $m = 1, \ldots, r$ e $\overline{y}_{..}$ la media muestral global de la variable respuesta sin tener en cuenta los grupos. Conviene observar que $SCT = SCE + SCR$, como se puede comprobar fácilmente. Asociado al estadístico de contraste F_{exp} estaría el p-valor bilateral $= P(|F| \geq |F_{exp}|) = P(F \leq -|F_{exp}|) + P(F \geq |F_{exp}|) = 0 + P(F \geq F_{exp}) = P(F \geq F_{exp})$ con F un modelo de distribución F de Snedecor con gln y gld los grados de libertad del numerador y del denominador, respectivamente.

	gl	SC	CM	F	p-valor
Explicada	gle	SCE	CME	F_{exp}	asociado a F_{exp}
Residual	glr	SCR	CMR		
Total	glt	SCT			

Tabla 3.4: Tabla ANOVA con datos genéricos del esquema $C \leftarrow N$

Por último, como recomendaciones prácticas, conviene explicitar que las asunciones de normalidad y homocedasticidad en el ANOVA de un factor se contrastan con el test de Shapiro-Wilk y el test de Levene, respectivamente.

En el caso de que no se pueda asumir igualdad de varianzas pero sí normalidad se pueden utilizar las aproximaciones equivalentes de Satherwaite y de Welch publicadas en 1941 y 1947, respectivamente.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa nominal en una variable respuesta continua. Han participado en el estudio 22 individuos. Los datos experimentales se dan en la tabla 3.5. ¿Influye la variable explicativa en la variable respuesta?

rta	*exp*
15	1
15	1
25	1
25	1
25	1
33	1
43	1
15	2
16	2
16	2
25	2
28	2
28	2
28	2
28	2
35	2
43	2
13	3
15	3
25	3
25	3
35	3

Tabla 3.5: Datos observados del esquema $C \leftarrow N$

SOLUCIÓN:

En primer lugar, se realiza una estadística descriptiva numérica básica de los datos con la sintaxis siguiente

```
1 rm(list=ls())
2
3 datos=read.table('c_n_1.txt',header=T)
4 attach(datos)
```

```
5
6  ind1=which(exp==1);
7  ind2=which(exp==2);
8  ind3=which(exp==3);
9  n1=length(rta[ind1]); n1
10 n2=length(rta[ind2]); n2
11 n3=length(rta[ind3]); n3
12 tapply(rta,exp,mean); tapply(rta,exp,sd)
```

que proporciona los estadísticos:

$$n_1 = 7;\ n_2 = 10;\ n_3 = 5$$
$$\overline{y}_1 = 25.8571; \overline{y}_2 = 26.2000; \overline{y}_3 = 22.6000$$
$$\widehat{s}_1 = 9.8561; \widehat{s}_2 = 8.8669; \widehat{s}_3 = 8.8769$$

En segundo lugar, se contrasta la normalidad de la variable respuesta en cada grupo y la homocedasticidad entre grupos con la sintaxis siguiente

```
1 shapiro.test(rta[ind1]); shapiro.test(rta[ind2]); shapiro.test(
     rta[ind3])
2
3 library(lawstat)
4 levene.test(rta,exp,location="mean")
```

que proporciona, en cuanto a la normalidad, para el grupo 1 un p-valor=0.3300, para el grupo 2 un p-valor=0.2268 y para el grupo 3 un p-valor=0.5347, por lo que se asume normalidad de la respuesta en cada grupo, y en cuanto a la homocedasticidad, un p-valor=0.9891 por lo que se asume homocedasticidad.

Por último, dado que se cumplen las condiciones de aplicabilidad del ANOVA de un factor, se calcula el estadístico de contraste y su p-valor asociado con la sintaxis

```
1 summary(aov(rta~factor(exp)))
```

que proporciona la tabla 3.6.

	gl	SC	CM	F	p-valor
Explicada	2	46.7065	23.3532	0.2763	0.7616
Residual	19	1605.6571	84.5083		
Total	21	1652.3636			

Tabla 3.6: Tabla ANOVA con datos observados del esquema $C \leftarrow N$

El cálculo de los valores de la tabla 3.6 es el siguiente:

$$\begin{aligned}
SCE &= \sum_{m=1}^{r} n_m(\overline{y}_{m.} - \overline{y}_{..})^2 \\
&= 7(25.8571 - 25.2727)^2 + 10(26.200 - 25.2727)^2 + 5(22.6 - 25.2727)^2 \\
&= 46.7065 \\
SCR &= \sum_{m=1}^{r}\sum_{i=1}^{n_m}(y_{mi} - \overline{y}_{m.})^2 = 1605.6571 \\
SCT &= \sum_{m=1}^{r}\sum_{i=1}^{n_m}(y_{mi} - \overline{y}_{..})^2 = 1652.3636 \\
gle &= r - 1 = 2 \\
glr &= n - r = 22 - 3 = 19 \\
glt &= n - 1 = 21 = gle + glr \\
CME &= \frac{SCE}{gle} = 23.3532 \\
CMR &= \frac{SCR}{glr} = 84.5083 \\
F_{exp} &= \frac{CME}{CMR} = 0.2763
\end{aligned}$$

con un p-valor igual a `1-pf(0.2763,2,19)`$= 0.7616 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de medias con lo que la variable explicativa no influye en la respuesta (no hay diferencias estadísticamente significativas entre $\overline{y}_1 = 25.8571$, $\overline{y}_2 = 26.2000$ y $\overline{y}_3 = 22.6000$). Es importante notar que la F es intrínsecamente bilateral (por eso no se multiplica por 2 en la expresión del p-valor asociado). Para ver esto, se puede analizar el ejemplo anterior de la t de Student mediante un ANOVA de un factor. En dicho ejemplo, se obtiene $t_{exp} = -0.0750$ con p-valor $= 0.9412$ calculado con la sintaxis `2*(1-pt(abs(-0.0750,15)` y $F_{exp} = 0.0056$ con p-valor $= 0.9412$ calculado con la sintaxis `1-pf(abs(0.0056,6,9)`. Esta equivalencia se da porque teóricamente se verifica que $F_{exp} = t^2_{exp}$, que en este caso se ejemplifica con $0.0056 = (-0.0750)^2$.

También sería válida la sintaxis `oneway.test(rta ~ exp, var.equal = TRUE)`. En el caso de que no se pudiera asumir homocedasticidad, la sintaxis para la aproximación de Satherwaite-Welch sería: `oneway.test(rta ~ exp, var.equal = FALSE)`.

Conviene observar que no sería válida la sintaxis `summary(aov(rta~exp))`.

Mini-capítulo 4

Respuesta nominal

En este mini-capítulo se contemplan el test χ^2 de homogeneidad y el test de Freeman-Halton que están enmarcados en el esquema $N \leftarrow N$ que indica que se está intentando explicar la variable respuesta Y nominal a través de la variable explicativa X nominal.

4.1. χ^2 de homogeneidad

El test χ^2 de homogeneidad está enmarcado en el esquema $N \leftarrow N$. La situación de $N \leftarrow N$ se da, por ejemplo, cuando se quiere estudiar si distintos tipos de efectos adversos están influidos por distintos tipos de dieta. Para ello se realiza un estudio en n individuos a los que se les asigna, por ejemplo, la dieta 1 (codificada con 1 en la variable dieta) a n_1 individuos, la dieta 2 (codificada con 2) a n_2 individuos, la dieta 3 (codificada con 3) a n_3 individuos, con $n = n_1+n_2+n_3$ y se observa qué tipo de efecto adverso presentan (codificado por ejemplo con 1 si dolor de cabeza, 2 calambres musculares, 3 náuseas y 4 cansancio). En esta situación los datos experimentales tendrán el patrón dado en la tabla 4.1, donde el número de individuos con perfil $Y = 1$ y $X = 1$ es n_{11}, con perfil $Y = 1$ y $X = 2$ es n_{12}, con perfil $Y = 1$ y $X = 3$ es n_{13}, con perfil $Y = 2$ y $X = 1$ es n_{21}, con perfil $Y = 2$ y $X = 2$ es n_{22}, con perfil $Y = 2$ y $X = 3$ es n_{23}, con perfil $Y = 3$ y $X = 1$ es n_{31}, con perfil $Y = 3$ y $X = 2$ es n_{32}, con perfil $Y = 3$ y $X = 3$ es n_{33}, con perfil $Y = 4$ y $X = 1$ es n_{41}, con perfil $Y = 4$ y $X = 2$ es n_{42} y con perfil $Y = 4$ y $X = 3$ es n_{43}.

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : \text{No hay diferencia entre los grupos}$$
$$H_1 : \text{Sí hay diferencia entre los grupos}$$

A partir de los datos experimentales se construye la tabla de datos cruzados genérica dada en la tabla 4.2, donde r_i es la suma por filas y c_j es la suma por columnas.

La expresión, publicada en 1900, para el cálculo del estadístico de contraste χ^2 de K. Pearson, que sigue una $\chi^2_{(r-1)(c-1)}$ donde $(r-1)(c-1)$ son los grados de libertad, toma el

valor experimental para la muestra en estudio dado por

$$\chi^2_{exp} = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

siendo e_{ij} las frecuencias esperadas bajo H_0 dadas por

$$e_{ij} = \frac{r_i}{n}\frac{c_j}{n}n = \frac{r_i c_j}{n}.$$

Por último, como recomendación práctica, conviene explicitar las asunciones del test χ^2 de homogeneidad que son que todos los valores de las frecuencias esperadas e_{ij} sean mayores que 5, que intuitivamente corresponde a tamaños muestrales grandes. Así mismo, hay que señalar que numéricamente el test χ^2 de homogeneidad también se usa en el marco de asociación entre dos variables nominales donde ninguna de ellas hace el papel de variable explicativa, en ese caso se le denomina χ^2 de independencia.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa nominal en una variable respuesta nominal. Han participado en el estudio 100 individuos. Los datos experimentales corresponden al esquema dado en la tabla 4.1 y se muestran ya tabulados en la tabla 4.3. ¿Influye la variable explicativa en la variable respuesta?

   SOLUCIÓN:

   En primer lugar, se muestra la tabla 4.4 con los datos esperados. A partir de esta tabla se calcula

   $$\chi^2_{exp} = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(n_{ij} - e_{ij})^2}{e_{ij}} = 23.8325$$

   con un p-valor asociado de `1-pchisq(23.8325,6)`$= 0.0006 < 0.05$, por lo que sí hay evidencia suficiente para rechazar H_0 con lo que se concluye que la variable explicativa sí influye en la respuesta (hay diferencias estadísticamente significativas entre los valores observados y los esperados bajo homogeneidad de no diferencia entre grupos). Es importante notar que la χ^2 es intrínsecamente bilateral (por eso no se multiplica por 2 en la expresión del p-valor asociado). Para ver esto, se puede analizar el ejemplo de la z de diferencia de dos proporciones. En dicho ejemplo, se obtiene $z_{exp} = -2.0841$ con p-valor $= 0.0371$ calculado con la sintaxis `2*(1-pnorm(abs(-2.0841)` y $\chi^2_{exp} = 4.3435$ con p-valor $= 0.0371$ calculado con la sintaxis `1-pchisq(4.3435,1)`. Esta equivalencia se da porque teóricamente se verifica que $\chi^2_{exp} = z^2_{exp}$, si hay un grado de libertad, que en este caso se ejemplifica con $4.3435 = (-2.0841)^2$.

   En segundo lugar, se muestra la sintaxis en R para el cálculo de la χ^2. Si se supone que los datos sin agrupar están en el fichero n_n_1.txt la sintaxis es

```
rm(list=ls())

datos=read.table('n_n_1.txt',header=T)
attach(datos)

tabla=table(rta,exp); tabla
chisq.test(tabla)$expected

chisq.test(tabla)
```

y si se supone que se introducen los datos agrupados directamente la sintaxis es

```
rm(list=ls())

tabla <- matrix(c(3,10,14,10,10,14,6,10,3,14,3,3),ncol=3,byrow=
   TRUE)
colnames(tabla) <- c("exp=1","exp=2","exp=3")
rownames(tabla) <- c("rta=1","rta=2","rta=3","rta=4")
tabla <- as.table(tabla); tabla
chisq.test(tabla)$expected
```

4.2. Freeman-Halton

El test de Freeman-Halton, publicado por Freeman y Halton en 1951, es una generalización del test exacto de Fisher. Más adelante, Mehta y Patel propusieron un algoritmo, publicado en 1983, para agilizar el cálculo del test de Freeman-Halton. Este algoritmo de Mehta-Patel es el que está implementado en la función `fisher.test` de `R`.

Y	X
1	1
...	...
1	1
1	2
...	...
1	2
1	3
...	...
1	3
2	1
...	...
2	1
2	2
...	...
2	2
2	3
...	...
2	3
3	1
...	...
3	1
3	2
...	...
3	2
3	3
...	...
3	3
4	1
...	...
4	1
4	2
...	...
4	2
4	3
...	...
4	3

Tabla 4.1: Datos genéricos del esquema $N \leftarrow N$

	$X=1$	$X=2$	$X=3$	
$Y=1$	n_{11}	n_{12}	n_{13}	r_1
$Y=2$	n_{21}	n_{22}	n_{23}	r_2
$Y=3$	n_{31}	n_{32}	n_{33}	r_3
$Y=4$	n_{41}	n_{42}	n_{43}	r_4
	c_1	c_2	c_3	n

Tabla 4.2: Tabla con datos genéricos del esquema $N \leftarrow N$

	$X=1$	$X=2$	$X=3$	
$Y=1$	3	10	14	27
$Y=2$	10	10	14	34
$Y=3$	6	10	3	19
$Y=4$	14	3	3	20
	33	33	34	100

Tabla 4.3: Tabla con datos observados del esquema $N \leftarrow N$

	$X=1$	$X=2$	$X=3$	
$Y=1$	8.91	8.91	9.18	27
$Y=2$	11.22	11.22	11.56	34
$Y=3$	6.27	6.27	6.46	19
$Y=4$	6.6	6.6	6.8	20
	33	33	34	100

Tabla 4.4: Tabla con datos esperados del esquema $N \leftarrow N$

Mini-capítulo 5

Respuesta ordinal

En este mini-capítulo se contemplan el test U de Mann-Whitney, el test W de Wilcoxon y el test H de Kruskal–Wallis. El test U de Mann-Whitney y el test W de Wilcoxon están enmarcados en el esquema $O \leftarrow D$ que indica que se está intentando explicar la variable respuesta Y ordinal a través de la variable explicativa X dicotómica. Sin embargo, el test H de Kruskal-Wallis está enmarcado en el esquema $O \leftarrow N$ que indica que se está intentando explicar la variable respuesta Y ordinal a través de la variable explicativa X nominal.

5.1. U de Mann-Whitney

El test U de Mann-Whitney está enmarcado en el esquema $O \leftarrow D$, aunque también se puede usar en el esquema $C \leftarrow D$ donde no se cumpla la asunción de que la variable Y continua sea normal en cada categoría de la variable dicotómica X. La situación de $O \leftarrow D$ se da, por ejemplo, cuando se quiere estudiar si la variable grado de mejoría (codificada por ejemplo con 1 si algo, 2 bastante, 3 casi total y 4 total) está influida por el hecho de recibir un tipo de tratamiento u otro. Para ello se realiza un estudio en n individuos a los que se les asigna el tratamiento 1 (codificado con 1 en la variable tratamiento) a n_1 individuos y el tratamiento 2 (codificado con 2) a n_2 individuos con $n = n_1 + n_2$ y se observa qué valor ordinal tienen en la variable grado de mejoría. En esta situación los datos experimentales tendrán el aspecto dado en la tabla 5.1, donde el número de individuos con $X = 1$ es n_1 y con $X = 2$ es n_2.

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : F_1 = F_2$$
$$H_1 : F_1 \neq F_2$$

siendo F_1 y F_2 las funciones de distribución de la variable respuesta para el grupo 1 y el grupo 2, respectivamente. Es importante observar que el test U de Mann-Whitney (o su equivalente W de Wilcoxon) no compara, en principio, medianas, sino la distribución

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2

Tabla 5.1: Datos genéricos del esquema $O \leftarrow D$

en general de una variable continua u ordinal entre dos grupos de interés. Sólo en el caso de que dicha distribución difiera entre grupos en únicamente un parámetro de localización (coincidiendo, por tanto, en todo lo demás: varianza, asimetría, etc.), se podrá usar el test U de Mann-Whitney para comparar medianas. Más formalmente, sería $H_0 : F_1(x) = F_2(x)$ y $H_1 : F_1(x + \Delta) = F_2(x)$, donde Δ es un parámetro de localización.

La expresión para el cálculo de la U de Mann-Whitney, publicada por Mann y Whitney en 1947, viene dada por $U_{Y_1Y_2}$ o por $U_{Y_2Y_1}$ donde

$$U_{Y_1Y_2} = \#\{Y_{1i_1} < Y_{2i_2}\}$$

$$U_{Y_2Y_1} = \#\{Y_{2i_2} < Y_{1i_1}\},$$

siendo Y_{1i_1} la variable respuesta para el individuo i_1 del grupo 1, con $i_1 = 1, \dots, n_1$, e Y_{2i_2} la variable respuesta para el individuo i_2 del grupo 2, con $i_2 = 1, \dots, n_2$, y donde la notación $\#\{\ \}$ representa el número de pares que verifican la condición entre llaves, teniendo en cuenta que cualquier par con $Y_{1i_1} = Y_{2i_2}$ suma $\frac{1}{2}$ en el cálculo de $U_{Y_1Y_2}$ o de $U_{Y_2Y_1}$. Es fácil ver que $U_{Y_1Y_2} + U_{Y_2Y_1} = n_1n_2$.

Para llevar a cabo el contraste requerido se construye el estadístico de contraste

$$Z = \frac{U_{Y_1Y_2} - E[U_{Y_1Y_2}]}{EE[U_{Y_1Y_2}]}$$

o el estadístico

$$Z = \frac{U_{Y_2Y_1} - E[U_{Y_2Y_1}]}{EE[U_{Y_2Y_1}]}$$

que se demuestra que bajo H_0 siguen ambos una $N(0, 1)$. Para la muestra en estudio, dichos estadísticos de contraste toman el valor experimental

$$z_{exp} = \frac{u_{Y_1Y_2} - \widehat{E}[U_{Y_1Y_2}]}{\widehat{EE}[U_{Y_1Y_2}]}$$

o el valor

$$z_{exp} = \frac{u_{Y_2Y_1} - \widehat{E}[U_{Y_2Y_1}]}{\widehat{EE}[U_{Y_2Y_1}]},$$

siendo

$$\widehat{E}[U_{Y_1Y_2}] = \widehat{E}[U_{Y_2Y_1}] = \frac{1}{2}n_1n_2$$

$$\widehat{EE}[U_{Y_1Y_2}] = \widehat{EE}[U_{Y_2Y_1}] = \sqrt{\frac{1}{12}\frac{n_1n_2}{n(n-1)}\Big(n^3 - n - \sum_{j=1}^{k}(d_j^3 - d_j)\Big)},$$

con d_j el número de empates en $j = 1, \ldots, k$, siendo k el número de valores distintos que se produce para cada valor de la variable respuesta sin distinguir grupos. Es importante notar que la expresión anterior es válida asintóticamente, es decir, para tamaño muestral grande. No obstante, el test U de Mann-Whitney está tabulado para tamaño muestral pequeño.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta ordinal. Han participado en el estudio 17 individuos. Los datos experimentales se dan en la tabla 5.2. ¿Influye la variable explicativa en la variable respuesta?

rta	*exp*
1	1
1	1
3	1
3	1
3	1
5	1
7	1
1	2
2	2
2	2
3	2
4	2
4	2
4	2
4	2
6	2
7	2

Tabla 5.2: Datos observados del esquema $O \leftarrow D$

SOLUCIÓN:

En primer lugar se realiza una estadística descriptiva numérica y gráfica básica de los datos con la sintaxis siguiente

```
rm(list=ls())

datos=read.table('o_d_1.txt',header=T)
attach(datos)

ind1=which(exp==1)
ind2=which(exp==2)
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2

tapply(rta,exp,median); tapply(rta,exp,IQR)

boxplot(rta[ind1],rta[ind2],names=c("1","2"),col=(c("white","
   gray")),
xlab="Grupo 1 (white), Grupo 2 (gray)", ylab="Rta")
```

que proporciona los estadísticos:

$$\begin{aligned} n_1 = 7 \quad ; \quad & n_2 = 10 \\ \text{mediana de } y_1 = 3 \quad ; \quad & \text{mediana de } y_2 = 4 \\ \text{rango intercuartílico de } y_1 = 2.0000 \quad ; \quad & \text{rango intercuartílico de } y_2 = 1.7500 \end{aligned}$$

y el gráfico Box-Plot dado en la figura 5.1.

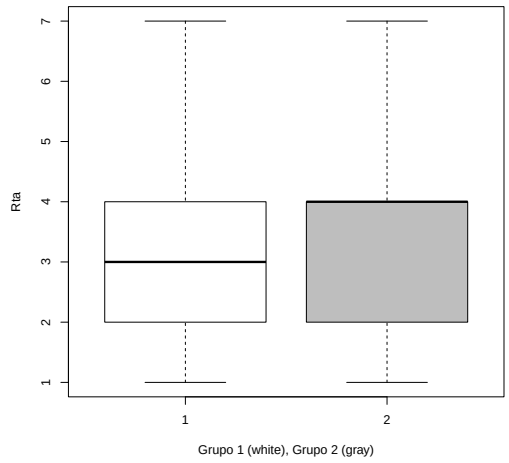


Figura 5.1: Box-Plot para los datos observados del esquema $O \leftarrow D$

A continuación se muestran los cálculos detallados del test U de Mann-Whitney:

$$\begin{aligned} u_{Y_1Y_2} &= \Big(\frac{1}{2}+9\Big)+\Big(\frac{1}{2}+9\Big)+\Big(\frac{1}{2}+6\Big)+\Big(\frac{1}{2}+6\Big) \\ &\quad +\Big(\frac{1}{2}+6\Big)+(2)+\Big(\frac{1}{2}\Big)=41 \\ u_{Y_2Y_1} &= \Big(\frac{1}{2}+\frac{1}{2}+5\Big)+(5)+(5)+\Big(\frac{3}{2}+2\Big)+(2)+(2) \\ &\quad +(2)+(2)+(1)+\Big(\frac{1}{2}\Big)=29 \end{aligned}$$

$$\begin{aligned} u_{Y_1Y_2}+u_{Y_2Y_1} &= 70=n_1n_2 \\ \widehat{E}[U_{Y_1Y_2}] &= \widehat{E}[U_{Y_2Y_1}]=\frac{1}{2}n_1n_2=\frac{1}{2}\cdot 70=35 \\ \sum_{j=1}^{k}(d_j^3-d_j) &= (3^3-3)+(2^3-2)+(4^3-4)+(4^3-4)+(2^3-2)=156 \end{aligned}$$

$$\begin{aligned} \widehat{EE}[U_{Y_1Y_2}] &= \widehat{EE}[U_{Y_2Y_1}]=\sqrt{\frac{1}{12}\frac{n_1n_2}{n(n-1)}\Big(n^3-n-\sum_{j=1}^{k}(d_j^3-d_j)\Big)} \\ &= \sqrt{\frac{1}{12}\frac{70}{17\cdot 16}\Big(17^3-17-156\Big)}=\sqrt{101.6544}=10.0824 \\ z_{exp} &= \frac{u_{Y_2Y_1}-\widehat{E}[U_{Y_2Y_1}]}{\widehat{EE}[U_{Y_2Y_1}]}=\frac{29-35}{10.0824}=-0.5951 \end{aligned}$$

Dichos cálculos se realizan con la sintaxis

```
1 wilcox.test(rta[ind1],rta[ind2],correct=FALSE)
```

que proporciona $u_{Y_2Y_1}=29$ y un p-valor asociado igual a `2*(1-pnorm(abs(-0.5951)))`$=0.5518>0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de funciones de distribución con lo que la variable explicativa no influye en la respuesta.

5.2. W de Wilcoxon

El test W de Wilcoxon está enmarcado en el esquema $O \leftarrow D$, al igual que el test U de Mann-Whitney, por lo que los datos experimentales tendrán el aspecto anterior dado en la tabla 5.1. Conviene remarcar que ambos tests son además equivalentes.

Como en el test U de Mann-Whitney, la pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : F_1 = F_2$$
$$H_1 : F_1 \neq F_2$$

siendo F_1 y F_2 las funciones de distribución de la variable respuesta para el grupo 1 y el grupo 2, respectivamente.

La expresión para el cálculo del test W de Wilcoxon, publicada en 1945, viene dada por W_1 o por W_2 con

$$W_1 = \sum_{grupo_1} Rangos$$

$$W_2 = \sum_{grupo_2} Rangos,$$

donde los rangos se calculan en relación a la muestra conjunta y en el caso de empates como promedios de los órdenes de las observaciones empatadas. Es fácil ver que $W_1 + W_2 = \frac{1}{2}n(n+1)$.

Para llevar a cabo el contraste requerido se construye el estadístico de contraste

$$Z = \frac{W_1 - E[W_1]}{EE[W_1]}$$

o el estadístico

$$Z = \frac{W_2 - E[W_2]}{EE[W_2]}$$

que se demuestra que bajo H_0 siguen ambos una $N(0,1)$. Para la muestra en estudio, dichos estadísticos de contraste toman el valor experimental

$$z_{exp} = \frac{w_1 - \widehat{E}[W_1]}{\widehat{EE}[W_1]}$$

o el valor

$$z_{exp} = \frac{w_2 - \widehat{E}[W_2]}{\widehat{EE}[W_2]},$$

siendo

$$\widehat{E}[W_1] = \frac{1}{2}n_1(n+1)$$

$$\widehat{E}[W_2] = \frac{1}{2}n_2(n+1)$$

$$\widehat{EE}[W_1] = \widehat{EE}[W_2] = \sqrt{\frac{1}{12}\frac{n_1 n_2}{n(n-1)}\Big(n^3 - n - \sum_{j=1}^{k}(d_j^3 - d_j)\Big)},$$

con d_j el número de empates en $j = 1, \ldots, k$, siendo k el número de valores distintos que se produce para cada valor de la variable respuesta sin distinguir grupos. Es importante notar que la expresión anterior es válida asintóticamente, es decir, para tamaño muestral grande. No obstante, el test W de Wilcoxon está tabulado para tamaño muestral pequeño.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa dicotómica en una variable respuesta ordinal. Han participado en el estudio 17 individuos. Los datos experimentales son los mismos que se utilizaron en el test U de Mann-Whitney y se dan en la tabla 5.2. ¿Influye la variable explicativa en la variable respuesta?

   SOLUCIÓN:

   La estadística descriptiva numérica y gráfica básica de los datos es la que se mostró en el test U de Mann-Whitney. Los cálculos detallados del test W de Wilcoxon se basan en rangos por lo que como paso previo se asigna a cada observación un rango según el orden que ocupe dicha observación en el cómputo total de datos, asignando el rango medio en caso de empates, según se muestra en la tabla 5.3.

rta	exp	$rango(rta)$
1	1	$\frac{1+2+3}{3} = 2$
1	1	$\frac{1+2+3}{3} = 2$
3	1	$\frac{6+7+8+9}{4} = 7.5$
3	1	$\frac{6+7+8+9}{4} = 7.5$
3	1	$\frac{6+7+8+9}{4} = 7.5$
5	1	14
7	1	$\frac{16+17}{2} = 16.5$
1	2	$\frac{1+2+3}{3} = 2$
2	2	$\frac{4+5}{2} = 4.5$
2	2	$\frac{4+5}{2} = 4.5$
3	2	$\frac{6+7+8+9}{4} = 7.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
4	2	$\frac{10+11+12+13}{4} = 11.5$
6	2	15
7	2	$\frac{16+17}{2} = 16.5$

Tabla 5.3: Rangos para los datos observados del esquema $O \leftarrow D$

A partir de estos rangos, se calculan los valores siguientes:

$$\begin{aligned} w_1 &= \sum_{grupo_1} rangos = 2+2+7.5+7.5+7.5+14+16.5 = 57 \\ w_2 &= \sum_{grupo_2} rangos = 2+4.5+4.5+7.5+11.5+11.5+11.5+11.5+16.5 \\ &= 96 \end{aligned}$$

$$\begin{aligned} w_1 + w_2 &= 153 = \frac{1}{2}n(n+1) \\ \widehat{E}[W_1] &= \frac{1}{2}n_1(n+1) = \frac{1}{2}\cdot 7 \cdot 18 = 63 \\ \widehat{E}[W_2] &= \frac{1}{2}n_2(n+1) = \frac{1}{2}\cdot 10 \cdot 18 = 90 \\ \sum_{j=1}^{k}(d_j^3 - d_j) &= (3^3-3)+(2^3-2)+(4^3-4)+(4^3-4)+(2^3-2) = 156 \end{aligned}$$

$$\begin{aligned} \widehat{EE}[W_1] &= \widehat{EE}[W_2] = \sqrt{\frac{1}{12}\frac{n_1 n_2}{n(n-1)}\Big(n^3 - n - \sum_{j=1}^{k}(d_j^3 - d_j)\Big)} \\ &= \sqrt{\frac{1}{12}\frac{70}{17\cdot 16}\Big(17^3 - 17 - 156\Big)} = \sqrt{101.6544} = 10.0824 \\ z_{exp} &= \frac{w_1 - \widehat{E}[W_1]}{\widehat{EE}[W_1]} = \frac{57-63}{10.0824} = -0.5951 \end{aligned}$$

Dichos cálculos se realizan con la sintaxis

```
1 wilcox.test(rta[ind1],rta[ind2],correct=FALSE)
```

que no proporciona el test de Wilcoxon, sino su equivalente de U de Mann-Whitney, con un p-valor igual a `2*(1-pnorm(abs(-0.5951)))`$= 0.5518 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de funciones de distribución con lo que la variable explicativa no influye en la respuesta.

5.3. H de Kruskal-Wallis

El test H de Kruskal-Wallis está enmarcado en el esquema $O \leftarrow N$, aunque también se puede usar en el esquema $C \leftarrow N$ donde no se cumpla la asunción de que la variable Y sea normal en cada categoría de la variable dicotómica X. La situación de $O \leftarrow N$ se da, por ejemplo, cuando se quiere estudiar si la variable grado de pérdida de peso (codificada por ejemplo con 1 si se ha perdido entre 0-5 kilos, 2 si 5-10, 3 si 10-15 y 4 si > 15) está influida por el hecho de recibir un tipo u otro de dieta. Para ello se realiza un estudio en n individuos

a los que se les asigna la dieta 1 (codificada con 1 en la variable dieta) a n_1 individuos, la dieta 2 (codificada con 2) a n_2 individuos o la dieta 3 (codificada con 3) a n_3 individuos con $n = n_1 + n_2 + n_3$ y se observa qué valor ordinal tienen en la variable grado de pérdida de peso. En esta situación, los datos experimentales tendrán el aspecto dado en la tabla 5.4, donde el número de individuos con $X = 1$ es n_1, con $X = 2$ es n_2 y con $X = 3$ es n_3.

Y	X
y_{11}	1
$\dots$	$\dots$
y_{1n_1}	1
y_{21}	2
$\dots$	$\dots$
y_{2n_2}	2
y_{31}	3
$\dots$	$\dots$
y_{3n_3}	3

Tabla 5.4: Datos genéricos del esquema $O \leftarrow N$

La pregunta de si X influye en Y se traduce en realizar el contraste de hipótesis

$$H_0 : F_1 = F_2 = F_3$$
$$H_1 : \text{Alguna } F_i \text{ distinta}$$

siendo F_1, F_2 y F_3 las funciones de distribución de la variable respuesta para el grupo 1, el grupo 2 y el grupo 3, respectivamente.

La expresión, publicada en 1952, para el cálculo del estadístico de contraste H de Kruskal-Wallis, que sigue una χ^2_{r-1} donde $r-1$ son los grados de libertad, toma el valor experimental para la muestra en estudio dado por

$$h_{exp} = \frac{\frac{12}{n(n+1)} \sum_{m=1}^{r} \frac{1}{n_m} \left(r_m - \widehat{E}[R_m] \right)^2}{1 - \frac{\sum_{j=1}^{k} (d_j^3 - d_j)}{n^3 - n}}$$

siendo

$$r_m = \sum_{grupo_m} rangos, \quad \widehat{E}[R_m] = \frac{n_m(n+1)}{2}$$

con $m = 1, \dots, r$ indicando el grupo y d_j el número de empates en $j = 1, \dots, k$ siendo k el número de valores distintos que se produce para cada valor de la variable respuesta sin distinguir grupos. Es importante notar que la expresión anterior es válida asintóticamente, es decir, para tamaño muestral grande. No obstante, el test H de Kruskal-Wallis está tabulado para tamaño muestral pequeño.

Se puede comprobar que el test H de Kruskal-Wallis para dos grupos es equivalente al test U de Mann-Whitney y al test W de Wilcoxon. Además, conviene remarcar que el test H de Kruskal-Wallis para r grupos, al igual que el test U de Mann-Whitney y el test W de Wilcoxon, no compara medianas.

Ejemplo

1. Se ha realizado un estudio para ver si influye una variable explicativa nominal en una variable respuesta ordinal. Han participado en el estudio 22 individuos. Los datos experimentales se dan en la tabla 5.5. ¿Influye la variable explicativa en la variable respuesta?

rta	exp
2	1
2	1
4	1
4	1
4	1
6	1
8	1
2	2
3	2
3	2
4	2
5	2
5	2
5	2
5	2
7	2
8	2
1	3
2	3
4	3
4	3
7	3

Tabla 5.5: Datos observados del esquema $O \leftarrow N$

SOLUCIÓN:

En primer lugar se realiza una estadística descriptiva numérica y gráfica básica de los datos con la sintaxis siguiente

```
rm(list=ls())

datos=read.table('o_n_1.txt',header=T)
attach(datos)

ind1=which(exp==1);
ind2=which(exp==2);
ind3=which(exp==3);
n1=length(rta[ind1]); n1
n2=length(rta[ind2]); n2
n3=length(rta[ind3]); n3
tapply(rta,exp,median); tapply(rta,exp,IQR)

boxplot(rta[ind1],rta[ind2],rta[ind3],names=c("1","2","3"),
col=(c("white","gray80","gray50")),
xlab="Grupo 1 (white), Grupo 2 (gray80), Grupo 3 (gray50)", ylab
   ="Rta")
```

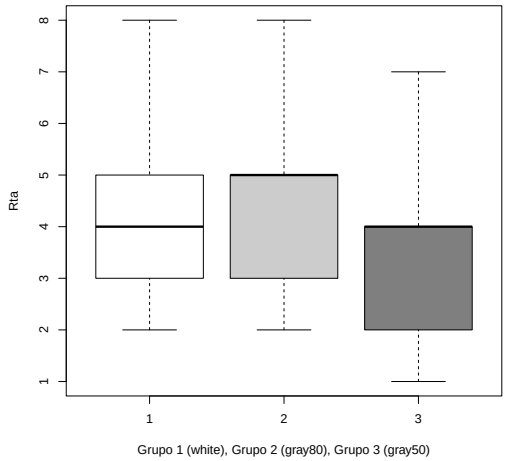


Figura 5.2: Box-Plot para los datos observados del esquema $O \leftarrow N$

que proporciona los estadísticos:

$$n_1 = 7 \quad ; \quad n_2 = 10 \; ; \; n_3 = 5$$
$$\text{mediana } (y)_1 = 4 \quad ; \quad \text{mediana } (y)_2 = 5 \; ; \; \text{mediana } (y)_3 = 4$$
$$\text{rango inter. } (y)_1 = 2.0000 \quad ; \quad \text{rango inter. } (y)_2 = 1.7500 \; ; \; \text{rango inter. } (y)_3 = 2.0000$$

y el gráfico Box-Plot dado en la figura 5.2.

Los cálculos detallados del test H de Kruskal-Wallis se basan en rangos por lo que como paso previo se asigna a cada observación un rango según el orden que ocupe dicha observación en el cómputo total de datos, asignando el rango medio en caso de empates, según se muestra en la tabla 5.6.

rta	exp	$rango(rta)$
2	1	$\frac{2+3+4+5}{4} = 3.5$
2	1	$\frac{2+3+4+5}{4} = 3.5$
4	1	$\frac{8+9+10+11+12+13}{6} = 10.5$
4	1	$\frac{8+9+10+11+12+13}{6} = 10.5$
4	1	$\frac{8+9+10+11+12+13}{6} = 10.5$
6	1	18
8	1	$\frac{21+22}{2} = 21.5$
2	2	$\frac{2+3+4+5}{4} = 3.5$
3	2	$\frac{6+7}{2} = 6.5$
3	2	$\frac{6+7}{2} = 6.5$
4	2	$\frac{8+9+10+11+12+13}{6} = 10.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
5	2	$\frac{14+15+16+17}{4} = 15.5$
7	2	$\frac{19+20}{2} = 19.5$
8	2	$\frac{21+22}{2} = 21.5$
1	3	1
2	3	$\frac{2+3+4+5}{4} = 3.5$
4	3	$\frac{8+9+10+11+12+13}{6} = 10.5$
4	3	$\frac{8+9+10+11+12+13}{6} = 10.5$
7	3	$\frac{19+20}{2} = 19.5$

Tabla 5.6: Rangos para los datos observados del esquema $O \leftarrow N$

A partir de estos rangos, se calculan los valores siguientes:

$$
\begin{aligned}
r_1 &= \sum_{grupo_1} rangos = 78 \\
r_2 &= \sum_{grupo_2} rangos = 130 \\
r_3 &= \sum_{grupo_3} rangos = 45 \\
\widehat{E}[R_1] &= \frac{1}{2} n_1(n+1) = \frac{1}{2} \cdot 7 \cdot 23 = 80.50 \\
\widehat{E}[R_2] &= \frac{1}{2} n_2(n+1) = \frac{1}{2} \cdot 10 \cdot 23 = 115.00 \\
\widehat{E}[R_3] &= \frac{1}{2} n_3(n+1) = \frac{1}{2} \cdot 5 \cdot 23 = 57.00 \\
\sum_{j=1}^{k} (d_j^3 - d_j) &= (4^3 - 4) + (2^3 - 2) + (6^3 - 6) + (4^3 - 4) \\
&+ (2^3 - 2) + (2^3 - 2) = 348 \\
h_{exp} &= \frac{\frac{12}{22 \cdot 23}\left(\frac{1}{7}(78 - 80.50)^2 + \frac{1}{10}(130 - 115.00)^2 + \frac{1}{5}(45 - 57.50)^2\right)}{1 - \frac{348}{22^3 - 22}} \\
&= 1.3398
\end{aligned}
$$

Dichos cálculos se realizan con la sintaxis

```
1 kruskal.test(rta~exp)
```

que proporciona, $h_{exp} = 1.3398$ con $gl = r - 1 = 3 - 1 = 2$ y un p-valor asociado igual a `1-pchisq(1.3398,2)`$= 0.5118 > 0.05$, por lo que no hay evidencia suficiente para rechazar la igualdad de funciones de distribución con lo que la variable explicativa no influye en la respuesta.

Autoevaluación

Conceptos básicos de inferencia estadística

Nivel 1

1. Si una variable dicotómica Y se codifica con 0 y 1, entonces tiene sentido calcular la media muestral y además coincide con la proporción muestral.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Correcto. Efectivamente, $\sum_{i=1}^{n} y_i = \underbrace{1+\ldots+1}_{r_1} + \underbrace{0+\ldots+0}_{r_0} = r_1$, por lo que la proporción muestral es $\frac{r_1}{n}$ que es la media muestral $\frac{1}{n}\sum_{i=1}^{n} y_i$.

   b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

2. Si una variable dicotómica Y se codifica con 0 y 1, entonces se puede considerar que $P(Y = 1)$ es un estadístico muestral.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

   b) Correcto. $P(Y = 1)$ es una constante desconocida que se pretende estimar, por lo que se trata de un parámetro poblacional.

3. Para una misma muestra, un $IC95\,\%$ de una proporción poblacional será siempre más ancho que un $IC99\,\%$.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

b) Correcto. El valor tabulado de $z_{1-\alpha/2}$ es mayor para $\alpha = 0.01$ que para $\alpha = 0.05$, por lo que el $IC99\,\%$ será más ancho que el $IC95\,\%$.

4. Con un tamaño muestral muy elevado, un $IC95\,\%$ siempre cubrirá al verdadero parámetro proporción poblacional.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

b) Correcto. Un tamaño muestral muy elevado está relacionado con un IC muy preciso (muy estrecho) pero siempre estará la "maldición" de la confianza.

5. En un CH, al ser $\alpha = P(H_1|H_0)$ y $\beta = P(H_0|H_1)$, se tiene que $\alpha + \beta = 1$.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

b) Correcto. En general, $\alpha+\beta$ no suman uno. Lo que sí se cumple es que $P(H_1|H_0)+P(H_0|H_0) = 1$ y que $P(H_0|H_1) + P(H_1|H_1) = 1$.

6. En un CH sobre una proporción poblacional, basado en el test z, la suma de los p-valores unilaterales es 1.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Correcto. En los CH unilaterales $P(Z < z_{exp}) + P(Z > z_{exp}) = 1$.

b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

Nivel 2

1. Si una variable dicotómica Y se codifica con 0 y 1, entonces en una muestra $\sum_{i=1}^{n}(y_i - \overline{y})^2$ es igual a:

   a) 0.

   b) $\sqrt{\widehat{\pi}(1-\widehat{\pi})}$.

   c) $\sqrt{\pi(1-\pi)}$.

   d) $\frac{r_0 r_1}{n}$, con r_1 el número de 1 y r_0 el número de 0 en la muestra.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

   b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

   c) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

   d) Correcto. Efectivamente,

   $$\sum_{i=1}^{n}(y_i - \overline{y})^2 = \left(1 - \frac{r_1}{n}\right)^2 r_1 + \left(0 - \frac{r_1}{n}\right)^2 r_0 = \frac{r_0^2}{n^2} r_1 + \frac{r_1^2}{n^2} r_0 = r_0 r_1 \left(\frac{r_0}{n^2} + \frac{r_1}{n^2}\right) = \frac{r_0 r_1}{n}.$$

2. Si una variable dicotómica Y se codifica con 0 y 1, entonces $V[Y]$ es:

   a) $E[Y^2]$.

   b) $E^2[Y]$.

   c) $E[Y](1 - E[Y])$.

   d) $0 + 1 = 1$.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

c) Correcto. Efectivamente, al ser, en este caso $E[Y^2] = E[Y]$, se tiene que

$$V[Y] = E[Y^2] - E^2[Y] = E[Y] - E^2[Y] = E[Y](1 - E[Y]).$$

d) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

3. Se sabe que el $IC95\,\%$ de una proporción poblacional es $(0.21, 0.47)$, entonces:

a) No es posible saber cuál es la proporción muestral porque no se sabe el tamaño muestral.

b) La proporción muestral es 0.34.

c) La proporción poblacional es 0.34.

d) El número de individuos que presentan la categoría de interés es 34.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

b) Correcto. Efectivamente, la proporción muestral es el punto medio del IC.

c) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

d) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

4. Se sabe que el $IC95\,\%$ de una proporción poblacional es $(0.21, 0.47)$, entonces:

a) El tamaño muestral será aproximadamente de 50.

b) No es posible saber cuál es el tamaño muestral.

c) El tamaño muestral estará entre 21 y 47.

d) El tamaño muestral es 95.

SOLUCIÓN:

a) Correcto. Efectivamente, se sabe que $\widehat{EE}[\widehat{\Pi}] = (0.47 - 0.34)/1.96 = 0.0663$, por lo que el tamaño muestral aproximado será $n = .34 * (1 - .34)/(0.0663^2)$, aproximadamente $n = 50$.

b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

c) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

d) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

5. En un CH,

$$H_0 : \pi \geq \pi_t$$
$$H_1 : \pi < \pi_t$$

se obtiene que el p-valor es 0.7000, entonces el p-valor correspondiente al CH bilateral sería:

a) 1.4000.

b) 0.3000.

c) 0.6000.

d) 0.3500.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

c) Correcto. Efectivamente, el otro p-valor unilateral es 0.3000 y por tanto el p-valor bilateral es el doble del menor de los p-valor unilaterales.

d) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

6. El CH

$$H_0 : \pi = 0.40$$
$$H_1 : \pi \neq 0.40$$

con $n = 50$ y $r_1 = 17$, proporciona un estadístico de contraste de $z = -0.8660$. Si se repitiese el estudio pero con $n = 500$ y se obtuviese $r_1 = 170$, entonces el estadístico de contraste sería:

a) -2.7386.

b) -8.660.

c) 2.7386.

d) 8.660.

SOLUCIÓN:

a) Correcto. Efectivamente, $z = (0.34 - 0.40)/0.0219089 = -2.7386$.

b) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

c) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

d) Incorrecto. Conviene repasar el mini-capítulo de conceptos básicos de inferencia estadística.

Respuesta dicotómica

Nivel 1

1. El parámetro diferencia de dos proporciones poblacionales, se suele denotar por $\widehat{\Theta} = \widehat{\Pi}_1 - \widehat{\Pi}_2$.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

   b) Correcto. El parámetro diferencia de dos proporciones poblacionales, se suele denotar por $\theta = \pi_1 - \pi_2$. La notación $\widehat{\Theta} = \widehat{\Pi}_1 - \widehat{\Pi}_2$ hace referencia a la v.a. diferencia de dos proporciones muestrales.

2. En general, $V[\widehat{\Pi}_1 - \widehat{\Pi}_2] = V[\widehat{\Pi}_1] - V[\widehat{\Pi}_2] - 2Cov(\widehat{\Pi}_1, \widehat{\Pi}_2)$.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Correcto. Efectivamente, en general, $V[\widehat{\Pi}_1 - \widehat{\Pi}_2] = V[\widehat{\Pi}_1] + V[\widehat{\Pi}_2] - 2Cov(\widehat{\Pi}_1, \widehat{\Pi}_2)$.

3. En el CH de diferencia de dos proporciones poblacionales dado por

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 \neq 0$$

si se obtiene que el estadístico de contraste es $z = -2.0000$ se concluye H_1 con un nivel de significación del 0.05

a) Verdadero

b) Falso

SOLUCIÓN:

a) Correcto. Efectivamente, al ser $|-2.0000| > 1.96$ se concluye H_1 con un nivel de significación del 0.05 .

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

4. El esquema del test exacto de Fisher es $O \leftarrow O$.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Correcto. Efectivamente, el esquema del test exacto de Fisher es $D \leftarrow D$.

5. El test exacto de Fisher supone que todas las frecuencias observadas de la tabla de contingencia son mayores o iguales a 5.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Correcto. Efectivamente, el test exacto de Fisher no tiene restricciones en cuanto a las frecuencias observadas de la tabla de contingencia.

6. El test exacto de Fisher tiene versión unilateral y bilateral.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Correcto. Efectivamente, el test exacto de Fisher tiene versión unilateral y bilateral, que se calculan directamente a partir de la tabla de contingencia observada y no a partir de un estadístico de contraste.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

Nivel 2

1. Se desea realizar el contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 \neq 0$$

   a partir de los datos muestrales $a_1 = 14$, $n_1 = 50$, $a_2 = 14$ y $n_2 = 50$. En este caso el p-valor es:

   a) 0.

   b) 0.05.

   c) 0.5.

   d) 1.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

   c) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

   d) Correcto. Efectivamente, desde un punto de vista intuitivo, al ser las proporciones muestrales iguales, se tiene que el p-valor bilateral es 1. De forma numérica $z = 0$, por lo que el p-valor bilateral es 1.

2. Se desea realizar el contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 \neq 0$$

a partir de los datos muestrales $a_1 = 20$, $n_1 = 50$, $a_2 = 25$ y $n_2 = 100$. Para ello un paso previo es estimar π_c bajo H_0 que para estos datos resulta ser:

a) 0.4.

b) 0.25.

c) 0.325.

d) 0.3.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

d) Correcto. Efectivamente, $\widehat{\pi}_c = \frac{20+25}{50+100} = \frac{45}{150} = 0.3$.

3. Se desea realizar el contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 \neq 0$$

a partir de los datos muestrales $a_1 = 20$, $n_1 = 50$, $a_2 = 25$ y $n_2 = 100$. Para ello un paso previo es estimar $EE[\widehat{\Pi}_1 - \widehat{\Pi}_2]$ bajo H_0 que para estos datos resulta ser:

a) 0.0817.

b) 0.0794.

c) 0.0811.

d) 0.0374.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Correcto. Efectivamente, $\widehat{EE}_0[\widehat{\Pi}_1 - \widehat{\Pi}_2] = \sqrt{\frac{45}{150}\frac{105}{150}(\frac{1}{50} + \frac{1}{100})} = 0.0794$.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

4. Se desea realizar el contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 \neq 0$$

a partir de los datos muestrales $a_1 = 1$, $n_1 = 6$, $a_2 = 1$ y $n_2 = 6$. En este caso el p-valor es:

a) 0.5454.

b) 0.2273.

c) 0.7727.

d) 1.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

d) Correcto. Efectivamente, desde un punto de vista intuitivo, al ser las proporciones muestrales iguales, se tiene que el p-valor bilateral es 1. De forma numérica el p-valor bilateral es $0.2273 + 0.5454 + 0.2273$.

5. Se desea realizar el contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 < 0$$

a partir de los datos muestrales $a_1 = 1$, $n_1 = 6$, $a_2 = 1$ y $n_2 = 6$. En este caso el p-valor es:

a) 0.5454.

b) 0.2273.

c) 0.7727.

d) 1.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

c) Correcto. Efectivamente, el p-valor unilateral por la izquierda es $0.2273 + 0.5454$.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

6. Se desea realizar el contraste de hipótesis

$$H_0 : \pi_1 - \pi_2 = 0$$
$$H_1 : \pi_1 - \pi_2 > 0$$

a partir de los datos muestrales $a_1 = 1$, $n_1 = 6$, $a_2 = 1$ y $n_2 = 6$. En este caso el p-valor es:

a) 0.5454.

b) 0.2273.

c) 0.7727.

d) 1.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

c) Correcto. Efectivamente, el p-valor unilateral por la derecha es $0.5454 + 0.2273$.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta dicotómica.

Respuesta continua

Nivel 1

1. Sea Y v.a. con media $E[Y] = \mu$ y varianza $V[Y] = \sigma^2$, entonces el error estándar de Y está dado por $EE[Y] = \frac{\sigma}{\sqrt{n}}$.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

b) Correcto. El error estándar hace siempre referencia a un estadístico, por ejemplo, la media muestral. En ese caso $EE[\overline{Y}] = \frac{\sigma}{\sqrt{n}}$. Otra cosa es la desviación estándar de una v.a., que se define como la raíz cuadrada de su varianza, es decir, $D[Y] = \sqrt{V[Y]} = \sigma$.

2. En el esquema $C \leftarrow D$, unos datos experimentales proporcionan $\overline{y}_1 = 25.8571$ e $\overline{y}_2 = 26.2000$, entonces se puede tomar la decisión de que $\mu_1 < \mu_2$.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   b) Correcto. No basta la estadística descriptiva para tomar decisiones.

3. En el esquema $C \leftarrow D$, donde además $Y_1 \sim N(\mu_1, \sigma_1)$ e $Y_2 \sim N(\mu_2, \sigma_2)$ siempre tiene sentido estimar la varianza conjunta con

$$\widehat{s}_c^2 = \frac{(n_1 - 1)\widehat{s}_1^2 + (n_2 - 1)\widehat{s}_2^2}{(n_1 - 1) + (n_2 - 1)},$$

   con n_1 y n_2 los tamaños muestrales en cada grupo y $\widehat{s}_1^2$ y $\widehat{s}_1^2$ las cuasivarianzas muestrales en cada grupo.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   b) Correcto. Hace falta la asunción de homocedasticidad.

4. El ANOVA de un factor se utiliza para comparar varianzas.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   b) Correcto. Efectivamente, el ANOVA de un factor no compara varianzas, compara medias.

5. Las asunciones para utilizar el ANOVA de un factor y la t de Student son las mismas.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Correcto. Efectivamente, las asunciones para ambas técnicas son las mimas: normalidad y homocedasticidad. Además ambas técnicas tienen versiones equivalentes en el caso de heterocedasticidad.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

6. En un ANOVA de un factor para comparar r medias, los grados de libertad para la variable explicativa son $r - 1$.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Correcto. Al estar comparando r medias se sabe que la variable explicativa tiene r categorías y por lo tanto los grados de libertad son $r - 1$.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

Nivel 2

1. Intuitivamente el test t de Student de diferencia de dos medias:

   a) Es invariante a traslaciones, pero no a cambio de unidades.

   b) No es invariante a traslaciones, pero sí a cambio de unidades.

   c) No es invariante a traslaciones ni a cambio de unidades.

   d) Es invariante a traslaciones y a cambio de unidades.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   c) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   d) Correcto.

2. En el esquema $C \leftarrow D$, el error estándar de la diferencia de medias muestrales es:

   a) $\sqrt{\frac{\sigma_1^2}{n_1} - \frac{\sigma_2^2}{n_2}}$.

   b) $\sqrt{\sigma_1^2 - \sigma_2^2}$.

   c) $\sqrt{\mu_1^2 - \mu_2^2}$.

   d) $\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   c) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   d) Correcto.

3. En el esquema $C \leftarrow D$, donde además $Y_1 \sim N(\mu_1, \sigma_1)$ e $Y_2 \sim N(\mu_2, \sigma_2)$, unos datos experimentales proporcionan $\overline{y}_1 = 25.8571$ e $\overline{y}_2 = 25.8571$, entonces:

   a) Sólo si se verificara la asunción de homocedasticidad se aceptaría $\mu_1 = \mu_2$.

   b) Sólo si se verificara la asunción de heterocedasticidad se aceptaría $\mu_1 = \mu_2$.

   c) Siempre se acepta $\mu_1 = \mu_2$.

   d) Faltan datos para tomar una decisión sobre las medias poblacionales.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

   c) Correcto.

   d) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

4. Si un ANOVA de un factor se utiliza para comparar dos medias, entonces:

   a) Con toda seguridad se obtiene un error en el programa estadístico.

   b) Se obtiene una conclusión distinta a la que se hubiera llegado al utilizar una t de Student.

   c) Se obtiene la misma conclusión a la que se hubiera llegado al utilizar una t de Student.

   d) Siempre se acepta H_0.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

c) Correcto.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

5. Si no se cumple la asunción de normalidad del ANOVA de un factor, entonces es conveniente:

a) Cambiar de unidades la variable respuesta.

b) Hacer una traslación de los datos.

c) Utilizar una técnica no paramétrica.

d) Estandarizar los datos.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

c) Correcto.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

6. La asunción de homocedasticidad en un ANOVA de un factor siempre se puede comprobar con el test:

a) F de Snedecor.

b) Levene.

c) Shapiro-Wilk.

d) t de Student.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

b) Correcto.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta continua.

Respuesta nominal

Nivel 1

1. El test χ^2 de homogeneidad también se puede aplicar al esquema $D \leftarrow D$.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Correcto. Efectivamente, una variable dicotómica es un caso particular de una variable nominal.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

2. En el esquema $N \leftarrow N$, si se obtienen en la tabla experimental todos los valores $n_{ij} = e_{ij}$ se concluirá H_1.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   b) Correcto. Si $n_{ij} = e_{ij}$ se tiene que $\chi^2 = 0$ con lo que el p-valor asociado es de 1 y al ser $1 > 0.05$ no hay evidencia suficiente para rechazar H_0 con lo que no se puede concluir H_1.

3. El valor numérico del test χ^2 de homogeneidad y el test χ^2 de independencia es el mismo.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Correcto. La expresión para ambos test es la misma. La única diferencia es que en el de homogeneidad hay una variable que es explicativa y otra que es respuesta.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

4. Se verifica que para un grado de libertad $\chi^2_{1-0.05/2} = 1.96^2$.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Correcto. En general se puede demostrar que para un grado de libertad $\chi^2 = z^2$.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

5. El test χ^2 de homogeneidad requiere asunciones similares al test z de diferencia de dos proporciones.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Correcto. Intuitivamente las asunciones corresponden a tamaños muestrales grandes.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

6. En el esquema $N \leftarrow N$, si se obtuvieran los datos experimentales de la tabla 5.7 no se cumplirían las asunciones para utilizar el test χ^2 de homogeneidad.

	$X=1$	$X=2$	$X=3$	
$tipo_enfermedad = 1$	20	0	0	20
$tipo_enfermedad = 2$	0	20	0	20
$tipo_enfermedad = 3$	0	0	20	20
	20	20	20	60

Tabla 5.7: Tabla con datos observados del esquema N "Tipo de enfermedad" $\leftarrow N$

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

b) Correcto. Dado que $e_{ij} = \dfrac{20 \cdot 20}{60} = 6.6667 > 5$, $\forall i, j = 1, 2, 3$, sí se cumplen las asunciones del test χ^2 de homogeneidad.

Nivel 2

1. En el esquema $D \leftarrow D$, si se usan el test χ^2 de homogeneidad y el test z de diferencia de dos proporciones, ocurre que:

   a) En el caso de tamaños muestrales grandes las conclusiones entre ambos test pueden diferir.

   b) En el caso de tamaños muestrales pequeños las conclusiones entre ambos test pueden diferir.

   c) Siempre darán las mismas conclusiones.

   d) Siempre se cumplirán las asunciones de ambos test.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   c) Correcto. En general se puede demostrar que para un grado de libertad $\chi^2 = z^2$, por lo que siempre darán las mismas conclusiones.

   d) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

2. En el esquema $N \leftarrow N$ con una tabla experimental 4x5, se tiene que los grados de libertad del test χ^2 de homogeneidad son:

   a) 9.

   b) 20.

   c) 12.

   d) 7.

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   c) Correcto. Efectivamente, los grados de libertad para una tabla experimental 4x5 son $(4-1)\cdot(5-1) = 12$.

   d) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

3. En el esquema $N \leftarrow N$ con una tabla experimental 4x5, en la que todos los $n_{ij} = 6$, se tiene que el test χ^2 de homogeneidad:

a) Afirma que no hay evidencia para rechazar H_0.

b) Afirma que hay evidencia para rechazar H_0.

c) No es aplicable porque no se cumplen las asunciones necesarias.

d) No tiene suficientes grados de libertad.

SOLUCIÓN:

a) Correcto. Para estos datos experimentales todos los $e_{ij} = \dfrac{(5 \cdot 6) \cdot (4 \cdot 6)}{20 \cdot 6} = 6 = n_{ij}$, por lo que $\chi^2 = 0$ con un p-valor asociado de 1 y al ser $1 > 0.05$ no hay evidencia suficiente para rechazar H_0.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

4. El test χ^2 de homogeneidad es:

a) Intrínsecamente bilateral.

b) Intrínsecamente unilateral.

c) Causal.

d) Paramétrico.

SOLUCIÓN:

a) Correcto.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

5. En el esquema $N \leftarrow N$ con una tabla experimental 3x3, en la que $n_{ij} = 30$, si $i = j$ y $n_{ij} = 0$ en caso contrario, se tiene que:

a) $e_{ij} = n_{ij}$, $\forall i, j = 1, 2, 3$.

b) $e_{ij} \neq n_{ij}$, $\forall i, j = 1, 2, 3$.

c) $e_{ij} = 30$, $\forall i, j = 1, 2, 3$.

d) $\sum_{i,j=1,2,3} e_{ij} = 30$.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

b) Correcto. Para estos datos experimentales todos los $e_{ij} = \dfrac{30 \cdot 30}{90} = 10$.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

6. En el esquema $N \leftarrow N$ con una tabla experimental 2x2, en la que todos los $n_{ij} = 10$, se tiene que

   a) $e_{ij} = 10$, $\forall i, j = 1, 2$.

   b) $\sum_{i,j=1,2} e_{ij} = 10$.

   c) $e_{ij} = 20$, $\forall i, j = 1, 2$.

   d) $\sum_{i,j=1,2} e_{ij} = 20$.

   SOLUCIÓN:

   a) Correcto. Para estos datos experimentales todos los $e_{ij} = \dfrac{20 \cdot 20}{40} = 10$.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   c) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

   d) Incorrecto. Conviene repasar el mini-capítulo de respuesta nominal.

Respuesta ordinal

Nivel 1

1. El test U de Mann-Whitney compara dos medianas.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

   b) Correcto. El test U de Mann-Whitney no compara dos medianas, compara dos distribuciones.

2. En el esquema $C \leftarrow N$, si no se cumplen las condiciones de aplicabilidad del ANOVA de un factor se puede utilizar el test U de Mann-Whitney.

   a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Correcto. El test U de Mann-Whitney se utiliza en el esquema $O \leftarrow D$ o $C \leftarrow D$ si no se cumplen las condiciones de aplicabilidad de la t de Student.

3. En el test W de Wilcoxon los rangos se calculan por separado en relación a cada muestra.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Correcto. Los rangos se calculan en relación a la muestra conjunta.

4. En el test W de Wilcoxon a la hora de calcular los rangos hay que sumar 0.5 por cada empate que se produzca en la variable respuesta.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Correcto. En el caso de empates, los rangos se calculan como promedios de los órdenes de las observaciones empatadas.

5. El test H de Kruskal-Wallis no se puede aplicar al esquema $O \leftarrow D$.

a) Verdadero

b) Falso

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Correcto. Aunque el test H de Kruskal-Wallis se corresponde con el esquema $O \leftarrow N$, también se podrá aplicar cuando las variables nominales tengan sólo dos categorías.

6. El test H de Kruskal-Wallis no contempla la posibilidad de empates en la variable respuesta.

   a) Verdadero

   b) Falso

   SOLUCIÓN:

   a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

   b) Correcto.

Nivel 2

1. En el esquema $O \leftarrow D$, si se obtuvieran los datos experimentales de la tabla 5.8 entonces:

grado_ansiedad	*exp*
4	1
4	1
5	2
5	2
5	2
5	2

Tabla 5.8: Datos observados del esquema O "Grado de ansiedad" $\leftarrow D$

   a) $U_{Y_1Y_2} = 8$ y $U_{Y_2Y_1} = 0$.

   b) $U_{Y_1Y_2} = 0$ y $U_{Y_2Y_1} = 8$.

   c) $U_{Y_1Y_2} = 8$ y $U_{Y_2Y_1} = 8$.

   d) $U_{Y_1Y_2} = 4$ y $U_{Y_2Y_1} = 4$.

   SOLUCIÓN:

   a) Correcto. Efectivamente, $U_{Y_1Y_2} = 4 + 4 = 8$ y $U_{Y_2Y_1} = 0 + 0 + 0 + 0 = 0$.

   b) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

   c) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

   d) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

2. En el esquema $O \leftarrow D$, si se obtuvieran los datos experimentales de la tabla 5.9 entonces:

grado_mejoria	*exp*
1	1
4	1
1	2
5	2
5	2
5	2

Tabla 5.9: Datos observados del esquema O "Grado de mejoría" $\leftarrow D$

a) $d_1 = 0$ y $d_2 = 0$.

b) $d_1 = 2$ y $d_2 = 4$.

c) $d_1 = 2$, $d_2 = 1$ y $d_3 = 3$.

d) $d_1 = 1$, $d_2 = 2$ y $d_3 = 3$.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

c) Correcto. Al haber tres valores distintos en la variable respuesta (1, 4 y 5) se tiene que hay tres valores d_1, d_2 y d_3. Dado que el primer valor 1 se repite dos veces, $d_1 = 2$. Análogamente, $d_2 = 1$ (puesto que el segundo valor 4 sólo aparece una vez) y $d_3 = 3$ (puesto que el tercer valor 5 se repite 3 veces).

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

3. En el esquema $O \leftarrow D$, si se obtuvieran los datos experimentales de la tabla 5.10 entonces:

grado_severidad	*exp*
7	1
7	1
8	2
8	2
8	2
8	2

Tabla 5.10: Datos observados del esquema O "Grado de severidad" $\leftarrow D$

a) $W_1 = 15$ y $W_2 = 38$.

b) $W_1 = 14$ y $W_2 = 32$.

c) $W_1 = 3$ y $W_2 = 18$.

d) $W_1 = 8$ y $W_2 = 0$.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

c) Correcto. Efectivamente, $W_1 = 1.5 + 1.5 = 3$ y $W_2 = 4.5 + 4.5 + 4.5 + 4.5 = 18$.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

4. En el esquema $O \leftarrow D$, si se obtuvieran los datos experimentales de la tabla 5.11 entonces:

$grado_satisfaccion$	exp
40	1
40	1
50	2
50	2
50	2
50	2

Tabla 5.11: Datos observados del esquema O "Grado de satisfacción" $\leftarrow D$

a) $\widehat{E}[W_1] = 40$ y $\widehat{E}[W_2] = 50$.

b) $\widehat{E}[W_1] = 6$ y $\widehat{E}[W_2] = 6$.

c) $\widehat{E}[W_1] = 6$ y $\widehat{E}[W_2] = 12$.

d) $\widehat{E}[W_1] = 7$ y $\widehat{E}[W_2] = 14$.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

d) Correcto. Efectivamente, $\widehat{E}[W_1] = \frac{1}{2} \cdot 2 \cdot 7 = 7$ y $\widehat{E}[W_2] = \frac{1}{2} \cdot 4 \cdot 7 = 14$.

5. En el esquema $O \leftarrow N$, si se obtuvieran los datos experimentales de la tabla 5.12 entonces:

$grado_satisfaccion$	exp
4	1
4	1
5	2
5	3
5	3
5	3

Tabla 5.12: Datos observados del esquema O "Grado de dependencia" $\leftarrow D$

a) $R_1 = 4$ y $R_2 = 5$.

b) $R_1 = 3$ y $R_2 = 18$.

c) $R_1 = 3$, $R_2 = 4.5$ y $R_3 = 13.5$.

d) $R_1 = 2$, $R_2 = 1$ y $R_3 = 3$.

SOLUCIÓN:

a) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

c) Correcto. Efectivamente, $R_1 = 1.5+1.5 = 3$, $R_2 = 4.5$ y $R_3 = 4.5+4.5+4.5 = 13.5$.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

6. En el esquema $O \leftarrow N$, si se obtuvieran los datos experimentales de la tabla 5.13 entonces:

$grado_satisfaccion$	exp
7	1
7	1
8	2
8	3
8	3
8	3

Tabla 5.13: Datos observados del esquema O "Grado de autonomía" $\leftarrow D$

a) $d_1 = 2$ y $d_2 = 4$.

b) $d_1 = 7$ y $d_2 = 8$.

c) $d_1 = 2$, $d_2 = 1$ y $d_3 = 3$.

d) $d_1 = 7$, $d_2 = 3.5$ y $d_3 = 10.5$.

SOLUCIÓN:

a) Correcto. Al haber dos valores distintos en la variable respuesta (7 y 8) se tiene que hay dos valores d_1 y d_2. Dado que el primer valor 7 se repite dos veces, $d_1 = 2$. y, puesto que el segundo valor 8 aparece cuatro veces, $d_2 = 4$.

b) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

c) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

d) Incorrecto. Conviene repasar el mini-capítulo de respuesta ordinal.

Referencias

D. Peña. *Fundamentos de Estadística*. Alianza editorial, Madrid, 2014.

E. Ramos, R. Vélez, and V. Hernández. *Modelos probabilísticos y optimización*. Sanz y Torres, Madrid, 2019.

R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2017. URL `https://www.R-project.org/`.

T.M. Davies. *The Book of R: A First course in programming and statistics*. No Starch Press, 2016.

A. García-Pérez. *Estadística básica con R*. Universidad Nacional de Educación a Distancia (UNED), Madrid, 2010.

Glosario

Chi-cuadrado: La distribución o modelo chi-cuadrado de parámetro n es una v.a. continua Y que se define como $Y = Z_1^2 + \ldots + Z_n^2$, donde las Z_i son variables aleatorias normales independientes de media cero y varianza uno. Se puede demostrar que si una v.a. Y sigue una chi-cuadrado de parámetro n, y que se denota por $Y \sim \chi_n^2$, se verifica que $E[Y] = n$ y $V[Y] = 2n$. Un caso especial es la χ_1^2 que corresponde al cuadrado de una $N(0,1)$ y que se puede escribir pedagógicamente como que $N(0,1) \cdot N(0,1) = \chi_1^2$. Conviene mencionar que, sin embargo, $\frac{N(0,1))}{N(0,1)}$ es Cauchy.

Desviación estándar y error estándar: Si se tiene una v.a Y, con media $E[Y]$ y varianza $V[Y]$ y se calcula $\sqrt{V[Y]}$ se está calculando la desviación típica o desviación estándar de la v.a. Y. Si se tiene el estadístico $\overline{Y}$, con media $E[\overline{Y}]$ y varianza $V[\overline{Y}]$ y se calcula $\sqrt{V[\overline{Y}]}$ se está calculando el error estándar del estadístico $\overline{Y}$. Es decir, siempre que se habla de error estándar se refiere a un estadístico muestral, por lo que en su expresión de alguna forma intervendrá el tamaño muestral.

Distribución: El término distribución es sinónimo de modelo, así si se dice que una variable aleatoria sigue una distribución Bernoulli, se quiere decir que su modelo es Bernoulli. Se usa la palabra distribución en referencia a que el concepto función de distribución es común tanto para las variables aleatorias discretas como continuas.

Esperanza matemática: La esperanza matemática de una variable aleatoria Y se define, siempre que se conozca el modelo o distribución de Y, y se denota por $E[Y]$. Para variables aleatorias discretas, siempre y cuando $\sum_{y_i} abs(y_i)p(y_i) < \infty$, se define $E[Y] = \sum_{y_i} y_i p(y_i)$. Para variables aleatorias continuas, siempre y cuando $\int_{-\infty}^{+\infty} abs(y)f(y)dy < \infty$, se define $E[Y] = \int_{-\infty}^{+\infty} yf(y)dy$. En muchos libros de texto no se especifican las condiciones de covergencia, pero son necesarias. Por ejemplo el modelo o distribución de Cauchy no la verifica y esa es la razón teórica por la que el modelo de Cauchy no tiene definida su esperanza matemática. Este aspecto se puede comprobar simulando la distribución de Cauchy y viendo el comportamiento errático de su media muestral.

Estadístico y estimador: Un estadístico es cualquier función de la muestra. Por ejemplo $\overline{Y}$ es un estadístico porque su expresión $\frac{1}{n}\sum_{i=1}^{n} Y_i$ depende de la muestra. Otro estadístico podría ser $\frac{1}{n}\sum_{i=1}^{n} \sqrt{Y_i}$. Hay estadísticos que tienen más utilidad que otros.

Los estadísticos más útiles son aquellos que sirven para estimar parámetros. Dichos estadísticos reciben el nombre de estimadores. Así el estadístico media muestral es un estimador del parámetro media poblacional. En ese proceso de pasar de muestras a poblaciones es importante conocer la esperanza, la varianza y la distribución (modelo) de los estadísticos. Por ejemplo, en el caso del estadístico media muestral se tiene lo siguiente. Si Y_i son variables aleatorias idénticamente distribuidas con $E[Y_i] = \mu$, se tiene que $E[\overline{Y}] = E[\frac{1}{n}(Y_1 + \ldots + Y_n)] = \frac{1}{n}(E[Y_1 + \ldots + Y_n])$ donde se ha usado que una constante sale de la esperanza tal cual. Y, utilizando que siempre la esperanza de una suma es la suma de las esperanzas, $E[\overline{Y}] = \frac{1}{n}(E[Y_1] + \ldots + E[Y_n]) = \frac{1}{n}n\mu = \mu$. Si Y_i son variables aleatorias independientes idénticamente distribuidas (v.a.i.i.d) con $V[Y_i] = \sigma^2$, se tiene que $V[\overline{Y}] = V[\frac{1}{n}(Y_1 + \ldots + Y_n)] = \frac{1}{n^2}(V[Y_1 + \ldots + Y_n])$ donde se ha usado que una constante sale de la varianza al cuadrado. Y ahora, dado que independencia implica incorrrelación que equivale a covarianza nula, se puede afirmar, en este caso, que la varianza de la suma es la suma de las varianzas, por lo que $V[\overline{Y}] = \frac{1}{n^2}(V[Y_1] + \ldots + V[Y_n]) = \frac{1}{n^2}n\sigma^2 = \frac{\sigma^2}{n}$. Por útlimo, si Y_i son variables aleatorias independientes idénticamente distribuidas (v.a.i.i.d) con $E[Y_i] = \mu$ y $V[Y_i] = \sigma^2$ finitas, se tiene por el teorema central del límite, que la distribución (modelo) de $\overline{Y}$ es Normal, para n suficientemente grande.

Función de distribución: La función de distribución F está definida para variables aleatorias Y de cualquier tipo, de forma que $F(y) = P(Y \leq y)$. Para variables aleatorias discretas, $F(y) = \sum_{y_i \leq y} p(y_i)$ donde $p(y) = P(Y = y)$ es la función de masa o función de probabilidad de Y. Para variables aleatorias continuas, $F(y) = \int_{-\infty}^{y} f(t)dt$ donde $f(y)$ es la función de densidad o función de densidad de probabilidad de Y (sin embargo, hay que tener en cuenta que $f(y)$ no es una probabilidad, por lo que pedagógicamente conviene utilizar el término función de densidad).

Media poblacional: La media poblacional μ de una variable aleatoria Y es un parámetro constante desconocido que indica el centro de la variable. Si no se conoce el modelo de Y no se puede saber más de ella, si se conoce el modelo de Y se puede determinar teóricamente a partir de la esperanza matemática $E[Y]$, pero sigue siendo un parámetro constante desconocido.

Método de Montecarlo: a veces no se sabe calcular algo desde el punto de vista teórico y se simula mediante generación de v.a. (de forma "algo poética" se dice por el Método de Montecarlo (haciendo referencia al azar existente en los casinos)). Un ejemplo sería calcular la $P(0.4 < Y < 39.6)$, para $Y \sim N(\mu = 20, \sigma = 10)$, mediante el método de montecarlo que en el caso concreto de R, se materializaría con:

- n <- 100000

- Y <- rnorm (n, mean=20, sd = 10)
- sum((Y > 0.4) & (Y < 39.6)) / n

.

Normal: La distribución o modelo Normal de parámetros μ y σ es una v.a. continua Y cuya función de densidad viene dada por $f(y) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(y-\mu)^2}$. Su función de distribución $F(y) = \int_{-\infty}^{y} f(t)dt$ no tiene una expresión cerrada por lo que hay que calcularla numéricamente como hacen los programas estadísticos. Se puede demostrar que si una v.a. Y sigue una Normal de parámetros μ y σ, y que se denota por $Y \sim N(\mu, \sigma)$, se verifica que $E[Y] = \mu$ y $V[Y] = \sigma^2$. Un caso especial es la $N(0, 1)$ con media cero y varianza 1. Se puede demostrar que si $Y \sim N(\mu, \sigma)$, entonces su estandarización, dada por $\frac{Y-\mu}{\sigma}$, sigue una $N(0, 1)$.

Teorema central del límite: Existen varias formulaciones de este teorema. Una de la más sencilla es la siguiente. Si Y_i son variables aleatorias independientes idénticamente distribuidas (v.a.i.i.d) con media y varianza finita, entonces $\overline{Y}$ sigue una distribución Normal para n suficientemente grande. Los parámetros de dicha normal son muy fáciles de calcular a través de las propiedades teóricas de la esperanza y de la varianza. Este teorema no se puede aplicar a la Cauchy ya que ésta no tiene esperanza matemática definida. Sin embargo, es posible determinar la distribución de la media muestral de Cauchy, que sorprendentemente sigue siendo Cauchy.

Variables explicativas: También llamadas independientes, son las variables candidatas a servir de explicación de las variables respuesta.

Variables respuesta: También llamadas dependientes, resultado u objetivo, son las variables que se pretende explicar o analizar.

Varianza de una variable aleatoria: La varianza de una v.a. $V[Y]$ se define como $V[Y] = E[(Y-E[Y])^2]$. A partir de esta expresión se demuestra que $V[Y] = E[Y^2]-E^2[Y]$ donde la notación $E^2[Y]$ indica el cuadrado de la esperanza, con el siguiente razonamiento: $V[Y] = E[(Y - E[Y])^2] = E[Y^2 - 2YE[Y] + E^2[Y]] = E[Y^2] - 2E[YE[Y]] + E^2[Y]] = E[Y^2]-2E[Y]E[Y]+E^2[Y] = E[Y^2]-E^2[Y]$ y que se lee así: la varianza es la esperanza del cuadrado menos el cuadrado de la esperanza. Otras propiedades de la varianza son:

- $V[kY] = k^2V[Y]$, ya que $V[kY] = E[k^2Y^2] - E^2[kY] = k^2E[Y^2] - (kE[Y])^2 = k^2E[Y^2] - k^2E^2[Y] = k^2(E[Y^2] - E^2[Y]) = k^2V[Y]$.
- $V[k] = 0$, ya que $V[k] = E[k^2] - E^2[k] = k^2 - k^2 = 0$. Este resultado es intuitivo, ya que la varianza es una medida de la variabilidad, y que más constante que una constante que no varía.

- $V[k+Y] = V[Y]$, ya que $V[k+Y] = E[(k+Y) - E[k+Y])^2] = E[(k+Y - k - E[Y])^2] = E[(Y - E[Y])^2 = V[Y]$ y que se interpreta como que la varianza es invariante a traslaciones

.

Acerca de

Emilio Letón



Figura 5.3: Emilio Letón

Emilio Letón nace en Madrid en 1966. Es Licenciado en Matemáticas por la UCM en 1989 y doctor en Matemáticas en la misma universidad en 2002. En la actualidad es Profesor Titular de Universidad de la UNED en el departamento de Inteligencia Artificial, al que se incorporó en 2009. Anteriormente fue profesor del departamento de Estadística de la UC3M durante 5 años. Asimismo, ha trabajado durante 15 años en departamentos de Planificación y Estadística dentro del sector bancario y de la industria farmacéutica. Sus lineas de investigación incluyen el Análisis de Supervivencia, tests no paramétricos, PLS, Meta-Análisis, Bioestadística, B-Learning e IA. Es coautor de 16 artículos reflejados en su ORCID (https://orcid.org/0000-0001-6908-9590). Ha participado en 34 proyectos de innovación docente en los últimos 15 años (siendo coordinador en 12 de ellos) colaborando con distintas universidades: UNED, UC3M, UCM y UPM. Realiza su transferencia desde el grupo miniXmodular (www.minixmodular.ia.uned.es) del que es coordinador desde su creación en 2016, desde el Canal Fundación ONCE en el que colabora desde su creación en 2016 y desde la Cátedra UNESCO de Educación a Distancia (CUED) a la que se incorporó en 2022 como miembro del consejo académico. Ha recibido 1 premio en excelencia en publicaciones científicas (UC3M), 5 premios en excelencia docente (1 en UC3M, 3 en UNED y 1 en OCW Consortium) y 1 premio de transferencia (UNED-Santander). En @emilioleton se pueden encontrar sus tweets y su página web personal (www.ia.uned.es/~eleton) con información ampliada de su curriculum.

Elisa M. Molanes-López



Figura 5.4: Elisa M. Molanes-López

Elisa M. Molanes-López nace en Vigo en 1976. Se licencia en Matemáticas por la Universidad de Santiago de Compostela en 2000 y adquiere el grado de doctora, con acreditación europea, por la Universidad de A Coruña en 2007. Entre 2003 y 2007, al amparo de una beca FPI, realiza varias estancias de investigación en las siguientes universidades extranjeras: Universiteit Hasselt (Bélgica), Université Catholique de Louvain (Bélgica) y The University of Texas (EE.UU.). Durante 8 años, entre 2007 y 2015, forma parte de la Universidad Carlos III de Madrid como profesora visitante en el Departamento de Estadística. En 2015, comienza su andadura en la Universidad Complutense de Madrid como profesora ayudante doctora en la Sección de Bioestadística del Departamento de Estadística e Investigación Operativa, y desde 2020 es profesora contratada doctora en dicho departamento. Durante su trayectoria académica participa en 12 proyectos de innovación educativa y desde 2016 es miembro del grupo de innovación docente "miniXmodular: una propuesta de realización de material docente digital modular en formato mini" de la Universidad Nacional de Educación a Distancia. En diciembre de 2013, recibe un accésit a la mejor práctica docente en los Premios del Consejo Social de la UNED por su participación en el MOOC "Mini-vídeos docentes modulares: un elemento crítico en el diseño de un MOOC", y en abril de 2014, el OpenCourseWare Consortium le otorga un premio de excelencia por su participación en el curso OCW "Mini-vídeos docentes modulares para diseñar un MOOC". Más recientemente, en junio de 2022, el Vicerrectorado de Calidad de la Universidad Complutense de Madrid le otorga un diploma de reconocimiento a la excelencia Docentia-UCM por su labor docente durante los trienios 2015-2018 y 2018-2021. Sus líneas de investigación incluyen la estadística no paramétrica, el análisis de supervivencia, las curvas ROC, las funciones cópula y las tecnologías web en el proceso de enseñanza-aprendizaje (HTML, CSS, ePub). En su página web personal (https://elisamariamolanes.wixsite.com/emolanes) y en su ORCID (https://orcid.org/0000-0003-3217-8551), se pueden encontrar más detalles.