Regresión lineal

(ver 7: 2025-2026)



Emilio Letón y Elisa M. Molanes-López

1-Oct-2025

Página legal

REGRESIÓN LINEAL
©Emilio Letón y Elisa M. Molanes-López
Madrid, ver 1: 2019-2020
Madrid, ver 2: 2020-2021
Madrid, ver 3: 2021-2022
Madrid, ver 4: 2022-2023
Madrid, ver 5: 2023-2024
Madrid, ver 6: 2024-2025
Madrid, ver 7: 2025-2026

Quedan rigurosamente prohibidas, sin la autorización escrita de los titulares del Copyright, bajo las sanciones establecidas en las leyes, la reproducción total o parcial de esta obra por cualquier medio o procedimiento, comprendidos la reprografía y el tratamiento informático, y la distribución de ejemplares de ella mediante alquiler o préstamo público.
ISBN electrónico: xxx.
Edición digital (epub): xxx.

Prefacio

Este material está diseñado con el paradigma del grupo de innovación docente miniXmodular de generar material en formato mini y modular, según se puede ver en la página web www.minixmodular.ia.uned.es, donde se introduce, entre otros, el concepto de mini-libro electrónico modular.

En este mini-libro se verán algunos conceptos básicos relativos a la regresión lineal que está indicada en la modelización de una variable respuesta Y (también llamada dependiente, explicada, "output" o resultado) continua a través de varias variables explicativas $X_1, X_2, \cdots, X_p$ (también llamadas independientes, predictoras, características, "input" o entradas).

En el mini-capítulo 1 se especifican los métodos de estimación puntual del vector de parámetros poblacional $\boldsymbol{\beta}$ que interviene en el modelo de regresión lineal. Conviene mencionar que a lo largo de este mini-libro se adoptará el convenio clásico de denotar a un vector aleatorio y al valor que toma dicho vector aleatorio con la misma letra, indicando explícitamente la diferencia sólo en el caso de ambigüedad.

En este mini-libro no se distinguirá el caso con $p = 1$, correspondiente a la regresión lineal simple, del caso con $p > 1$, correspondiente a la regresión lineal múltiple. No obstante, se recomienda a los lectores que se adentren por primera vez en la regresión que consulten el capítulo 3 de [1] para una primera toma de contacto con la regresión lineal simple.

También se recomienda refrescar los conceptos básicos de esperanza y varianza de una variable aleatoria (v.a.) en, por ejemplo, [2].

Mini-capítulo 1

Estimación puntual de los parámetros

Desde un punto de vista poblacional, el modelo de regresión lineal establece para cada individuo i, que

$$Y_i = \beta_0 + \beta_1 X_{i1} + \ldots + \beta_p X_{ip} + \mathcal{E}_i$$

donde $\mathcal{E}_i$ son v.a. i.i.d $\sim N(0, \sigma)$, siendo $i = 1, \ldots, n$, con n el número de individuos. Una vez observados los datos, el modelo anterior se traduce, desde un punto de vista muestral, en la siguiente expresión matricial

$$\begin{pmatrix} y_1 \\ y_2 \\ \ldots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \ldots & x_{1p} \\ 1 & x_{21} & \ldots & x_{2p} \\ \ldots & \ldots & \ldots & \ldots \\ 1 & x_{n1} & \ldots & x_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \ldots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \ldots \\ \varepsilon_n \end{pmatrix}$$

o, equivalentemente,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

donde $\mathbf{y} \in \mathfrak{M}_{n\text{x}1}$, $\mathbf{X} \in \mathfrak{M}_{n\text{x}(p+1)}$, $\boldsymbol{\beta} \in \mathfrak{M}_{p\text{x}1}$ y $\varepsilon \in \mathfrak{M}_{n\text{x}1}$. Por razones que se verán más adelante, es importante señalar que es imprescindible que haya más datos que variables explicativas ($n > p$) y que el rango de $\mathbf{X}$ sea completo ($rg(\mathbf{X}) = p + 1$).

Existen dos métodos para estimar el vector poblacional de parámetros $\boldsymbol{\beta}$: el método de mínimos cuadrados y el método de máxima verosimilitud.

1.1. Mínimos cuadrados

La obtención de los estimadores mínimo cuadráticos de los parámetros $\boldsymbol{\beta}$, se hace minimizando la suma de los cuadrados de los residuos, dada por $SCR(\boldsymbol{\beta}) = \sum_{i=1}^{n}(y_i - (\beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip}))^2$ y que en términos matriciales se puede escribir como $\mathbf{y}^T\mathbf{y} - 2\boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y} + \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta}$.

Para minimizar $SCR(\boldsymbol{\beta})$ se deriva la expresión anterior de $SCR(\boldsymbol{\beta})$ con respecto a β y se iguala a cero, obteniéndose la llamada ecuación normal del modelo de regresión lineal dada por $\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} = \mathbf{X}^T\mathbf{y}$. Si se resuelve la ecuación normal se obtiene $\widehat{\boldsymbol{\beta}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$, donde la inversa de $\mathbf{X}^T\mathbf{X}$ existe por tratarse de una matriz cuadrada de rango completo (ya que $rg(\mathbf{X}^T\mathbf{X}) = rg(\mathbf{X})$ y $rg(\mathbf{X}) = p+1$). Por último, habría que demostrar que efectivamente se trata de un mínimo estudiando la segunda derivada.

Ejemplo

1. Demostrar la fórmula de la suma de cuadrados residuales en función de los parámetros.

   SOLUCIÓN:

   La expresión inicial $SCR(\boldsymbol{\beta}) = \sum_{i=1}^{n}(y_i - (\beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip}))^2$ se sustituye por su expresión matricial y se opera, es decir

$$\begin{aligned} SCR(\boldsymbol{\beta}) &= (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \\ &= (\mathbf{y}^T - (\mathbf{X}\boldsymbol{\beta})^T)(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \\ &= (\mathbf{y}^T - \boldsymbol{\beta}^T\mathbf{X}^T)(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) \\ &= \mathbf{y}^T\mathbf{y} - \mathbf{y}^T\mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y} + \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} \\ &= \mathbf{y}^T\mathbf{y} - (\mathbf{y}^T\mathbf{X}\boldsymbol{\beta})^T - \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y} + \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} \\ &= \mathbf{y}^T\mathbf{y} - (\boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y}^{TT}) - \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y} + \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} \\ &= \mathbf{y}^T\mathbf{y} - 2\boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y} + \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta}, \end{aligned}$$

donde se ha usado el hecho de que $\mathbf{y}^T\mathbf{X}\boldsymbol{\beta}$ es un número y, por tanto, coincide con su traspuesto.

2. Demostrar la obtención de la ecuación normal
   Se trata de derivar $SCR(\boldsymbol{\beta})$ con respecto a $\boldsymbol{\beta}$ e igualar a cero, es decir

$$\begin{aligned}\frac{\partial}{\partial\boldsymbol{\beta}}SCR(\boldsymbol{\beta}) &= \frac{\partial}{\partial\boldsymbol{\beta}}(\mathbf{y}^T\mathbf{y} - 2\boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y} + \boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta}) \\ &= \frac{\partial}{\partial\boldsymbol{\beta}}(\mathbf{y}^T\mathbf{y}) + \frac{\partial}{\partial\boldsymbol{\beta}}(-2\boldsymbol{\beta}^T\mathbf{X}^T\mathbf{y}) + \frac{\partial}{\partial\boldsymbol{\beta}}(\boldsymbol{\beta}^T\mathbf{X}^T\mathbf{X}\boldsymbol{\beta}) \\ &= 0 - 2\mathbf{X}^T\mathbf{y} + 2\mathbf{X}^T\mathbf{X}\boldsymbol{\beta} = -2(\mathbf{X}^T\mathbf{y} - \mathbf{X}^T\mathbf{X}\boldsymbol{\beta}) = 0,\end{aligned}$$

   donde se ha usado el hecho de que $\mathbf{X}^T\mathbf{X}$ es simétrica a la hora de derivar.

3. Demostrar que los $\widehat{\boldsymbol{\beta}}$ de la ecuación normal corresponden efectivamente a un mínimo.
   Se trata de calcular la matriz

$$\frac{\partial^2}{\partial\boldsymbol{\beta}^{\mathbf{2}}}SCR(\boldsymbol{\beta})$$

   y ver que dicha matriz particularizada en $\widehat{\boldsymbol{\beta}}$ es una matriz definida positiva.
   Por una parte

$$\frac{\partial^2}{\partial\boldsymbol{\beta}^{\mathbf{2}}}SCR(\boldsymbol{\beta}) = \frac{\partial}{\partial\boldsymbol{\beta}}(-2\mathbf{X}^T\mathbf{y} + 2\mathbf{X}^T\mathbf{X}\boldsymbol{\beta}) = 0 + 2\mathbf{X}^T\mathbf{X}.$$

   La matriz anterior no depende de $\widehat{\boldsymbol{\beta}}$, por lo que al particularizarla en $\widehat{\boldsymbol{\beta}}$ vuelve a ser ella misma. Es decir

$$\left[\frac{\partial^2}{\partial\boldsymbol{\beta}^{\mathbf{2}}}SCR(\boldsymbol{\beta})\right]_{\boldsymbol{\beta}=\widehat{\boldsymbol{\beta}}} = 2\mathbf{X}^T\mathbf{X}.$$

   Por último, ver que la matriz $2\mathbf{X}^T\mathbf{X}$ es definida positiva es equivalente a ver que la matriz $\mathbf{X}^T\mathbf{X}$ es definida positiva. Para ver esto último, hay que demostrar que $\forall\mathbf{d}\neq\mathbf{0}$ se tiene que $\mathbf{d}^T(\mathbf{X}^T\mathbf{X})\mathbf{d} > 0$. Esto se consigue considerando $\mathbf{c} = \mathbf{X}\mathbf{d}$, que verifica que $\mathbf{c}\neq\mathbf{0}$, ya que en caso contrario se tendría que habría una dependencia lineal entre las columnas de $\mathbf{X}$ lo que entraría en contradicción con el hecho de que se está suponiendo que el rango de $\mathbf{X}$ es completo. Por tanto, al ser $\mathbf{c}\neq\mathbf{0}$, se tiene que $\mathbf{c}^T\mathbf{c} > 0$ y dado que $\mathbf{c}^T\mathbf{c} = \mathbf{d}^T(\mathbf{X}^T\mathbf{X})\mathbf{d}$ se tiene que $\mathbf{d}^T(\mathbf{X}^T\mathbf{X})\mathbf{d} > 0$.

1.2. Máxima verosimilitud

Para un individuo i, se tiene que

$$Y_i \sim N(\beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip}, \sigma),$$

con

$$f(y_i) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{1}{2\sigma^2}(y_i-(\beta_0+\beta_1 x_{i1}+\ldots+\beta_p x_{ip}))^2},$$

con lo que

$$\begin{aligned}f(y_1,\ldots,y_n) &= \prod_{i=1}^n f(y_i) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{1}{2\sigma^2}(y_i-(\beta_0+\beta_1 x_{i1}+\ldots+\beta_p x_{ip}))^2} \\ &= \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n e^{-\frac{1}{2\sigma^2}\sum_{i=1}^n(y_i-(\beta_0+\beta_1 x_{i1}+\ldots+\beta_p x_{ip}))^2} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{1}{2\sigma^2}SCR(\boldsymbol{\beta})}.\end{aligned}$$

Dicha función de densidad constituye la función de verosimilitud cuando se considera como función de los parámetros $\beta_0,\ldots,\beta_p,\sigma^2$ y la muestra fija:

$$\ell(\beta_0,\ldots,\beta_p,\sigma^2) = \ell(\beta_0,\ldots,\beta_p,\sigma^2|y_1,\ldots,y_n) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\frac{1}{2\sigma^2}SCR(\boldsymbol{\beta})}.$$

Dado que el logaritmo neperiano es una función monótona creciente, maximizar la función de verosmilitud equivale a maximizar su logaritmo neperiano, es decir la función dada por

$$Ln(\ell(\beta_0,\ldots,\beta_p,\sigma^2)) = -\frac{n}{2}Ln(2\pi) - \frac{n}{2}Ln(\sigma^2) - \frac{1}{2\sigma^2}SCR(\boldsymbol{\beta}),$$

con lo que el vector de parámetros $\boldsymbol{\beta}$ que maximiza la función de verosimilitud es el mismo que minimiza la suma de cuadrados residuales $SCR(\boldsymbol{\beta})$.

Referencias

[1] James, G., Witten, D., Hastie, T., & Tibshirani, R., *An introduction to statistical learning*, Springer (New York), 2021.

[2] Ramos, E., Vélez, R., Hernández, V., *Modelos probabilísticos y optimización*, Sanz y Torres (Madrid), 2019.

Acerca de

Emilio Letón



Figura 1.1: Emilio Letón

Emilio Letón nace en Madrid en 1966. Es Licenciado en Matemáticas por la UCM en 1989 y doctor en Matemáticas en la misma universidad en 2002. En la actualidad es Profesor Titular de Universidad de la UNED en el departamento de Inteligencia Artificial, al que se incorporó en 2009. Anteriormente fue profesor del departamento de Estadística de la UC3M durante 5 años. Asimismo, ha trabajado durante 15 años en departamentos de Planificación y Estadística dentro del sector bancario y de la industria farmacéutica. Sus lineas de investigación incluyen el Análisis de Supervivencia, tests no paramétricos, PLS, Meta-Análisis, Bioestadística, B-Learning e IA. Es coautor de 16 artículos reflejados en su ORCID (https://orcid.org/0000-0001-6908-9590). Ha participado en 34 proyectos de innovación docente en los últimos 15 años (siendo coordinador en 12 de ellos) colaborando con distintas universidades: UNED, UC3M, UCM y UPM. Realiza su transferencia desde el grupo miniXmodular (www.minixmodular.ia.uned.es) del que es coordinador desde su creación en 2016, desde el Canal Fundación ONCE en el que colabora desde su creación en 2016 y desde la Cátedra UNESCO de Educación a Distancia (CUED) a la que se incorporó en 2022 como miembro del consejo académico. Ha recibido 1 premio en excelencia en publicaciones científicas (UC3M), 5 premios en excelencia docente (1 en UC3M, 3 en UNED y 1 en OCW Consortium) y 1 premio de transferencia (UNED-Santander). En @emilioleton se pueden encontrar sus tweets y su página web personal (www.ia.uned.es/˜eleton) con información ampliada de su curriculum.

Elisa M. Molanes-López



Figura 1.2: Elisa M. Molanes-López

Elisa M. Molanes-López nace en Vigo en 1976. Se licencia en Matemáticas por la Universidad de Santiago de Compostela en 2000 y adquiere el grado de doctora, con acreditación europea, por la Universidad de A Coruña en 2007. Entre 2003 y 2007, al amparo de una beca FPI, realiza varias estancias de investigación en las siguientes universidades extranjeras: Universiteit Hasselt (Bélgica), Université Catholique de Louvain (Bélgica) y The University of Texas (EE.UU.). Durante 8 años, entre 2007 y 2015, forma parte de la Universidad Carlos III de Madrid como profesora visitante en el Departamento de Estadística. En 2015, comienza su andadura en la Universidad Complutense de Madrid como profesora ayudante doctora en la Sección de Bioestadística del Departamento de Estadística e Investigación Operativa, y desde 2020 es profesora contratada doctora en dicho departamento. Durante su trayectoria académica participa en 12 proyectos de innovación educativa y desde 2016 es miembro del grupo de innovación docente "miniXmodular: una propuesta de realización de material docente digital modular en formato mini" de la Universidad Nacional de Educación a Distancia. En diciembre de 2013, recibe un accésit a la mejor práctica docente en los Premios del Consejo Social de la UNED por su participación en el MOOC "Mini-vídeos docentes modulares: un elemento crítico en el diseño de un MOOC", y en abril de 2014, el OpenCourseWare Consortium le otorga un premio de excelencia por su participación en el curso OCW "Mini-vídeos docentes modulares para diseñar un MOOC". Más recientemente, en junio de 2022, el Vicerrectorado de Calidad de la Universidad Complutense de Madrid le otorga un diploma de reconocimiento a la excelencia Docentia-UCM por su labor docente durante los trienios 2015-2018 y 2018-2021. Sus líneas de investigación incluyen la estadística no paramétrica, el análisis de supervivencia, las curvas ROC, las funciones cópula y las tecnologías web en el proceso de enseñanza-aprendizaje (HTML, CSS, ePub). En su página web personal (https://elisamariamolanes.wixsite.com/emolanes) y en su ORCID (https://orcid.org/0000-0003-3217-8551), se pueden encontrar más detalles.

Índice general

1. Estimación puntual de los parámetros **1**
1.1. Mínimos cuadrados 1
1.2. Máxima verosimilitud 2

Índice de figuras

1.1. Emilio Letón 5
1.2. Elisa M. Molanes-López 5