La **minería de texto** consiste en el proceso de analizar colecciones de texto para extraer información y descubrir patrones que no aparecen implícitamente.

La **recuperación de la información** consiste en la búsqueda de documentos a partir de la información que contienen o de los metadatos.

Un **corpus** es un conjunto de documentos que permite entrenar y comparar técnicas o modelos de aprendizaje automático, además de proporcionar una muestra amplia y natural del lenguaje, aportando estadísticas sobre las palabras.

Pueden estar anotados (marcados con información lingüística, denominados *gold standard*) o sin anotar (texto puro). Pueden ser multilingües o monolingües. Los multilingües pueden ser paralelos si el mismo documento está en varios idiomas o comparables si el número de documentos en diferentes idiomas es similar.

El procesamiento del lenguaje natural (**PLN**) es una rama de la informática cuyo objetivo es adquirir conocimiento a partir de datos contextuales, así como permitir la comunicación ordenador-persona.

La dificultad reside en:

- Ambigüedad de significados, discursos, estructuras, ...
- Implica conocimiento del mundo.
- Aspectos que intervienen en la interpretación.

Los pasos dentro de un procedimiento para desarrollar un PLN:

- **Normalización del texto**. Consiste en convertir el texto a una forma canónica
    - Eliminación de caracteres especiales: tildes, signos de puntuación, números según convenga, espacios en blanco excesivos
    - Eliminación de la capitalización de las letras.
    - Eliminación de trozos de texto si conviene: como correos electrónicos, cabeceras constantes, etc.
- **Tokenización de oraciones o palabras**. Separado de las palabras o de los morfemas de las palabras según espacios en blanco, signos de puntuación, etc.
- **Eliminación de palabras vacíos**. Palabras que no tienen significado por sí mismas, como los determinantes, preposiciones.
- **Lematización o *stemmer***. Eliminación de los prefijos, sufijos y afijos de las palabras para mantener las raíces. El más usado: Porter. En español snowball.

- **Etiquetado gramatical**. POS Tagging. Consiste en etiquetar las palabras según su categoría gramatical. La etiqueta se puede decidir en base a la propia palabra únicamente (uni-grama) o teniendo en cuenta también la anterior (bi-grama).

A la tokenización, eliminación de palabras vacías, lematización, normalización léxica, etc. se les consideran técnicas de **selección de rasgos** y **reducción de dimensionalidad**. Generalmente se definen en función del problema.

Se usa los *gold standard* se usan para evaluar los modelos. Métricas para evaluar modelos PLN:

- Precisión: $p = \frac{TP}{TP+FP}$
- Exhaustividad o cobertura: $r = \frac{TP}{TP+FN}$
- Medida-F-beta: $F_\beta = (1+\beta^2)\frac{p \cdot r}{\beta^2 \cdot p + r}$. Generalmente se hace con β = 1.

NER: Reconocimiento de entidades nombradas. Se encarga de detectar entidades y asignarles una clasificación. Las entidades son generalmente nombres propios.

Junto con la clase, se suele asignar una etiqueta para indicar la posición dentro de la entidad general. El sistema más usado es IOB o IO:

- I: indica que el token se encuentra en una posición interna o final de la entidad.
- B: indica que el token se encuentra en la posición inicial de la entidad.
- O: indica que se trata de un token que no pertenece a una entidad.

La evaluación se hace calculando la precisión, exhaustividad o medida-F de cada clase y calculando la media (macroaveragging).

Si un clasificador NER es Deep learning se usa el **word embedding**. Consiste en representar el significado de las palabras en base a vectores, de forma que se pueda reducir la dimensionalidad. La generación de los vectores se basa en la hipótesis distribucional: palabras que aparecen en contextos similares tienden a tener significados similares. Se construye un espacio vectorial con las palabras, de forma que se puede aplicar álgebra sobre las palabras. Se suele usar modelos Bi-LSTM que reciben el vector junto con la palabra.

Las **expresiones regulares** son fórmulas a modo de patrón para detectar secuencias de caracteres. Se pueden usar para definir el lenguaje de forma formal.

Las expresiones regulares definen los lenguajes y las expresiones regulares son definidas por autómatas finitos. Cada uno de los estados representa un carácter o tipo de carácter aceptado y las funciones de transición de cada estado representa el orden en el que se aceptan dichos caracteres. Se define formalmente un autómata por la tupla:

$$< Q, \Sigma, q_0, F, \delta(q, i) >$$

La **distancia de edición** entre dos palabras se define como el coste que conllevaría pasar de una a otra mediante las operaciones de sustitución, eliminación y adición de letras. La distancia siempre será la mínima posible.

El **chunking** es una técnica que parte y etiqueta secuencias de palabras.

Cuando una palabra tiene varios significados según el contexto (**WSD**) es necesario seleccionar el sentido correcto. Algunas de las técnicas que existen para realizar este procedimiento son:

- Métodos basados en **diccionarios**.
- Métodos **supervisados** usando corpus anotados.
- Métodos **semi-supervisados**. Se usa una fuente secundaria de conocimiento como pequeño corpus anotado como datos de semillas en un proceso de bootstraping.
- Métodos **no supervisados**. Se basan en la hipótesis que sentidos similares aparecen en contextos similares. Se usa la relación entre sentidos:
    - Sinónimos.
    - Hipónimo. X es hipónimo de Y si la palabra X es más específica que Y.
    - Hiperónimo. X es hiperónimo de Y si la palabra Y es más específica que X.

Para la selección del significado existe el algoritmo de Lesk: sea una palabra p con n significados y una frase f tal que $p \in f$. Para cada significado n_i se genera el conjunto $N_i = \{p' | p' \in f \wedge p' \neq p \wedge p' \text{tiene relación con } n_i\}$. Se tomará el significado n_i tal que $|N_i|$ es máximo.

La **extracción de relaciones** consiste en identificar la existencia de relaciones entre tipos de entidades. Una relación es un conjunto ordenado de tuplas sobre los elementos de un dominio.

Para la extracción de relaciones se puede usar:

- **Patrones hechos a manos**. Muy eficientes, pero pueden no detectar todas. Se pueden generar patrones usando
    - Modelos estadísticos. Son usados en los modelos no supervisados. Las relaciones extraídas que no tienen suficiente frecuencia se descartan.
    - Modelos supervisados. Hay que decidir las relaciones de interés y tener un corpus anotado.
    - Modelo semi-supervisado. Usando bootstrap un pequeño grupo de semillas de tuplas de entidades se buscan oraciones que contengan ambas entidades y se genera un patrón junto con un valor de confianza para decidir cuanta fiabilidad tiene. Se extraen nuevas entidades usando ese patrón y, a partir de esas entidades, se vuelve a ejecutar el proceso.

Las **expresiones temporales** que no vienen indicadas en la forma estándar DD-MM-AAAA, sino que son relativas o son duraciones, se normalizan según la ISO 8601. La mayoría de las fechas se expresan con respecto a una referencia, generalmente la fecha del documento, denominada ancla temporal.

La **extracción de información** tiene como objetivo convertir información no estructurada en datos estructurados.

Métodos más usados:

- **Clustering**.
    - Organiza el conjunto de datos según la similitud sin conocer a priori la forma de agrupación.
    - Se buscarán grupos con alta cohesión (similitud entre los datos) y aislamiento (grupos bien definidos)
    - Se suele usar matrices de rasgo-documento como entrada.
    - Tipos de clustering según pertenencia de las instancias:
        - **Duro o exclusivo**: una instancia pertenece a un solo clúster.
        - **Suave o solapado**: una instancia tiene una probabilidad de pertenecer a cada clúster.
    - Tipos de clustering según el método de agrupación:
        - **No jerárquico**: los clústeres no tienes relación entre ellos. Se usan medidas que buscan minimizar heterogeneidad (diferencia dentro de un clúster) y maximizar la separación entre clústeres.
        - **Jerárquicos**. Los clústeres tienen relación entre ellos:
            - **Aglomerativo**. Se parte de las instancias individuales y se van uniendo según la distancia definida. La distancia entre dos clústeres se puede definir según la distancia máxima, mínima o promedia de las instancias que lo componen.
            - **Divisivos**. A partir del conjunto de todas las instancias se van dividiendo según se optimice la función criterio. Se puede decidir el nivel en el que parar.
        - **Basados en modelos estadísticos**. Se modelan utilizando un modelo estadístico estándar para trabajar con distribuciones. Por ejemplo, el topic model.
    - Tipos de clustering según el algoritmo:
        - **Modelos de conectividad**: misma idea que la agrupación jerárquica. Misma división también
            - **Abajo arriba**.

        - **Arriba abajo**.
    - **Modelos de centroides**. La similitud se determina según cuán cerca se encuentren de un elemento representativo del clúster.
    - **Modelos distribucionales**. Se basan en la noción de cuán de probable es que los puntos del clúster pertenezcan a la misma distribución.
    - **Modelos basados en densidad**. Se busca áreas en el espacio con alta densidad y se aíslan cada área como un clúster.
    - **Algoritmos iterativos de reubicación.** Se parte de c clústeres, los cuales se van reorganizando en función de cálculos hechos en cada iteración. Por ejemplo, el k-medias.
  - Medidas de evaluación en el clústering:
    - **Intrínsecas**: basada en los propios objetos agrupados. Evalúan la homogeneidad y separación. Por ejemplo, la silueta.
    - **Extrínsecas**: basada en función a los *gold standard*. Se usa la matriz de confusión y las métricas derivadas, de las cuales se saca una métrica global realizando la media entre ellas (**macroaveragging**).
- **Clasificación**.
  - Dadas C categorías conocidas, se determina si un documento pertenece a cada categoría.
  - Se requiere un subconjunto de documentos de los que se sepan la clase para poder realizar la clasificación. La clasificación de este subconjunto puede haber sido hecha con un algoritmo no supervisado, por lo que se tendrían de una clasificación semi-supervisada.
  - Según la etiqueta:
    - **Monoetiqueta**: una única clase cada documento.
    - **Multietiqueta**: varias clases cada documento.
  - Según la forma de asignar la etiqueta:
    - **Hard**: se decide si pertenece o no a la clase.
    - **Ranking**: se da un ranking de las clases según la adecuación.
  - Según el tipo de información usada:
    - **FastFeatures**: no se tiene información externa.
    - **FullFeature**: se tiene características adicionales.
  - Algoritmos para la clasificación:
    - **Naïve Bayes**.
    - **Árboles de decisión**.
    - **Máquinas de vectores de soporte**. Se puede modificar el kernel para aplicar transformaciones a los datos de forma que sea más sencillo calcular el hiperplano.
    - **Redes neuronales**.
    - **Deep learnig**. Como las LSTM, los transformers.

Existen principalmente cuatro formas de representar la información extraída de los documentos:

- **Modelo vectorial**:
  - Un documento es una combinación lineal de rasgos: $d = a_1 \cdot \overrightarrow{r_1} + a_2 \cdot \overrightarrow{r_2} + \cdots + a_n \cdot \overrightarrow{r_n}$. Los rasgos son tokens, palabras, etc., que se consideran independientes entre ellos (base del espacio vectorial).
  - La determinación de los coeficientes viene determinada por una función de pesado: $f(d, \overrightarrow{r_i}) = a_i$.
    - Una función de pesado es aquella que dado un documento y un rasgo (o término) determina qué ponderación tiene ese rasgo en el documento. Por ejemplo: la **bolsa de palabras**. Se define como la matriz rasgo-documento donde cada se recoge la frecuencia de cada rasgo i dentro del documento j. Suele ser una matriz dispersa.
- **Modelo estadístico**:
  - Se definen temas a partir de suposiciones estadísticas, como a partir de la frecuencia de las palabras.
    - **Topic model**: Se asume que, si un documento trata sobre un tema, habrá palabras que aparezcan con mayor o menor frecuencia si están relacionadas con dicho tema y viceversa.
  - Los métodos más conocidos son la Indexación Semántica Latente Probabilística (PLSI) y la Asignación Latente de Dirichlet (LDA).
- **Modelo probabilístico**:
  - Define una distribución de probabilidad sobre secuencias de palabras: la probabilidad de aparición de una palabra o rasgos depende de los n anteriores (n-grama). Si n es 1 es equivalente a una bolsa de palabras.
- **Modelo semántico vectorial**:
  - También se basa en la hipótesis distribucional: palabras en contextos similares tendrán significados similares.
  - Cada palabra tiene asociado un vector de un espacio semántico.
  - Para un vocabulario de V palabras, se define una matriz $V \times V$ donde se contabiliza cuantas veces aparecen cada par de palabra en un contexto. Esta matriz se suele reducir su dimensionalidad a, como máximo, 1024.
    - También se puede definir cada posición de la matriz como el TF-IDF entre cada par de palabras.
    - Información Mutua Puntual Positivo (PPMI): frecuencia con la que aparecen dos palabras comparando con lo esperado si fueran independientes.
  - La similitud de dos palabras (en cuanto a significado) dependería de la distancia del coseno.

- La similitud de documentos se puede hacer tomando las n palabras más similares entre ambos.
- Ejemplos de modelos:
  - **Word2Vec**.
    - Red neuronal de dos capas que toma un corpus y genera los word embeddings.
    - Implementa dos modelos neuronales: CBOW, que predice la palabra objetivo a partir del contexto; y el Skip-gram, que lo hace al revés.
  - **FastText**.
    - Extensión de Word2Vec.
    - Cada palabra se trata como la suma de sus composiciones de n-gramas.
    - Una composición de 4-gramas de la palabra "estadio" sería: <est, esta, stad, tadi, adio, dio>.
  - **Modelos contextualizados**.
    - Generan una representación de cada palabra basada en las otras palabras de la oración, ya sea bidireccional o unidireccional, dependiendo donde se encuentre en la oración.
    - Modelos de este tipo:
      - **Bert**. Se trata de un transformer que enmascara una serie de palabras e intenta predecirlas usando información anterior y posterior.
      - **ELMo**. Red neuronal Bi-LSTM que generan embeddings leyendo de izquierda a derecha y viceversa.

Los **transformers** son encoders y decoders usados para procesar secuencias en paralelo (independiente al orden de las palabras) basadas en la autoatención. La **atención** ayuda a crear conexiones entre cualquier parte de la secuencia, es decir, que la palabra se analiza en función del contexto completo, no solo teniendo en cuenta las dependencias a corto plazo.

El encoder recorre la entrada y la codifica en un vector denominado vector de contexto. El decoder lee el vector de contexto para generar el texto objetivo.

En función de qué se utilice se pueden generar diferentes tipos de modelos:

- **Solo codificadores o autocodificación**. Tareas de clasificación de oraciones o NER. Atención bidireccional. Por ejemplo, BERT.
- **Solo decodificadores o autorregresivos**. Tareas generativas de texto. Solo se puede acceder a palabras anteriores. Por ejemplo, GPT.

- **Codificador-decodificador o secuencia a secuencia**. Tareas generativas a partir de una entrada. Traducción o generación de resúmenes. Por ejemplo, BART.

Las **funciones de pesado** se encargan de determinar el peso que tiene una palabra o un rasgo dentro de un documento. Pueden ser locales, cuando solo se tiene en cuenta el propio documento, o globales, si se tiene en cuenta la colección completa. Estas funciones se pueden usar para la selección y reducción de rasgos, estableciendo un umbral para ser tenidos en cuenta.

En el caso de funciones locales:

- **Binaria**. 1 si aparece 0 si no
- **Frecuencia** con la que aparece el rasgo en el documento.
- **Frecuencia compensada**. Frecuencia entre el total de palabras del documento.
- **Frecuencia aumentada normalizada**. Frecuencia del rasgo entre la frecuencia del rasgo más repetido en el documento.

$$ANTF(\vec{t_\iota}, d_j) = 0.5 + 0.5\frac{f_{ij}}{max(f_{pj}|t_p \in d_j)}$$

- **Normalización logarítmica**.

$$L(\vec{t_\iota}, d_j) = log_2(f_{ij} + 1)$$

En el caso de funciones globales:

- **Frecuencia inversa del documento**.

$$IDF(\vec{t_\iota}, d_j) = log\left(\frac{N}{1 + df(\vec{t_\iota})}\right)$$

  $df(\vec{t_\iota})$ es el número de documentos de la colección en los que aparece el rasgo $\vec{t_\iota}$ y N es el número de documentos total.
- **Frecuencia del término por la frecuencia inversa del documento.**

$$TF - IDF(\vec{t_\iota}, d_j) = f_{ij} \cdot log\left(\frac{N}{1 + df(\vec{t_\iota})}\right)$$

  Si un rasgo aparece en muchos documentos, el valor tiende a cero.
- **Frecuencia inversa probabilística**.

$$PIF(\vec{t_\iota}, d_j) = log\frac{N - df(\vec{t_\iota})}{df(\vec{t_\iota})}$$

- **Función normal**.

$$N(\vec{t_\iota}, d_j) = \sqrt{\frac{1}{\sum_{d_j \in C} f_{ij}^2}}$$

  El denominador se trata de la suma de las frecuencias al cuadrado de aparición del rasgo en cada documento del corpus.

- **Frecuencia global por frecuencia inversa de documento**.

$$GF - IDF(\overrightarrow{t_\iota}, d_j) = \frac{gf(\overrightarrow{t_\iota})}{df(\overrightarrow{t_\iota})}$$

Donde $gf(\overrightarrow{t_\iota})$ es cantidad de veces que aparece el rasgo en el corpus: $\sum_{d_j \in C} f_{ij}$.

La **minería de opinión** o **análisis de sentimientos** consiste en la extracción de información sobre un evento, producto, entidad y sus atributos. Se aborda como un problema de clasificación de un texto en una polaridad positiva, negativa o neutra, usando una escala 1-5.

Se utiliza para la toma de decisiones:

- **Elección de servicio**.
- **Política de mercadotecnia de una empresa**.
- **Predicción de tendencias en elecciones**.
- **Identificación de eventos relevantes para los usuarios**.

Es importante determinar la entidad y sus aspectos, atributos y contexto. Estos pueden tener un significado positivo, negativo o incluso ambos dentro de la oración.

Dos enfoques:

- **Enfoque semántico**.
    - Se usan diccionarios de términos junto con la valoración semántica.
    - Se tokeniza, se elimina palabras vacías, se normaliza a nivel léxico y se comprueba su valoración semántica. Se suman las valoraciones para obtener el sentido de la oración.
    - Los modificadores (como adverbios o negadores) puede alterar la valoración semántica individual de los términos.
    - La corrección de errores se lleva a cabo actualizando el diccionario utilizado.
- **Aprendizaje automático**.
    - Se entrena un modelo usando un corpus anotado con las valoraciones semánticas.
    - Son cajas negras fáciles de construir, pero difíciles de corregir los errores.
    - Requiere esfuerzo humano para anotar los textos, si no se usa aprendizaje semi supervisado.

Las **tendencias** son temas candentes que provocan interés extraordinario de forma temporal en una comunidad de usuarios de una red social. Una tendencia no puede durar prolongado en el tiempo, sino que debe surgir de forma repentina, durar cierto intervalo de tiempo y desaparecer.

Se usa para detectar emergencias o noticias.

Hay que tener en cuenta:

- **La temporalidad**. Si se está detectando una tendencia actual (uso de flujo de datos) o de una pasada (uso colección de datos).
- **Tipo de aprendizaje** usado para el análisis.
- **Tipos de tendencia.**

Las principales técnicas para el análisis de tendencias son:

- Técnicas de **clústering** como LDA, K-medias o LSH.
- **Análisis de frecuencias**.
    - Busca términos que aumenten de frecuencia repentinamente.
    - Requiere llevar un historial de las frecuencias.
    - Se usan métricas destinadas a comprobar la variación de frecuencias entre instantes diferentes.