TEMA 3

El contenido de los textos de puede representar de diferentes formas, aunque siempre fiel a su contenido e incluyendo toda la información útil para la extracción del conocimiento.

Los modelos de representación más usados son:

- Espacio vectorial.
- Probabilístico.
- Estadístico.
- Semántico vectorial.

1. Modelo vectorial

Un modelo vectorial de documentos se representa por la cuádrupla:

$$< X, B, \mu, F >$$

Donde X son las cadenas que constituyen el vocabulario, B es el álgebra que generaliza las relaciones entre objetos de X, μ es la métrica de distancia o similitud entre los objetos y F es la función de pesado que establece la proyección de cada objeto sobre la recta real.

Un documento se modela como conjuntos de rasgos (las cadenas de caracteres que serán tokens, palabras, etc). Estos rasgos pueden ser tratados individualmente y asignados un peso. Estos rasgos, según este modelo, se asumen independientes: no tienen relación entre sí y no se tiene en cuenta el orden de aparición en el documento. Estas suposiciones reducen la complejidad (no se tienen en cuenta ni la relación entre palabras adyacentes ni las relaciones semánticas) sin penalizar excesivamente los resultados.

Los documentos son vectores dentro del espacio, por lo que la distancia entre ambos vectores determina la similitud. Las medidas de distancia más populares son la distancia euclídea y la del coseno.

Es decir, dada una base del espacio vectorial:

$$\overrightarrow{t_1}, \overrightarrow{t_2}, \dots, \overrightarrow{t_n}$$

un documento se expresa como una combinación lineal de esta base:

$$d_j = \left(t_1^j, t_2^j, \dots, t_n^j\right)$$

La determinación de estos coeficientes vendrá dada por la función de pesado: dado un vector de la base y un documento se obtendrá un coeficiente:

$$f(\vec{t_i}, d_j) = t_i^j$$

Dos documentos se consideran iguales si la combinación lineal de cada uno es idéntica:

$$d_j \neq d_k \Leftrightarrow \forall i, \{i \mid t_i^j \neq t_i^k\} \neq \emptyset$$

Es decir, con que solo un coeficiente sea diferente, se considerarán los documentos diferentes.

Una forma de determinar los coeficientes es mediante el método de la **bolsa de palabras**: se realiza una matriz término i-documento j donde cada posición m_{ij} es la cantidad de veces que aparece el término i en el documento j. Este método puede ocasionar una matriz dispersa debido a la alta cantidad de términos y documentos que puede haber en un corpus (alta dimensionalidad del espacio vectorial debido a la cantidad de términos).

2. Modelo probabilístico

Los documentos se representan como una mezcla de temas, donde un tema es una distribución de probabilidad sobre palabras. Es decir, si un documento es sobre el tema i se espera que las palabras relacionadas con ese tema (alta probabilidad de aparición) tengan una frecuencia elevada.

Un modelo probabilístico calcula la frecuencia de las palabras en los documentos e infiere los temas a partir de dichas frecuencias. Se puede extender el modelo a términos en general (palabra, frase, etc).

Los métodos más conocidos son la Indexación Semántica Latente Probabilística (PLSI) y la Asignación Latente de Dirichlet (LDA).

3. Modelo estadístico

Consiste en definir una distribución de probabilidad sobre secuencias de palabras o caracteres. Se aplica en muchas tareas de procesamiento del lenguaje natural. El modelo más utilizado es el de n-gramas.

Este modelo asume que la probabilidad de aparición de una palabra o carácter depende de los n anteriores. La probabilidad de ver la secuencia $w_1, w_2, \dots, w_m$ se puede aproximar como el producto de las probabilidades de ver el término w_i en función de los anteriores:

$$P(w_1, w_2, \dots, w_m) = \prod_{i=1}^{m} (w_i | w_1, \dots, w_i | w_{i-1})$$

Si se decide que n = 1, es equivalente a la bolsa se palabras.

4. Modelo semántico vectoriales

Se basa en la hipótesis distribucional: palabras que ocurren en contextos similares tienden a tener significados similares (palabras sinónimas). La diferencia entre dos palabras será la diferencia de los contextos en los que aparecen. Cada palabra tiene asociado un vector (**embedding**) de un espacio semántico.

En este caso no se tendrían una matriz término-documento, sino una término-término. Para un vocabulario con V términos, la matriz sería de $V \times V$: cada celda representa el número de veces que dos palabras coaparecen en un determinado contexto en un corpus. Las palabras de las columnas representarían el contexto.

Para determinar la similitud de dos palabras se suele usar la distancia del coseno:

$$cos(\vec{v}, \vec{w}) = \frac{\sum_{i=0}^{n}(v_i \cdot w_i)}{\sqrt{\sum_{i=0}^{n} w_i^2}\sqrt{\sum_{i=0}^{n} v_i^2}}$$

Esta distancia irá de 0 (son totalmente diferentes) a 1 (misma dirección).

Para comparar documentos con este modelo se puede, entre otras cosas:

- Encontrar las palabras más similares a una palabra objetivo calculando los cosenos, ordenar los resultados y obtener las n más altas.
- Decidir si dos documentos son similares. Se toman los vectores de todas las palabras del documento, se calcula la suma y se divide cada componente entre el número de palabras del documento. A este vector resultante se le denomina centroide. A partir de los centroides se puede calcular la distancia del coseno.

El uso de una matriz con $V \times V$ puede provocar el mismo caso de matriz dispersa, por lo que suele reducir la dimensionalidad a 256, 512 o 1024. También se puede sustituir la frecuencia de coaparición por el TF-IDF como función de pesado. Esta métrica representa que tan relevante es una palabra con respecto a otra en una colección, permitiendo conocer qué palabras son más comunes de forma general.

Otra alternativa es el uso de la Información Mutua Puntual Positivo (PPMI), que se trata de una medida de la frecuencia con la que aparecen dos eventos (palabras) comparando con lo esperado si fueran independientes.

Los modelos semánticos vectoriales no necesitan datos etiquetados para aprender.

4.1. Word2Vec

Uno de los modelos semánticos vectoriales más utilizados es el Word2vec, que usa word embeddings. Se trata de una red neuronal de dos capas que toma un corpus

textual y genera los word embeddings para que sea pueda ser utilizado. El word embeddings es un método que se basa en la idea de que si es posible predecir en qué contexto aparece una palabra entonces significa que se entiende el significado de la palabra en su contexto.

Word2vec implementa dos modelos neuronales: CBOW que predice la palabra objetivo a partir de una ventana de palabras (el contexto) y el Skip-gram que predice al revés.

4.2. FastText

Extensión del modelo Word2Vec donde cada palabra se trata como la suma de sus composiones de n-gramas de caracteres. Por ejemplo, para la palabra “apple”, esta suma sería <ap, app, appl, apple>, ppl, pple, pple>, ple, ple>, le>... De esta forma se pretende obtener mejores representaciones para palabras poco frecuentes.

4.3. Modelos contextualizados

Las representaciones prentrenadas pueden ser independientes de contexto o contextualizadas.

A diferencia de los modelos independientes del contexto que generan una única representación vectorial para la palabra, independientemente del significado que se esté utilizando en el texto, estos modelos generan una representación de cada palabra basada en las otras palabras de la oración en la que aparece, pudiendo ser una contextualización bidireccional si se encuentra entre otras palabras o unidireccional si solo tiene

Los primeros modelos fueron Bert, de Google, y ELMo. En español tenemos RigoBERTa, Beto y la versión multilingüe de Bert.

4.3.1 Bert

Realiza un análisis global de todas las palabras de la secuencia a la vez. Este proceso lo lleva a cabo una estructura denominada Transformer, que es mas eficaz que las estructuras secuenciales.

Este modelo no intenta predecir la siguiente palabra dadas las previas o posteriores, sino que enmascara una serie de palabras e intenta predecirlas usando conjuntamente la información anterior y posterior.

Debido a su arquitectura, se puede usar como entrada a una tarea de aprendizaje supervisado para comprobar la similitud entre texto o como preentrenamiento, usando los embeddings de las palabras de una secuencia.

4.3.2 ELMo

Este modelo se trata de una red neuronal biLSTM que se genera las representaciones de cualquier vector a medida que recibe texto de entrada. Los embeddings se forman leyendo el texto de izquierda a derecha y viceversa.

5. Funciones de pesado

Existen dos tipos de funciones:

- Locales: solo tienen en cuenta el propio documento para determinar el peso de un rasgo.
- Globales: tienen en cuenta la colección completa. Suelen implicar el uso de un fichero inverso con información relativa a la frecuencia de los rasgos en cada documento de la colección.

Algunos ejemplos de funciones locales:

- **Binaria**:

$$bin(\vec{t_\iota}, d_j) = 1 \text{ si } \vec{t_\iota} \in d_j, 0 \text{ sino}$$

- **Frecuencia**:

$$tf(\vec{t_\iota}, d_j) = f_{ij}$$

  Frecuencia con la que aparece el rasgo en el documento.

- **Frecuencia compensada**:

$$wtf(\vec{t_\iota}, d_j) = \frac{f_{ij}}{\sum_{\vec{t_p} \in d_j} f_{pj}}$$

  Frecuencia entre el número total de palabras del documento.

- **Frecuencia aumentada normalizada**:

$$ANTF(\vec{t_\iota}, d_j) = 0.5 + 0.5 \frac{f_{ij}}{max(f_{pj} | t_p \in d_j)}$$

  El denominador es la frecuencia de la palabra que más se repite.

- **Normalización logarítmica:**

$$L(\vec{t_\iota}, d_j) = log_2(f_{ij} + 1)$$

En el caso de funciones globales:

- **Frecuencia inversa del documento**:

$$IDF(\vec{t_\iota}, d_j) = log\left(\frac{N}{1 + df(\vec{t_\iota})}\right)$$

$df(\vec{t_i})$ es el número de documentos de la colección en los que aparece el rasgo $\vec{t_i}$ y N es el número de documentos total.

- **Frecuencia del término por la frecuencia inversa del documento**:

$$TF - IDF(\vec{t_i}, d_j) = f_{ij} \cdot log\left(\frac{N}{df(\vec{t_i})}\right)$$

Si un rasgo aparece en muchos documentos, el valor tiende a cero.

- Frecuencia inversa probabilística

$$PIF(\vec{t_i}, d_j) = log\frac{N - df(\vec{t_i})}{df(\vec{t_i})}$$

- Función normal

$$N(\vec{t_i}, d_j) = \sqrt{\frac{1}{\sum_{d_j \in C} f_{ij}^2}}$$

El denominador se trata de la suma de las frecuencias al cuadrado de aparición del rasgo en cada documento del corpus.

- Frecuencia Global por Frecuencia inversa de documento.

$$GF - IDF(\vec{t_i}, d_j) = \frac{gf(\vec{t_i})}{df(\vec{t_i})}$$

Donde $gf(\vec{t_i})$ es cantidad de veces que aparece el rasgo en el corpus: $\sum_{d_j \in C} f_{ij}$.

6. Funciones de selección y reducción de rasgos

La selección de rasgos consiste en transformar un texto en un conjunto de rasgos que lo representa. Algunas transformaciones son: tokenización, normalización léxica, truncado, lematización o eliminación de palabras vacías.

La reducción de rasgos permite disminuir la dimensión de las representaciones de los documentos. En una reducción se suelen realizar una ponderación de los rasgos para decidir cuales son los que más representan el documento.

Estas dos funciones se definen normalmente en función de la tarea a desarrollar, no se puede aplicar de forma general.

Las funciones de pesado también se pueden utilizar para realizar una selección y reducción de rasgos, pues indican información acerca de la aparición de los rasgos en el documento o en el corpus.

La utilización de estas funciones tiene como objetivo reducir el sobrentrenamiento y mejorar la predicción eliminando los rasgos que puedan ser considerados como ruido. En scikit existe la clase SelectKBest con diferentes pruebas estadísticas para seleccionar las mejores características.

Algunos modelos ofrecen el cálculo de la importancia de la característica sobre la predicción, como por ejemplo el modelo ExtraTreeClassifier.

Algunas de las formas de seleccionar qué características son importantes son:

- Ganancia de información.
- Información mutua. Se puede estimar como el valor medio sobre el conjunto total de clases o como el valor máximo sobre el total de clases.