TEMA 4

Las técnicas más usadas para extraer conocimiento del contenido textual son la clasificación y el clustering. Ambos modelos intentan realizar una ordenación lógica de la información. La diferencia entre ambos es que el clustering no se requiere conocer las clases mientras que para la clasificación sí.

1. Clustering

El objetivo del clustering es organizar el conjunto de datos iniciales según la similitud de las características. A priori, las agrupaciones no se conocen, por lo que se trata de un aprendizaje no supervisado.

Los grupos definidos por el modelo deben tener cohesión (los datos son muy similares entre sí) y aislamiento (los datos de diferentes clústeres son marcadamente diferentes).

A la hora de clasificar los documentos, los clústeres que se crean pueden ser en relación con la temática o a la estructura del contenido entre otras características. Normalmente la entrada puede ser una matriz rasgo-documento o una matriz de distancias entre documentos. Este tipo de matrices se puede obtener desde una matriz de rasgos usando una medida de similitud o de distancia. Es necesario, por tanto, tener definida la función de pesado y la función de similitud o distancia (que pueden estar restringidas según el modelo usado).

1.1 Tipos

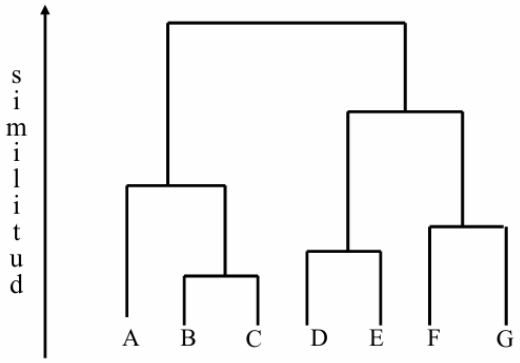
Existen dos tipos de clustering:

- **Duro**. Un objeto pertenece a un único cluster. También se denomina clustering exclusivo.
- **Suave**. A cada objeto se le asigna una probabilidad de perteneces a un clúster en concreto, pero sin asignar ninguno. Se denomina clustering solapado.

En función de las características de los clusters, los métodos de clustering también se pueden clasificar en:

- **No jerárquicos**: los objetos se organizan en clústeres que no tienen ninguna relación entre ellos. Se usa una medida de competencia para un clúster y se busca la optimización de esta. Generalmente las medidas definidas son la heterogeneidad, que se busca minimizar, y la separación, que se busca maximizar.
- **Jerárquicos**: Los objetos están organizados en una jerarquía de grupos, que puede ser una jerarquía de más general a más específico (métodos divisivos)

o viceversa (métodos aglomerativos). A la jerarquía de clústeres se le denomina **dendograma**.



Se puede definir que granularidad se quiere tener a la hora de realizar la separación o la unión.

  - **Aglomerativos**: en cada paso los clústeres se van uniendo según la similitud. Se llega a un punto donde todos los objetos perteneces al mismo clúster. La forma de unir los clústeres es usando una métrica de enlace o conexión. Las principales son: enlace simple (op = mínimo), promedio y completo (op = máximo). Si C_i son clústeres, la métrica entre dos clústeres se definiría tal que:

    $$d(C_1, C_2) = op\{d(x, y) | x \in C_1, y \in C_2\}$$

    El objetivo es, a partir de una matriz de distancias, ir haciendo parejas hasta que solo quede un clúster.
  - **Divisivos**: en cada paso los clústeres se van dividiendo según se optimice la función criterio. Tiene la ventaja que se puede decidir en qué nivel parar.
- **Basados en modelos estadísticos**: los datos se modelan utilizando un modelo estadístico estándar para trabajar con distribuciones.
  - **Topic model**: Se asume que, si un documento trata sobre un tema, habrá palabras que aparezcan con mayor o menor frecuencia si están relacionadas con dicho tema. Cada documento tiene una lista de temas con un porcentaje asociado. El LDA es un modelo de este tipo.

Otra forma de clasificación de los algoritmos de clustering es:

- **Modelos de conectividad**: los puntos más cercanos en el espacio presentan más similitudes entre sí que los más lejanos. Los algoritmos jerárquicos pertenecen a este tipo de modelos. Los dos enfoques son:
  - **Abajo arriba**: todos los puntos pertenecen a un grupo formado por ellos mismos. Se van uniendo grupos según aumenta la distancia límite

    - **Arriba abajo**: todos los puntos se clasifican en un mismo grupo y se va haciendo subdivisiones según aumenta la disminuye la distancia límite entre puntos.
- **Modelos de centroides**: algoritmos iterativos de agrupación donde la similitud deriva de cuán cerca se encuentren a un elemento representativo del clúster, el centroide. En este tipo de algoritmos necesitan indicar el número de clústeres a utilizar.
- **Modelos distribucionales**: se basan en la noción de cuán probable es que todos los puntos del clúster pertenezcan a la misma distribución. Suelen sufrir sobreajuste.
- **Modelos basados en densidad**: se busca áreas en el espacio con diferentes densidades y se aíslan los puntos dentro de dichas áreas, asignándolos al mismo clúster. El algoritmo DBSCAN pertenece a este tipo de modelos.
- **Algoritmos iterativos de reubicación**: son algoritmos no jerárquicos. Dado un criterio de competencia de una partición de n objetos y c clústeres hay dos fases: partición inicial y las transformaciones para cambiar la partición. La partición inicial se puede hacer de manera aleatoria o usando un conjunto de puntos representativos de los c clústeres. A partir de un proceso de transformaciones se van reasignando clústeres a los datos y recalculando los centros hasta que se alcance el mínimo del criterio de competencia. El k-means se trata de un algoritmo de este tipo.

1.2 Evaluación

Existen medidas intrínsecas y extrínsecas.

Las intrínsecas se basan en los propios objetos agrupados, asignando mejor puntuación a los clústeres más homogéneos y con mayor separación. Una puntuación alta no implica una aplicación efectiva. La silueta o el índice de Davies-Bouldin se trata de medidas de este tipo.

Las extrínsecas se basan en calcular como se ajustan los clústeres calculados en función de un conjunto de referencia, denominado *gold standard*. Los gold standard son realizados por humanos. Se suelen usar las medidas relacionadas con la matriz de confusión, bien haciéndolos en función de todos los valores (**microaveraging**) o de las diferentes categorías y después computando la media (**macroaveraging**). También se usa el **índice de Rand ajustado**.

2. Clasificación

Es la tarea por la que un documento de etiqueta como perteneciente a un determinado conjunto y otro. Si se tienen $C = \{c_1, \dots, c_n\}$ categorías, el clasificador podrá determinar para cada par de documento y categoría si dicho documento

pertenece a dicha categoría. También se puede determinar la categoría directamente.

En la clasificación supervisada, la representación de las clases se realiza mediante descriptores de clase, sobre los que se genera un clasificador. Estos descriptores de clases se crean usando un conjunto de documentos de los cuales se conocen su clase.

En la clasificación semisupervisada se usan datos no etiquetados para refinar una estimación inicial obtenida a partir de unos datos etiquetados. Dentro de este tipo de clasificación se encuentra la supervisión distante, donde se tiene un conjunto pequeño etiquetado que se utiliza para etiquetar uno más grande mediante el uso de heurísticas. Estas heurísticas deben asumir que hay ruido en el etiquetado.

1.2 Tipos

Hay diferentes formas de clasificar las tareas de clasificación:

- Según la etiqueta:
  - **Monoetiqueta**: cada documento solo tiene una asignado una etiqueta. Se trata de una clasificación binaria.
  - **Multietiqueta**: cada documento puede tener varias etiquetas. Se puede basar en una clasificación binaria si se asigna un booleano a cada par documento-clase.
- Según la forma de asignar la etiqueta:
  - **Hard**: se decide o no si el documento pertenece a la categoría.
  - **Ranking**: se da un ranking de cada categoría según la adecuación.
- Según el tipo de información utilizada:
  - **Fastfeature**: cuando no se tiene información externa.
  - **Fullfeature**: cuando se emplean características adicionales.

1.2 Algoritmos

Los principales algoritmos que existen para clasificar instancias, y en este caso documentos son:

- **Naïve Bayes**: basado en la teoría de decisión de Bayes. Se calcula la probabilidad a posteriori de darse la clase una vez se del documento.

  $$P(c_k|d_i) = \frac{P(d_j|c_k)P(c_k)}{P(d_j)}$$

  El término $P(d_j|c_k)$ se puede calcular también mediante la asunción del principio de independencia entre rasgos. Es decir

$$P(d_j|c_k) = \prod_{i=1}^{N_j} P(\vec{t_i}|c_k)$$

La diferencia entre algoritmos naïve bayes vendrá dada por la distribución usada para estimar $P(\vec{t_i}|c_k)$ (la probabilidad del rasgo dada la clase)

- **Árboles de decisión**: los nodos internos son umbrales de características que deciden que rama escoger hasta llegar a una hoja, que representa una clase. Cuando la variable objetivo toma valores continuos se denominan árboles de regresión.
- **Máquinas de vectores de soporte**: En espacios de dimensión T, siendo el número de términos de la colección, se busca una hipersuperficie que separe el conjunto de ejemplos positivos (perteneces a la clase) de los negativos. Esta hipersuperficie se determina con los vectores de soporte. Se escogerán aquellos que hagan máximos los márgenes entre la hipersuperficie y las clases. Como las clases pueden tener una separación no necesariamente lineal, se puede especificar la función del kernel de forma que trasnforma el espacio vectorial a otro de mayor dimensión. Las principales funciones son:
    - **Lineal**. La función básica
    - **Polinomial**. Transforma el espacio a uno de dimensión n.
    - **Funciones de base radial**.
    - **Sigmoidea**.
- **Redes neuronales**: son capaces de aprender cualquier tipo de función. Consiste en un conjunto de neuronas conectadas que se transmiten señales entre sí, y operando con dichas señales. Los principales algoritmos de machine learning son: perceptrón, perceptrones multicapa, etc.
- **Deep learning**: son modelos de machine learning mucho más complejos y con más capas de neuronas. Algunos algoritmos son: redes neuronales convolucionales, redes neuronales recurrentes, LSTM, auto-encoders, etc. Un caso de deep learning son los trasnformers.

1.2.1 Transformers

Son modelos formados por encoders y decoders a través de los cuales va fluyendo la entrada. La entrada y salida suele ser texto. La idea más natural es su uso para traducciones.

Los encoders y los decoders permiten determinar las partes más relevantes de un texto y aprender las relaciones de contexto entre las palabras. El encoder recorre la entrada y la codifica en un vector denominado vector de contexto. El decoder lee el vector de contexto para generar el texto objetivo.

Estos modelos permiten el procesamiento del texto de forma independiente al orden de las palabras, es decir, en paralelo.

El encoder y el decoder pueden utilizarse de forma independiente dando lugar a diferentes tipos de modelos:

- **De solo codificadores o autocodificación**: para tareas de clasificación de oraciones y reconocimiento de entidades nombradas. Suelen tener una atención bidireccional. Se encuentran modelos como BERT, DistilBERT, etc.
- **De solo decodificadores o autorregresivos**: para tareas generativas de texto. En cada etapa las palabras solo pueden acceder a las palabras anteriores. Se encuentran modelos como GPT, GPT-2, etc.
- **Codificador-decodificador o modelos secuencia a secuencia**: para tareas generativas a partir de una entrada, como la traducción o la generación de resúmenes. Se encuentran modelos como BART, mBART, etc.

Muchos de los trasnformers existentes se han entrenado con grandes cantidades de texto en crudo de forma autosupervisada. Este tipo de aprendizaje consiste en calcular automáticamente el objetivo a partir de las entradas del modelo, sin anotaciones manuales.

Este tipo de modelos desarrolla una compresión estadística de la lengua, pero puede no llegar a ser suficiente para tareas específicas. Para ello se utiliza el aprendizaje por transferencia con anotaciones.

2. Clasificación

Para evaluar la salida del sistema se suele usar un gold standard usando una tabla de contingencia o matriz de confusión:

	Real positivo	Real negativo
Predicho positivo	VP	FP
Predicho negativo	FN	VN

A partir de esta matriz se sacan métricas como la exactitud (total de aciertos entre total de objetos) o el error (opuesto del acierto), además de las clásicas precisión, recall y medida-F.