TEMA 5

Las principales aplicaciones de la minería de texto.

1. Análisis de sentimientos

También se le llama minería de opinión. Consiste en la extracción de información subjetiva sobre un evento, producto, entidad y sus atributos. Este problema se aborda como un problema de clasificación de un texto en una polaridad positiva, negativa o neutra, generalmente usando la escala 1-5. Al ser una tarea bastante complicada, a más corto sea el texto y menos explícito/formal, más difícil resulta.

La minería de opinión se utiliza fundamentalmente para la toma de decisión: elección de servicio, política de mercadotecnia de una empresa, predicción de tendencias en elecciones, identificación de eventos relevantes para los usuarios, etc.

Es importante determinar la entidad la entidad de la que se está opinando, así como sus aspectos y atributos. El contexto de la entidad es muy importante para determinar la opinión, pues un aspecto o atributo puede tener un significado positivo o negativo acerca de la entidad según la intención del mensaje o a lo que se esté referenciando. También es posible encontrar dentro de una misma oración comentarios positivos y negativos.

Hay principalmente dos enfoques para la minería de opinión:

- Semántico.
- Aprendizaje automático.

1.1 Enfoque semántico

Consiste en usar diccionarios de términos con valoración semántica de polaridad. El procedimiento general de este enfoque consiste en separar el texto por palabras, eliminar las palabras vacías, el resto se normalizan a nivel léxico y se comprueba si aparecen en el diccionario para asignar el valor de la polaridad. Para saber la polaridad del texto se suman las polaridades independientes.

Los términos modificadores (principalmente adverbios) y lo términos inversores o negadores tienen efecto sobre los valores de polaridad de las palabras a las que acompañan.

La principal ventaja es que algunos de los errores que se comenten se pueden solucionar usando diccionarios más completos, mientras que esto mismo es una de sus principales desventajas, pues la construcción de estos diccionarios es un trabajo manual costoso.

1.2 Enfoque aprendizaje automático

En este enfoque se entrena un clasificador a partir de una colección de textos anotados con polaridad, normalmente representados con un vector de palabras, n-gramas o skip-gramas, con características semánticas que modelan la estructura semántica de las palabras.

La principal ventaja es que cuesta muy poco construir estos modelos, aunque suelen ser cajas negras en las que corregir errores o añadir nuevo conocimiento suele requerir ampliar la colección de textos etiquetados y reentrenar el modelo.

En este enfoque también se necesita esfuerzo humano para anotar los textos, aunque puede ser medianamente llevado a cabo por sistemas semisupervisados.

El uso de transformers ha mejorado notablemente los resultados del análisis de texto.

2. Análisis de tendencias

Las tendencias son temas candentes que provocan un interés extraordinario de forma temporal en una comunidad de usuarios de una red social. Una tendencia no puede ser un tema candente en el tiempo, sino que debe surgir de forma repentina, durar un tiempo y posteriormente dejar de hablar de ella. Normalmente se usa para detectar emergencias o noticias, o para la gestión de reputación en el momento actual.

Las principales técnias de detección de tendencias están relacionadas con el clustering, como el LDA, el K-means y el LSH. Otras técnicas utilizadas son el análisis de frecuencias, que consiste en buscar términos cuya frecuencia aumenta de forma repentina. Estas técnicas requieren llevar un historial de frecuencias por término para descubrir tendencias. Una de las opciones es usar la divergencia de Kullback-Leibler, que compara las frecuencias del término en el momento actual con la de los momentos anteriores. Si esa comparación sale elevada se considera que el término es tendencia.

En el análisis de tendencias hay que considerar:

- **La temporalidad**: si se hace sobre un stream de datos (conocer la tendencia en el presente) o de forma offline sobre una colección (conocer la tendencia en el pasado).
- **Aprendizaje**: si se usa aprendizaje supervisado o no supervisado.
- **Los tipos de tendencia**.