Aprendizaje Automático II

Práctica 1 - Algoritmos Ensembles

Manuel Castillo Cara / Luis Sarro

Enero 2026

Introducción

En este documento se presenta la primera actividad de la asignatura Aprendizaje Automático II, del Máster en Ingeniería y Ciencia de Datos. Esta actividad abarca los siguientes temas:

1. Bosques Aleatorios.
2. Intensificación de Gradiente.
3. Aprendizaje Conjunto.

Antes de su realización, se asume que el alumnado ha completado las lecturas indicadas en la guía de la asignatura sobre cada uno de los temas. Aunque no son obligatorias, la realización de las prácticas de programación disponibles en el aula virtual será de gran ayuda para la realización de la PEC.

El objetivo de esta actividad es que el alumnado ponga en práctica los contenidos teóricos/prácticos relativos a los algoritmos ensembles para consolidar su conocimiento de estas técnicas. Es importante destacar que, como ocurre en el resto de las actividades evaluables de esta asignatura, lo crucial no es tanto resolver un problema propuesto por el equipo docente, sino demostrar que se han comprendido e interiorizado los diversos aspectos clave de las técnicas que se ponen en juego.

Cómo desarrollar la PEC

En cuanto al software utilizado para realizar la actividad, el equipo docente recomienda el uso de `Scikit-learn` (sobre Python) por su facilidad de uso, aunque no es obligatorio y es posible elegir otras alternativas, tanto en el uso de librerías como uso de otros lenguajes de programación. Se recomienda encarecidamente realizar las prácticas de programación, ya que suponen la comprensión de cómo implementar la práctica en Python. Además, recordamos que las prácticas de programación se han trabajado intensivamente con esta librería, que incluye la gran mayoría de los algoritmos ensembles.

Por tanto, para quienes no tengan experiencia previa, se recomienda, como primer paso para el desarrollo de esta práctica, seguir las prácticas de programación que se encuentran en el mismo aula virtual. Así mismo, podrán utilizar otros lenguajes de programación o librerías con las que se encuentren más cómodos para desarrollar la PEC. En tal caso, a fin de compartir experiencias, se sugiere al alumnado que abra un hilo en el foro y exponga los motivos de tal decisión y las posibles ventajas de esas alternativas.

Datasets con los que trabajar la PEC

El equipo docente pone a disposición del alumnado un conjunto de datasets que han sido trabajados anteriormente tanto por nosotros como por la comunidad, para que pueda seleccionar uno de

ellos. Para la práctica, se trabajará **un único dataset** de entre todos los disponibles, el cual deberá entender en su contexto y desarrollar en la PEC. En este sentido, a continuación se presentan un conjunto variado de datasets:

- https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+%28Diagnostic%29
- https://archive.ics.uci.edu/dataset/471/electrical+grid+stability+simulated+data
- https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients
- https://archive.ics.uci.edu/ml/datasets/Wine+Quality
- https://archive.ics.uci.edu/dataset/162/forest+fires
- https://archive.ics.uci.edu/ml/datasets/Air+quality
- https://archive.ics.uci.edu/ml/datasets/HCV+data
- https://archive.ics.uci.edu/ml/datasets/Statlog+%28Image+Segmentation%29
- https://archive.ics.uci.edu/dataset/329/diabetic+retinopathy+debrecen
- https://archive.ics.uci.edu/ml/datasets/Bike+Sharing+Dataset
- https://archive.ics.uci.edu/ml/datasets/Appliances+energy+prediction
- https://archive.ics.uci.edu/ml/datasets/QSAR+aquatic+toxicity
- https://archive.ics.uci.edu/dataset/31/covertype
- https://www.kaggle.com/datasets/camnugent/california-housing-prices

Adicionalmente, desde el equipo docente exponemos que la elección de los datasets es totalmente libre, es decir, el alumnado podrá seleccionar cualquier otro dataset en formato tabular que considere interesante. **Importante: Eso sí, antes de realizar cualquier tipo de elección propia de un dataset que no sea los expuestos anteriormente, se debe subir al foro para poder evaluarlo previamente**.

Especificación de la tarea

A partir del conjunto de datos que se haya escogido para la tarea, se propone el desarrollo de un proyecto de machine learning completo. La idea es realizar todas las fases de un proyecto de machine learning, poniendo un énfasis en el desarrollo de la fase de modelado con los algoritmos ensembles vistos en las unidades 1, 2 y 3. Así, las diferentes fases a realizar serán:

- Fase de análisis de datos.
- Fase de preprocesamiento de datos.
- Fase de modelado.
- Fase de optimización.
- Explicabilidad e interpretabilidad.

IMPORTANTE: Aunque se deberá exponer en la práctica el código, no se calificará el mismo, sino que se calificarán el análisis crítico de los resultados, la discusión en la salida del código y visualizaciones y, sobre todo, la discusión crítica y el hilo argumental que el alumnado proporcione.

Fase de análisis y procesamiento de datos

Esta fase sienta las bases del modelado: permite **entender** el dataset seleccionado para la PEC1 y **prepararlo** para que los modelos aprendan de forma fiable. El trabajo se organiza en tres bloques:

- **Estadística descriptiva.** Calcular y comentar medidas de tendencia central (media, mediana, moda), dispersión (desviación estándar, IQR), asimetría/curtosis y tablas de frecuencia. Indicar tipos de variables (numéricas/categóricas), tamaño muestral y posibles anomalías iniciales.
- **Visualización de datos.** Usar gráficos apropiados para cada variable y objetivo: histogramas/densidades, boxplots (detección de atípicos), scatterplots y pairplots (relaciones bivariantes), mapas de calor de correlación (multicolinealidad), countplots para clases. Incluir al menos una figura que **relacione** variables clave con el *target*.
- **Procesamiento de datos.** Preparar el dataset para el modelado documentando cada decisión:
  - *Calidad de datos:* detección y tratamiento de valores perdidos (imputación), outliers (reglas IQR/Z-score o robustas) y registros inconsistentes.
  - *Transformaciones:* escalado (estandarización/normalización), transformaciones log/Box-Cox/Yeo–Johnson cuando proceda, codificación de categóricas (one-hot/ordinal) y tratamiento de fecha/hora.
  - *Desbalance de clases (si aplica):* ponderación de clases, *resampling* (undersampling/SMOTE, etc.) y métricas adecuadas.
  - *Reducción/selección (opcional y justificada):* PCA u otras técnicas, *feature importance/feature selection* (p. ej., árboles/ExtraTrees). Explicar el criterio y el impacto en el rendimiento.

Ejemplos de aspectos a discutir: tipo de problema (clasificación/regresión), distribución de variables, presencia e impacto de outliers, grado de desbalance, multicolinealidad, y cómo cada decisión de procesado mejora la *calidad modelizable* de los datos.

IMPORTANTE. Se han puesto y detallado varias técnicas, eso no quiere decir que haya que utilizar todas o la mayoría. La evaluación no premiará la *cantidad* de técnicas, sino su *pertinencia y justificación*. Cada paso debe motivarse (por qué), describirse (cómo) y evaluarse (impacto en métricas/estabilidad). Evitad aplicar métodos de forma mecánica sin evidenciar su utilidad.

Fase de modelado

En esta fase se abordará el trabajo con algoritmos *ensemble*, con el objetivo de comparar su rendimiento y seleccionar los mejores candidatos para la fase posterior de optimización. El propósito principal es identificar, a partir de un análisis tanto cuantitativo como cualitativo, los cinco modelos que ofrezcan mejores resultados sobre el conjunto de datos elegido.

Se espera que el estudiante experimente con diferentes algoritmos, aplicando las tres taxonomías de *ensembles* estudiadas en el curso: **Bagging**, **Boosting** y **Voting**. De esta manera, no solo se busca evaluar su capacidad predictiva, sino también desarrollar un criterio crítico sobre la idoneidad de cada enfoque para el problema en cuestión.

Al finalizar esta fase, se deberá contar con un conjunto reducido de modelos candidatos, cuya elección esté debidamente justificada en base a las métricas de evaluación y a las características propias de los datos.

Fase de optimización

La fase de optimización constituye un paso esencial en el proceso de aprendizaje automático, pues resulta determinante para mejorar el rendimiento de los modelos y garantizar su capacidad

de generalización. En esta etapa se seleccionarán los cinco modelos *ensemble* con mejor desempeño (tanto cuantitativo como cualitativo) con el fin de ajustar sus hiperparámetros y maximizar su robustez.

Para este propósito, se recomienda emplear técnicas de búsqueda y validación de hiperparámetros tales como la validación cruzada, la búsqueda en cuadrícula (*grid search*), la búsqueda aleatoria (*random search*) o enfoques más avanzados, como la optimización bayesiana. Estas metodologías permiten explorar combinaciones de hiperparámetros y seleccionar aquellas que proporcionen mejoras significativas en el modelo.

Es fundamental que el proceso de optimización se documente adecuadamente. Se debe justificar por qué se han elegido determinados hiperparámetros frente a otros y explicar cómo los cambios introducidos afectan al rendimiento del modelo. Más allá de aplicar un gran número de configuraciones de manera mecánica, se espera que el estudiante demuestre criterio analítico, valorando cuáles ajustes aportan un beneficio real y cuáles no tienen impacto relevante.

En este sentido, la evaluación no se centrará en la cantidad de técnicas aplicadas, sino en la pertinencia de las mismas, así como en la capacidad de argumentar y reflexionar sobre los resultados obtenidos. El objetivo es que el alumno desarrolle una visión crítica y sea capaz de identificar configuraciones que optimicen el modelo sin sacrificar interpretabilidad ni estabilidad.

Explicabilidad e interpretabilidad en *Ensemble*

En esta fase, el objetivo es que los estudiantes exploren y discutan cómo los modelos *ensemble* pueden ser interpretados y explicados. A menudo, la alta complejidad de estos modelos dificulta comprender cómo llegan a una predicción, por lo que resulta fundamental aplicar técnicas de explicabilidad que ayuden a entender qué factores influyen en las decisiones del modelo.

Se recomienda utilizar metodologías consolidadas como SHAP (*SHapley Additive exPlanations*) [1], o cualquier otra técnica relevante que permita obtener una visión clara y práctica sobre la importancia de las variables y el comportamiento de los modelos.

- **Implementación de técnicas de explicabilidad**: Aplicar una o más técnicas de explicabilidad al modelo *ensemble* desarrollado en la práctica. Esto puede incluir la generación de gráficos SHAP[1] [1] o la adopción de técnicas adicionales de interpretación global o local.
- **Análisis crítico**: Reflexionar sobre los resultados obtenidos. Por ejemplo, algunas preguntas que podemos hacernos (aunque no todas y tenéis que investigar): ¿Qué atributos son más influyentes en las predicciones del modelo? ¿Cómo varía su importancia según distintas instancias del conjunto de datos? ¿Existen diferencias en la relevancia de las variables según las clases en un problema de clasificación? La discusión debe poner en valor no solo qué resultados se obtienen, sino cómo se interpretan y qué implicaciones tienen.
- **Visualización**: Presentar los resultados de manera clara y comprensible. Se pueden utilizar gráficos de importancia de características, gráficos de dependencia parcial o cualquier otra visualización que facilite la interpretación de las decisiones del modelo.

IMPORTANTE: La evaluación no se centrará en el número de técnicas aplicadas, sino en la pertinencia de las mismas y en la capacidad de analizarlas de forma crítica. Aplicar múltiples técnicas sin justificación o sin extraer conclusiones claras no aporta valor. Lo relevante es demostrar criterio a la hora de seleccionar las herramientas de explicabilidad y saber argumentar los hallazgos obtenidos.

Conclusiones

Esta sección debe recoger las principales conclusiones del trabajo realizado, con un enfoque no solo en los resultados cuantitativos obtenidos, sino también en una reflexión crítica sobre el proceso

[1] https://shap.readthedocs.io/en/latest/

seguido. El objetivo no es simplemente resumir lo hecho, sino ofrecer un **análisis razonado y sintético** que ponga en perspectiva tanto los logros alcanzados como las limitaciones encontradas.

Algunos aspectos clave a incluir son:

- **Resumen de hallazgos relevantes:** Identificar qué técnicas *ensemble* han mostrado un mejor rendimiento, en qué condiciones y por qué. Se espera una justificación que conecte los resultados con los fundamentos teóricos revisados en el curso.
- **Fortalezas y limitaciones:** Reflexionar sobre posibles debilidades del estudio, como características del dataset, del enfoque de modelado o de la capacidad de generalización de los modelos aplicados.
- **Implicaciones prácticas:** Explicar qué enseñanzas aportan los resultados respecto al uso real de modelos *ensemble* en contextos similares, señalando posibles aplicaciones en entornos profesionales o de investigación.
- **Líneas de mejora y futuro:** Proponer acciones para optimizar el *pipeline*, explorar nuevas estrategias de modelado o incorporar otros algoritmos que permitan superar las limitaciones detectadas.

Las conclusiones deben reflejar una visión **global y crítica** del proyecto, vinculando los resultados con los conceptos del curso y aportando ideas claras sobre cómo avanzar hacia trabajos futuros más sólidos y enriquecedores.

Entregable

El entregable constará de una **memoria de un máximo de 10 páginas**, con tamaño de fuente 12pt, en la que se presenten los experimentos realizados y las conclusiones derivadas de los mismos. Dentro de este límite deben incluirse las figuras más relevantes, por lo que se recomienda centrar el contenido en los aspectos fundamentales de la práctica, evitando extenderse en definiciones o conceptos ampliamente conocidos. En caso necesario, se podrán emplear **Anexos** para incorporar figuras, imágenes o fragmentos de código que complementen la discusión del texto principal.

Adicionalmente, será obligatorio entregar el **Notebook con el código fuente**, que deberá contener una breve descripción en cada sección para contextualizar las celdas de código y facilitar la comprensión del flujo de trabajo.

IMPORTANTE: La memoria deberá seguir estrictamente la estructura definida en el Cuadro 1, de manera que todos los apartados sean abordados de forma clara, ordenada y sistemática. La calidad de la discusión, la justificación de las decisiones tomadas y el rigor en el análisis serán los elementos más valorados.

Evaluación

Cuadro 1: Rúbrica o distribución de puntos para la evaluación.

Concepto	**Puntos**
1. Fase de análisis y procesamiento de datos	1
2. Fase de modelado	3
3. Fase de optimización	2
4. Explicabilidad e interpretabilidad en Ensemble	3
5. Conclusiones	1

La evaluación se basará exclusivamente en la memoria entregada, siguiendo la rúbrica indicada en el Cuadro 1. La nota máxima será de 10 puntos, siendo necesario obtener al menos 5 para superar la práctica.

Se valorará de manera prioritaria la **capacidad de análisis crítico**, la conexión de los resultados con la teoría y la bibliografía, así como la reflexión sobre las limitaciones y alcances del trabajo. También se tendrá en cuenta la claridad expositiva, la coherencia argumentativa y la corrección ortográfica.

No se deben incluir definiciones ni formalizaciones matemáticas ampliamente conocidas. Lo que se espera es una **discusión técnica y crítica** de los resultados, mostrando un manejo sólido de los contenidos y la capacidad de aplicarlos con criterio en un caso práctico.

Como punto final, se recomienda que la extensión de la memoria guarde una proporción razonable con el peso de cada apartado en la rúbrica. Por ejemplo, si la *Fase de análisis y procesamiento de datos* puntúa 1, lo ideal es que se desarrolle en aproximadamente una página. De forma análoga, los apartados con mayor puntuación podrán ocupar más espacio, en consonancia con su relevancia en la evaluación. Este criterio busca favorecer la claridad, la concisión y la adecuada distribución del esfuerzo a lo largo de todo el trabajo.

Referencias

[1] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in neural information processing systems*, 30, 2017. https://doi.org/10.48550/arXiv.1705.07874.