Aprendizaje Automático II

Práctica 2 - Aprendizaje No Supervisado

Manuel Castillo Cara / Luis Sarro

Enero 2026

Introducción

En este documento se presenta la segunda actividad de la asignatura Aprendizaje Automático II, del Máster en Ingeniería y Ciencia de Datos. Esta actividad abarca el Tema 4: Aprendizaje No Supervisado.

Antes de su realización, se asume que el alumnado ha completado las lecturas indicadas en la guía de la asignatura sobre cada uno de los temas. Aunque no son obligatorias, la realización de las prácticas de programación disponibles en el aula virtual será de gran ayuda para la realización de la PEC2.

El objetivo de esta actividad es que el alumnado ponga en práctica los contenidos teóricos/prácticos relativos al aprendizaje no supervisado para consolidar su conocimiento de estas técnicas. Es importante destacar que, como ocurre en el resto de las actividades evaluables de esta asignatura, lo crucial no es tanto resolver un problema propuesto por el equipo docente, sino demostrar que se han comprendido e interiorizado los diversos aspectos clave de las técnicas que se ponen en juego.

Cómo desarrollar la PEC

En cuanto al software utilizado para realizar la actividad, el equipo docente recomienda el uso del lenguaje de programación Python por su facilidad de uso, aunque no es obligatorio y es posible elegir otras alternativas, tanto en el uso de librerías como uso de otros lenguajes de programación. Se recomienda encarecidamente realizar las prácticas de programación, ya que suponen la comprensión de cómo implementar la práctica en Python. Además, recordamos que las prácticas de programación se han trabajado intensivamente la gran mayoría de los algoritmos clustering.

Por tanto, para quienes no tengan experiencia previa, se recomienda, como primer paso para el desarrollo de esta práctica, seguir las prácticas de programación que se encuentran en el mismo aula virtual en Python. Así mismo, y como se ha comentado anteriormente, podrán utilizar otros lenguajes de programación o librerías con las que se encuentren más cómodos para desarrollar la PEC2. En tal caso, a fin de compartir experiencias, se sugiere al alumnado que abra un hilo en el foro y exponga los motivos de tal decisión y las posibles ventajas de esas alternativas.

Datasets con los que trabajar la PEC

En este caso el equipo docente recomienda utilizar el dataset ya antes escogido en la PEC1. A ese dataset se le quitaría la variable `Target` y, únicamente, se utilizarían las variables características.

Adicionalmente, desde el equipo docente exponemos que la elección de los datasets es totalmente libre, es decir, el alumnado podrá seleccionar cualquier otro dataset en formato tabular que considere interesante. **Importante:** Eso sí, antes de realizar cualquier tipo de elección propia de un dataset que no sea los expuestos anteriormente, se debe subir al foro para poder evaluarlo previamente.

Especificación de la tarea

En esta práctica se propone resolver un proyecto de aprendizaje no supervisado utilizando **tres técnicas de clustering**. El alumnado podrá seleccionar los algoritmos concretos a emplear (por ejemplo, K-means, mezclas de Gaussianas, clustering jerárquico (ya sea aglomerativo o divisivo), entre otros), siempre y cuando justifique adecuadamente la elección realizada.

El desarrollo puede llevarse a cabo en cualquier lenguaje de programación. No obstante, en caso de utilizar *Python*, el equipo docente podrá proporcionar un mayor apoyo para identificar los paquetes de software más apropiados.

Como parte esencial del proyecto, deberá realizarse un análisis del número de grupos presentes en el conjunto de datos, empleando para ello las técnicas habituales en la disciplina. Se recomienda la lectura del documento de referencia en la bibliografía base[1] [1] y la selección de al menos **tres métricas de validación interna**. A partir de estas métricas, se deberá determinar el número óptimo de clusters y justificar de manera crítica las conclusiones obtenidas. Para ello, se podrán emplear librerías del lenguaje elegido que implementen dichas métricas (muchas de ellas ya han sido introducidas en las prácticas de programación previas).

La práctica se estructurará en los siguientes apartados:

- **Análisis exploratorio de datos**.
- **Análisis cuantitativo del problema**.
- **Análisis cualitativo del problema**.
- **Conclusiones**.

IMPORTANTE: Aunque se incluirá el código empleado en el cuaderno de trabajo, i.e., Notebook, este **no será objeto de calificación directa**. La evaluación se centrará en la capacidad de análisis crítico, en la discusión científica y técnica de los resultados, en la interpretación de las visualizaciones, y en la solidez del hilo argumental desarrollado a lo largo de la memoria que se entregará en PDF. Se valorará especialmente la justificación de las decisiones metodológicas y la reflexión crítica sobre los hallazgos.

Análisis Exploratorio de Datos

En esta fase se deberá realizar un **análisis exploratorio del conjunto de datos**, presentando en un máximo de una páginas las características más relevantes del mismo. El análisis deberá incluir las gráficas que se consideren más ilustrativas, cuidando especialmente la presentación y la legibilidad de los resultados.

IMPORTANTE: Este análisis exploratorio no puede ser una repetición del realizado en la PEC1. Aquí se trabaja con un **problema de Aprendizaje No Supervisado**, por lo que el tipo de análisis, la discusión y las técnicas empleadas deberán adaptarse a este enfoque. Se espera que el estudiante explore y justifique cuestiones como:

- posibles estructuras latentes en los datos,
- similitudes o diferencias entre instancias,
- relaciones entre variables sin referencia a etiquetas de clase,
- detección de patrones o agrupamientos potenciales.

En todo momento, se debe justificar la pertinencia de las técnicas utilizadas y reflexionar críticamente sobre cómo estas aportan al entendimiento del problema desde la perspectiva del Aprendizaje No Supervisado.

Extensión recomendada: esta parte de la memoria deberá ocupar como máximo 1 páginas. Recordamos que se puede agregar al Anexo algún artefacto secundario para entender la sección.

[1] https://arxiv.org/abs/1905.05667

Análisis cuantitativo del problema

En esta fase se presentará una tabla que recoja, para cada técnica de clustering aplicada y para cada número de grupos comprendido entre 2 y 10, los valores obtenidos con las **métricas de evaluación interna** seleccionadas. Estas métricas deberán haber sido previamente definidas y justificadas en la memoria.

El análisis no debe limitarse a mostrar qué técnica alcanza el valor más alto en una métrica concreta. Se espera un **estudio crítico y científico** que explore el porqué de dichos resultados, por ejemplo:

- ¿Qué características de los datos favorecen a un algoritmo frente a otro?
- ¿Cómo evoluciona cada métrica al aumentar el número de clústeres?
- ¿Existen inconsistencias entre métricas distintas y cómo se interpretan?
- ¿Qué implicaciones tienen estos resultados para la comprensión de la estructura de los datos?

La reflexión debe ir más allá de lo meramente numérico, estableciendo conexiones entre los resultados observados y la naturaleza del dataset, así como con las propiedades de los algoritmos empleados.

Extensión recomendada: esta parte de la memoria deberá ocupar como máximo 2 páginas, incluyendo tanto la tabla de resultados como la discusión asociada. Recordamos que se puede agregar al Anexo algún artefacto secundario para entender la sección.

Análisis cualitativo del problema

En esta fase se debe realizar un **análisis interpretativo** de los resultados obtenidos, complementando el estudio cuantitativo previo. Mientras que en la parte anterior el foco estuvo en las métricas y su comparación numérica, aquí lo relevante es discutir la **adecuación de cada técnica de clustering** a las características del dataset y reflexionar sobre las implicaciones de su uso.

Este análisis podría incluir aspectos como:

- La justificación de los parámetros seleccionados para cada algoritmo y su influencia en los resultados.
- La valoración de la coherencia entre los resultados de validación interna y la estructura real de los datos observada en el análisis exploratorio.
- Una reflexión sobre posibles limitaciones de cada técnica frente al conjunto de datos empleado (e.g., sensibilidad a outliers, escalado de variables, forma de los clústeres).
- El impacto de diferentes estrategias de tratamiento de datos ausentes (eliminación vs. imputación) y cómo afectan a la calidad de los clústeres.

La discusión debe ser **rigurosa y concisa**, priorizando los aspectos más relevantes y evitando descripciones mecánicas. El objetivo es demostrar una comprensión profunda de cómo y por qué cada técnica funciona (o no) en el problema concreto, más allá de los simples valores de las métricas.

Extensión recomendada: esta parte de la memoria deberá ocupar como máximo 2,5 páginas. Recordamos que se puede agregar al Anexo algún artefacto secundario para entender la sección.

Conclusiones

En esta sección final deben exponerse las **conclusiones más relevantes** del trabajo realizado. No se trata únicamente de resumir los resultados obtenidos, sino de ofrecer una **reflexión crítica y razonada** que aporte valor añadido al análisis. El objetivo es demostrar que se ha comprendido

en profundidad tanto el problema como las técnicas aplicadas, conectando los hallazgos con las limitaciones y posibles líneas de avance.

Se recomienda que las conclusiones aborden, al menos, los siguientes aspectos:

- **Síntesis de los hallazgos clave:** Principales observaciones derivadas de los experimentos y del análisis realizado.
- **Fortalezas y limitaciones:** Aspectos que han funcionado bien y elementos mejorables, ya sea en los datos, en los algoritmos empleados, en las métricas utilizadas o en los supuestos del estudio.
- **Implicaciones prácticas o teóricas:** Relevancia de los resultados obtenidos en el contexto del problema trabajado y su posible aplicación en escenarios reales o académicos.
- **Propuestas de mejora y trabajo futuro:** Qué pasos se podrían seguir para ampliar o perfeccionar el análisis, incluyendo alternativas metodológicas o nuevos enfoques a explorar.

En definitiva, las conclusiones deben aportar una visión **global, crítica y sintética** del proyecto, destacando no solo lo conseguido, sino también la capacidad de reflexión y de proyección hacia posibles mejoras y líneas futuras de trabajo.

Extensión recomendada: esta parte de la memoria deberá ocupar como máximo 0,5 páginas. Recordamos que se puede agregar al Anexo algún artefacto secundario para entender la sección.

Especificaciones de la PEC

Se entregará una **memoria de 6 páginas** como máximo en formato PDF, con tamaño de fuente 12pt, en la que se dé cuenta de los experimentos realizados y las conclusiones que pueden extraerse de los mismos. En estas 6 caras de folio deben de entrar las figuras clave, por lo tanto, centraros en los conceptos a debatir y justificar en la práctica y no introducir conceptos ampliamente sabido. En todo caso, a continuación se exponen los puntos más relevantes para el desarrollo correcto de la PEC2:

- Se ha establecido una *extensión recomendada* como referencia orientativa. Esto no implica que debáis ceñiros estrictamente a dicha extensión, sino que tenéis libertad para ajustar la distribución: algunas secciones podrán ocupar más espacio y otras menos, siempre que el conjunto mantenga el equilibrio y la coherencia.
- Se deberá entregar también el Notebook con el código fuente. A fines de claridad este cuaderno deberá tener una descripción breve de lo que representan las celdas de código en cada parte.
- No poner definiciones ni formalización matemática ampliamente conocidas, lo que interesa es la discusión técnica y científica de los resultados que se van obteniendo y como se enlazan estos resultados con la teoría.
- Se pueden utilizar Anexos para el uso de Figuras o imágenes adicionales que puedan ser de interés en la discusión técnica y científica.
- Que las gráficas/imágenes no estén pixeladas ni sus textos deformados como resultado de recortarla de una captura de pantalla en lugar de volcarla a un fichero directamente desde el software en la que fue creada.
- Como podéis ver por la rúbrica en el Cuadro 1, nos interesan sobre todo vuestro análisis, de modo que centraos en ello.
- Lo más importante es que demostréis que habéis entendido los contenidos del tema y que los manejáis con soltura.

Evaluación

La rúbrica de evaluación, sobre 10 puntos, será la siguiente:

Cuadro 1: Rúbrica o distribución de puntos para la evaluación.

Concepto	**Puntos**
1. Análisis Exploratorio de datos	1
2. Análisis cuantitativo del problema	4
3. Análisis cualitativo del problema	4
4. Conclusiones	1

La evaluación de esta práctica estará basada exclusivamente en la memoria entregada, y se hará teniendo en cuenta la distribución de puntos mostrada en el Cuadro 1. La nota final máxima será de 10 puntos, y será necesario obtener al menos 5 para aprobar.

Nuevamente, incidimos en que se valorará particularmente la capacidad de análisis crítico y la puesta en juego de los conceptos, antecedentes y limitaciones presentadas en la bibliografía. También se valorará el estilo y la corrección ortográfica del texto.

Finalmente, no se deben incluir definiciones ni formalización matemática ampliamente conocidas. Lo que se valora es la discusión técnica de los resultados obtenidos y cómo se enlazan estos resultados con la teoría. Se debe centrar en la discusión crítica de los resultados obtenidos en la práctica y no en definiciones ampliamente conocidas. Lo más importante es que demostréis que habéis entendido los contenidos del tema y que los manejáis con soltura.

IMPORTANTE: Para asegurar una evaluación justa y coherente, es crucial que el alumnado siga estrictamente el orden y los puntos expuestos en el Cuadro 1. Esto garantizará que todos los aspectos importantes del proyecto sean abordados de manera completa y sistemática. La estructura y el contenido de la memoria deben reflejar claramente cada uno de los puntos mencionados, proporcionando un análisis detallado y crítico en cada sección.

Referencias

[1] Julio-Omar Palacio-Niño and Fernando Berzal. Evaluation metrics for unsupervised learning algorithms. *arXiv preprint arXiv:1905.05667*, 2019. https://doi.org/10.48550/arXiv.1905.05667.