UNED

Máster de Ingeniería y Ciencia de Datos

ETS de Ingeniería Informática

Deep learning 2 (DL 2)

Tipologías de las redes neuronales profundas

José Manuel Cuadra Troncoso

Índice

1 Tipologías de las redes neuronales profundas
- Deep learning supervisado
- Deep learning no supervisado

Índice

1 Tipologías de las redes neuronales profundas
- Deep learning supervisado
- Deep learning no supervisado

Índice

1 Tipologías de las redes neuronales profundas
- Deep learning supervisado
- Deep learning no supervisado

Introducción a las CNN (1985, 2005(GPUs))

- Son redes que usan la convolución en lugar de la multiplicación de matrices en al menos una capa.
- Se usan para datos que tengan topología de malla: imagen (malla de píxeles en 2D), serie temporal (malla 1D de datos tomados a intervalos regulares), vídeo (píxeles 2D tomados en el tiempo 1D = 3D).
- Inspiradas en la visión natural.

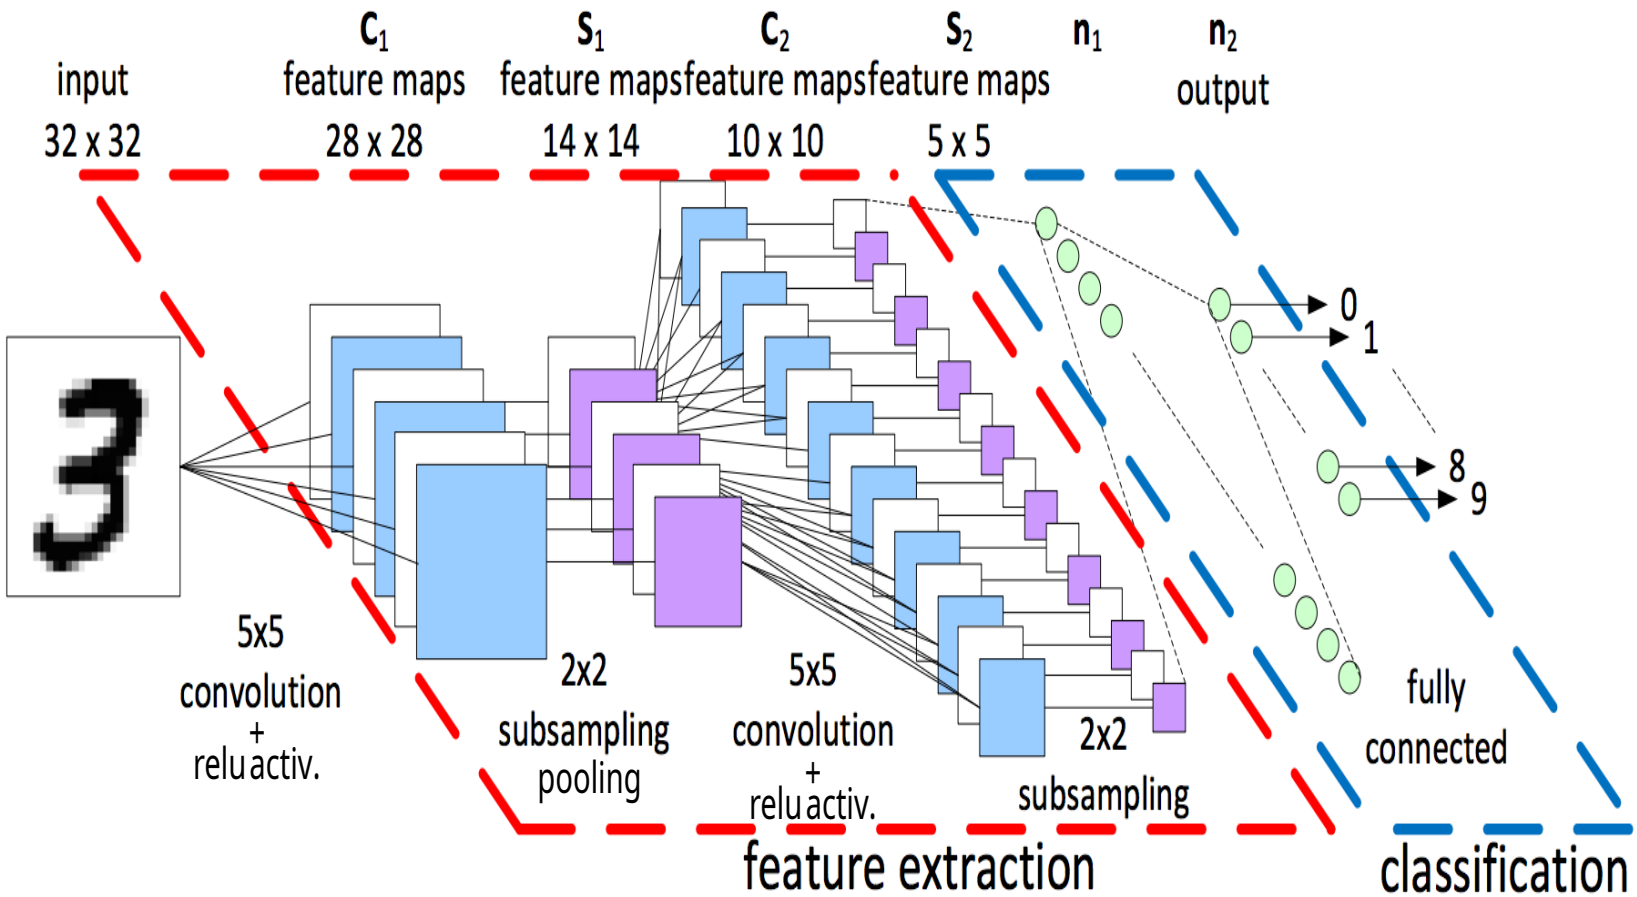
Introducción a las CNN (1985, 2005(GPUs))

- Son redes que usan la convolución en lugar de la multiplicación de matrices en al menos una capa.
- Se usan para datos que tengan topología de malla: imagen (malla de píxeles en 2D), serie temporal (malla 1D de datos tomados a intervalos regulares), vídeo (píxeles 2D tomados en el tiempo 1D = 3D).
- Inspiradas en la visión natural.

Introducción a las CNN (1985, 2005(GPUs))

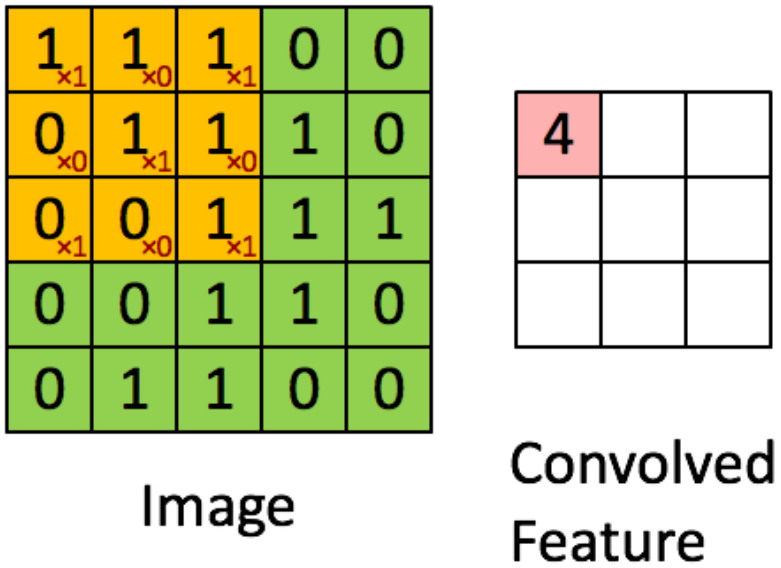
- Son redes que usan la convolución en lugar de la multiplicación de matrices en al menos una capa.
- Se usan para datos que tengan topología de malla: imagen (malla de píxeles en 2D), serie temporal (malla 1D de datos tomados a intervalos regulares), vídeo (píxeles 2D tomados en el tiempo 1D = 3D).
- Inspiradas en la visión natural.

Estructura de las CNN 1



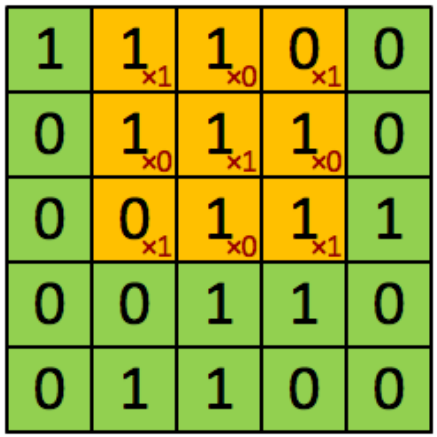
Estructura de las CNN 2

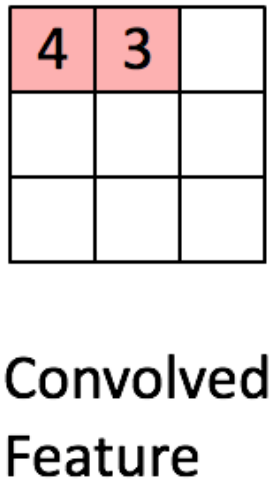
- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



Estructura de las CNN 2

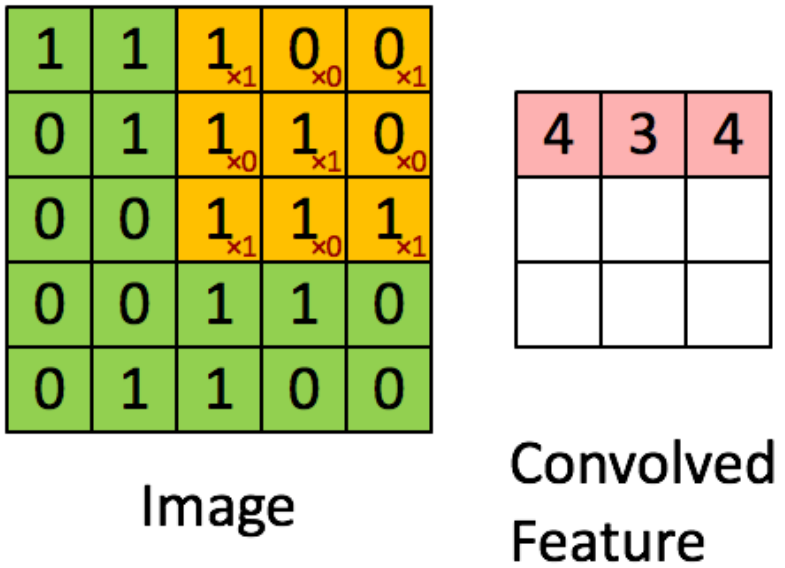
- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.





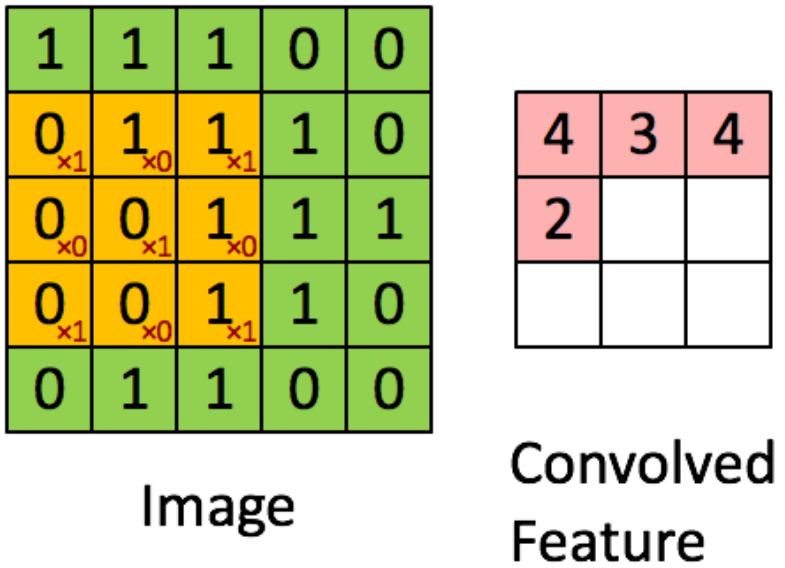
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



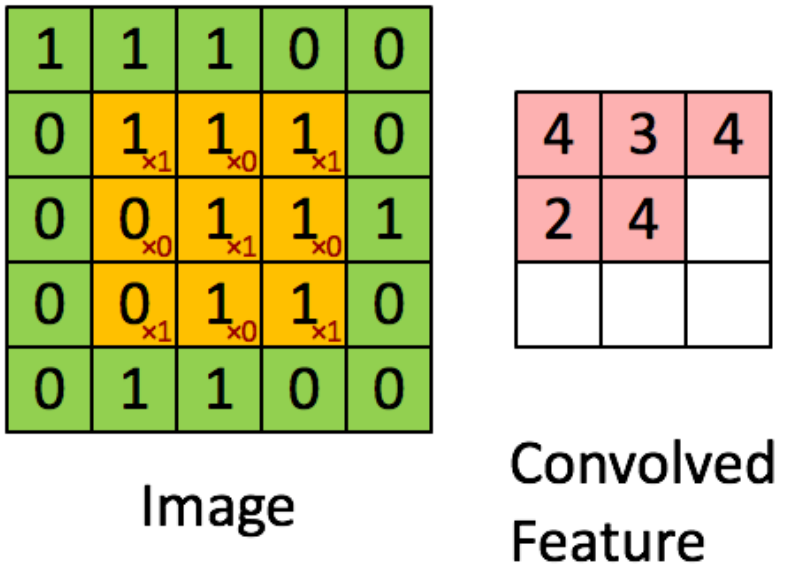
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



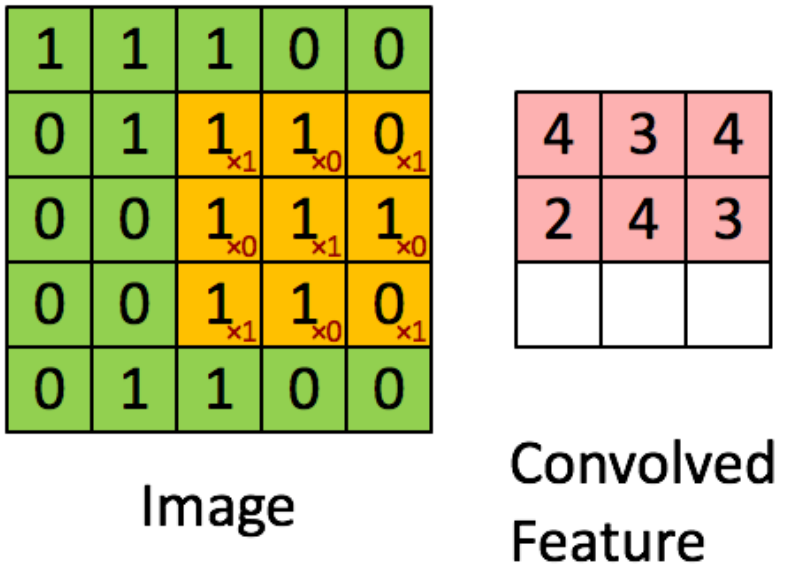
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



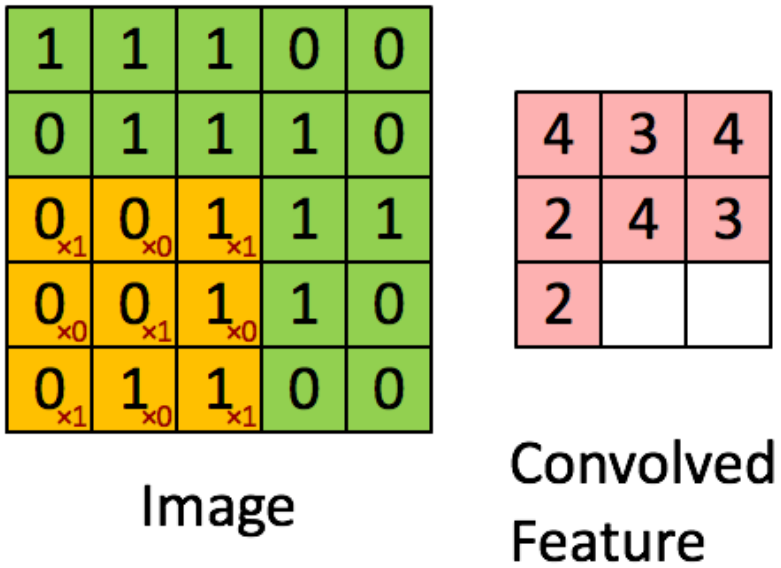
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



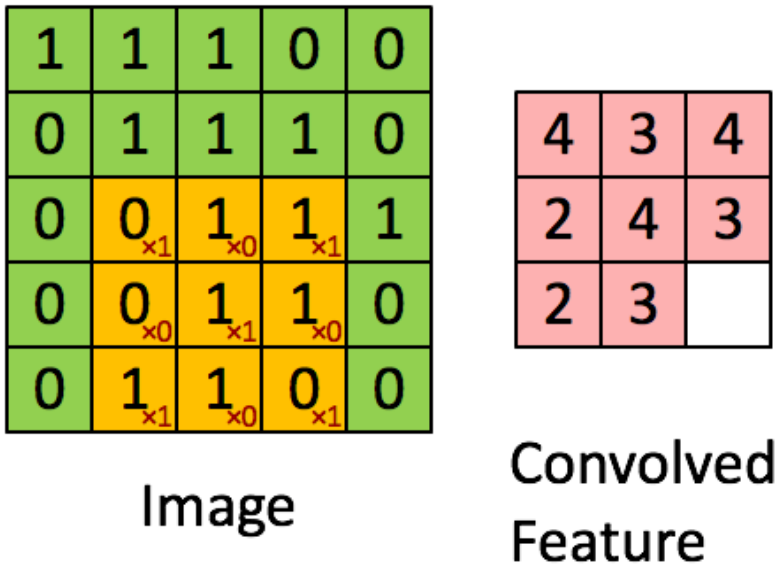
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



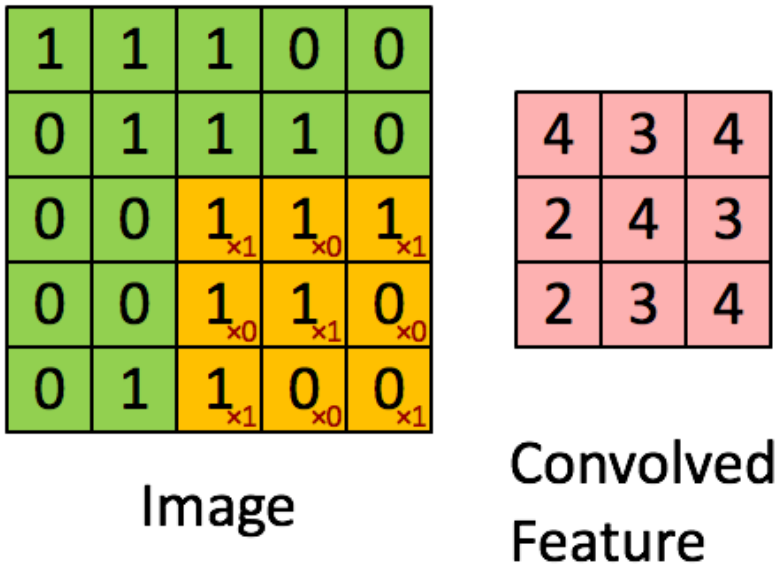
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



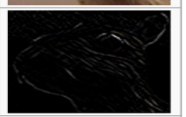
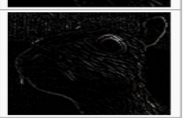
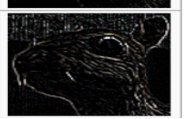
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



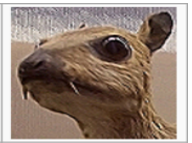
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.

Operation	Filter	Convolved Image
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	

Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.

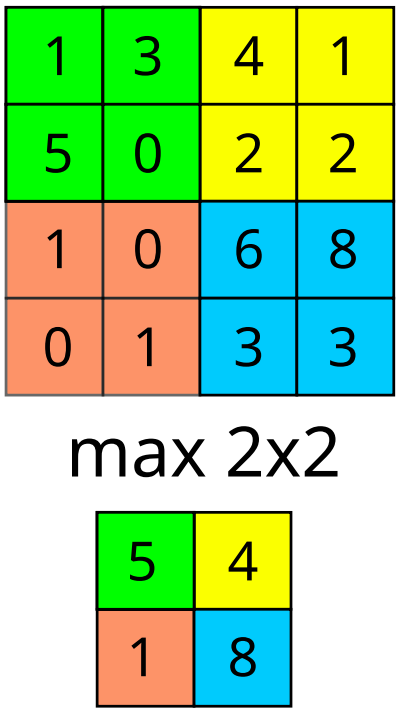
Operation	Filter	Convolved Image
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	
Box blur (normalized)	$\frac{1}{9}\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	
Gaussian blur (approximation)	$\frac{1}{16}\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	

Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.

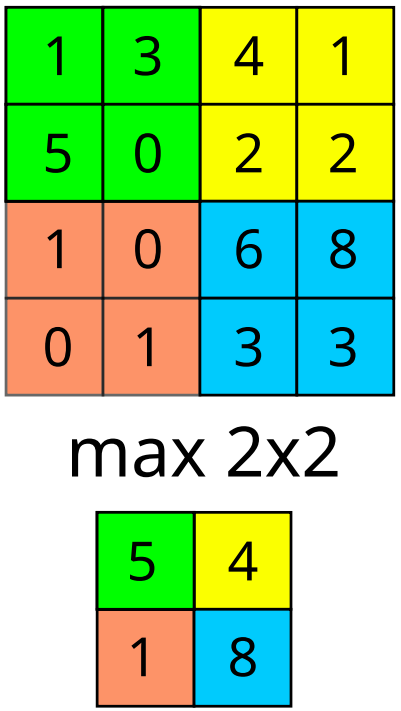
Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.



Estructura de las CNN 2

- Capa convolutiva:
  - Va extrayendo características según los filtros empleados.
  - Suele ir seguida de una capa de activación no lineal, p. ej. $max(0, x)$, que mejora las capacidades discriminativas de la red.
- Agrupamiento (pooling):
  - Reemplaza la salida anterior por una estadística de las salidas cercanas, aumenta la eficiencia computacional.

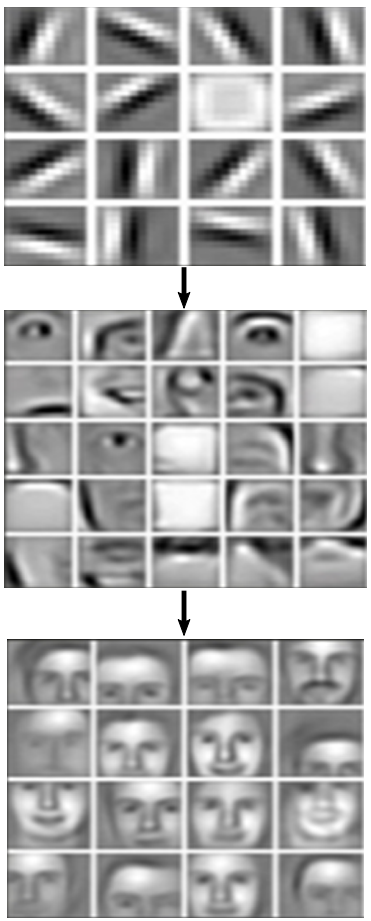


Estructura de las CNN 3

- Se van añadiendo capas convolucionales y de agrupamiento de manera que la salida de una es la entrada de la siguiente.
- De esta manera se extraen características de más alto nivel.

Estructura de las CNN 3

- Se van añadiendo capas convolucionales y de agrupamiento de manera que la salida de una es la entrada de la siguiente.
- De esta manera se extraen características de más alto nivel.



La última capa (fully connected)

- Tras varias capas convolucionales y de agrupamiento se añade una (o varias) capa totalmente conectada a la última de agrupamiento que funciona como una red neuronal normal.
- Determina las características de alto nivel más correlacionadas con cada etiqueta:
  $pico + alas + 2patas \longrightarrow pájaro$.

La última capa (fully connected)

- Tras varias capas convolucionales y de agrupamiento se añade una (o varias) capa totalmente conectada a la última de agrupamiento que funciona como una red neuronal normal.
- Determina las características de alto nivel más correlacionadas con cada etiqueta:
  $pico + alas + 2patas \longrightarrow pájaro$.

Introducción a redes recurrentes (1986)

- Las RNN están especializadas en procesar secuencias de valores.
- La salida es añadida a la siguiente entrada, $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t, \theta)$.
- Una RNN con una capa oculta puede ser vista como un MLP (unfolding).
- Las RNNs pueden recibir secuencias de entradas y producen secuencias de salida.
- Suelen usar backpropagation.

Introducción a redes recurrentes (1986)

- Las RNN están especializadas en procesar secuencias de valores.
- La salida es añadida a la siguiente entrada, $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t, \theta)$.
- Una RNN con una capa oculta puede ser vista como un MLP (unfolding).
- Las RNNs pueden recibir secuencias de entradas y producen secuencias de salida.
- Suelen usar backpropagation.

Introducción a redes recurrentes (1986)

- Las RNN están especializadas en procesar secuencias de valores.
- La salida es añadida a la siguiente entrada, $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t, \theta)$.
- Una RNN con una capa oculta puede ser vista como un MLP (unfolding).
- Las RNNs pueden recibir secuencias de entradas y producen secuencias de salida.
- Suelen usar backpropagation.

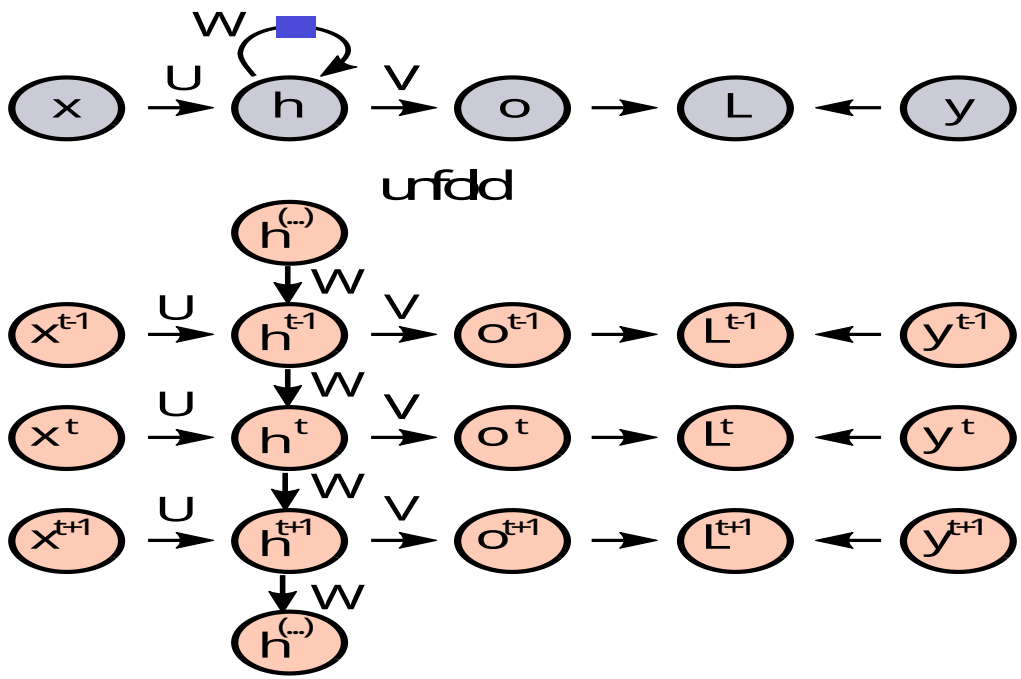
Introducción a redes recurrentes (1986)

- Las RNN están especializadas en procesar secuencias de valores.
- La salida es añadida a la siguiente entrada, $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t, \theta)$.
- Una RNN con una capa oculta puede ser vista como un MLP (unfolding).
- Las RNNs pueden recibir secuencias de entradas y producen secuencias de salida.
- Suelen usar backpropagation.

Introducción a redes recurrentes (1986)

- Las RNN están especializadas en procesar secuencias de valores.
- La salida es añadida a la siguiente entrada, $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t, \theta)$.
- Una RNN con una capa oculta puede ser vista como un MLP (unfolding).
- Las RNNs pueden recibir secuencias de entradas y producen secuencias de salida.
- Suelen usar backpropagation.

Grafo RNN


W
U
V
x
h
o
L
y
unfdd
h(...)
W
x t-1
h t-1
o t-1
L t-1
y t-1
x t
h t
o t
L t
y t
x t+1
h t+1
o t+1
L t+1
y t+1

RNN profundas (1992, 2013)

- Una DRNN es un pila de RNNs.
- Una DRNN puede ser vista como un DMLP.
- Una DRNN es difícil de entrenar, cada etapa implica backpropagation en todas las RNN apiladas.

RNN profundas (1992, 2013)

- Una DRNN es un pila de RNNs.
- Una DRNN puede ser vista como un DMLP.
- Una DRNN es difícil de entrenar, cada etapa implica backpropagation en todas las RNN apiladas.

RNN profundas (1992, 2013)

- Una DRNN es un pila de RNNs.
- Una DRNN puede ser vista como un DMLP.
- Una DRNN es difícil de entrenar, cada etapa implica backpropagation en todas las RNN apiladas.

Redes recursivas (1990, 2011)

- Son una variante de las redes recurrentes que usa un grafo binario profundo en lugar de uno encadenado.
- Suelen ser utilizadas en análisis de textos o contenidos estructurados jerárquicamente.
- Actúan de forma recurrente, p. ej. se añaden las palabras de una en una, como una sucesión temporal (importa el orden).
- El grafo puede ser balanceado (diapositiva siguiente) o adoptar otras formas que se adapten mejor a la estructura de los datos a analizar.

Redes recursivas (1990, 2011)

- Son una variante de las redes recurrentes que usa un grafo binario profundo en lugar de uno encadenado.
- Suelen ser utilizadas en análisis de textos o contenidos estructurados jerárquicamente.
- Actúan de forma recurrente, p. ej. se añaden las palabras de una en una, como una sucesión temporal (importa el orden).
- El grafo puede ser balanceado (diapositiva siguiente) o adoptar otras formas que se adapten mejor a la estructura de los datos a analizar.

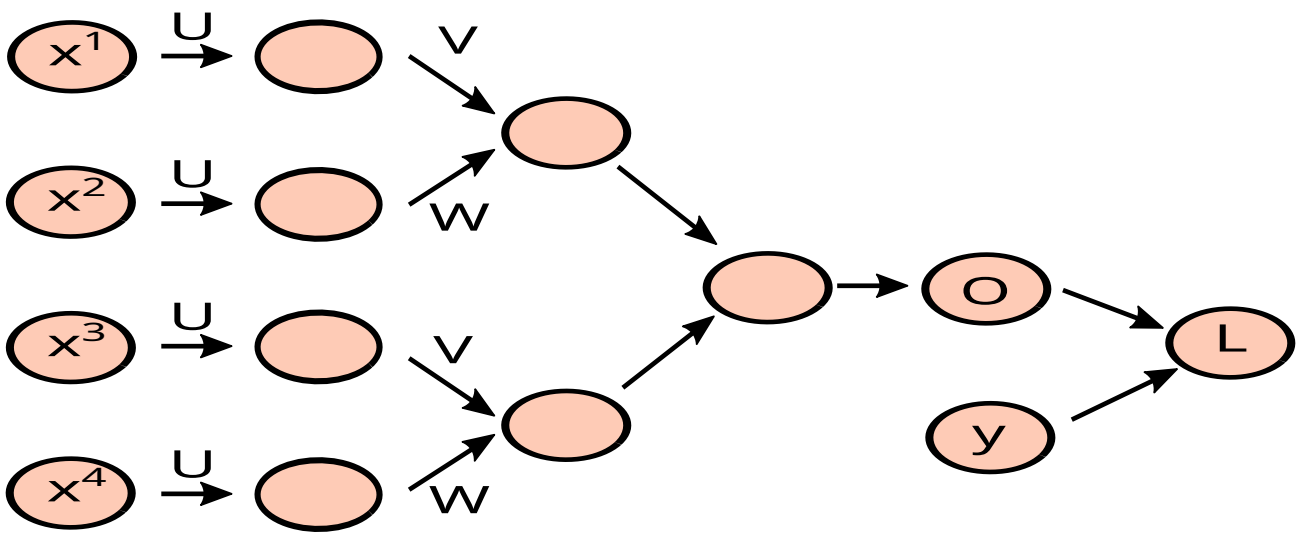
Redes recursivas (1990, 2011)

- Son una variante de las redes recurrentes que usa un grafo binario profundo en lugar de uno encadenado.
- Suelen ser utilizadas en análisis de textos o contenidos estructurados jerárquicamente.
- Actúan de forma recurrente, p. ej. se añaden las palabras de una en una, como una sucesión temporal (importa el orden).
- El grafo puede ser balanceado (diapositiva siguiente) o adoptar otras formas que se adapten mejor a la estructura de los datos a analizar.

Redes recursivas (1990, 2011)

- Son una variante de las redes recurrentes que usa un grafo binario profundo en lugar de uno encadenado.
- Suelen ser utilizadas en análisis de textos o contenidos estructurados jerárquicamente.
- Actúan de forma recurrente, p. ej. se añaden las palabras de una en una, como una sucesión temporal (importa el orden).
- El grafo puede ser balanceado (diapositiva siguiente) o adoptar otras formas que se adapten mejor a la estructura de los datos a analizar.

Grafo RNTN



Índice

1 Tipologías de las redes neuronales profundas
- Deep learning supervisado
- Deep learning no supervisado

Restricted Boltzmann machines (RBM 1986)

- Las RBM encuentran patrones reconstruyendo la entrada. Aprenden la pdf del conjunto de entradas. US.
- Tienen un capa de entrada (visible) y una oculta totalmente conectadas, no hay conexiones dentro de una capa (restricted).
- Realizan dos pasos, uno hacia adelante y otro hacia atrás. Es como un traductor bidireccional.
- Se usan para formar bloques de DBN y las deep RBM.
- Fueron muy populares hasta que llegaron las CNN, son más fáciles de usar.

Restricted Boltzmann machines (RBM 1986)

- Las RBM encuentran patrones reconstruyendo la entrada. Aprenden la pdf del conjunto de entradas. US.
- Tienen un capa de entrada (visible) y una oculta totalmente conectadas, no hay conexiones dentro de una capa (restricted).
- Realizan dos pasos, uno hacia adelante y otro hacia atrás. Es como un traductor bidireccional.
- Se usan para formar bloques de DBN y las deep RBM.
- Fueron muy populares hasta que llegaron las CNN, son más fáciles de usar.

Restricted Boltzmann machines (RBM 1986)

- Las RBM encuentran patrones reconstruyendo la entrada. Aprenden la pdf del conjunto de entradas. US.
- Tienen un capa de entrada (visible) y una oculta totalmente conectadas, no hay conexiones dentro de una capa (restricted).
- Realizan dos pasos, uno hacia adelante y otro hacia atrás. Es como un traductor bidireccional.
- Se usan para formar bloques de DBN y las deep RBM.
- Fueron muy populares hasta que llegaron las CNN, son más fáciles de usar.

Restricted Boltzmann machines (RBM 1986)

- Las RBM encuentran patrones reconstruyendo la entrada. Aprenden la pdf del conjunto de entradas. US.
- Tienen un capa de entrada (visible) y una oculta totalmente conectadas, no hay conexiones dentro de una capa (restricted).
- Realizan dos pasos, uno hacia adelante y otro hacia atrás. Es como un traductor bidireccional.
- Se usan para formar bloques de DBN y las deep RBM.
- Fueron muy populares hasta que llegaron las CNN, son más fáciles de usar.

Restricted Boltzmann machines (RBM 1986)

- Las RBM encuentran patrones reconstruyendo la entrada. Aprenden la pdf del conjunto de entradas. US.
- Tienen un capa de entrada (visible) y una oculta totalmente conectadas, no hay conexiones dentro de una capa (restricted).
- Realizan dos pasos, uno hacia adelante y otro hacia atrás. Es como un traductor bidireccional.
- Se usan para formar bloques de DBN y las deep RBM.
- Fueron muy populares hasta que llegaron las CNN, son más fáciles de usar.

Deep belief networks (DBN 2006)

- Las DBN son RBM apiladas de manera que la capa oculta de una RBM es la visible de la siguiente.
  - Básicamente es como un perceptrón multicapa (MLP), con un método de entrenamiento diferente.
  - Se entrena el primer RBM, luego el segundo, usando como entradas los valores de la capa oculta del primero y así sucesivamente hasta llegar al último RBM.
  - Tras el último RBM hay una capa de salida con SL para mapear la capa oculta del último RBM a (pocas) etiquetas.
  - Los pesos de la DBN se usan para construir una feed-forward DNN que ajusta los pesos iniciales por back-propagation.

Deep belief networks (DBN 2006)

- Las DBN son RBM apiladas de manera que la capa oculta de una RBM es la visible de la siguiente.
  - Básicamente es como un perceptrón multicapa (MLP), con un método de entrenamiento diferente.
  - Se entrena el primer RBM, luego el segundo, usando como entradas los valores de la capa oculta del primero y así sucesivamente hasta llegar al último RBM.
  - Tras el último RBM hay una capa de salida con SL para mapear la capa oculta del último RBM a (pocas) etiquetas.
  - Los pesos de la DBN se usan para construir una feed-forward DNN que ajusta los pesos iniciales por back-propagation.

Deep belief networks (DBN 2006)

- Las DBN son RBM apiladas de manera que la capa oculta de una RBM es la visible de la siguiente.
  - Básicamente es como un perceptrón multicapa (MLP), con un método de entrenamiento diferente.
  - Se entrena el primer RBM, luego el segundo, usando como entradas los valores de la capa oculta del primero y así sucesivamente hasta llegar al último RBM.
  - Tras el último RBM hay una capa de salida con SL para mapear la capa oculta del último RBM a (pocas) etiquetas.
  - Los pesos de la DBN se usan para construir una feed-forward DNN que ajusta los pesos iniciales por back-propagation.

Deep belief networks (DBN 2006)

- Las DBN son RBM apiladas de manera que la capa oculta de una RBM es la visible de la siguiente.
  - Básicamente es como un perceptrón multicapa (MLP), con un método de entrenamiento diferente.
  - Se entrena el primer RBM, luego el segundo, usando como entradas los valores de la capa oculta del primero y así sucesivamente hasta llegar al último RBM.
  - Tras el último RBM hay una capa de salida con SL para mapear la capa oculta del último RBM a (pocas) etiquetas.
  - Los pesos de la DBN se usan para construir una feed-forward DNN que ajusta los pesos iniciales por back-propagation.

Deep belief networks (DBN 2006)

- Las DBN son RBM apiladas de manera que la capa oculta de una RBM es la visible de la siguiente.
  - Básicamente es como un perceptrón multicapa (MLP), con un método de entrenamiento diferente.
  - Se entrena el primer RBM, luego el segundo, usando como entradas los valores de la capa oculta del primero y así sucesivamente hasta llegar al último RBM.
  - Tras el último RBM hay una capa de salida con SL para mapear la capa oculta del último RBM a (pocas) etiquetas.
  - Los pesos de la DBN se usan para construir una feed-forward DNN que ajusta los pesos iniciales por back-propagation.

Deep Boltzmann machines (DBM) (1982, 2009)

- Como las de DBN pero incluyen un último entrenamiento de arriba a abajo, los que les permite manejar mejor la incertidumbre y manejar más robustamente entradas ambiguas.
- Grafos no dirigidos, hay realimentación desde las capas superiores a las inferiores en cada etapa del entrenamiento. Las DBN son grafos dirigidos, salvo la última capa.
- Son más lentas.

Deep Boltzmann machines (DBM) (1982, 2009)

- Como las de DBN pero incluyen un último entrenamiento de arriba a abajo, los que les permite manejar mejor la incertidumbre y manejar más robustamente entradas ambiguas.
- Grafos no dirigidos, hay realimentación desde las capas superiores a las inferiores en cada etapa del entrenamiento. Las DBN son grafos dirigidos, salvo la última capa.
- Son más lentas.

Deep Boltzmann machines (DBM) (1982, 2009)

- Como las de DBN pero incluyen un último entrenamiento de arriba a abajo, los que les permite manejar mejor la incertidumbre y manejar más robustamente entradas ambiguas.
- Grafos no dirigidos, hay realimentación desde las capas superiores a las inferiores en cada etapa del entrenamiento. Las DBN son grafos dirigidos, salvo la última capa.
- Son más lentas.

Generative adversarial GAN (2014)

- Sirven para imitar: imágenes, sonidos, prosa, etc. WaveNet.
- En un GAN se plantea un juego entre dos redes adversarias, la generadora y la discriminadora.
- La generadora produce muestras a partir de un supuesto modelo de los datos.
- La discriminadora intenta distinguir entre muestras extraídas de los datos de entrenamiento y generadas por la generadora.
  - La generadora aprende a falsificar cada vez mejor.
  - La discriminadora aprende a distinguir cada vez mejor.
- Tipos: DCGAN, SeqGAN, LSTM-GAN y CGAN.

Generative adversarial GAN (2014)

- Sirven para imitar: imágenes, sonidos, prosa, etc. WaveNet.
- En un GAN se plantea un juego entre dos redes adversarias, la generadora y la discriminadora.
- La generadora produce muestras a partir de un supuesto modelo de los datos.
- La discriminadora intenta distinguir entre muestras extraídas de los datos de entrenamiento y generadas por la generadora.
  - La generadora aprende a falsificar cada vez mejor.
  - La discriminadora aprende a distinguir cada vez mejor.
- Tipos: DCGAN, SeqGAN, LSTM-GAN y CGAN.

Generative adversarial GAN (2014)

- Sirven para imitar: imágenes, sonidos, prosa, etc. WaveNet.
- En un GAN se plantea un juego entre dos redes adversarias, la generadora y la discriminadora.
- La generadora produce muestras a partir de un supuesto modelo de los datos.
- La discriminadora intenta distinguir entre muestras extraídas de los datos de entrenamiento y generadas por la generadora.
  - La generadora aprende a falsificar cada vez mejor.
  - La discriminadora aprende a distinguir cada vez mejor.
- Tipos: DCGAN, SeqGAN, LSTM-GAN y CGAN.

Generative adversarial GAN (2014)

- Sirven para imitar: imágenes, sonidos, prosa, etc. WaveNet.
- En un GAN se plantea un juego entre dos redes adversarias, la generadora y la discriminadora.
- La generadora produce muestras a partir de un supuesto modelo de los datos.
- La discriminadora intenta distinguir entre muestras extraídas de los datos de entrenamiento y generadas por la generadora.
  - La generadora aprende a falsificar cada vez mejor.
  - La discriminadora aprende a distinguir cada vez mejor.
- Tipos: DCGAN, SeqGAN, LSTM-GAN y CGAN.

Generative adversarial GAN (2014)

- Sirven para imitar: imágenes, sonidos, prosa, etc. WaveNet.
- En un GAN se plantea un juego entre dos redes adversarias, la generadora y la discriminadora.
- La generadora produce muestras a partir de un supuesto modelo de los datos.
- La discriminadora intenta distinguir entre muestras extraídas de los datos de entrenamiento y generadas por la generadora.
  - La generadora aprende a falsificar cada vez mejor.
  - La discriminadora aprende a distinguir cada vez mejor.
- Tipos: DCGAN, SeqGAN, LSTM-GAN y CGAN.

Autoencoders (1987, 2006)

- Descubrir la estructura subyacente un conjunto de datos.
- Toman un conjunto de datos no etiquetados, los codifican e intentan reconstruirlos de forma precisa. Son una especie de generalización de las RBM.
- La red debe decidir qué características son más importantes actuando como un extractor de características.

Autoencoders (1987, 2006)

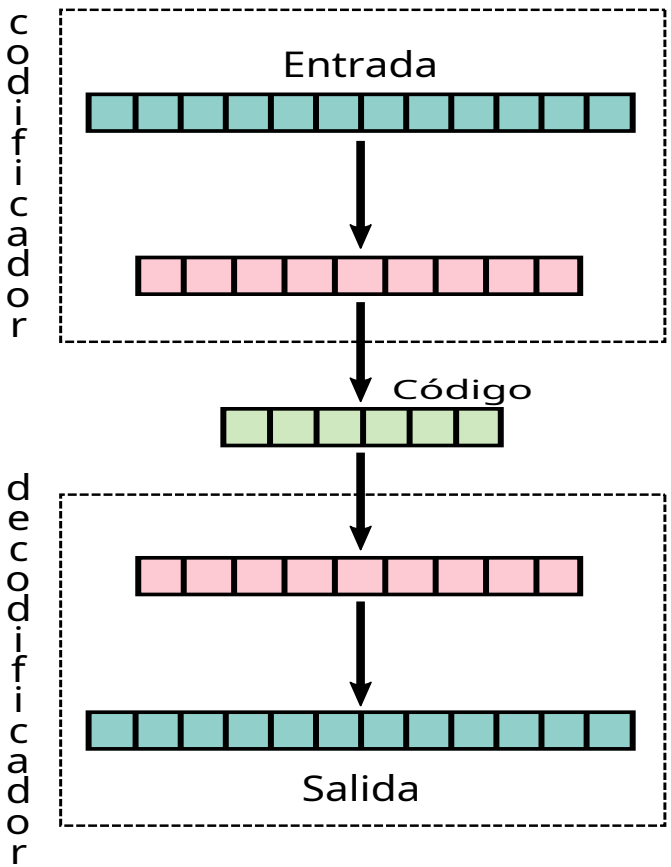
- Descubrir la estructura subyacente un conjunto de datos.
- Toman un conjunto de datos no etiquetados, los codifican e intentan reconstruirlos de forma precisa. Son una especie de generalización de las RBM.
- La red debe decidir qué características son más importantes actuando como un extractor de características.

Autoencoders (1987, 2006)

- Descubrir la estructura subyacente un conjunto de datos.
- Toman un conjunto de datos no etiquetados, los codifican e intentan reconstruirlos de forma precisa. Son una especie de generalización de las RBM.
- La red debe decidir qué características son más importantes actuando como un extractor de características.

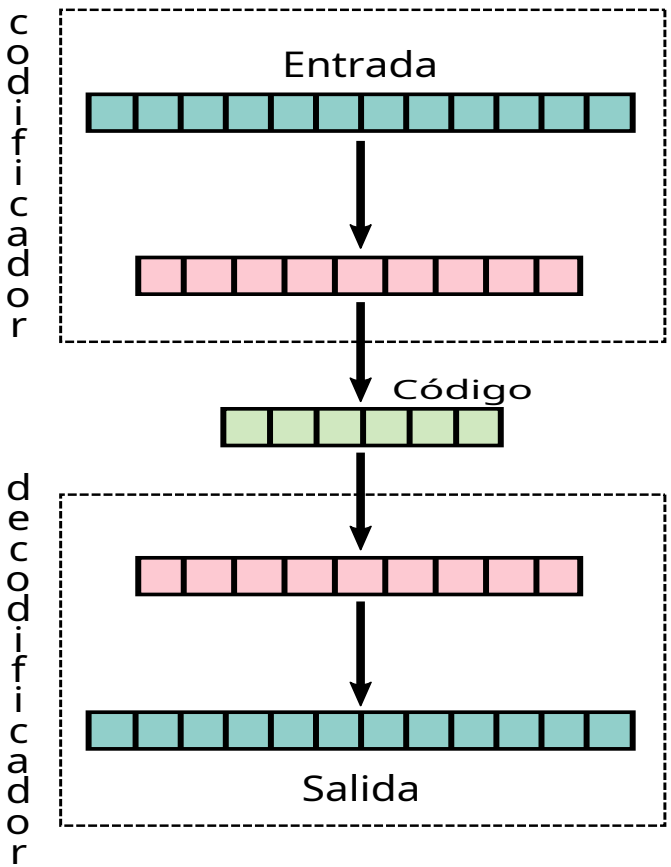
Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
  - El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
  - Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.



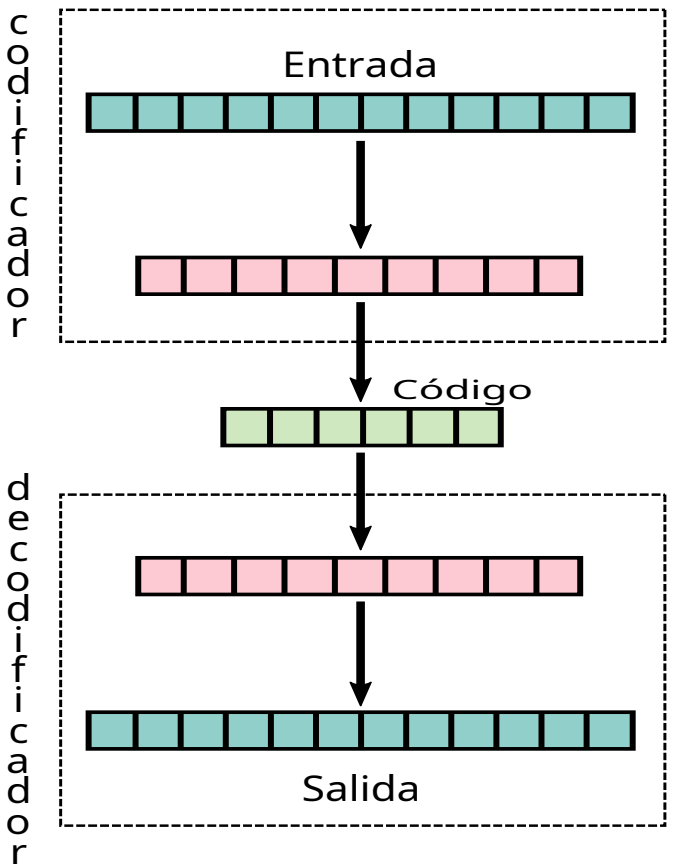
Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
  - El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
  - Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.



Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
  - El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
  - Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.



Thank You



Deep learning 2 (DL 2)

José Manuel Cuadra Troncoso