UNED

Máster de Ingeniería y Ciencia de Datos

ETS de Ingeniería Informática

Deep learning 4 (DL 4)

Redes neuronales convolucionales en Visión Artificial

José Manuel Cuadra Troncoso

Índice

1 Clasificación de imágenes con CNN

2 Detección de objetos

3 Segmentación semántica

4 Tópicos no cubiertos

Índice

1 Clasificación de imágenes con CNN
- Introducción
- Aumento de muestras
- Redes preentrenadas

2 Detección de objetos

3 Segmentación semántica

4 Tópicos no cubiertos

Índice

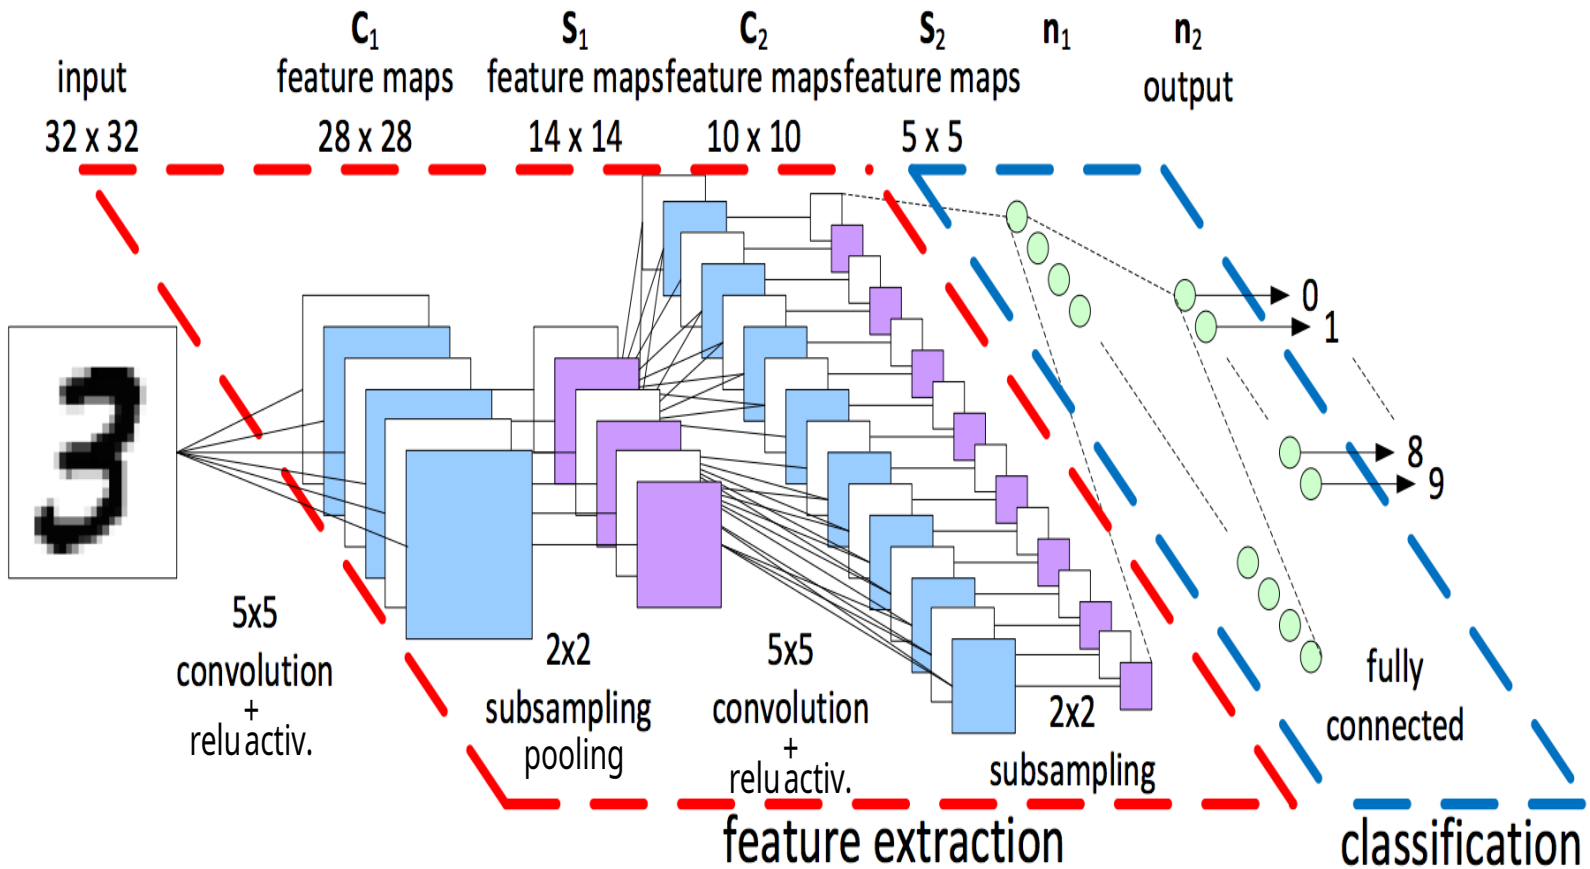
1 Clasificación de imágenes con CNN
- Introducción
- Aumento de muestras
- Redes preentrenadas

2 Detección de objetos

3 Segmentación semántica

4 Tópicos no cubiertos

Estructura de las CNN



Cantidad de datos

- Las CNN realizan extracción automática de características, sin necesidad de conjeturas ni heurísticas.
- Para ello suelen necesitar muchas muestras para el entrenamiento y potencia computacional.
- ¿Qué significa muchas muestras?
  - Con decenas de muestras no es posible.
  - Hay formas de hacerlo con solo centenas.
- Aumento (artificial) de muestras.
- Uso de redes pre-entrenadas.

Cantidad de datos

- Las CNN realizan extracción automática de características, sin necesidad de conjeturas ni heurísticas.
- Para ello suelen necesitar muchas muestras para el entrenamiento y potencia computacional.
- ¿Qué significa muchas muestras?
  - Con decenas de muestras no es posible.
  - Hay formas de hacerlo con solo centenas.
- Aumento (artificial) de muestras.
- Uso de redes pre-entrenadas.

Cantidad de datos

- Las CNN realizan extracción automática de características, sin necesidad de conjeturas ni heurísticas.
- Para ello suelen necesitar muchas muestras para el entrenamiento y potencia computacional.
- ¿Qué significa muchas muestras?
  - Con decenas de muestras no es posible.
  - Hay formas de hacerlo con solo centenas.
- Aumento (artificial) de muestras.
- Uso de redes pre-entrenadas.

Cantidad de datos

- Las CNN realizan extracción automática de características, sin necesidad de conjeturas ni heurísticas.
- Para ello suelen necesitar muchas muestras para el entrenamiento y potencia computacional.
- ¿Qué significa muchas muestras?
  - Con decenas de muestras no es posible.
  - Hay formas de hacerlo con solo centenas.
- Aumento (artificial) de muestras.
- Uso de redes pre-entrenadas.

Cantidad de datos

- Las CNN realizan extracción automática de características, sin necesidad de conjeturas ni heurísticas.
- Para ello suelen necesitar muchas muestras para el entrenamiento y potencia computacional.
- ¿Qué significa muchas muestras?
  - Con decenas de muestras no es posible.
  - Hay formas de hacerlo con solo centenas.
- Aumento (artificial) de muestras.
- Uso de redes pre-entrenadas.

Índice

1 Clasificación de imágenes con CNN
- Introducción
- Aumento de muestras
- Redes preentrenadas

2 Detección de objetos

3 Segmentación semántica

4 Tópicos no cubiertos

Aumento de muestras

- El uso de pocas muestras produce sobreajuste.
- Crear nuevas muestras a partir de las existentes usando transformaciones aleatorias que produzcan imágenes creíbles.
  - Rotaciones y traslaciones.
  - Recorte o zoom.
  - Voltear horizontalmente (si no hay suposiciones de simetría horizontal).
  - Añadir pequeñas cantidades de ruido (jitter).

Aumento de muestras

- El uso de pocas muestras produce sobreajuste.
- Crear nuevas muestras a partir de las existentes usando transformaciones aleatorias que produzcan imágenes creíbles.
  - Rotaciones y traslaciones.
  - Recorte o zoom.
  - Voltear horizontalmente (si no hay suposiciones de simetría horizontal).
  - Añadir pequeñas cantidades de ruido (jitter).

Aumento de muestras

- El uso de pocas muestras produce sobreajuste.
- Crear nuevas muestras a partir de las existentes usando transformaciones aleatorias que produzcan imágenes creíbles.
  - Rotaciones y traslaciones.
  - Recorte o zoom.
  - Voltear horizontalmente (si no hay suposiciones de simetría horizontal).
  - Añadir pequeñas cantidades de ruido (jitter).

Aumento de muestras

- El uso de pocas muestras produce sobreajuste.
- Crear nuevas muestras a partir de las existentes usando transformaciones aleatorias que produzcan imágenes creíbles.
  - Rotaciones y traslaciones.
  - Recorte o zoom.
  - Voltear horizontalmente (si no hay suposiciones de simetría horizontal).
  - Añadir pequeñas cantidades de ruido (jitter).

Aumento de muestras

- El uso de pocas muestras produce sobreajuste.
- Crear nuevas muestras a partir de las existentes usando transformaciones aleatorias que produzcan imágenes creíbles.
  - Rotaciones y traslaciones.
  - Recorte o zoom.
  - Voltear horizontalmente (si no hay suposiciones de simetría horizontal).
  - Añadir pequeñas cantidades de ruido (jitter).

Aumento de muestras

- El uso de pocas muestras produce sobreajuste.
- Crear nuevas muestras a partir de las existentes usando transformaciones aleatorias que produzcan imágenes creíbles.
  - Rotaciones y traslaciones.
  - Recorte o zoom.
  - Voltear horizontalmente (si no hay suposiciones de simetría horizontal).
  - Añadir pequeñas cantidades de ruido (jitter).

Herramientas en Keras

- keras.preprocessing.image.ImageDataGenerator es el módulo con las herramientas necesarias.
  - Cargar la imagen.
  - Normalizar sus valores entre 0 y 1.
  - Escalarla al tamaño de entrada de la red.
  - Convertirla en un tensor de 4 dimensiones.
  - Realizar el aumento de muestras.

Herramientas en Keras

- keras.preprocessing.image.ImageDataGenerator es el módulo con las herramientas necesarias.
  - Cargar la imagen.
  - Normalizar sus valores entre 0 y 1.
  - Escalarla al tamaño de entrada de la red.
  - Convertirla en un tensor de 4 dimensiones.
  - Realizar el aumento de muestras.

Herramientas en Keras

- keras.preprocessing.image.ImageDataGenerator es el módulo con las herramientas necesarias.
  - Cargar la imagen.
  - Normalizar sus valores entre 0 y 1.
  - Escalarla al tamaño de entrada de la red.
  - Convertirla en un tensor de 4 dimensiones.
  - Realizar el aumento de muestras.

Herramientas en Keras

- keras.preprocessing.image.ImageDataGenerator es el módulo con las herramientas necesarias.
  - Cargar la imagen.
  - Normalizar sus valores entre 0 y 1.
  - Escalarla al tamaño de entrada de la red.
  - Convertirla en un tensor de 4 dimensiones.
  - Realizar el aumento de muestras.

Herramientas en Keras

- keras.preprocessing.image.ImageDataGenerator es el módulo con las herramientas necesarias.
  - Cargar la imagen.
  - Normalizar sus valores entre 0 y 1.
  - Escalarla al tamaño de entrada de la red.
  - Convertirla en un tensor de 4 dimensiones.
  - Realizar el aumento de muestras.

Herramientas en Keras

- keras.preprocessing.image.ImageDataGenerator es el módulo con las herramientas necesarias.
  - Cargar la imagen.
  - Normalizar sus valores entre 0 y 1.
  - Escalarla al tamaño de entrada de la red.
  - Convertirla en un tensor de 4 dimensiones.
  - Realizar el aumento de muestras.

Índice

1 Clasificación de imágenes con CNN
- Introducción
- Aumento de muestras
- Redes preentrenadas

2 Detección de objetos

3 Segmentación semántica

4 Tópicos no cubiertos

Introducción

- Red grabada entrenada con un dataset grande.
- Si el dataset es lo suficientemente grande y general puede actuar como un modelo efectivo del mundo visual.
  - Puede aplicarse a clases no usadas en el entrenamiento original.
    - Esto es una ventaja clave del Deep Leaning sobre otros métodos.
    - Hace al Deep Learning efectivo usando pequeños datasets.

Introducción

- Red grabada entrenada con un dataset grande.
- Si el dataset es lo suficientemente grande y general puede actuar como un modelo efectivo del mundo visual.
  - Puede aplicarse a clases no usadas en el entrenamiento original.
    - Esto es una ventaja clave del Deep Leaning sobre otros métodos.
    - Hace al Deep Learning efectivo usando pequeños datasets.

Introducción

- Red grabada entrenada con un dataset grande.
- Si el dataset es lo suficientemente grande y general puede actuar como un modelo efectivo del mundo visual.
  - Puede aplicarse a clases no usadas en el entrenamiento original.
    - Esto es una ventaja clave del Deep Leaning sobre otros métodos.
    - Hace al Deep Learning efectivo usando pequeños datasets.

Técnicas de uso

- Extracción de características: usar representaciones aprendidas por una red previa para extraer características interesantes de una muestra nueva. Con las nuevas características se entrena un nuevo clasificador de cero.
- Ajuste fino: desbloquear unas cuantas capas finales de la red previa y entrenar conjuntamente estas capas con el nuevo clasificador. Es complementario de la extracción de características.

Técnicas de uso

- Extracción de características: usar representaciones aprendidas por una red previa para extraer características interesantes de una muestra nueva. Con las nuevas características se entrena un nuevo clasificador de cero.
- Ajuste fino: desbloquear unas cuantas capas finales de la red previa y entrenar conjuntamente estas capas con el nuevo clasificador. Es complementario de la extracción de características.

Extracción de características

- Se toma la base convolucional (capas convolutivas y de agrupamiento) de la red previa. Ir a figura
- Se crea un nuevo clasificador y se entrena. La salida del nuevo clasificador no tiene porqué tener las mismas clases que el previo.
- Hay dos maneras de proceder:
  - Ejecutar la base convolutiva sobre nuestro dataset, guardar su salida en disco y usarla para entrenar un clasificador. No permite aumento de datos.
  - Extender la base convolutiva con un nuevo clasificador y entrenar todo el conjunto. Es mucho más lenta (usar GPUs). Permite aumento de datos.

Extracción de características

- Se toma la base convolucional (capas convolutivas y de agrupamiento) de la red previa. Ir a figura
- Se crea un nuevo clasificador y se entrena. La salida del nuevo clasificador no tiene porqué tener las mismas clases que el previo.
- Hay dos maneras de proceder:
  - Ejecutar la base convolutiva sobre nuestro dataset, guardar su salida en disco y usarla para entrenar un clasificador. No permite aumento de datos.
  - Extender la base convolutiva con un nuevo clasificador y entrenar todo el conjunto. Es mucho más lenta (usar GPUs). Permite aumento de datos.

Extracción de características

- Se toma la base convolucional (capas convolutivas y de agrupamiento) de la red previa. Ir a figura
- Se crea un nuevo clasificador y se entrena. La salida del nuevo clasificador no tiene porqué tener las mismas clases que el previo.
- Hay dos maneras de proceder:
  - Ejecutar la base convolutiva sobre nuestro dataset, guardar su salida en disco y usarla para entrenar un clasificador. No permite aumento de datos.
  - Extender la base convolutiva con un nuevo clasificador y entrenar todo el conjunto. Es mucho más lenta (usar GPUs). Permite aumento de datos.

Extracción de características

- Se toma la base convolucional (capas convolutivas y de agrupamiento) de la red previa. Ir a figura
- Se crea un nuevo clasificador y se entrena. La salida del nuevo clasificador no tiene porqué tener las mismas clases que el previo.
- Hay dos maneras de proceder:
  - Ejecutar la base convolutiva sobre nuestro dataset, guardar su salida en disco y usarla para entrenar un clasificador. No permite aumento de datos.
  - Extender la base convolutiva con un nuevo clasificador y entrenar todo el conjunto. Es mucho más lenta (usar GPUs). Permite aumento de datos.

Extracción de características

- Se toma la base convolucional (capas convolutivas y de agrupamiento) de la red previa. Ir a figura
- Se crea un nuevo clasificador y se entrena. La salida del nuevo clasificador no tiene porqué tener las mismas clases que el previo.
- Hay dos maneras de proceder:
  - Ejecutar la base convolutiva sobre nuestro dataset, guardar su salida en disco y usarla para entrenar un clasificador. No permite aumento de datos.
  - Extender la base convolutiva con un nuevo clasificador y entrenar todo el conjunto. Es mucho más lenta (usar GPUs). Permite aumento de datos.

Ajuste fino

1. Añadir nuestra red encima de la red previa.
2. Bloquear la red base.
3. Entrenar nuestra red (si no se propagaría un error grande y se destruirían las representaciones previamente aprendidas).
4. Desbloquear algunas capas superiores (características más especializadas) de la red base. Ir a figura
5. Entrenar conjuntamente estas capas y nuestra red.

Ajuste fino

1. Añadir nuestra red encima de la red previa.
2. Bloquear la red base.
3. Entrenar nuestra red (si no se propagaría un error grande y se destruirían las representaciones previamente aprendidas).
4. Desbloquear algunas capas superiores (características más especializadas) de la red base. Ir a figura
5. Entrenar conjuntamente estas capas y nuestra red.

Ajuste fino

1. Añadir nuestra red encima de la red previa.
2. Bloquear la red base.
3. Entrenar nuestra red (si no se propagaría un error grande y se destruirían las representaciones previamente aprendidas).
4. Desbloquear algunas capas superiores (características más especializadas) de la red base. Ir a figura
5. Entrenar conjuntamente estas capas y nuestra red.

Ajuste fino

1. Añadir nuestra red encima de la red previa.
2. Bloquear la red base.
3. Entrenar nuestra red (si no se propagaría un error grande y se destruirían las representaciones previamente aprendidas).
4. Desbloquear algunas capas superiores (características más especializadas) de la red base. Ir a figura
5. Entrenar conjuntamente estas capas y nuestra red.

Ajuste fino

1. Añadir nuestra red encima de la red previa.
2. Bloquear la red base.
3. Entrenar nuestra red (si no se propagaría un error grande y se destruirían las representaciones previamente aprendidas).
4. Desbloquear algunas capas superiores (características más especializadas) de la red base. Ir a figura
5. Entrenar conjuntamente estas capas y nuestra red.

Arquitecturas en Keras

- Xception, VGG16, VGG19, ResNet50, InceptionV3, InceptionResNetV2, MobileNet, MobileNetV2, DenseNet, NASNet. Otras AlexNet, GoogleNet.
- Generalmente entrenadas con ImageNet, ImageNet Wiki (más de 14 millones de imágenes y 20000 clases en marzo de 2020).
- Documentación en Keras Applications.

Arquitecturas en Keras

- Xception, VGG16, VGG19, ResNet50, InceptionV3, InceptionResNetV2, MobileNet, MobileNetV2, DenseNet, NASNet. Otras AlexNet, GoogleNet.
- Generalmente entrenadas con ImageNet, ImageNet Wiki (más de 14 millones de imágenes y 20000 clases en marzo de 2020).
- Documentación en Keras Applications.

Arquitecturas en Keras

- Xception, VGG16, VGG19, ResNet50, InceptionV3, InceptionResNetV2, MobileNet, MobileNetV2, DenseNet, NASNet. Otras AlexNet, GoogleNet.
- Generalmente entrenadas con ImageNet, ImageNet Wiki (más de 14 millones de imágenes y 20000 clases en marzo de 2020).
- Documentación en Keras Applications.

Índice

1 Clasificación de imágenes con CNN

2 Detección de objetos
- Introducción
- Métodos

3 Segmentación semántica

4 Tópicos no cubiertos

Índice

1 Clasificación de imágenes con CNN

2 Detección de objetos
- Introducción
- Métodos

3 Segmentación semántica

4 Tópicos no cubiertos

Introducción

- Un sistema de detección de objetos debe producir la siguiente información:
  - Nombre para las clases de objetos en la imagen.
  - Cajas de abarque.
- Retos: oclusiones, cambios de puntos de vista y tamaños, objetos no rígidos y desenfoque por movimiento.

Introducción

- Un sistema de detección de objetos debe producir la siguiente información:
  - Nombre para las clases de objetos en la imagen.
  - Cajas de abarque.
- Retos: oclusiones, cambios de puntos de vista y tamaños, objetos no rígidos y desenfoque por movimiento.

Introducción

- Un sistema de detección de objetos debe producir la siguiente información:
  - Nombre para las clases de objetos en la imagen.
  - Cajas de abarque.
- Retos: oclusiones, cambios de puntos de vista y tamaños, objetos no rígidos y desenfoque por movimiento.

Introducción

- Un sistema de detección de objetos debe producir la siguiente información:
  - Nombre para las clases de objetos en la imagen.
  - Cajas de abarque.
- Retos: oclusiones, cambios de puntos de vista y tamaños, objetos no rígidos y desenfoque por movimiento.

Índice

1 Clasificación de imágenes con CNN

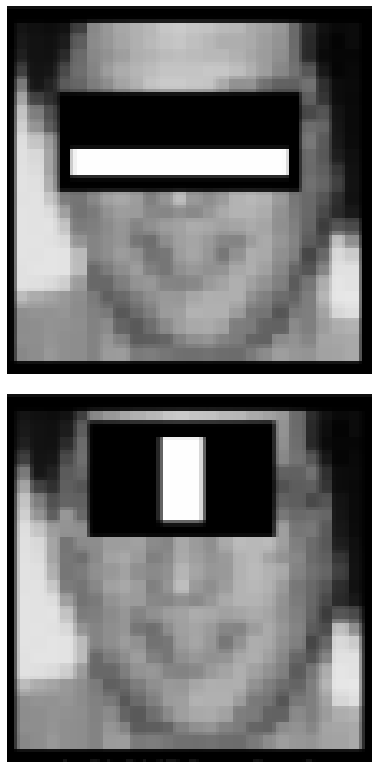
2 Detección de objetos
- Introducción
- Métodos

3 Segmentación semántica

4 Tópicos no cubiertos

Métodos

- Cascadas de Haar (2001): extrae características por convolución con kernels suma de píxeles en negro menos en blanco que luego pasan a un clasificador entrenado.
- Detección basada en CNN: modificar las CNN para que además de clasificar den la caja de abarque y la forma.
  - Detectores de dos etapas: Region CNN (R-CNN 2014), regiones con características CNN. La versión original es bastante lenta. Variantes: Fast-CNN (2015), Faster-CNN (2016), Mask R-CNN (2017).
  - Detectores de una etapa: Single Shot MultiBox Detector (SSD 2016), funciona en tiempo real.



Métodos

- Cascadas de Haar (2001): extrae características por convolución con kernels suma de píxeles en negro menos en blanco que luego pasan a un clasificador entrenado.
- Detección basada en CNN: modificar las CNN para que además de clasificar den la caja de abarque y la forma.
  - Detectores de dos etapas: Region CNN (R-CNN 2014), regiones con características CNN. La versión original es bastante lenta. Variantes: Fast-CNN (2015), Faster-CNN (2016), Mask R-CNN (2017).
  - Detectores de una etapa: Single Shot MultiBox Detector (SSD 2016), funciona en tiempo real.

Métodos

- Cascadas de Haar (2001): extrae características por convolución con kernels suma de píxeles en negro menos en blanco que luego pasan a un clasificador entrenado.
- Detección basada en CNN: modificar las CNN para que además de clasificar den la caja de abarque y la forma.
  - Detectores de dos etapas: Region CNN (R-CNN 2014), regiones con características CNN. La versión original es bastante lenta. Variantes: Fast-CNN (2015), Faster-CNN (2016), Mask R-CNN (2017).
  - Detectores de una etapa: Single Shot MultiBox Detector (SSD 2016), funciona en tiempo real.

Métodos

- Cascadas de Haar (2001): extrae características por convolución con kernels suma de píxeles en negro menos en blanco que luego pasan a un clasificador entrenado.
- Detección basada en CNN: modificar las CNN para que además de clasificar den la caja de abarque y la forma.
  - Detectores de dos etapas: Region CNN (R-CNN 2014), regiones con características CNN. La versión original es bastante lenta. Variantes: Fast-CNN (2015), Faster-CNN (2016), Mask R-CNN (2017).
  - Detectores de una etapa: Single Shot MultiBox Detector (SSD 2016), funciona en tiempo real.

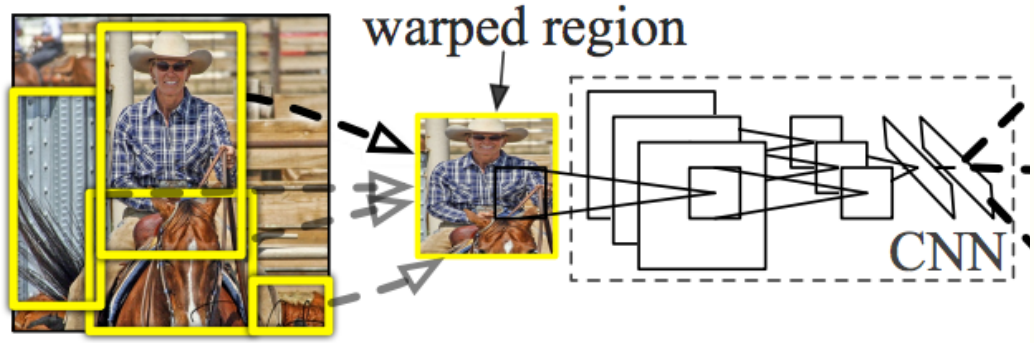
Region-CNN

1. Generar propuestas para las cajas de abarque (a distintas escalas).
2. Procesar las cajas usando una CNN preentrenada.
3. Clasificar usando SVM (p. ej.).
4. Procesar las cajas usando regresión lineal para ajustar las coordenadas.



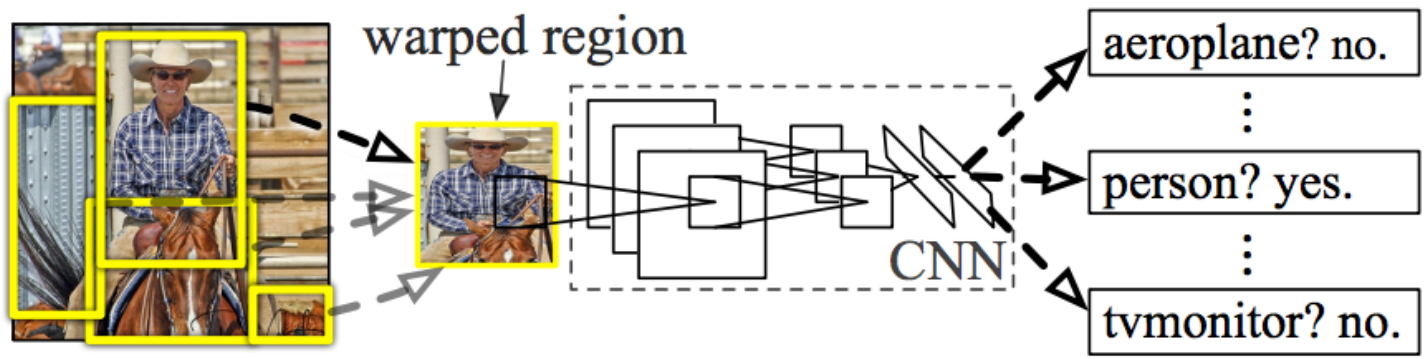
Region-CNN

1. Generar propuestas para las cajas de abarque (a distintas escalas).
2. Procesar las cajas usando una CNN preentrenada.
3. Clasificar usando SVM (p. ej.).
4. Procesar las cajas usando regresión lineal para ajustar las coordenadas.



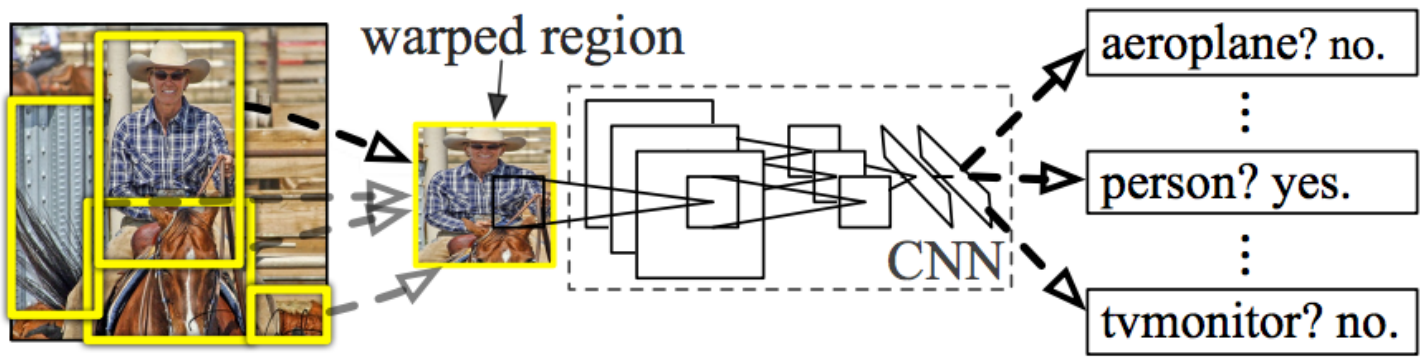
Region-CNN

1. Generar propuestas para las cajas de abarque (a distintas escalas).
2. Procesar las cajas usando una CNN preentrenada.
3. Clasificar usando SVM (p. ej.).
4. Procesar las cajas usando regresión lineal para ajustar las coordenadas.



Region-CNN

1. Generar propuestas para las cajas de abarque (a distintas escalas).
2. Procesar las cajas usando una CNN preentrenada.
3. Clasificar usando SVM (p. ej.).
4. Procesar las cajas usando regresión lineal para ajustar las coordenadas.



Índice

1 Clasificación de imágenes con CNN

2 Detección de objetos

3 Segmentación semántica
- Introducción
- Métodos

4 Tópicos no cubiertos

Índice

1 Clasificación de imágenes con CNN

2 Detección de objetos

3 Segmentación semántica
- Introducción
- Métodos

4 Tópicos no cubiertos

Concepto de segmentación

- Agrupar píxeles contiguos de una categoría similar.





Concepto de segmentación semántica

- Se distingue de la Segmentación a secas en que se intenta particionar la imagen en partes con significado y clasificarlas.
- Sinónimos: etiquetados de escenas, clasificación densa a nivel de píxel.
- Githubs sobre segmentación semántica.

Concepto de segmentación semántica

- Se distingue de la Segmentación a secas en que se intenta particionar la imagen en partes con significado y clasificarlas.
- Sinónimos: etiquetados de escenas, clasificación densa a nivel de píxel.
- Githubs sobre segmentación semántica.

Concepto de segmentación semántica

- Se distingue de la Segmentación a secas en que se intenta particionar la imagen en partes con significado y clasificarlas.
- Sinónimos: etiquetados de escenas, clasificación densa a nivel de píxel.
- Githubs sobre segmentación semántica.

Índice

1 Clasificación de imágenes con CNN

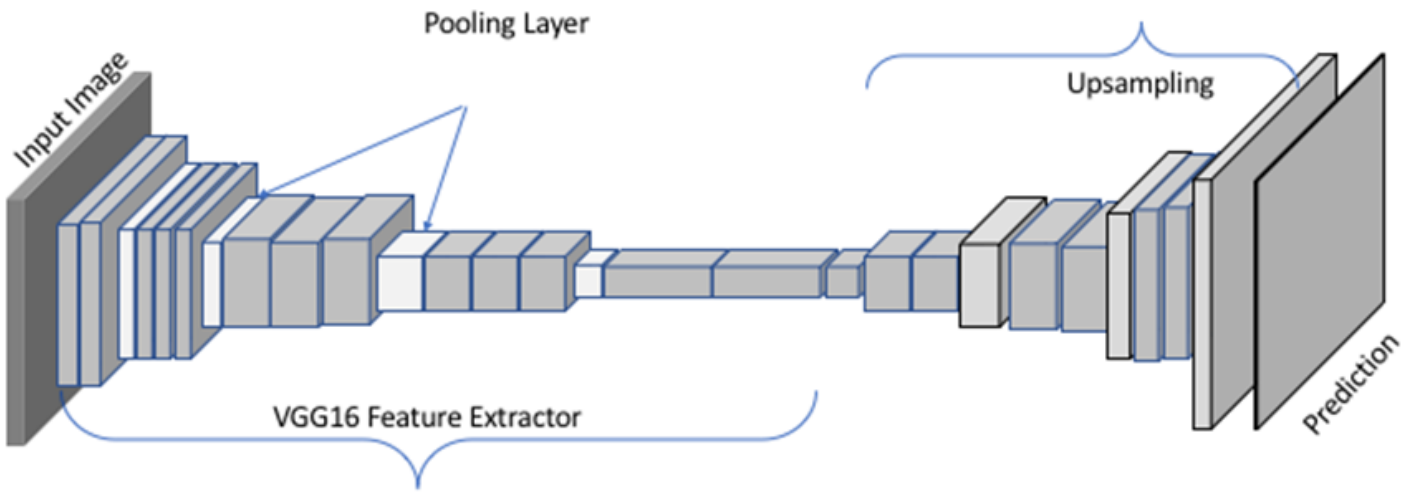
2 Detección de objetos

3 Segmentación semántica
- Introducción
- Métodos

4 Tópicos no cubiertos

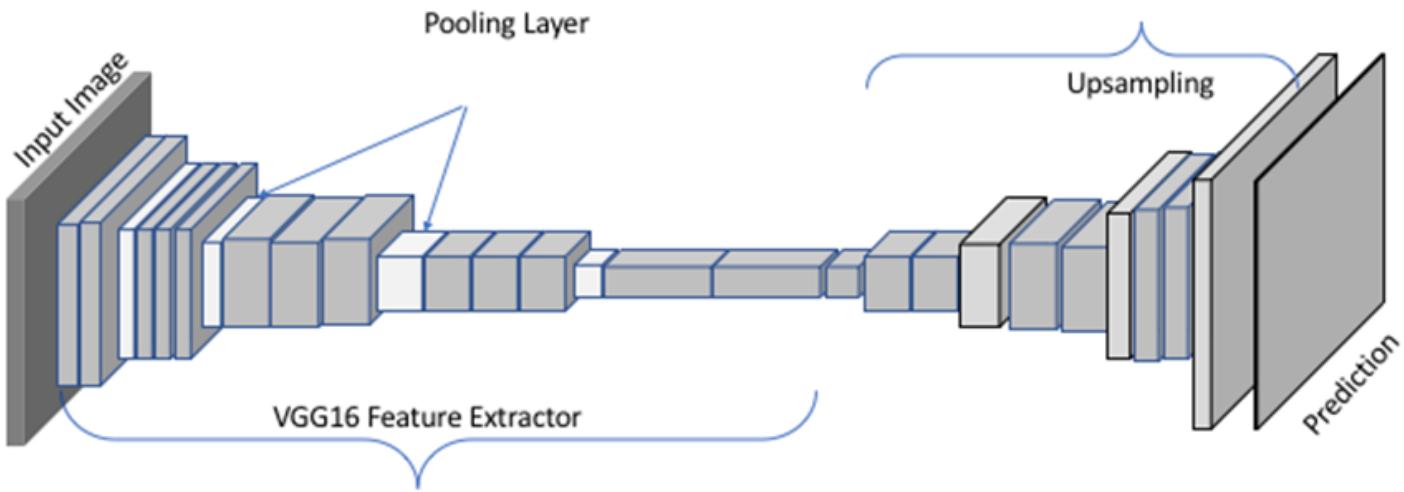
Métodos

- Básicamente la red se construye con una CNN codificadora preentrenada (VGG/ResNet) seguida de una decodificadora:
  - La cod. aprende características distintivas a baja resolución.
  - La decod. proyecta semánticamente las características en el espacio de píxeles (alta resolución).
- Tipos: Fully CNN (FCN 2014), SegNet (2015) y tipos de FCNs



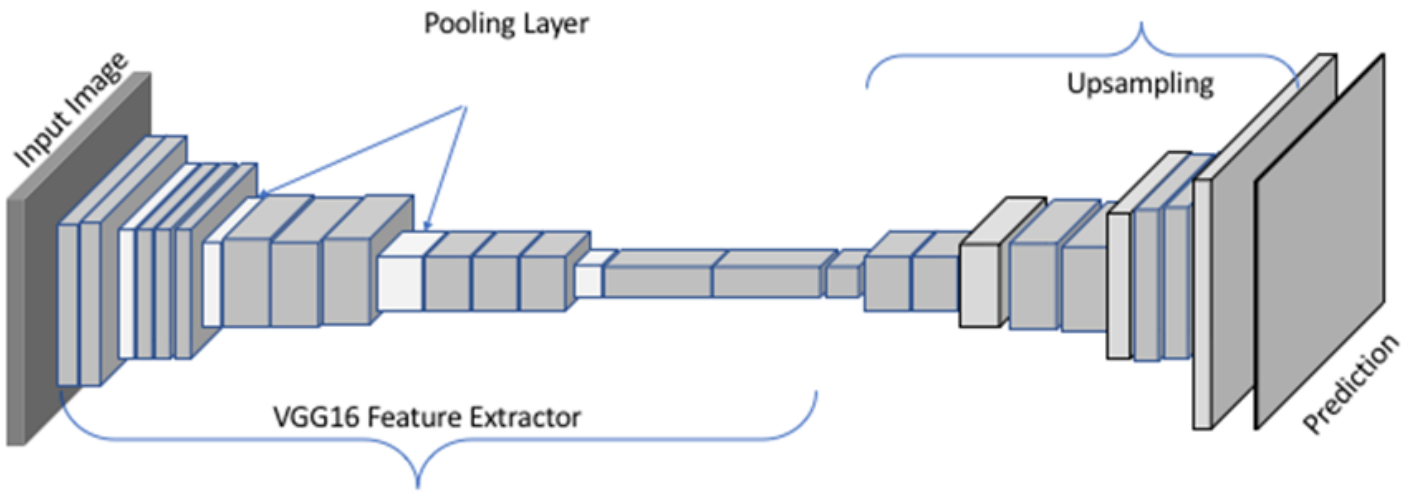
Métodos

- Básicamente la red se construye con una CNN codificadora preentrenada (VGG/ResNet) seguida de una decodificadora:
  - La cod. aprende características distintivas a baja resolución.
  - La decod. proyecta semánticamente las características en el espacio de píxeles (alta resolución).
- Tipos: Fully CNN (FCN 2014), SegNet (2015) y tipos de FCNs



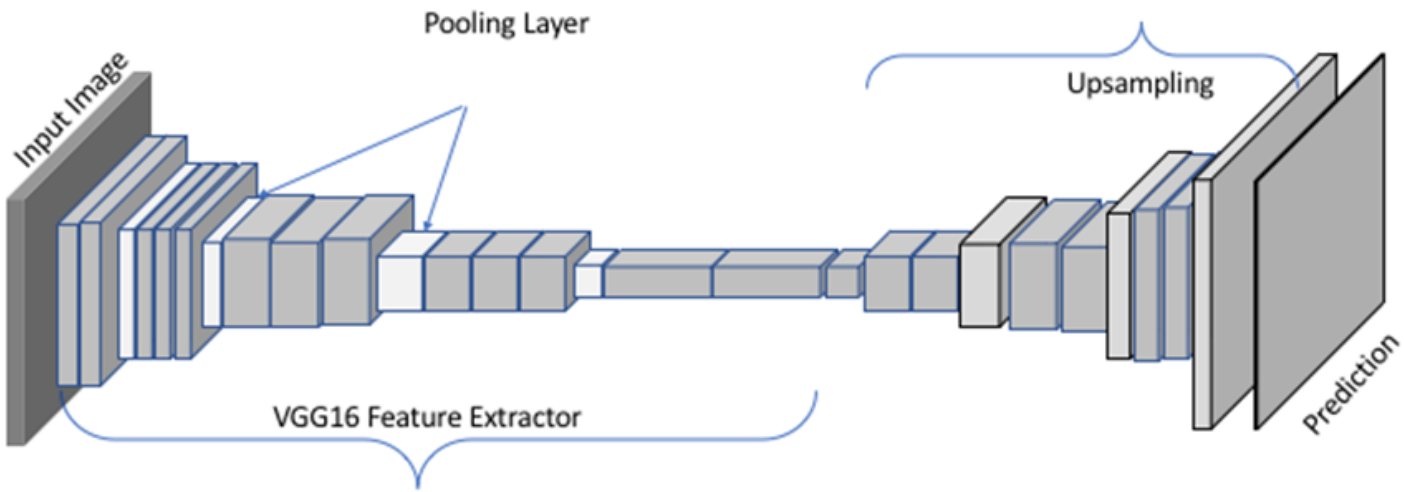
Métodos

- Básicamente la red se construye con una CNN codificadora preentrenada (VGG/ResNet) seguida de una decodificadora:
  - La cod. aprende características distintivas a baja resolución.
  - La decod. proyecta semánticamente las características en el espacio de píxeles (alta resolución).
- Tipos: Fully CNN (FCN 2014), SegNet (2015) y tipos de FCNs



Métodos

- Básicamente la red se construye con una CNN codificadora preentrenada (VGG/ResNet) seguida de una decodificadora:
  - La cod. aprende características distintivas a baja resolución.
  - La decod. proyecta semánticamente las características en el espacio de píxeles (alta resolución).
- Tipos: Fully CNN (FCN 2014), SegNet (2015) y tipos de FCNs



Índice

1 Clasificación de imágenes con CNN

2 Detección de objetos

3 Segmentación semántica

4 Tópicos no cubiertos

Qué más hay por ver

- Aprendizaje de similaridad.
- Subtitulado de imágenes.
- Generación de imágenes.
- Seguimiento en secuencias de imágenes.
- Todo lo comentado aplicado a vídeo y a imagen 3D.
- Robots: odometría y localización y creación de mapas (SLAM) usando cámaras.

Qué más hay por ver

- Aprendizaje de similaridad.
- Subtitulado de imágenes.
- Generación de imágenes.
- Seguimiento en secuencias de imágenes.
- Todo lo comentado aplicado a vídeo y a imagen 3D.
- Robots: odometría y localización y creación de mapas (SLAM) usando cámaras.

Qué más hay por ver

- Aprendizaje de similaridad.
- Subtitulado de imágenes.
- Generación de imágenes.
- Seguimiento en secuencias de imágenes.
- Todo lo comentado aplicado a vídeo y a imagen 3D.
- Robots: odometría y localización y creación de mapas (SLAM) usando cámaras.

Qué más hay por ver

- Aprendizaje de similaridad.
- Subtitulado de imágenes.
- Generación de imágenes.
- Seguimiento en secuencias de imágenes.
- Todo lo comentado aplicado a vídeo y a imagen 3D.
- Robots: odometría y localización y creación de mapas (SLAM) usando cámaras.

Qué más hay por ver

- Aprendizaje de similaridad.
- Subtitulado de imágenes.
- Generación de imágenes.
- Seguimiento en secuencias de imágenes.
- Todo lo comentado aplicado a vídeo y a imagen 3D.
- Robots: odometría y localización y creación de mapas (SLAM) usando cámaras.

Qué más hay por ver

- Aprendizaje de similaridad.
- Subtitulado de imágenes.
- Generación de imágenes.
- Seguimiento en secuencias de imágenes.
- Todo lo comentado aplicado a vídeo y a imagen 3D.
- Robots: odometría y localización y creación de mapas (SLAM) usando cámaras.

Thank You



Deep learning 4 (DL 4)

José Manuel Cuadra Troncoso