UNED

Máster de Ingeniería y Ciencia de Datos

ETS de Ingeniería Informática

Deep learning 5 (DL 5)

Aplicaciones del Deep Learning al Procesamiento del Lenguaje Natural

José Manuel Cuadra Troncoso

Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP

Índice

1 Introducción a las aplicaciones del DL para el NLP
- Comparación entre enfoques clásico y de DL
- Arquitecturas de DNN a usar

2 Ejemplos de DL para NLP

Índice

1 Introducción a las aplicaciones del DL para el NLP
- Comparación entre enfoques clásico y de DL
- Arquitecturas de DNN a usar

2 Ejemplos de DL para NLP

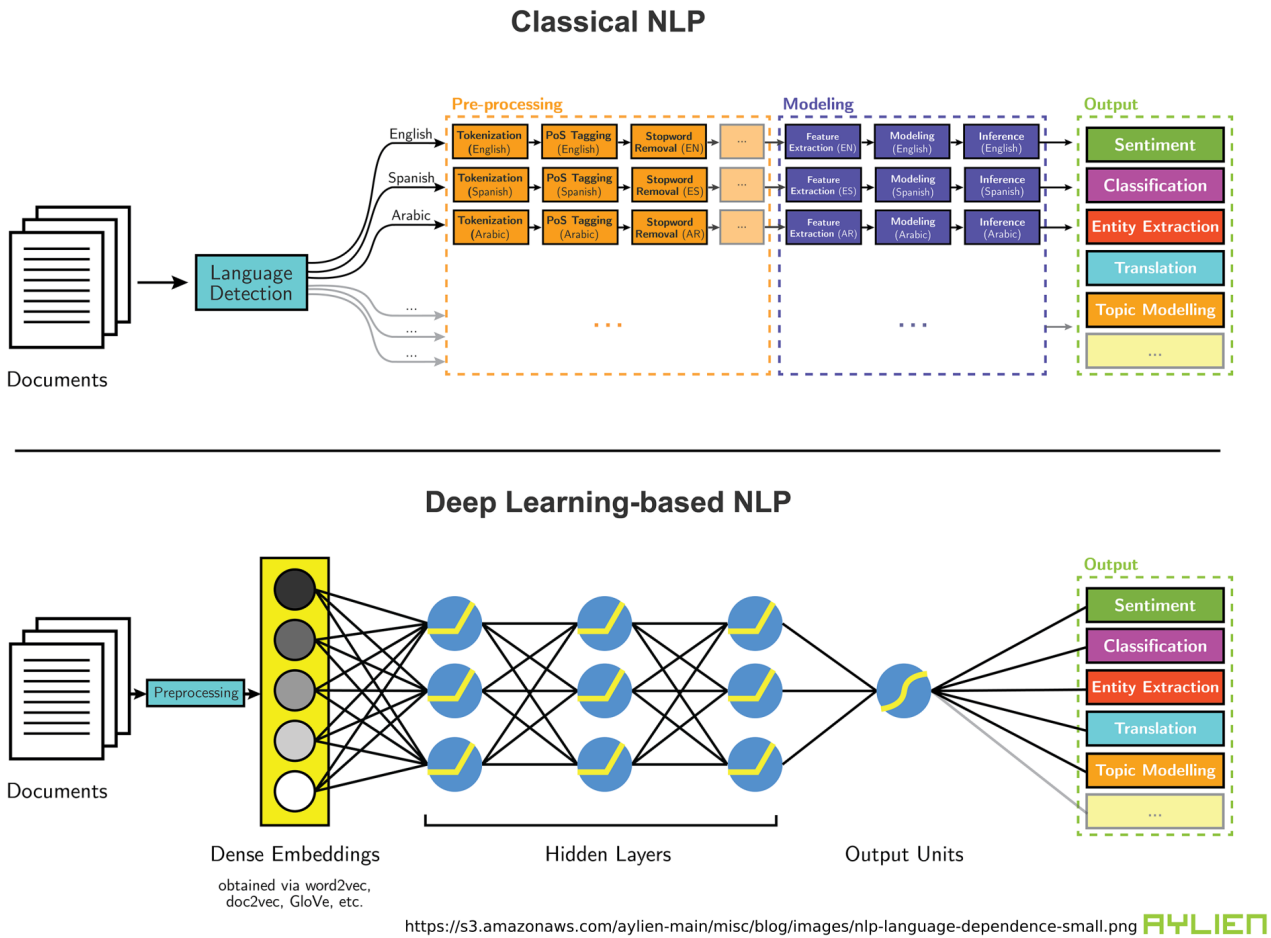
Enfoques clásico

1. Detección de idioma
2. Pre-procesado
   - Tokenizado
   - Etiquetado gramatical (POS)
   - Eliminación de stop-words
   - etc.
3. Modelado
   - Extracción «artesanal» de características (entidades (NER), categorías (POS) ...)
   - Algoritmos de ML
   - etc.
4. Salida
   - Análisis de sentimientos
   - Clasificación de textos
   - Traducción
   - etc.

Enfoque de DL

1. Pre-procesado
   - Tokenizado
   - Etiquetado gramatical (POS)
   - Eliminación de stop-words
   - etc.
2. Representaciones distribuidas (word embeddings)
   - word2vec
   - Glove
   - etc.
3. Procesamiento en capas ocultas: representación comprimida.
4. Capa de salida
   - Análisis de sentimientos
   - Clasificación de textos
   - Traducción
   - etc

Los dos enfoques



https://s3.amazonaws.com/aylien-main/misc/blog/images/nlp-language-dependence-small.png AYLIEN

Índice

1 Introducción a las aplicaciones del DL para el NLP
- Comparación entre enfoques clásico y de DL
- Arquitecturas de DNN a usar

2 Ejemplos de DL para NLP

Arquitecturas

- Redes recurrentes (RNN)
  - LSTM (Long Short Term Memory)
  - GRU (Gated Recurrent Units)
- Redes convolucionales (CNN)
- Autoencoders

Arquitecturas

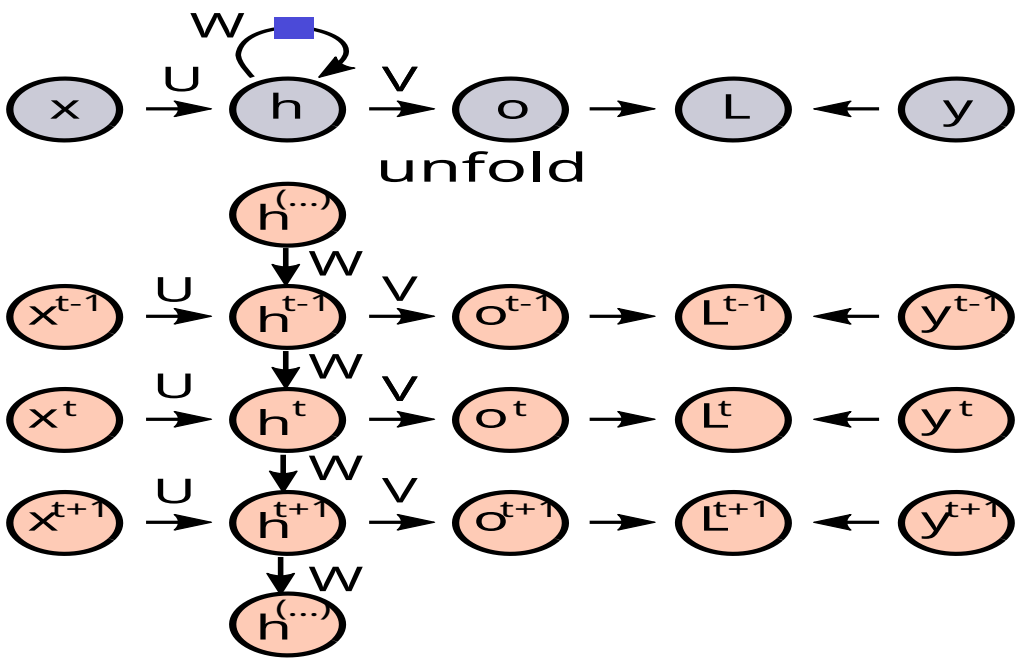
- Redes recurrentes (RNN)
  - LSTM (Long Short Term Memory)
  - GRU (Gated Recurrent Units)
- Redes convolucionales (CNN)
- Autoencoders

Arquitecturas

- Redes recurrentes (RNN)
  - LSTM (Long Short Term Memory)
  - GRU (Gated Recurrent Units)
- Redes convolucionales (CNN)
- Autoencoders

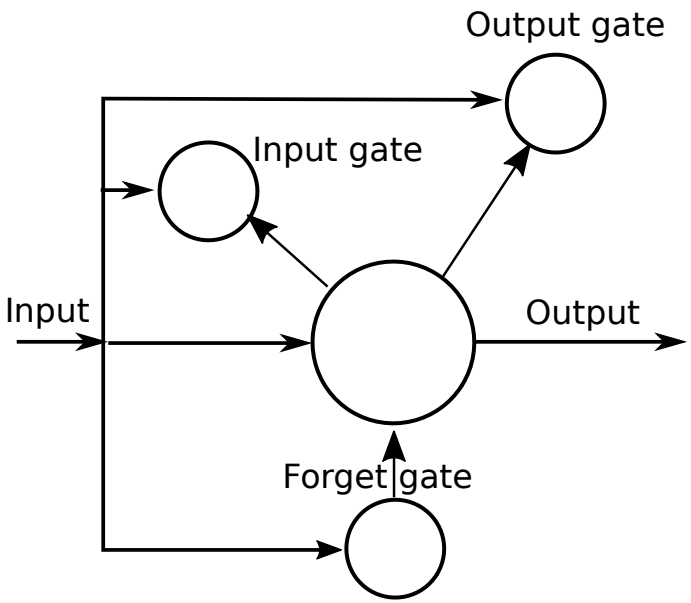
Estructura de las RNN

- Las RNN están especializadas en procesar secuencias de entradas y producen secuencias de salida. Cada salida es añadida a la siguiente entrada.



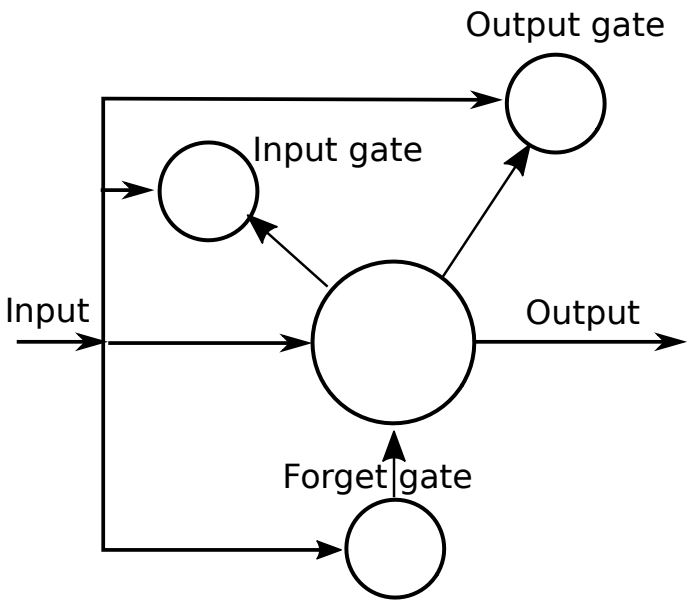
Variantes de RNN: LSTM

- En las LSTM (Long Short Term Memory) las ocultas son células de memoria.
  - La input gate controla cuándo nueva información puede memorizarse.
  - La forget gate controla cuándo la información guardada puede olvidarse y memorizarse una nueva.
  - La output gate controla cuándo la información memorizada puede usarse como salida.
  - Hay pesos que controlan cada gate.



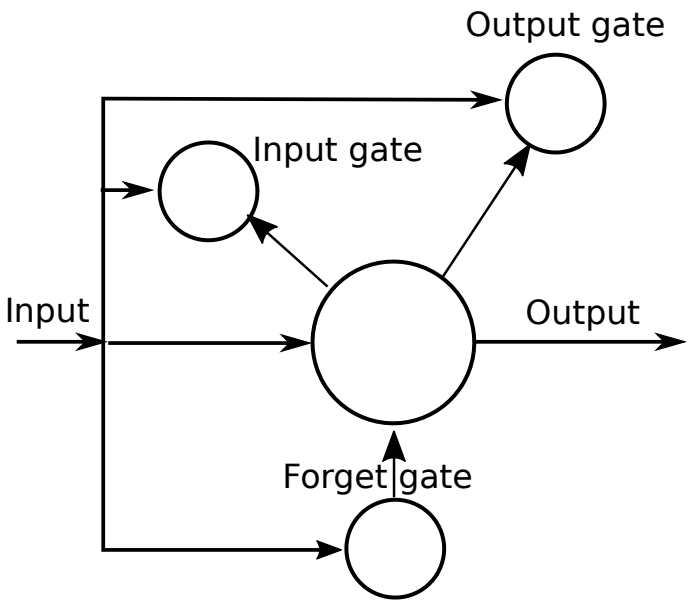
Variantes de RNN: LSTM

- En las LSTM (Long Short Term Memory) las ocultas son células de memoria.
  - La input gate controla cuándo nueva información puede memorizarse.
  - La forget gate controla cuándo la información guardada puede olvidarse y memorizarse una nueva.
  - La output gate controla cuándo la información memorizada puede usarse como salida.
  - Hay pesos que controlan cada gate.



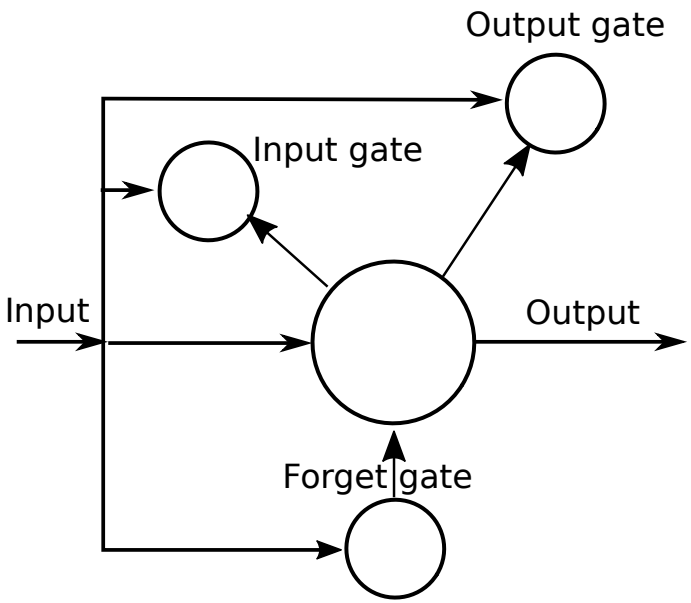
Variantes de RNN: LSTM

- En las LSTM (Long Short Term Memory) las ocultas son células de memoria.
  - La input gate controla cuándo nueva información puede memorizarse.
  - La forget gate controla cuándo la información guardada puede olvidarse y memorizarse una nueva.
  - La output gate controla cuándo la información memorizada puede usarse como salida.
  - Hay pesos que controlan cada gate.



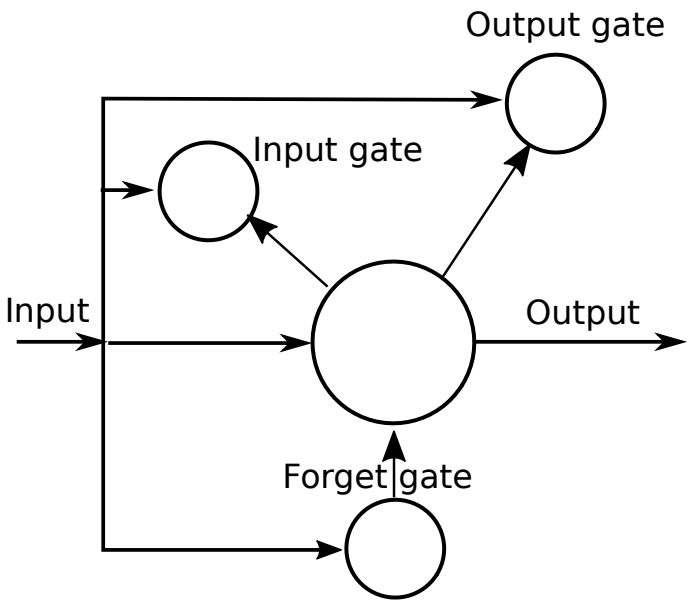
Variantes de RNN: LSTM

- En las LSTM (Long Short Term Memory) las ocultas son células de memoria.
  - La input gate controla cuándo nueva información puede memorizarse.
  - La forget gate controla cuándo la información guardada puede olvidarse y memorizarse una nueva.
  - La output gate controla cuándo la información memorizada puede usarse como salida.
  - Hay pesos que controlan cada gate.



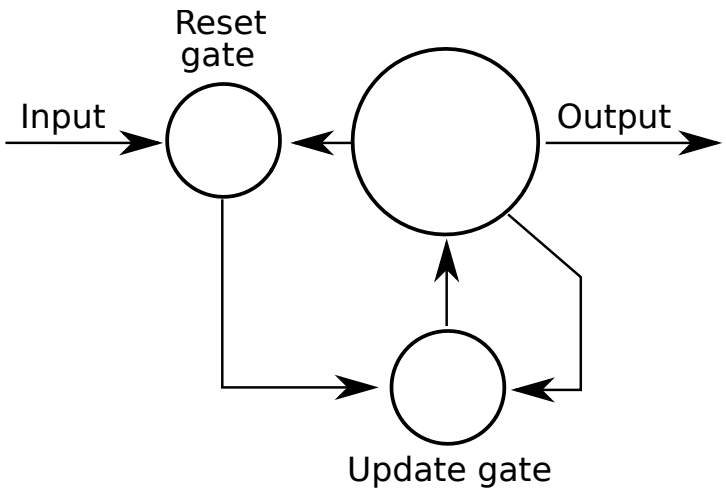
Variantes de RNN: LSTM

- En las LSTM (Long Short Term Memory) las ocultas son células de memoria.
  - La input gate controla cuándo nueva información puede memorizarse.
  - La forget gate controla cuándo la información guardada puede olvidarse y memorizarse una nueva.
  - La output gate controla cuándo la información memorizada puede usarse como salida.
  - Hay pesos que controlan cada gate.



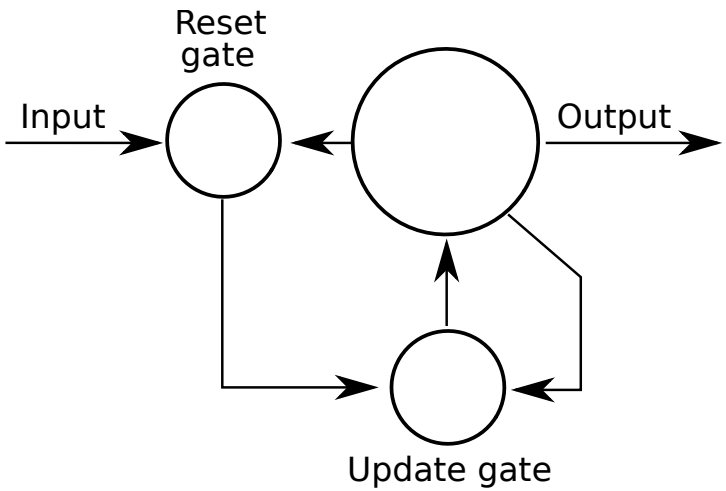
Variantes de RNN: GRU

- Las GRU(Gated Recurrent Units) son una simplificación de las LSTM, más rápidas pero pueden dar peores resultados.
  - La update gate indica cuánto del contenido de la célula anterior se mantiene.
  - La reset gate indica cómo incorporar la nueva entrada con los contenidos de la célula anterior.
  - Reset = 1 y update = 0 equivale a estándar RNN.



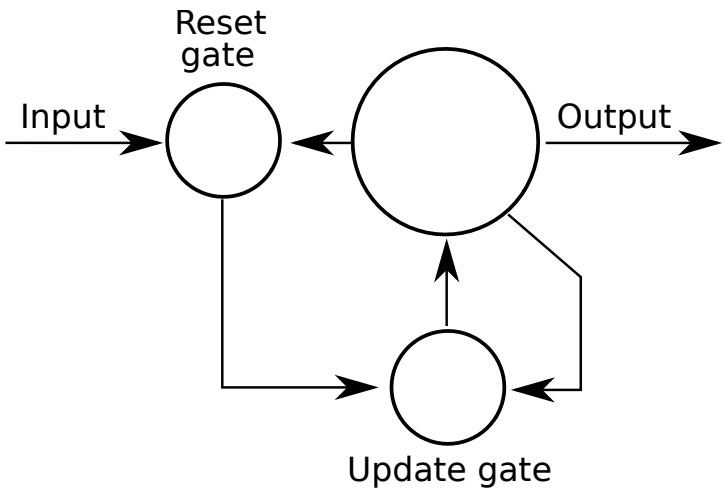
Variantes de RNN: GRU

- Las GRU(Gated Recurrent Units) son una simplificación de las LSTM, más rápidas pero pueden dar peores resultados.
  - La update gate indica cuánto del contenido de la célula anterior se mantiene.
  - La reset gate indica cómo incorporar la nueva entrada con los contenidos de la célula anterior.
  - Reset = 1 y update = 0 equivale a estándar RNN.



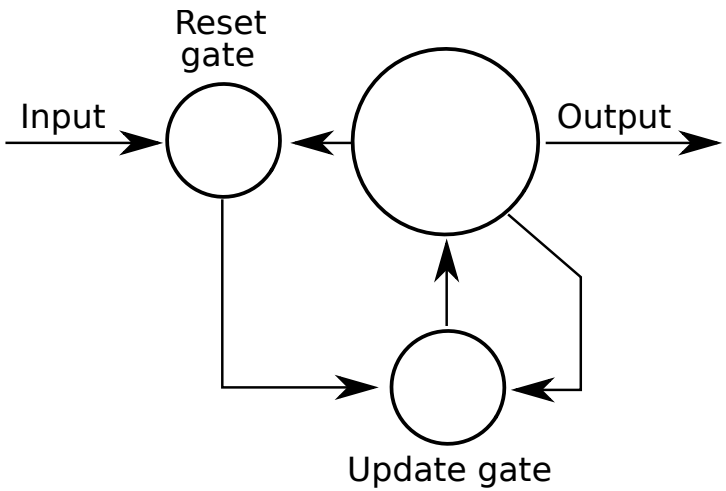
Variantes de RNN: GRU

- Las GRU(Gated Recurrent Units) son una simplificación de las LSTM, más rápidas pero pueden dar peores resultados.
  - La update gate indica cuánto del contenido de la célula anterior se mantiene.
  - La reset gate indica cómo incorporar la nueva entrada con los contenidos de la célula anterior.
  - Reset = 1 y update = 0 equivale a estándar RNN.

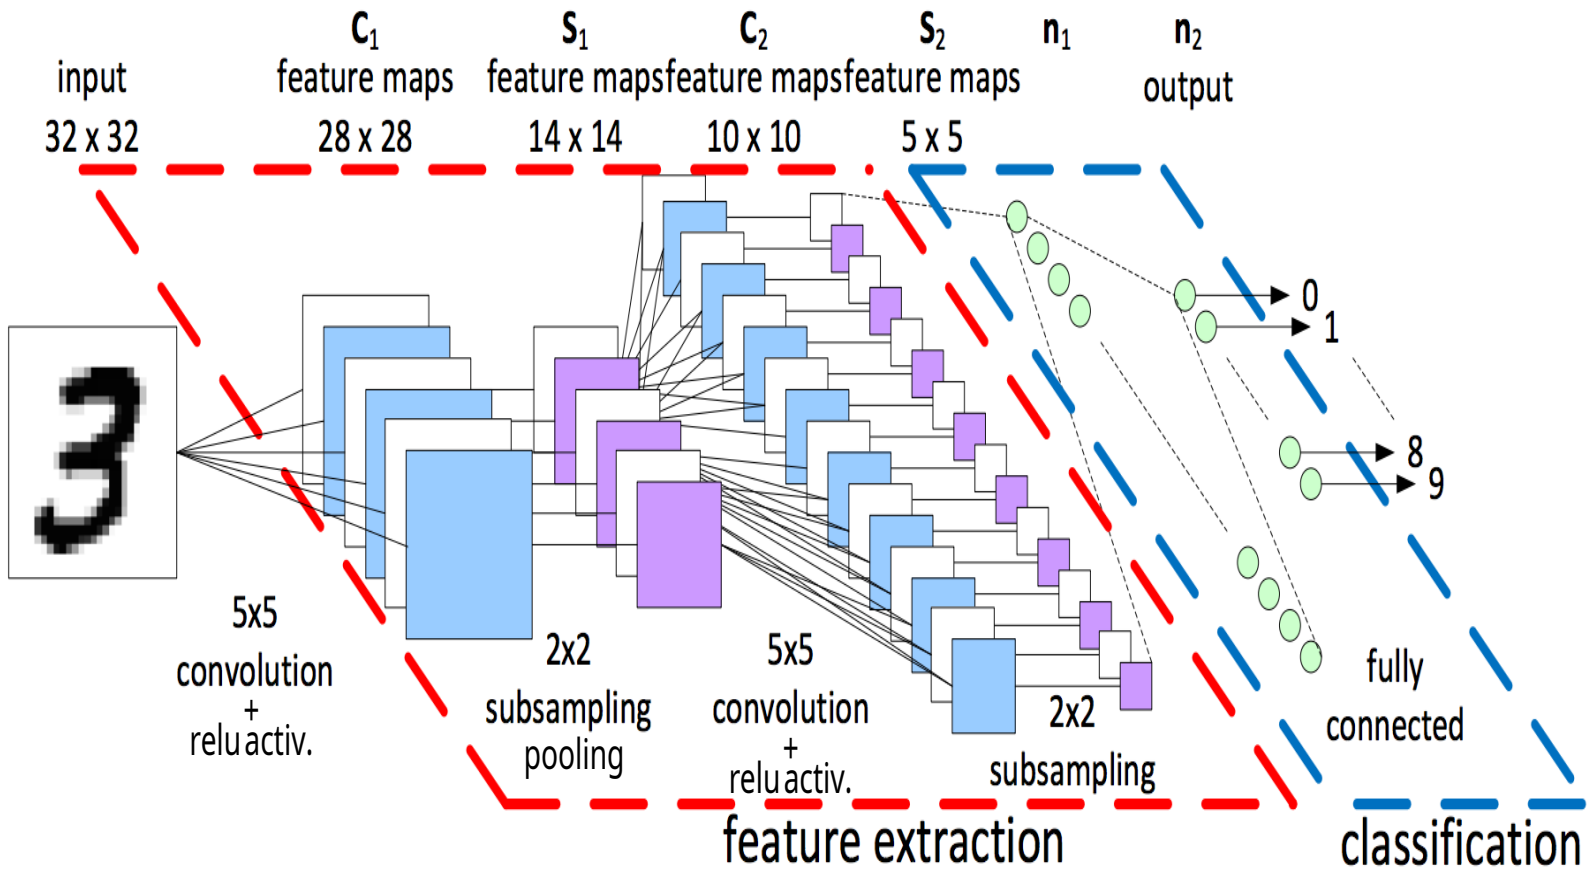


Variantes de RNN: GRU

- Las GRU(Gated Recurrent Units) son una simplificación de las LSTM, más rápidas pero pueden dar peores resultados.
  - La update gate indica cuánto del contenido de la célula anterior se mantiene.
  - La reset gate indica cómo incorporar la nueva entrada con los contenidos de la célula anterior.
  - Reset = 1 y update = 0 equivale a estándar RNN.

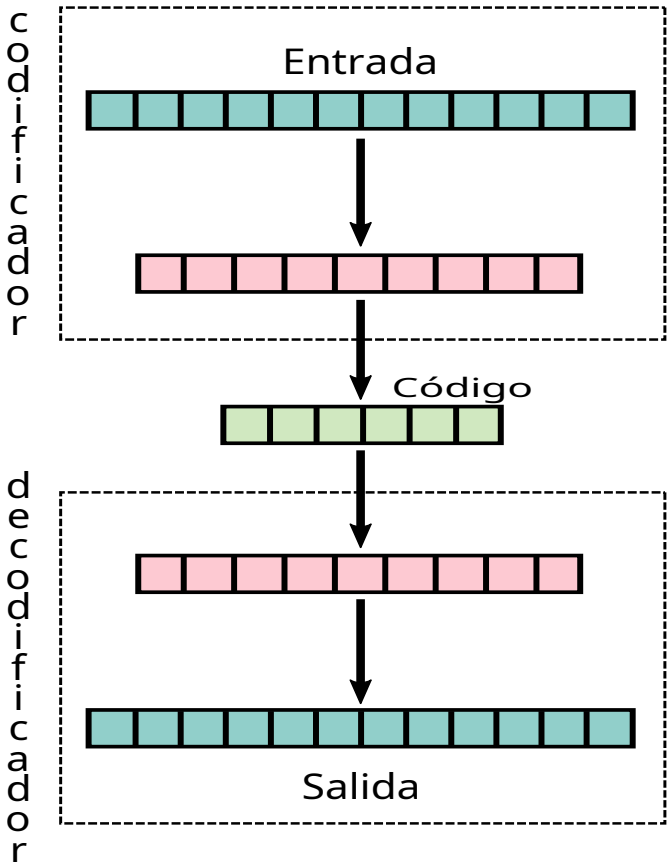


Estructura de las CNN



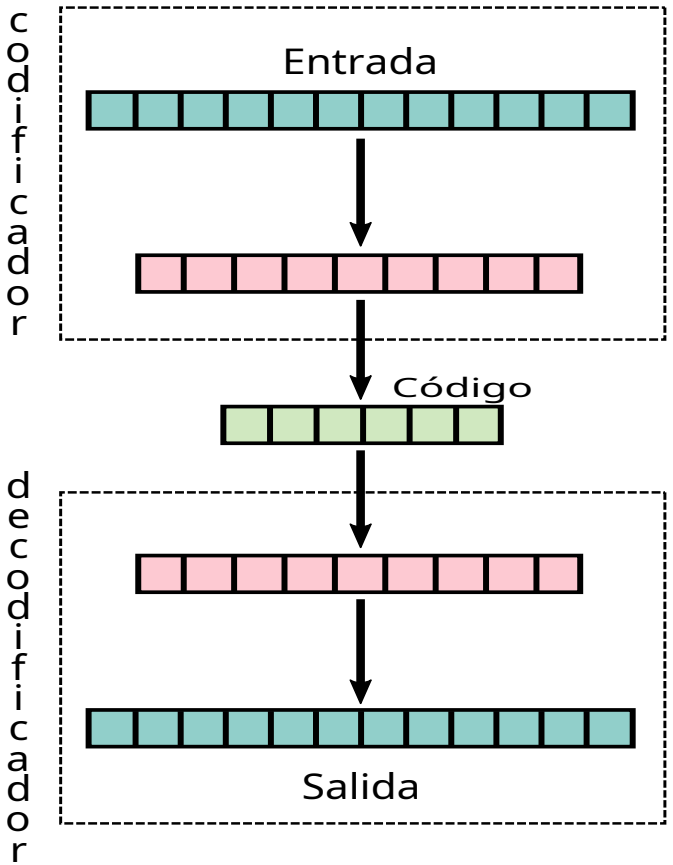
Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
- El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
- Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.
- Similar a PCA.



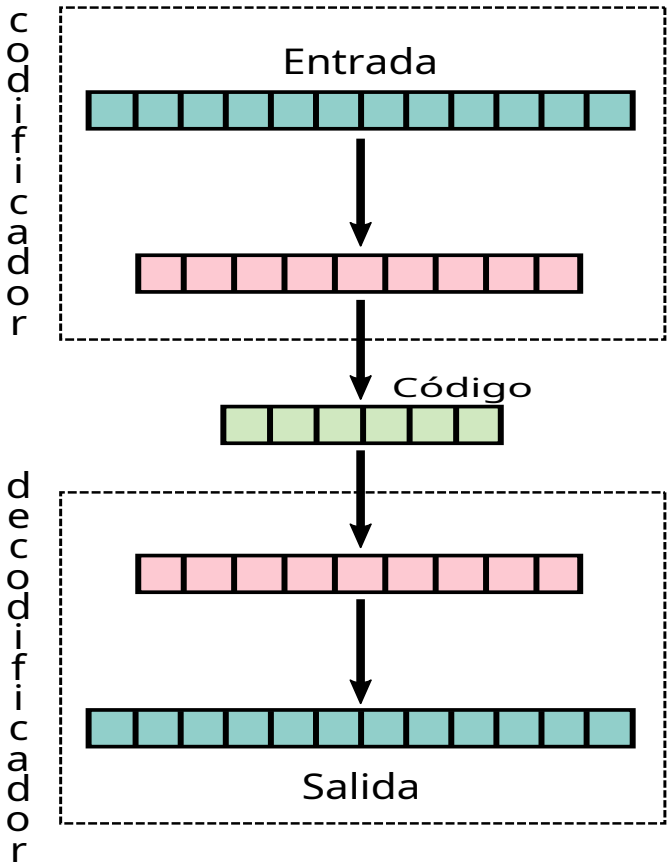
Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
- El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
- Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.
- Similar a PCA.



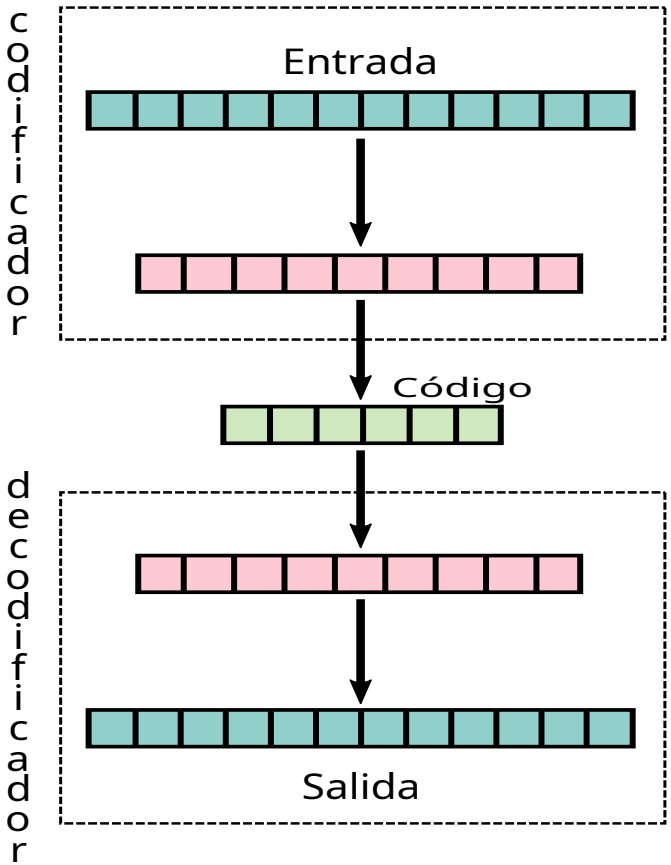
Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
- El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
- Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.
- Similar a PCA.



Estructura de autoencoders

- Tiene dos partes un codificador y un decodificador.
- El codificador aprende una representación comprimida de la entrada que el decodificador reconstruye.
- Si hay una estructura como correlaciones entre características algunas correlaciones serán descubiertas.
- Similar a PCA.



Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP
- Clasificación de textos
- Generación y resumen de textos
- Traducción
- Búsqueda y eliminación de duplicados
- Otras aplicaciones

Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP
- Clasificación de textos
- Generación y resumen de textos
- Traducción
- Búsqueda y eliminación de duplicados
- Otras aplicaciones

Meta arquitectura

- Capa de embedding.
  - Transforma la secuencia de palabras de entrada en una tabla de vectores.
  - Los vectores capturan la semántica
- Componente de representación profunda.
  - Proporcionan un representación comprimida de los vectores.
  - Se pueden usar RNN o CNN.
- Parte totalmente conectada.
  - Transforma la representación comprimida en clases o puntuaciones de clases.
  - Puede contener capas de normalización y dropout.
- Ver el capítulo Text Classification Using LSTM de Hands-On Natural Language Processing with Python

Meta arquitectura

- Capa de embedding.
  - Transforma la secuencia de palabras de entrada en una tabla de vectores.
  - Los vectores capturan la semántica
- Componente de representación profunda.
  - Proporcionan un representación comprimida de los vectores.
  - Se pueden usar RNN o CNN.
- Parte totalmente conectada.
  - Transforma la representación comprimida en clases o puntuaciones de clases.
  - Puede contener capas de normalización y dropout.
- Ver el capítulo Text Classification Using LSTM de Hands-On Natural Language Processing with Python

Meta arquitectura

- Capa de embedding.
  - Transforma la secuencia de palabras de entrada en una tabla de vectores.
  - Los vectores capturan la semántica
- Componente de representación profunda.
  - Proporcionan un representación comprimida de los vectores.
  - Se pueden usar RNN o CNN.
- Parte totalmente conectada.
  - Transforma la representación comprimida en clases o puntuaciones de clases.
  - Puede contener capas de normalización y dropout.
- Ver el capítulo Text Classification Using LSTM de Hands-On Natural Language Processing with Python

Meta arquitectura

- Capa de embedding.
  - Transforma la secuencia de palabras de entrada en una tabla de vectores.
  - Los vectores capturan la semántica
- Componente de representación profunda.
  - Proporcionan un representación comprimida de los vectores.
  - Se pueden usar RNN o CNN.
- Parte totalmente conectada.
  - Transforma la representación comprimida en clases o puntuaciones de clases.
  - Puede contener capas de normalización y dropout.
- Ver el capítulo Text Classification Using LSTM de Hands-On Natural Language Processing with Python

Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP
- Clasificación de textos
- Generación y resumen de textos
- Traducción
- Búsqueda y eliminación de duplicados
- Otras aplicaciones

Generación de textos

- Las RNNs puede ser usadas para crear modelos generativos.
- Las RNNs aprenden dependencias a largo plazo y pueden generar nuevas secuencias.
- La generación puede estar basada en caracteres o palabras.
- Ver el capítulo Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

Generación de textos

- Las RNNs puede ser usadas para crear modelos generativos.
- Las RNNs aprenden dependencias a largo plazo y pueden generar nuevas secuencias.
- La generación puede estar basada en caracteres o palabras.
- Ver el capítulo Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

Generación de textos

- Las RNNs puede ser usadas para crear modelos generativos.
- Las RNNs aprenden dependencias a largo plazo y pueden generar nuevas secuencias.
- La generación puede estar basada en caracteres o palabras.
- Ver el capítulo Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

Generación de textos

- Las RNNs puede ser usadas para crear modelos generativos.
- Las RNNs aprenden dependencias a largo plazo y pueden generar nuevas secuencias.
- La generación puede estar basada en caracteres o palabras.
- Ver el capítulo Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

Resumen de textos

- Hay dos clases de resúmenes: extractivos y abstractivos.
- Extractivos: frases o palabras claves son extraídas y concatenadas
  - Es robusto y simple, el texto es extraído directamente del documento.
  - No permite la paráfrasis (comentario más claro).
- Abstractivos: la salida contiene texto no contenido en el original manteniendo el significado.
- Ver el cap. Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

Resumen de textos

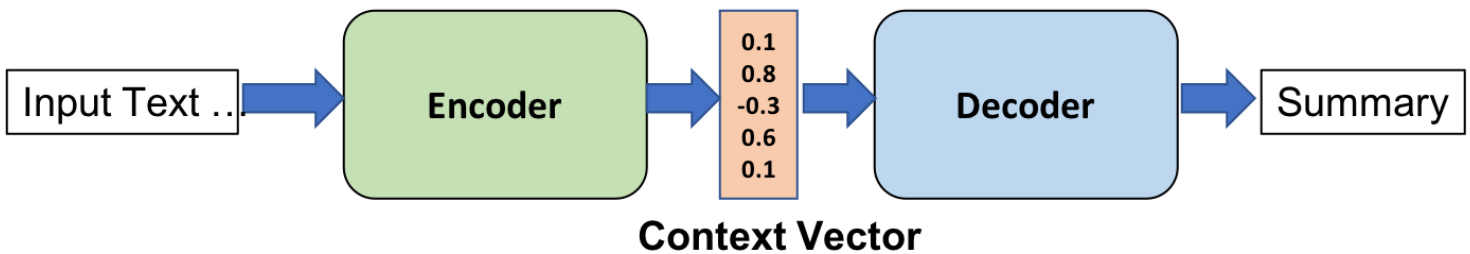
- Hay dos clases de resúmenes: extractivos y abstractivos.
- Extractivos: frases o palabras claves son extraídas y concatenadas
  - Es robusto y simple, el texto es extraído directamente del documento.
  - No permite la paráfrasis (comentario más claro).
- Abstractivos: la salida contiene texto no contenido en el original manteniendo el significado.
- Ver el cap. Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

Resumen de textos

- Hay dos clases de resúmenes: extractivos y abstractivos.
- Extractivos: frases o palabras claves son extraídas y concatenadas
  - Es robusto y simple, el texto es extraído directamente del documento.
  - No permite la paráfrasis (comentario más claro).
- Abstractivos: la salida contiene texto no contenido en el original manteniendo el significado.
- Ver el cap. Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python

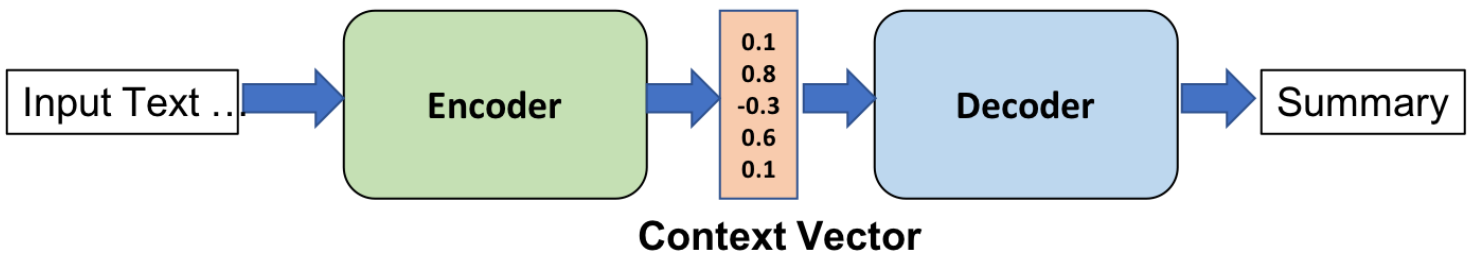
Resumen de textos

- Hay dos clases de resúmenes: extractivos y abstractivos.
- Extractivos: frases o palabras claves son extraídas y concatenadas
  - Es robusto y simple, el texto es extraído directamente del documento.
  - No permite la paráfrasis (comentario más claro).
- Abstractivos: la salida contiene texto no contenido en el original manteniendo el significado.
- Ver el cap. Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python



Resumen de textos

- Hay dos clases de resúmenes: extractivos y abstractivos.
- Extractivos: frases o palabras claves son extraídas y concatenadas
  - Es robusto y simple, el texto es extraído directamente del documento.
  - No permite la paráfrasis (comentario más claro).
- Abstractivos: la salida contiene texto no contenido en el original manteniendo el significado.
- Ver el cap. Text Generation and Summarization Using GRUs de Hands-On Natural Language Processing with Python



Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP
- Clasificación de textos
- Generación y resumen de textos
- Traducción
- Búsqueda y eliminación de duplicados
- Otras aplicaciones

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Tipos de traducción automática

- Sistemas expertos: definen reglas lingüísticas y sintácticas.
- Traducción estadística (SMT, p. ej. NLTK): las reglas son aprendidas estadísticamente a partir de una gran colección de datos bilingües.
  - Utiliza un modelo de traducción que mapea textos de un lenguaje al otro. Y un modelos del lenguaje de salida que captura estadísticas de secuencias.
  - Solo funciona bien traduciendo textos similares a los de entrenamiento, necesita gran cantidad de datos.
- Traducción con redes neuronales (NMT).
  - Solo usa un modelo.
  - Trabaja sobre segmentos de textos, no solo palabras o frases.
- Ver el cap. Machine Translation Using the Attention-Based Model de Hands-On Natural Language Processing with Python

Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP
- Clasificación de textos
- Generación y resumen de textos
- Traducción
- Búsqueda y eliminación de duplicados
- Otras aplicaciones

Búsqueda y eliminación de duplicados

- La búsqueda y eliminación de duplicados se puede conseguir usando una CNN basada en caracteres.
- Las CNN proporciona flexibilidad para entrenar modelos con caracteres desconocidos y es más genérico que el embedding a nivel de palabras
- Este tipo de redes puede para otras búsquedas y emparejamientos.
- Ver el capítulo Searching and DeDuplicating Using CNNs de Hands-On Natural Language Processing with Python

Búsqueda y eliminación de duplicados

- La búsqueda y eliminación de duplicados se puede conseguir usando una CNN basada en caracteres.
- Las CNN proporciona flexibilidad para entrenar modelos con caracteres desconocidos y es más genérico que el embedding a nivel de palabras
- Este tipo de redes puede para otras búsquedas y emparejamientos.
- Ver el capítulo Searching and DeDuplicating Using CNNs de Hands-On Natural Language Processing with Python

Búsqueda y eliminación de duplicados

- La búsqueda y eliminación de duplicados se puede conseguir usando una CNN basada en caracteres.
- Las CNN proporciona flexibilidad para entrenar modelos con caracteres desconocidos y es más genérico que el embedding a nivel de palabras
- Este tipo de redes puede para otras búsquedas y emparejamientos.
- Ver el capítulo Searching and DeDuplicating Using CNNs de Hands-On Natural Language Processing with Python

Búsqueda y eliminación de duplicados

- La búsqueda y eliminación de duplicados se puede conseguir usando una CNN basada en caracteres.
- Las CNN proporciona flexibilidad para entrenar modelos con caracteres desconocidos y es más genérico que el embedding a nivel de palabras
- Este tipo de redes puede para otras búsquedas y emparejamientos.
- Ver el capítulo Searching and DeDuplicating Using CNNs de Hands-On Natural Language Processing with Python

Índice

1 Introducción a las aplicaciones del DL para el NLP

2 Ejemplos de DL para NLP
- Clasificación de textos
- Generación y resumen de textos
- Traducción
- Búsqueda y eliminación de duplicados
- Otras aplicaciones

Otras aplicaciones

- Preguntas-respuestas y chatbots: ver el capítulo Question-Answering and Chatbots Using Memory Networks de Hands-On Natural Language Processing with Python
- Reconocimiento de voz: ver el capítulo Speech Recognition Using DeepSpeech de Hands-On Natural Language Processing with Python
- Texto a voz: ver el capítulo Text-to-Speech Using Tacotron de Hands-On Natural Language Processing with Python

Otras aplicaciones

- Preguntas-respuestas y chatbots: ver el capítulo Question-Answering and Chatbots Using Memory Networks de Hands-On Natural Language Processing with Python
- Reconocimiento de voz: ver el capítulo Speech Recognition Using DeepSpeech de Hands-On Natural Language Processing with Python
- Texto a voz: ver el capítulo Text-to-Speech Using Tacotron de Hands-On Natural Language Processing with Python

Otras aplicaciones

- Preguntas-respuestas y chatbots: ver el capítulo Question-Answering and Chatbots Using Memory Networks de Hands-On Natural Language Processing with Python
- Reconocimiento de voz: ver el capítulo Speech Recognition Using DeepSpeech de Hands-On Natural Language Processing with Python
- Texto a voz: ver el capítulo Text-to-Speech Using Tacotron de Hands-On Natural Language Processing with Python

Thank You



Deep learning 5 (DL 5)

José Manuel Cuadra Troncoso