Teorías sociales en la minería social

Dr. Antonio Rodríguez Anaya

Apuntes del Tema 1 de la asignatura *Minería de Datos en los Medios Sociales* del Master Universitario en Ingeniería y Ciencia de Datos, UNED.

Índice

1. Introducción **1**

2. Retos de la minería de los medios sociales **2**

3. Hacer minería en los medios sociales **3**

4. Teorías sociales en los medios sociales **3**

4.1. Teoría de Correlación social 4

4.2. Teoría del balance 4

4.3. Teoría del estatus 4

5. Teoría sociales en las tareas de minería **5**

5.1. Sobre los usuarios 5

5.2. Sobre las relaciones sociales 6

5.3. Sobre los contenidos 6

Resumen

Durante años se ha investigado entornos sociales desde un punto de vista social, psicológico, pedagógico. Sin embargo, nos encontramos en la actualidad con el gran auge de los entornos sociales virtuales, que tienen unas características especiales debidas al contexto social a la vez que al virtual, en la web, Estos entornos tienen la gran ventaja de que almacenan lo que hacen los usuarios de forma clara y estable. pero sin estructuración, ruidosamente, de forma incompleta, etc. En este tema nos queremos centrar en la utilidad de las teorías sociales en entornos virtuales y la ventaja que ofrece su uso.

1. Introducción

[Zafarani et al., 2014] Los datos de los medios sociales son significativamente distintos de los datos tradicionales en el contexto de la minería de datos. Además del enorme tamaño, los datos generados por usuarios son

desestructurados y con ruido. Por eso, otras formas de análisis de datos son necesarios, además de combinar el análisis con teorías sociales.

Se pueden integrar teorías sociales con métodos computacionales para estudiar cómo los individuos (átomos sociales) interaccionan y cómo se forman las comunidades (moléculas sociales). La minería de los medios sociales es el proceso de representar, analizar y extraer patrones de los datos de los medios sociales. Esta área de investigación cultiva un nuevo tipo de científico de datos el cual tiene que estar bien informado en teorías sociales y computacionales para analizar los datos de los medios sociales, y que tenga las suficientes habilidades para construir puentes entre lo que se conoce, teorías sociales y computacionales, con lo que se quiere conocer sobre el vasto mundo de los medios sociales con herramientas computacionales.

En general en los medios sociales se pueden considerar: átomos sociales (individuos, usuarios, etc.); entidades (contenidos, sitios, redes, etc.); interacciones entre átomos y entidades (entre átomo y átomo, o entre átomo y entidad). Para una minería de datos de medios sociales eficiente:

1. se recolecta información sobre átomos y entidades;
2. se miden sus interacciones;
3. se descubren patrones para entender el comportamiento humano.

2. Retos de la minería de los medios sociales

[Zafarani et al., 2014] Los retos que nacen al contemplar la minería de los datos de los medios sociales son:

- Paradoja del Big Data. Los datos de los medios sociales son muy grandes, pero si enfocamos en un individuo, nos damos cuenta de la poca información sobre él. Por esto mismo hay que utilizar las características de los medios sociales y usar su multi-dimensionalidad, multi-fuente y multi-procedencia para añadir o completar con más información sobre los usuarios individuales para poder realizar el proceso de minería.
- Muestreo suficiente. Las principales fuentes de datos de los medios sociales son las APIs, de las cuales se extrae una cantidad de información limitada de toda la que se podría obtener o de la que el medio social almacena. Se obtiene la que el desarrollo de la API ofrece independientemente de los deseos o necesidades del analista. Además, existe la duda de que la información accesible no sea representativa de la información sobre el individuo o átomo social. Debido a esto, hay que tener en cuenta que ninguna de las fuentes de información puede ser veraz al 100 %.
- El engaño de la eliminación del ruido. En un proceso tradicional de minería se realiza un gran trabajo de preprocesado y eliminación del ruido. Los datos de los medios sociales son, en origen, desestructurados y ruidosos. Si se realiza un proceso exhaustivo de eliminación del ruido nos encontramos con dos escenarios:
    1. se puede eliminar gran parte de los datos sobre un átomo social por lo que el problema de la paradoja de los Big Data se hace más grande;
    2. la definición de ruido se vuelve complicada ya que es relativa a la tarea que se esté realizando.

- El dilema de la evaluación. En los procedimientos estándares de minería, para evaluar patrones se puede dividir el total de los datos en conjuntos más reducidos. En el proceso se utilizan algunos de los conjuntos para inferir el patrón y otros para testar la calidad. Sin embargo, esto no suele ser posible en el proceso de minería de los datos de los medios sociales por su propia naturaleza. Pero hay que tener un medio de evaluación de los patrones inferidos para saber su calidad.

3. Hacer minería en los medios sociales

[Tang et al., 2014] Los datos de los medios sociales son grandes, relacionados, ruidosos, altamente desestructurados e incompletos, y difieren de los datos en la minería de datos tradicional. En estos datos se pueden aplicar teorías sociales con el objetivo de extraer e identificar patrones de comportamiento.

- Grandes: en los medios sociales se pueden obtener algunos pocos datos de los usuarios. Sin embargo, la perspectiva social de estos datos enlazan juntos datos de otros usuarios, lo cual provee una gran cantidad de datos. Puede haber pocos datos de un átomo social pero puede haber un número muy grandes de átomos sociales.
- Enlazados, relacionados: la posibilidad de las relaciones sociales determina que los datos de los medios sociales estén inherentemente enlazados. Estos enlaces ofrecen relaciones de afinidad, de amistad, de estatus, o viceversa, relaciones muy útiles para las teorías sociales.
- Ruidosos: estos datos requieren un extensivo preprocesamiento para la eliminación del ruido, pero, como se ha advertido en la sección precedente, la definición de ruido es relativa a la tarea de procesado y un preprocesado estricto podría eliminar un gran número de datos, y de información significativa..
- Desestructurados: los contenidos generados por los usuarios en los medios sociales son altamente desestructurados. En primer lugar porque las fuentes de datos (API's por ejemplo) ofrecen parte de la información posible sin un formato estándar. En segundo lugar, podría haber varias fuentes de datos, que ofrecen la información de una forma cada una.
- Incompletos: Los patrones de los usuarios pueden ser predecibles con sus datos personales. Sin embargo, los medios sociales permiten a los usuarios configurar la privacidad de sus datos por lo que en su gran mayoría, la información accesible sobre un usuario es incompleta.

El analista, el minero, de los medios sociales tiene que ser consciente de la naturaleza de los datos que va a analizar para tener una perspectiva completa. De esta forma puede realizar unos u otros procesos de filtrado, de obtención, eligiendo las fuentes de los datos, y hacer hipótesis, en la mayor parte de los casos reduccionistas o simplificadoras, para obtener unos patrones de comportamiento que puedan ser útiles en las conclusiones.

4. Teorías sociales en los medios sociales

Las teorías sociales son útiles para explicar varios tipos de fenómenos sociales. Aquí nos centramos en tres:

4.1. Teoría de Correlación social

[Neville and Jensen, 2007, La Fond and Neville, 2010] La teoría de Correlación se basa en el resultado de dos procesos que suceden de forma alternativa, la homofilia social y la influencia, aunque pueden verse involucrados más procesos.

- Homofilia social ("el amor a lo mismo") es la tendencia de los individuos a asociarse y relacionarse con otros similares. Los individuos en relaciones sociales homofílicas comparten características comunes (creencias, valores, educación, etc.) que hacen que la formación de la comunicación y de la relación sean más fáciles. Homofilia social es una métrica estudiada en el campo de análisis de redes sociales en las que también se conoce como asortatividad.
- Influencia en donde usuarios con lazos sociales tienden a generar atributos similares. La influencia sugiere que la gente tiende a seguir el comportamiento de sus amigos, y personas próximas es probable que exhiban comportamientos similares.
- [Chua et al., 2013] Otro factor a tener en cuenta en la teoría de la Correlación social es el denominado k-exposición, por algunos investigadores, o confusión, por otros. Se define como la probabilidad de que un usuario adopte un elemento, aumenta con el número k de sus amigos que lo han adoptado. Se puede entender que el usuario se ve forzado por influencias externas del entorno.

4.2. Teoría del balance

La teoría del equilibrio social o balance es una clase de teoría sobre el equilibrio o desequilibrio de la relación de confianza en las relaciones entre dos o tres personas dentro de la teoría de redes sociales[1]. En esta teoría se pueden agrupar a los individuos dentro de dos grupos con las siguientes normas: los miembros del mismo grupo tienen afinidad entre ellos; los miembros de distintos grupos sienten aversión.

[Tang et al., 2014] Esta teoría implica intuitivamente que los amigos de los mis amigos son mis amigos. Ocurre también, por tanto, las siguientes relaciones: los amigos de mis enemigos son mis enemigos; los enemigos de mis enemigos son mis amigos; los enemigos de mis amigos son mis enemigos. Esta teoría implica que para cada relación entre dos usuarios existe una etiqueta que los identifica como amigos o como enemigos. Este tipo de etiquetas no suele estar señalada de forma explícita en los datos de los medios sociales.

4.3. Teoría del estatus

[Tang et al., 2014] En sociología, estatus social describe la posición social que un individuo ocupa dentro de una sociedad o en un grupo social de personas. Dentro de las redes sociales los átomos sociales pueden ser distintos estatus sociales, y ese estatus se podrá ver representado por las relaciones entre los átomos sociales. La teoría del estatus se refiere a la posición o rango de un usuarios en la comunidad social y representa el grado de honor o prestigio. Con esta teoría un enlace positivo entre un usuario u(1) y u(2) implica que el usuario u(2) tiene un estatus más alto que el usuario u(1). Para poder aplicar esta teoría al análisis de redes sociales, las relaciones entre átomos sociales deberán ser direccionales. Por lo tanto, la dirección de la relación indicará el origen y el destino de la relación. Además, deberá poder etiquetarse la relación desde el punto de vista del estatus, para poder indicar la diferencia de estatus entre uno y otro.

[1] `https://en.wikipedia.org/wiki/Social_balance_theory`

5. Teoría sociales en las tareas de minería

Hay tres tipos de objetos en los datos de los medios sociales: usuarios, relaciones sociales y contenidos generados por los usuarios. Por lo tanto, se puede señalar los tres tipos de tareas de minería: sobre el usuario, sobre las relaciones, sobre los contenidos.

5.1. Sobre los usuarios

Detección de comunidades [Zafarani et al., 2014]

Para la minería de medios sociales, la detección de comunidades es esencial e importante por distintos motivos:

1. Los individuos a menudo forman grupos según sus intereses, por ejemplo por sus gustos de lectura. En este caso, a un individuo de la comunidad se le podría aconsejar la compra de algún libro según su entorno en esta comunidad.
2. Los grupos desvelan una visión general de las interacciones de los usuarios. Los átomos de una red social suelen mostrar un comportamiento, deducido por sus interacciones, ruidoso o para un fin preciso. Sin embargo, en el grupo los individuos se comportan siguiendo un patrón común, lo que hace que el comportamiento sea más robusto a los cambios. De esta forma se puede extraer información sobre el comportamiento de un individuo siguiendo sus interacciones en el grupo, además de las del grupo en su conjunto.

Se pueden establecer dos tipos de comunidades:

- Comunidades explícitas:
  - Los miembros de la comunidad entienden que son miembros.
  - Los no-miembros de la comunidad entienden que no son miembros.
  - Los miembros de la comunidad a menudo interaccionan más con otros miembros que con lo que no lo son.
- Comunidades implícitas:
  - Los individuos interaccionan tácitamente en la forma de una comunidad no reconocida.

Encontrar comunidades implícitas es de gran interés en la minería de medios sociales. Se pueden encontrar comunidades implícitas identificando a grupos de usuarios densamente conectados entre ellos en comparación a la red en su conjunto. Esta detección beneficia a tareas de minería de los medios sociales como la búsqueda del usuario apropiado o la personalización. Hemos visto que la homofilia social sugiere que usuarios similares es probable que estén enlazados, y la influencia indica que usuarios enlazados influirán en los otros para ser más similares. Por lo tanto, utilizando la de Correlación social, comunidades implícitas pueden identificarse.

Clasificación de usuarios [Tang et al., 2014]

Dada una red social y alguna información personal de los usuarios, se puede clasificar a los usuarios, o a un conjunto de los mismos, completando la información individual con la del conjunto. Por ejemplo, una vez que una comunidad es identificada, se clasificará a los miembros de la comunidad por la información que se extraiga del conjunto de la información individual de todos los miembros.

Detección de spammers sociales[Tang et al., 2014]

De acuerdo con la teoría de correlación social, nos podemos encontrar usuarios normales y usuarios spammers. Los primeros se comportan de forma similar a sus vecinos, lo contrario que los spammers, ya que la mayor parte de sus vecinos deberán ser usuarios normales. Si se analiza la red total, los usuarios normales formarán una subred de mayor densidad dentro de la red total.

5.2. Sobre las relaciones sociales

Predicción de enlaces [Tang et al., 2014]

Homofilia social en la teoría de Correlación social sugiere que usuarios similares es probable que establezcan relaciones sociales. El coeficiente de homofilia social es definido como una medida de la fuerza de la homofilia social entre usuarios. La más fuerte homofilia social entre dos usuarios es la distancia más pequeña entre ellos en el espacio implícito. El coeficiente de homofilia social entre dos usuario de una misma red, en la que no se encuentran directamente conectados, está relacionado con la probabilidad de realizar una conexión directa entre ellos.

El efecto de confusión en la teoría de correlación social sugiere que usuarios que comparen un alto grado de solapamiento en sus trayectorias es esperado que tengan más probabilidad de formar nuevos enlaces.

La teoría de status sugiere que los nuevos enlaces son más probables de usuarios con poco estatus a usuarios con alto estatus.

5.3. Sobre los contenidos

Recomendación social [Zafarani et al., 2014]

En los medios sociales hay información adicional que es la red de amistad entre los individuos. Esta información puede ser utilizada para mejorar la recomendación basándose en la suposición del impacto que tienen los amigos del individuo. El impacto puede ser debido a la homofilia social, a la influencia o a la k-exposición, o confusión, a la que se ve expuesto el individuo por formar parte de una red social. La recomendación ha sido probada que es eficiente para mitigar los problemas de sobrecarga de información, la recomendación de contenidos, etc.

Referencias

Freddy Chong Tat Chua, Hady W Lauw, and Ee-Peng Lim. Generative models for item adoptions using social correlation. *IEEE Transactions on Knowledge and Data Engineering*, 25(9):2036–2048, 2013.

Timothy La Fond and Jennifer Neville. Randomization tests for distinguishing social influence and homophily effects. In *Proceedings of the 19th international conference on World wide web*, pages 601–610. ACM, 2010.

Jennifer Neville and David Jensen. Relational dependency networks. *Journal of Machine Learning Research*, 8:653–692, 2007.

Jiliang Tang, Yi Chang, and Huan Liu. Mining social media with social theories: a survey. *ACM SIGKDD Explorations Newsletter*, 15(2):20–29, 2014.

Reza Zafarani, Mohammad Ali Abbasi, and Huan Liu. *Social media mining: an introduction*. Cambridge University Press, 2014.