# Introducción a la minería de datos en redes sociales

Dr. Antonio Rodríguez Anaya

2 de febrero de 2021

Apuntes del Tema 3 de la asignatura *Minería De Datos De Los Medios Sociales* del Máster Universitario En Ingeniería Y Ciencia De Datos, UNED, curso 2020/2021.

## Índice

**1. Introducción** **1**

**2. Datos** **2**

2.1. Calidad de los datos . . . . . 2

**3. Preproceso de datos** **2**

**4. Algoritmos de minería de datos** **3**

4.1. Algoritmos de aprendizaje supervisado . . . . . 4

4.2. Algoritmos de aprendizaje no supervisado . . . . . 5

## 1. Introducción

La minería de datos ofrece las herramientas necesarias para descubrir patrones en conjuntos de datos. El proceso de minería de datos consiste en varias fases:

1. Extracción de datos desde un almacén de datos en crudo. Esta fase se suele llamar descubrimiento de conocimiento en bases de datos. Del conjunto de datos en crudo se selecciona solamente una parte, los datos .
2. A la parte seleccionada se le realiza un preprocesamiento para que puedan ser utilizados con los algoritmos de minería de datos.
3. Ahora se pueden utilizar herramientas de minería de datos, como algoritmos, para inferir de los datos patrones.
4. Los patrones son evaluados para asegurarse su validez y veracidad, además de interpretados para comprobar su utilidad.

# 2. Datos

En el proceso de descubrimiento de conocimiento en bases de datos, el formato de los mismos es tabular, en forma de tabla. Las filas de la tabla son llamadas instancias, o puntos, u observables. Las instancias se componen de características, también llamados atributos o medias, que son las columnas de la tabla. Cada instancias tendrá ciertos valores en sus atributos. Uno de esos atributos es denominado la clase. La clase indica una información sobre la instancia que es inferida debido a los valores de los otros atributos. El proceso de minería de datos consiste en inferir esos valores o encontrar la relación entre los atributos y la clase.

En la minería de datos de medios sociales, los datos en crudo pueden provenir de varias fuentes en formatos no tabulados, como texto, relaciones, sonido, vídeos, etc. El primer paso es crear un conjunto de datos en forma tabular que contenga toda la información sobre los átomos de la investigación, normalmente seres humanos y sus relaciones. Existen varios procesos para transformar los observables a formato tabular. Por ejemplo, en el caso de texto existe un proceso llamado de vectorización [Salton et al., 1975] muy útil y popular [1].

## 2.1. Calidad de los datos

A la hora de preparar los datos, hay cuatro casos que hay que tener en cuenta:

- El ruido es una distorsión de los datos. Esta distorsión tiene que ser eliminada sino se quiere que los algoritmos sean afectados. Sin embargo, en los medios sociales los datos suelen ser de gran volumen, incompletos, desestructurados, ruidosos, por lo que si se siguen procedimientos comunes en otros contextos de minería de eliminar y no dejar huella de los datos ruidosos, se puede perder gran parte de la información.
- Valores erráticos o atípicos que son instancias consideradas diferentes de otras instancias del conjunto de datos. En la mayor parte de los casos estos valores tendrán que ser eliminados, pero habrá casos especiales, que dependan del contexto de la investigación, que estos datos sean útiles.
- Valores perdidos. Hay algunas instancias que no todos sus atributos tendrán algún valor. Ocurre este caso en los medios sociales, en donde ya se dijo que los datos suelen ser incompletos. Se pueden tomar tres estrategias: 1- eliminar todas las instancias con valores perdidos; 2- estimar los valores perdidos; 3- ignorar los valores perdidos al ejecutar los algoritmos. Hay que tener en cuenta que algunos algoritmos pueden manejar valores perdidos, mientras otros no pueden ser ejecutados.
- Datos duplicados que ocurren cuando distintas instancias tienen el mismo valor en todos sus atributos. Dependiendo del contexto, los datos duplicados pueden tener entidad por si mismos, o pueden ser útiles en el proceso de interpretación de los resultados.

# 3. Preproceso de datos

Cuando los datos no están preparados para los algoritmos, se pueden realizar los siguientes procesos:

- Agregación. Este proceso se realiza para combinar múltiples atributos en uno o cuando la escala de los atributos cambia.

[1] Interesante entrada de la Wikipedia (`https://en.wikipedia.org/wiki/Vector_space_model`)

- Discretización[2]. Si se tiene un atributo que puede tomar valores en un continuo, como por ejemplo números, pero se quiere concentrar los valores en unos posibles, se realiza el proceso de discretización. Un ejemplo típico podría ser el atributo sueldo de un trabajador. Este atributo es numérico y puede tomar valores entre un amplio intervalo, pero se quiere concretar los valores en alto, medio o bajo, lo cual es fácil de entender. En el ejemplo pasado se realizaría un proceso de discretización.

- Normalización estadística[3] (El término estandarización se emplea con el mismo sentido que normalización en bastantes entornos estadísticos). Es muy común que los atributos de cada instancia del dataset tengan un rango de valores muy variado. Un ejemplo, si cada instancia representa una persona y sus atributos son datos fisiológicos, tendríamos, por ejemplo, altura en centímetros, peso en kilos, edad en años, grasa corporal en porcentaje[4]. Los valores de estos atributos tendrían un rango distinto (de 20 a 230 cm para la altura, de 1 a 180 kg para el peso, de 0 a 120 para la edad, de 0 % a 50 % para el porcentaje de grasa corporal). Dependiendo del algoritmo de aprendizaje automático que utilicemos nos convendrá normalizar los valores para que los rangos de los atributos sean compatibles. Es importante conocer los procedimientos matemáticos que utiliza los algoritmos ya que se podría dar mayor importancia a los rangos con valores más altos, por ejemplo. Por lo tanto, si se da el caso, sería conveniente normalizar los valores. La normalización ocurre cuando los posibles rangos de los valores para cada atributo toman un valor entre un determinado intervalo, siendo este intervalo el mismo para cada atributo. Lo más general es que el intervalo ocurra entre 0 y 1 ($x_i \epsilon [0, 1]$, siendo $i$ el índice del atributo del dataset).

- Selección de atributos. Cuando no todas los atributos son útiles para el contexto de investigación, o hay un problema de potencia computacional, u otros factores, se puede seleccionar un subconjunto de atributos del total.

- Extracción de atributos. En este proceso se construye un nuevo conjunto de datos con otros atributos pero siendo una transformación de los anteriores.

- Muestreo. Cuando el conjunto de datos es grande y el proceso es caro, en tiempo, en poder computacional, etc., se toma una muestra, un subconjunto, del total suponiendo que son representativos de todos.

- Eliminación de las instancias con valores atípicos o erráticos. Puede ocurrir que haya un determinado número de instancias con valores atípicos en uno o varios atributos. Si el número total de instancias es algo y el número de instancias con valores atípicos no es representativo, se pueden eliminar para mejorar la interpretación de los resultados finales. Si algunos de los atributos de las instancias se pueden representar con una distribución normal[5], se pueden eliminar todas aquellas instancias que estén alejadas del valor central ($2 * \sigma \implies 5\,\%$; $3 * \sigma \implies 1\,\%$; en donde $\sigma$representa la desviación estándar).

# 4. Algoritmos de minería de datos

Los algoritmos de minería de datos se dividen en dos categorías:

[2] https://es.wikipedia.org/wiki/Discretización
[3] https://en.wikipedia.org/wiki/Normalization_(statistics)
[4] https://es.wikipedia.org/wiki/Porcentaje_de_grasa_corporal
[5] https://es.wikipedia.org/wiki/Distribución_normal

- De aprendizaje supervisado[6]. En el aprendizaje supervisado existe un valor de clase para las instancias, o un conjunto de ellas. Estos algoritmos son entrenados por un subconjunto de datos con el valor de la clase para aprender como se han clasificado esas instancias. Una vez que han aprendido, el algoritmo es capaz de clasificar el resto de instancias, es decir, dar a cada instancia un valor de clase. Cuando la clase toma valores discretos, se llama clasificación. Cuando la clase toma valores en un continuo, se llama regresión. El aprendizaje supervisado puede ser dividido en clasificación y regresión. Introducimos métodos de clasificación como los algoritmos de árbol de decisión, el clasificador Naive Bayes, el clasificador vecino más cercano de k, y la clasificación por redes de información. Los métodos de regresión son la regresión lineal y la regresión logística.

- De aprendizaje no supervisado[7]. Si el conjunto de datos no tiene un atributo de clase, o no se quiere utilizar, y nuestro objetivo es agrupar las instancias según similitud, se aplican algoritmos de aprendizaje no supervisado. Con la simple agrupación de las instancias, se pueden deducir patrones en los datos.

## 4.1. Algoritmos de aprendizaje supervisado

En el aprendizaje supervisado tiene que haber un conjunto de datos con valores para los atributos y para la clase. Un conjunto de instancias tendrían que tener un valor de clase, es decir, estar etiquetados. Un gran reto de los procesos de minería de datos con algoritmos de aprendizaje supervisado es etiquetar instancias o encontrar un conjunto de datos previamente etiquetados de forma realista. Este es un gran problema o el mayor problema de los algoritmos de aprendizaje supervisado.

El aprendizaje ocurre cuando el total o partes del conjunto de datos se utiliza para entrenar el algoritmo. Una vez entrenado el algoritmo se propone un modelo que tiene que ser validado utilizando una parte del conjunto de datos. Podemos encontrar diferentes tipos de algoritmos:

- Algoritmos que utilizan un valor discreto en la clase:

  - *Árboles de decisión*. Estos algoritmos necesitan un conjunto de datos de entrenamiento con un valor de clase para cada instancia. Al entrenarlos, el algoritmo aprende un árbol lógico que describe los valores que tienen que tomar los atributos para llegar a un determinado valor de la clase. En el árbol lógico cada nodo representa un atributo y cada rama un valor o intervalo de valores de ese atributo. Una vez que ha sido entrenado el algoritmo, se utiliza el mismo conjunto de datos, o parte de él, para comprobar la exactitud del árbol lógico propuesto. Este tipo de algoritmos proponen una explicación, que valores tienen que tomar los atributos, para cada posible valor de la clase.
  - *Naive Bayes*. Este clasificador utiliza el teorema de Bayes[8] de la forma más sencilla. El teorema de Bayes expresa que: $P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$ en donde $X$ e $Y$ son dos variables aleatorias. El clasificador Naive Bayes utiliza el atributo de clase como variable $Y$, mientras que el resto de atributos como variable $X$. De esta forma $P(X)$ es independiente de los valores de $Y$ por lo que se puede ignorar, y sólo se tiene que proponer una función de densidades a priori ($P(Y)$) para resolver la clasificación, ya que a través del conjunto de datos se puede deducir la función de probabilidades $P(X|Y)$. Este algoritmo ofrece la probabilidad de que suceda un valor de clase en relación a las probabilidades de que sucedan los valores de los atributos.

[6] https://es.wikipedia.org/wiki/Aprendizaje_supervisado
[7] https://es.wikipedia.org/wiki/Aprendizaje_no_supervisado
[8] https://es.wikipedia.org/wiki/Teorema_de_Bayes

- Redes neuronales[9]. Una red neuronal es un conjunto de nodos u objetos computacionales cuya misión es computar si la información que les llega de entrada la comunican al resto de neuronas conectadas entre sí previamente. Si tenemos dos variables $X$ las entradas, en nuestro caso los atributos, e $Y$, en nuestro caso el atributo de clase, la red construye una función $f(x) = y$; La red aprende, mediante el entrenamiento con el conjunto de datos, total o parcial, estableciendo unos pesos para las conexiones entre neuronas. Este modelo se verifica con otra parte del resto del conjunto de datos. Este tipo de algoritmo no ofrece una explicación de como se ha conseguido la función $f(x)$, pero ofrece otras ventajas como la rapidez computacional.
- *El vecino más cercano*. Este algoritmo utiliza los k instancias más cercanas, llamados vecinos, para llevar a cabo la clasificación. El número $k$ es un valor elegido a priori. El algoritmo asigna el mismo valor de clase a los $k$ vecinos. Para determinar los vecinos de una instancia, necesitamos medir su distancia al resto de los casos sobre la base de una cierta distancia métrica. Comúnmente, se emplea la distancia euclidiana. Un problema importante es la elección de $k$. La elección de $k$ puede cambiar fácilmente la etiqueta de la instancia que se predijo. En general, estamos interesados en un valor de $k$ que maximize el rendimiento del algoritmo.

- Métodos que utilizan un valor continuo en la clase:
  - Regresión. En este caso el valor de clase es un número real. La entrada del método $x_i$ son los valores de los atributos y la clase $(y)$ es llamada variable dependiente. El objetivo de este método es encontrar una función matemática $F(x_i) = y$; La función puede ser:
    - Lineal[10]. Se asume una relación lineal entre las variables x e y.
    - Logística ([11]). La regresión logística es un tipo de análisis de regresión utilizado para predecir el resultado de una variable categórica (una variable que puede adoptar un número limitado de categorías) en función de las variables independientes o predictoras.

## 4.2. Algoritmos de aprendizaje no supervisado

Con estos algoritmos se consigue dividir el conjunto de datos en distintos grupos, cuyas instancias tienen semejanzas entre sí. La evaluación de la certeza de los resultados es difícil ya que no se conoce a priori que instancia debería estar en el mismo grupo de otra instancia. No hay un atributo de clase que guíe la agrupación de los datos. Por lo tanto, es difícil conocer la viabilidad de los resultados, es decir, saber cuánto de correctos son los resultados obtenidos. Sin embargo, se tiene la gran ventaja de no necesitar una etiqueta o clase para cada instancia. Esto último es una gran ventaja en entornos de datos desestructurados como los que normalmente se manejan en la web social. Por esta razón damos mucha importancia a esta clase de algoritmos.

El principal grupo de algoritmos son los de clustering[12]. Estos algoritmos agrupan en un número de grupos preestablecido, o no, las instancias del conjunto de datos según la similitud ente ellas. Es importante estudiar el problema de clustering siguiendo los siguientes pasos [Theodoridis and Koutroumbas, 2003]:

- Selección de características o atributos. Los atributos deben ser seleccionados apropiadamente para contener la mayor cantidad de información útil para los interés de la tarea a realizar. También habría

[9] https://en.wikipedia.org/wiki/Artificial_neural_network#Supervised_learning
[10] https://es.wikipedia.org/wiki/Regresión_lineal
[11] https://en.wikipedia.org/wiki/Logistic_regression
[12] https://es.wikipedia.org/wiki/Algoritmo_de_agrupamiento

que minimizar la redundancia de la información. Por lo tanto, el objetivo sería utilizar un subconjunto de datos del total con el mínimo número de atributos para obtener una agrupación de las instancias viable. Los procesos de preprocesamiento son muy útiles en este paso.

- Medida de la proximidad. Los algoritmos de clustering agrupan las instancias según su semejanza. Para ello utilizan medidas de proximidad con la hipótesis de a mayor proximidad, mayor semejanza. Para calcular la proximidad se utilizan distancias métricas. Un ejemplo de estas distancias son: distancia euclidea, distancia euclidea al cuadrado, distancia de Manhattan, similitud coseno, etc. Dependiendo de la distancia que se utilice, es muy importante que los atributos estén normalizados. Por lo tanto, los procesos de preprocesamiento también tienen gran importancia en este paso.
- Criterios de agrupación. Dependiendo del algoritmo de clustering seleccionado, los grupos resultantes pueden ser compactos (cuando una instancia solo puede pertenecer en un grupo o cluster), probabilistas (cuando cada instancia pertenece a distintos grupos o clusters con diferente probabilidad), borrosos (cuando cada instancia pertenece a distintos grupos o clusters según un grado de ambigüedad).
- Algoritmos de clustering. Según las elecciones previas, se selecciona el algoritmo de clustering más apto.
- Validación de los resultados. La corrección de los resultados se puede llevar a cabo usando test apropiados.
- Interpretación de los resultados. En muchos casos, un experto del campo puede estudiar la agrupación obtenida para sacar las conclusiones correctas.

El principal problema de este tipo de algoritmos es tener un método de verificación. Hay varios factores a tener en cuenta:

- *La cohesión.* En la evaluación de la agrupación estamos interesados en cluster que presentan cohesión. En las agrupaciones cohesivas, las instancias dentro de las agrupaciones están cerca entre sí. En términos estadísticos esto es equivalente a tener una pequeña desviación (es decir, que está cerca del valor medio, del centro del grupo o cluster). Así cohesión se define como la distancia de las instancias al centroide de sus respectivos grupos, a menor valor de las distancias, más cohesionado el cluster.
- *Separación.* También estamos interesados en la agrupación de los datos que generan clusters que están bien separados unos de otros. Para medir esta distancia entre racimos, podemos utilizar la medida de separación. En estadística, la separación puede ser medida por la desviación estándar. La desviación estándar se maximiza cuando los casos están lejos de la media. En términos de agrupación, esto es equivalente a agruparse alrededor de centroides que están más separados entre sí que la media.
- Índice de silueta[13]. Se compara el valor de distancia media entre instancias en el mismo grupo y el valor promedio de distancia entre las instancias en los diferentes grupos.

# Referencias

Gerard Salton, Anita Wong, and Chung-Shu Yang. A vector space model for automatic indexing. *Communications of the ACM*, 18(11):613–620, 1975.

S. Theodoridis and K. Koutroumbas. *Pattern Recognition*. Elsevier Academic Press, 2003.

[13] `https://en.wikipedia.org/wiki/Silhouette_(clustering)`