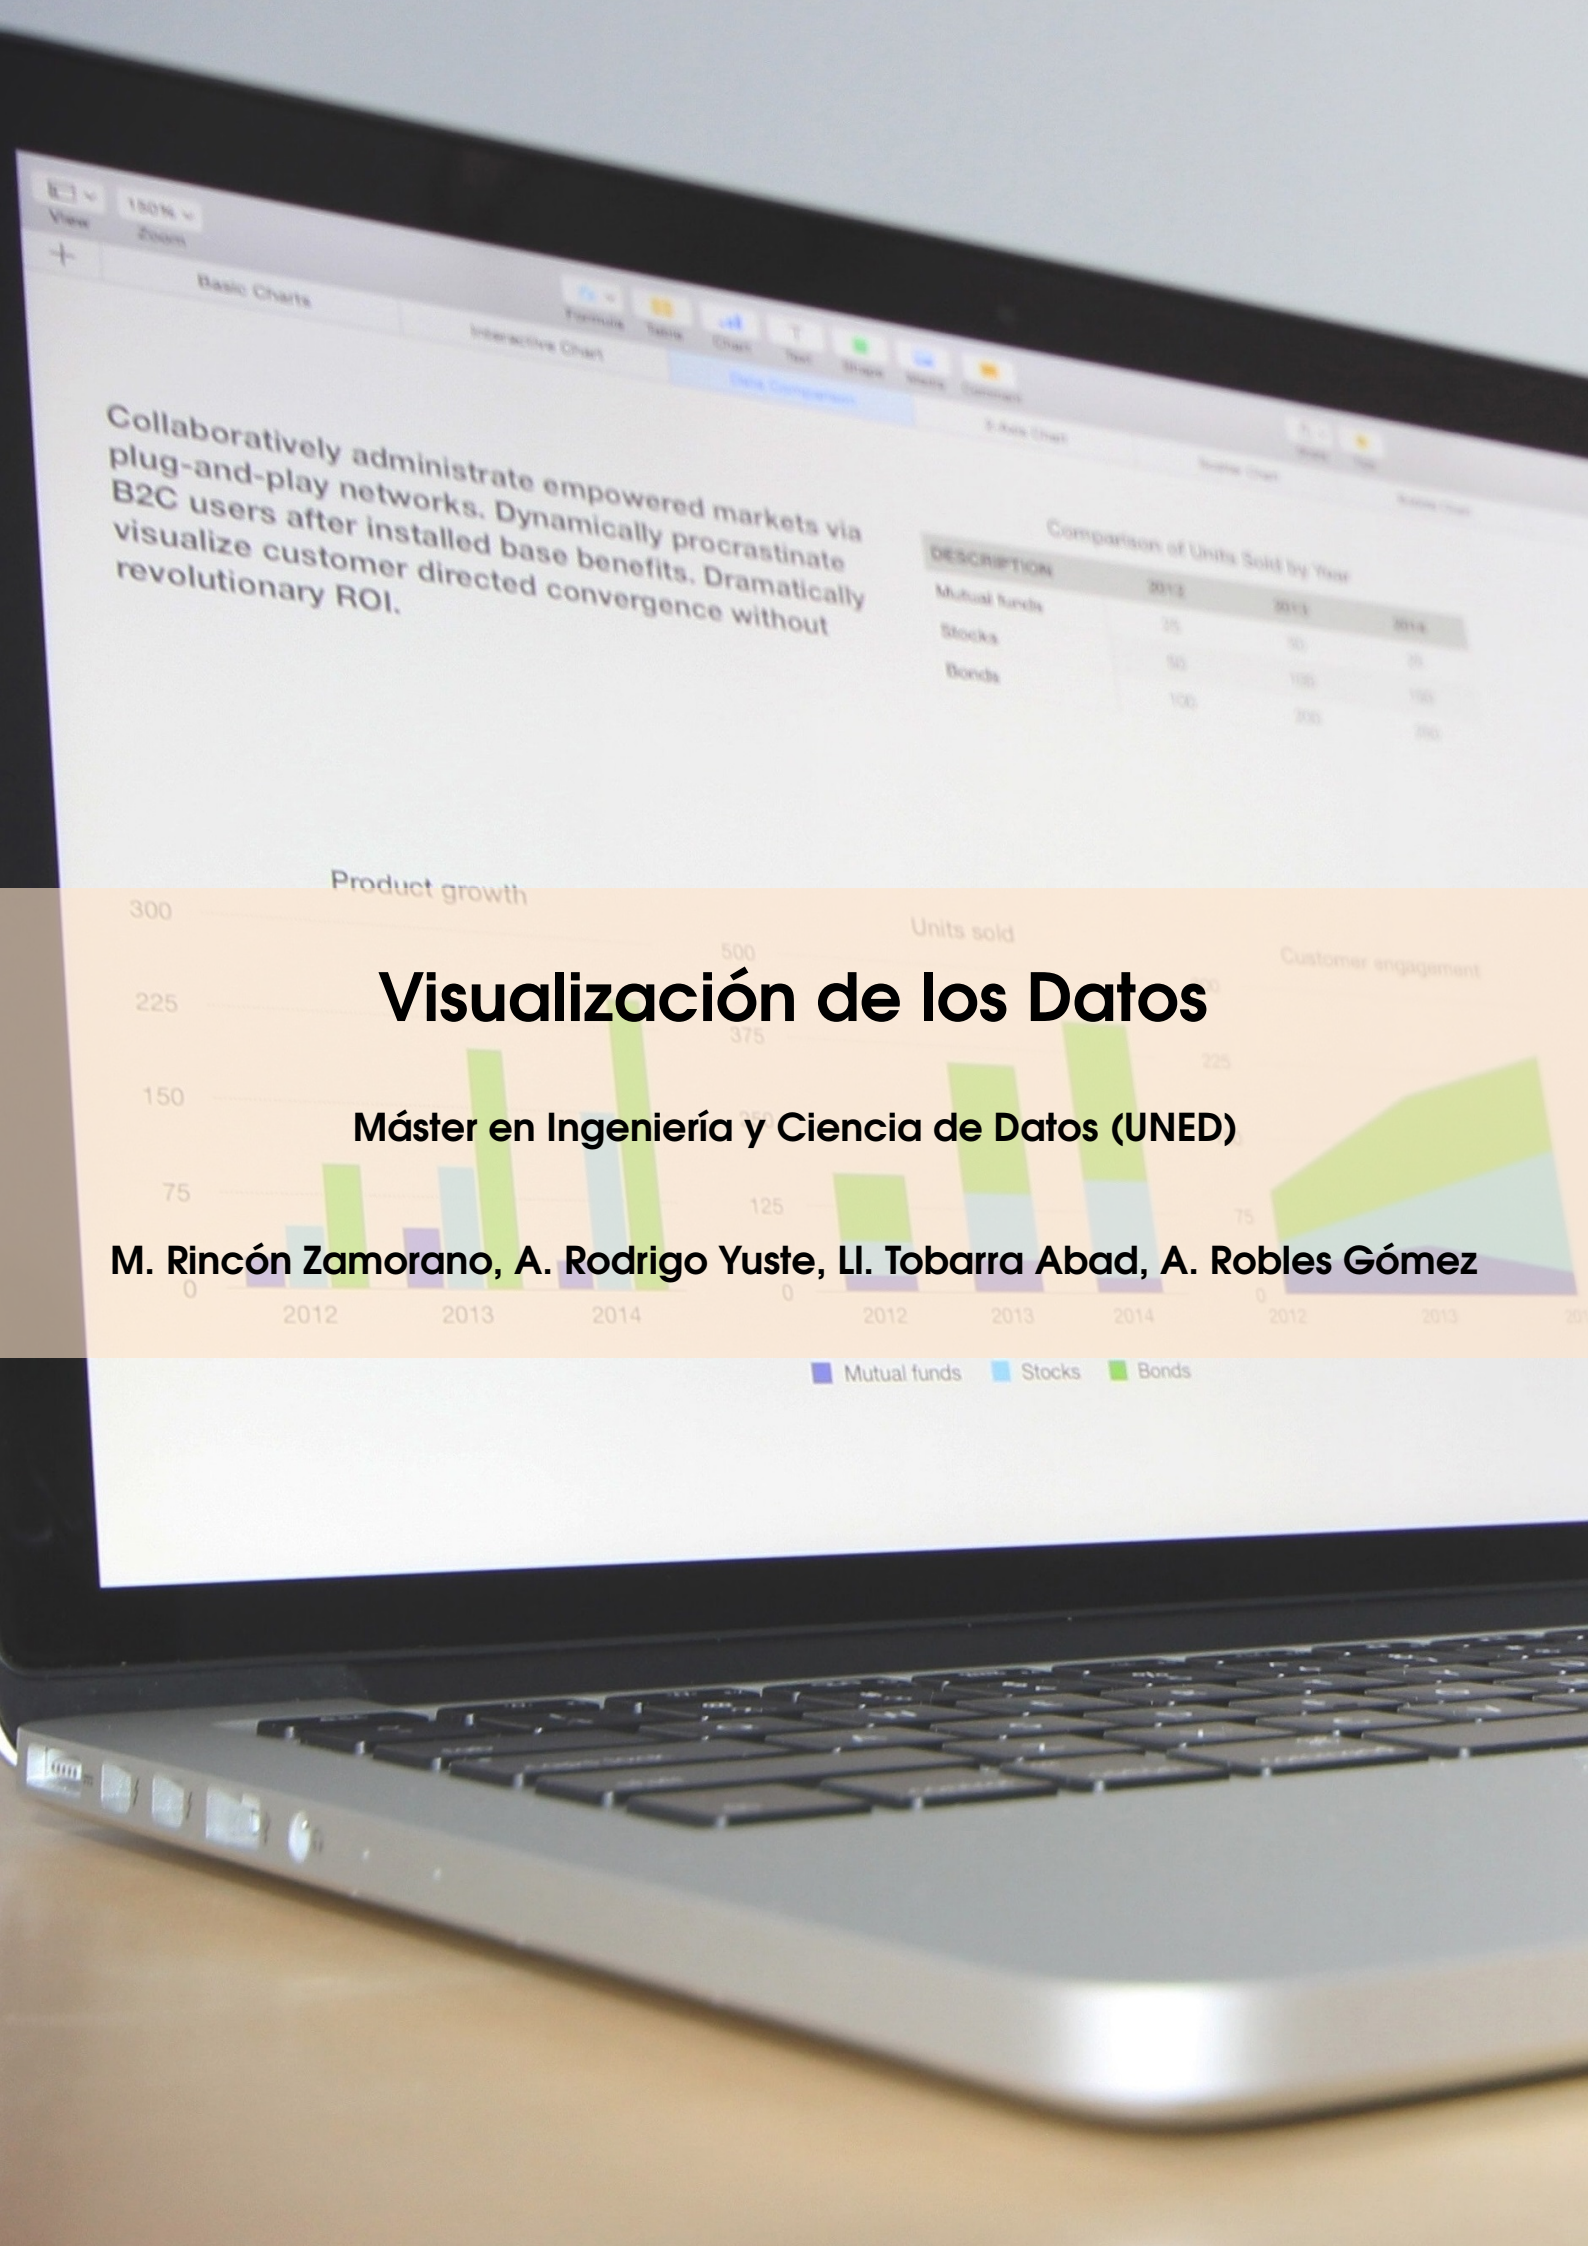


Visualización de los Datos

Máster en Ingeniería y Ciencia de Datos (UNED)

M. Rincón Zamorano, A. Rodrigo Yuste, Ll. Tobarra Abad, A. Robles Gómez

Copyright © 2019 M. Rincón Zamorano, A. Rodrigo Yuste, Ll. Tobarra Abad, A. Robles Gómez

ETSI INFORMÁTICA. UNED

HTTP://WWW.UNED.ES

Pendiente de licencia.

Versión 1.0, Febrero 2020



Índice general

1 Introducción a la visualización 5

1.1 Introducción 5

1.1.1 Introducción a la Visualización 5

1.1.2 El reto de la visualización 8

1.2 Definición de visualización para ingeniería de datos 10

1.2.1 Definiendo la visualización 10

1.2.2 Otras definiciones necesarias 11

1.3 Necesidad de la visualización de datos 13

1.4 La visualización en el proceso de análisis de información 14

1.4.1 El proceso de análisis de información 14

1.4.2 La creación de una visualización 15

1.4.3 Roles en el proceso de la visualización 17

1.4.4 Algunos consejos sobre la visualización 18

1.5 "Presentación de información" frente a "análisis de información" 20

1.6 Ejercicios 20

2 Representación de la información 23

2.1 Representación de datos: Tipos de variables de datos y su estructura 23

2.1.1 Introducción a la teoría de sistemas 24

2.1.2 Representación de objetos y relaciones 25

2.1.3 Tipos de variables 25

2.1.4 Estructuras formales de representación de datos 28

2.1.5 Conversión entre estructuras de datos 28

2.2 Proceso de análisis de datos 29

2.2.1 Preprocesado de datos 30

2.2.2 Tareas de procesado 32

2.2.3 Evaluación . . . 33
2.2.4 Mejorar . . . 33
2.3 Caso práctico 34
2.4 Ejercicios 39
2.5 Cuestiones 41
2.6 Glosario 41

3 Análisis visual de la información . . . 43
3.1 Características visuales que facilitan el análisis de la información 44
3.1.1 Elementos gráficos y canales de información visual . . . 44
3.1.2 Efectividad de los canales de información visual . . . 46
3.2 Elección de la representación más adecuada. Visual mapping 48
3.3 Del análisis visual a la comunicación visual. Storytelling 55
3.4 Ejercicios 57

4 Técnicas de representación visual . . . 67
4.1 Elementos formales 67
4.1.1 El objetivo de una representación visual . . . 67
4.1.2 Métodos de selección de gráficos . . . 68
4.2 Representación estática 69
4.2.1 Gráfico de columnas/barras . . . 69
4.2.2 Gráfico de líneas . . . 70
4.2.3 Gráfico de área . . . 70
4.2.4 Gráfico de barras apiladas . . . 72
4.2.5 Grafico circular . . . 72
4.2.6 Gráfico de dispersión . . . 72
4.2.7 Gráfico de burbujas . . . 74
4.2.8 Gráfico en cascada . . . 74
4.2.9 Mapa de calor . . . 75
4.2.10 Grafos . . . 76
4.2.11 Visualización de textos . . . 78
4.3 Representación dinámica 79
4.3.1 Dashboards . . . 79
4.3.2 Actividades sobre cuadros de mandos . . . 80
4.4 Ejercicios 81

Index . . . 85



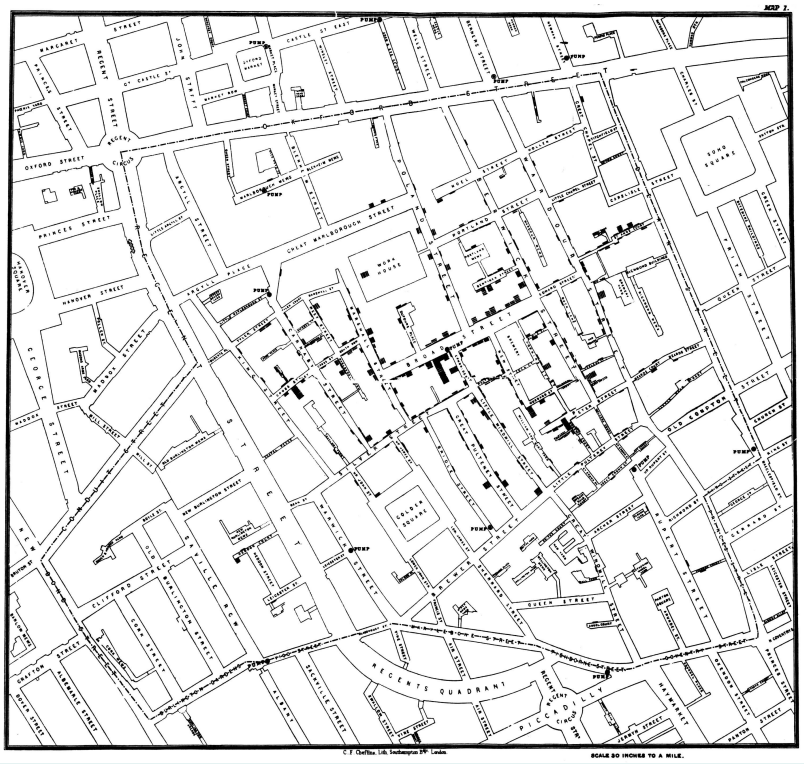
1. Introducción a la visualización

1.1 Introducción

1.1.1 Introducción a la Visualización

La expresión “una imagen vale más que mil palabras” significa que con una sola imagen puedes describir una situación que te llevaría más de mil palabras. Esta expresión resume perfectamente la idea de la visualización de información. La visualización de datos no es algo nuevo; la comunicación visual de datos ha existido en varias formas durante cientos y posiblemente miles de años. Los métodos populares que todavía dominan las salas de juntas de las corporaciones en todo el país -los gráficos de líneas, de barras y de porciones- se originan en el siglo XVIII. Impulsado por nuevas y más poderosas herramientas tecnológicas, así como por un cambio cultural hacia una mayor transparencia y accesibilidad de los datos, el campo ha experimentado un rápido crecimiento.

■ **Ejemplo 1.1** En 1845 en Londres se desató un brote de cólera. Cerca de 700 personas fallecieron en el barrio del Soho, cerca de donde tenía su consulta un médico llamado John Snow. John Snow solía usar mapas como apoyo a las explicaciones que ofrecía en sus artículos y charlas. Así compró un mapa de la zona, y ayudado por el párroco Henry Whitehead, fue anotando las muertes que se iban produciendo. En la siguiente imagen se puede ver el mapa realizado por John Snow mostrando la agrupación de los casos de cólera (representados por rectángulos).



Con esta simple representación, el mapa de John Snow trasmitía un claro mensaje visual al conectar incidencia con concentración. El resultado fue esclarecedor: la mayor parte de las muertes se habían producido en las proximidades de Broad Street. Además, marcó también en el mapa los pozos de agua, encontrando que gran cantidad de las víctimas estaban cerca de la fuente en la intersección de Broad Street con Cambridge Street, hacia Little Windmill Street.

También comparó la zona de estudio donde había más víctimas con otras que tenían diferentes pozos, demostrando que en estas zonas el número de casos era inferior. Finalmente, con todas las pruebas y sus conclusiones, consiguió convencer a las autoridades para que cerrarán el pozo de Broad Street y reducir el número de muertes.

Su estudio, apoyado por una visualización, le permitió cambiar el modelo de propagación de enfermedades, demostrando que estaba asociado a aguas contaminadas con heces. De hecho se le considera el padre de epidemiología moderna. Más información: `https://scielo.conicyt.cl/pdf/rci/v24n4/art14.pdf` ■

Casi todo lo que hacemos tiene una consecuencia digital. Nuestras vidas están siendo constantemente registradas y cuantificadas. Esta situación puede crear recelos e incomodidad, dónde podemos llegar a considerar que nos acercamos a la visión distópica de Orwell. Sin embargo, también surge una curiosidad analítica, que considera que la cantidad de datos que se registran crea nuevas y emocionantes oportunidades para hacer y compartir descubrimientos sobre el mundo en el que vivimos.

Gracias a los increíbles avances y al acceso generalizado a las nuevas tecnologías podemos capturar, crear y movilizar grandes cantidades de datos a un ritmo increíble. De hecho, tal es el crecimiento exponencial de la información digital, que sólo en los últimos dos años la humanidad ha creado más datos que nunca antes se habían acumulado[1].

Los datos se consideran ahora, con bastante razón, como un activo inestimable, algo que puede realmente ayudar a cambiar el mundo para mejor. Pero también son una mina de oro en términos de

[1] Disponible en:`http://www.emc.com/leadership/programs/digital-universe.htm`



Figura 1.1: Evolución de los datos hacia la información

competitividad: partiendo de las grandes cantidades de datos se puede obtener cierta información que puede dar lugar a un nuevo conocimiento, una interpretación del mundo real (ver fig. 1.1). La célebre cita *"Los datos son el nuevo petróleo"*, que aparece por primera vez en 2006 y se atribuye a Clive Humby de Dunnhumby, es una idea que está ganando fuerza hoy en día. Las empresas, los periodistas, los organismos gubernamentales y los investigadores científicos, entre otros colectivos, se están dando cuenta de los desafíos y, más aún, de las oportunidades que existen con la utilización efectiva de los extraordinarios volúmenes, las grandes variedades y la gran velocidad de los datos. Sin embargo, para desbloquear el potencial contenido en estos profundos pozos de unos y ceros se requiere la aplicación de técnicas para explorar y transmitir estos conocimientos clave.

Por otra parte, no olvidemos que la vista es el sentido que más información es capaz de asimilar en los humanos, con lo que tiene sentido aprovecharlo para el tratamiento y análisis de los datos. A través de periódicos, revistas, publicidad, la Web, mensajes de texto, medios sociales y correo electrónico, nuestros ojos y cerebros están siendo incesantemente bombardeados por la información. Se dice que en un día normal podemos llegar a consumir unas 100.000 palabras [2], lo cual es una cantidad asombrosa de señales que tenemos que asimilar.

Incuestionablemente, la mayoría de esta cantidad de información visual no es procesada. Solemos tratar la gran mayoría de la información como ruido como una forma de hacer frente a la sobrecarga y saturación de cosas, permitiéndonos concentrarnos en pensar y procesar lo relevante.

Luego es evidente la necesidad de ser más efectivos y eficientes en la forma de comunicar información. Es necesario presentar los datos de manera que ayude a transmitir el mensaje que queremos comunicar de una forma atractiva e informativa. Si los datos son el petróleo, entonces la visualización de los datos es el motor que facilita su verdadero valor y por eso es una disciplina tan relevante en esta era digital.

Para ello, en este primer tema expondremos el contexto en el que se plantea la necesidad de utilizar herramientas informáticas y técnicas de visualización de información para poder sacar el mayor partido posible a los datos puestos a nuestra disposición. Comenzaremos introduciendo algunos términos relacionados con el tratamiento informatizado de la información, después veremos la necesidad y la justificación de la visualización de la información (o de los datos) y dónde y de qué manera puede ayudarnos.

Por tanto, no trataremos la visualización de la información desde el punto de vista artístico, que tiene su importancia a la hora de captar la atención, sino desde el punto de vista científico de representación de información. Tampoco nos limitaremos a presentar técnicas de visualización de resultados, sino que intentaremos ir un poco más allá. Haremos especial hincapié en las estructuras matemáticas subyacentes, en su capacidad de representación y de tratamiento y en sus posibles

[2] Disponible en: `http://hmi.ucsd.edu/howmuchinfo_research_report_consum.php`

representaciones visuales (capítulo 2). Tiene que quedar claro desde el principio que para implementar una buena visualización de los datos de un proyecto es necesario ser capaces de abstraer estas estructuras matemáticas y tener muy claro los objetivos de la visualización. No nos asustemos, sólo se trata de ser metódicos y encontrar la base común de características que permiten describir fácilmente el conjunto de individuos o instancias que queremos representar. Cada característica o atributo será una variable que permitirá discriminar entre grupos de instancias y la combinación de todos los atributos permitirá localizar a un individuo o instancia concreta. Cuando hayamos definido esta estructura matemática de base de la representación, para la visualización de la información sólo será necesario realizar una correspondencia entre cada variable y una característica visual con la única condición de aprovechar al máximo la capacidad de percepción humana (capítulo 3). Hablamos de visualización de información en sentido amplio, como representación de los datos para interaccionar con ellos, no solo para mostrarlos de manera pasiva.

Las representaciones más ampliamente utilizadas en función de la estructura formal de la información se describirán en el capítulo 4. Sin embargo, el campo de la visualización de la información está actualmente en auge y aparecen continuamente nuevas representaciones visuales que mejoran de algún modo la capacidad de interacción con grandes volúmenes de datos.



Los grandes volúmenes de datos actualmente reciben el nombre de Big Data si cumplen tres propiedades: velocidad de creación, volúmen en términos de cantidad de datos y gran variedad respecto a la naturaleza de los datos.

1.1.2 El reto de la visualización

La visualización de datos no es algo sencillo: implica la convergencia de muchas habilidades diferentes y requiere una gran cantidad de práctica y experiencia, lo que claramente exige tiempo y paciencia. En ella intervienen varias materias dispares como son ciencia cognitiva, estadística, diseño gráfico, cartografía e informática. Si queremos simplificar esta convergencia, la visualización de datos podría describirse como una intersección del arte y la ciencia. Esta combinación de perspectivas creativas y científicas representa una delicada mezcla. Lograr un equilibrio adecuado entre estos ingredientes es uno de los factores fundamentales que determinará el éxito o el fracaso del trabajo de una visualización.

El lado artístico del campo se refiere a las posibilidades de aplicar el talento de diseño y fomentar la innovación, donde se trabaja por diseñar visualizaciones que atraigan a un nivel estético y luego sobrevivan en la mente a un nivel emocional.

La ciencia detrás de la visualización se presenta de muchas formas. Es inevitable tener en cuenta la presencia de la informática, las matemáticas y la estadística., pero uno de los fundamentos clave del tema viene a través de la comprensión de la ciencia cognitiva. En particular, el estudio de la percepción visual. Esto tiene que ver con la forma en que las funciones del ojo y del cerebro trabajan juntas para procesar la información como señales visuales.

Otro de los estudios fundadores más influyentes sobre la percepción visual surgió de la Escuela Gestalt de Psicología a principios de 1900, específicamente en la forma de las Leyes de Organización Perceptual [3]. Estas leyes proveen un entendimiento organizado acerca de las diferentes maneras en que nuestros ojos y cerebro inherentemente y automáticamente forman un sentido global de patrones basados en el arreglo y atributos físicos de elementos individuales. Profundizaremos sobre estas leyes más adelante.

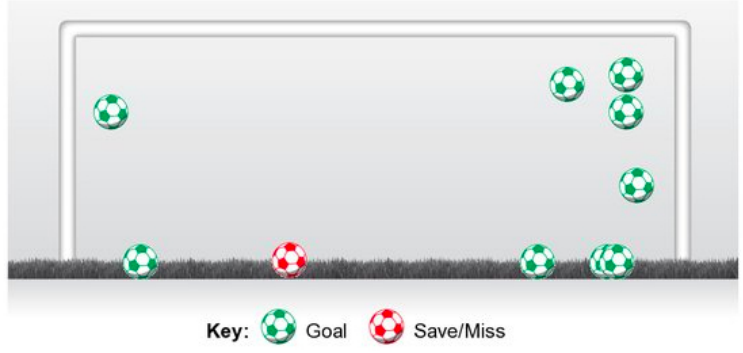
En la raíz del conocimiento de la percepción visual está la comprensión de que nuestras funciones visuales son procesos extremadamente rápidos y eficientes, mientras que nuestros procesos

[3] Disponible en: `http://www.interaction-design.org/encyclopedia/data_visualization_for_human_perception.html`

cognitivos, el acto de pensar, es mucho más lento y menos eficiente. La forma en que explotamos estos atributos en la visualización tiene un impacto significativo en la eficacia del diseño para ayudar a la interpretación.

■ **Ejemplo 1.2** Vamos a analizar los siguientes ejemplos de visualizaciones, todas ellas enfocadas en determinar la zona de la portería por la que los jugadores tiran más penalties.

Si nos fijamos en la siguiente imagen, la claridad de esta primera visualización nos permite identificar instantáneamente los símbolos de fútbol, su posición y su color de clasificación.



Fuente de la imagen: `http://www.facebook.com/castrolfootball`

Gracias a esta visualización, prácticamente no necesitamos pensar en cómo interpretarlo, simplemente lo hacemos. Nuestros pensamientos, en cambio, se centran en el análisis de esta información: ¿qué significan estos patrones para nosotros? Si eres un portero, aprenderás que, en general, el lanzador de un penalti tiende a colocar sus tiros a la derecha de la portería.

Por el contrario, si nos fijamos en la siguiente imagen, esta segunda visualización intenta ofrecernos la misma información, pero su representación causa un significativo desorden y confusión visual.



Fuente de la imagen: `http://www.mirror.co.uk/sport/football/euro-2012-where-italy-will-place-their-penalties-907506`

En lugar de utilizar una imagen simple con un fondo en blanco como la anterior, esta visualización incluye colores fuertes e imágenes en el fondo. El resultado es que nuestros ojos y nuestro cerebro tienen que trabajar mucho más duro para detectar los balones de fútbol y sus colores porque la capa de datos tiene que competir por la atención con las imágenes de fondo. Por lo tanto, no podemos confiar en las capacidades de nuestra percepción visual preatentativa porque no podemos percibir fácilmente las formas que representan los datos. Esto retrasa

considerablemente nuestros procesos interpretativos, lo que socava la eficacia y la eficiencia de la comunicación de información.

Este es sólo un ejemplo sencillo, extraído de [**Kirk2012**], pero revela la importancia de entender y obedecer las leyes de la percepción visual cuando se representan los datos. ■

1.2 Definición de visualización para ingeniería de datos

1.2.1 Definiendo la visualización

A través de la visualización, buscamos representar los datos de manera que nos permitan verlos bajo una nueva luz, para observar visualmente los patrones, las excepciones y las posibles historias que se encuentran detrás de ellos. Luego una primera aproximación es considerar la visualización como una herramienta de descubrimiento.

Actividad 1.1 Una demostración bien conocida que apoya esta noción fue desarrollada por el conocido estadístico Francis Anscombe [**anscombe73**] en la década de 1970. Él compiló un experimento que involucraba cuatro conjuntos de datos, cada uno exhibiendo propiedades estadísticas casi idénticas. Dados los siguientes datos, calcula la media, la varianza y la correlación:

I		II		III		IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

En base a estos cálculos, ¿qué se puede ver en estos conjuntos de datos? ¿Salen algunos patrones o tendencias? ¿Quizás la secuencia de ochos en el cuarto conjunto?.

Ahora representa visualmente estos datos usando cualquier herramienta de visualización o alguna hoja de cálculo. ¿Qué puedes concluir en base a esta representación. ■

El tratamiento digital de la información ha permitido simplificar y automatizar muchas tareas que anteriormente se realizaban manualmente, con el consiguiente coste tanto de recursos materiales como humanos. Con el acceso a una mayor cantidad de información, tanto en cantidad como en variedad, surgen nuevos problemas para su tratamiento, siendo necesarios nuevos métodos y tecnologías. La informática se encarga de definir estos procedimientos y tecnologías que nos facilitan el manejo de grandes volúmenes de información de una manera amigable.

Antes de conocer otros términos, vamos a intentar dar una definición de la visualización de datos. Para ello, primero debemos considerar los principales agentes involucrados en el intercambio de información: el emisor, el receptor y el mensaje (ver Fig. 1.2).

Por una parte tenemos el emisor, quien suele querer transmitir resultados, análisis o interpretación. En el otro extremo están los receptores del mensaje, que en la visualización son los usuarios a los que va destinada. El mensaje se transmite mediante el medio de canal: un gráfico, un cuadro de mandos, una infografía interactiva,. . . .

Nuestro rol será por tanto el del emisor. Y deberemos ponernos en la situación del receptor,

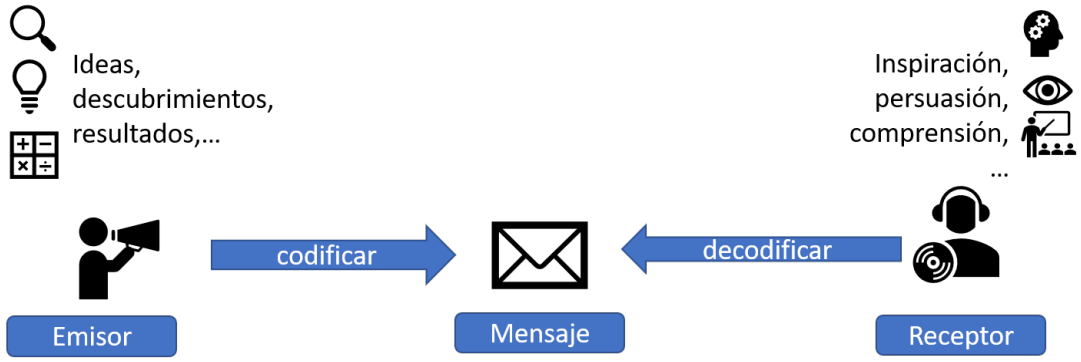


Figura 1.2: Elementos de la visualización

imaginando y anticipándonos para saber cómo va a reaccionar al mensaje, considerando y respetando sus necesidades. Luego, para asegurarnos de que nuestro mensaje se transmite de la forma más efectiva y eficiente, una que sirva a las necesidades del receptor, necesitamos asegurarnos de que diseñamos (o "codificamos") nuestro mensaje de forma que se adapte activamente a la posible interpretación del mensaje por parte del receptor (o "descodificará") de la forma más efectiva, explotando su percepción visual y teniendo en cuenta sus potenciales intereses.

De forma, que podemos definir la visualización como:

Definición 1.2.1 — Visualización. La representación y presentación de datos que explota nuestras capacidades de percepción visual para amplificar la cognición orientado hacia un objetivo.

Dentro de esta definición aparecen dos términos que debemos clarificar: representación y presentación.

La **representación de datos** es la manera en que se decide mostrar los datos a través de una serie de formas geométricas generalmente. Ya sea a través de una línea, una barra, un círculo o cualquier otra variable visual, usted está tomando los datos como materia prima y creando una representación para mostrar mejor sus atributos. Trataremos este elemento más adelante.

Por otra parte, la **presentación de los datos** va más allá de la representación de los datos. Se refiere a la forma en que se integra su representación de datos en el conjunto del trabajo comunicado, incluyendo la elección de los colores, las anotaciones y las características interactivas. Igual que la representación, trataremos la presentación más adelante.

La explotación de nuestras habilidades de percepción visual está directamente asociada a cómo nuestros ojos y cerebros procesan la información de manera más efectiva. Se trata de aprovechar nuestras habilidades con el razonamiento espacial, el reconocimiento de patrones y el pensamiento a gran escala. En última instancia, el objetivo de la visualización debería ser hacer que el receptor o los usuarios sientan que han recibido toda la información contenida en la misma. Esto se consigue facilitando el procesamiento cognitivo de la información contenida en nuestra visualización.

1.2.2 Otras definiciones necesarias

A continuación incluimos las definiciones de algunos conceptos que deben ser conocidos y que utilizaremos habitualmente durante este documento.

Definición 1.2.2 — Preprocesado. Preprocesado es toda transformación que simplifica u organiza los datos para aumentar la relación señal a ruido. Obviamente esto se consigue de dos maneras, o incrementando la señal o disminuyendo el ruido (organizando los datos conveniente-

mente, agrupando por características significativas, filtrando datos que no están relacionados con el objetivo perseguido, etc.). El resultado es un nuevo conjunto de datos más manejable y orientado al objetivo.

Definición 1.2.3 — Análisis. Análisis es el proceso de transformación de los datos para la extracción de nueva información. El resultado son valores de conceptos más abstractos a partir de conceptos previamente conocidos. La relación entre los conceptos puede ser tanto cuantitativa, cuando existe una relación directa entre los conceptos, como cualitativa, cuando tal relación es más subjetiva. El preprocesado se considera una etapa previa del análisis porque es independiente del dominio, pero en realidad sus objetivos son similares. El análisis puede dar lugar a nuevo conocimiento o simplemente actualizar los valores de un modelo previamente conocido.

Definición 1.2.4 — Presentación. Los resultados del análisis se pueden mostrar directamente, pero normalmente resulta conveniente simplificarlos o resumirlos para que resulten fácilmente interpretables. La presentación de los resultados consiste en un informe con varios apartados en los que se analizan los resultados atendiendo a diferentes perspectivas. La presentación visual de los resultados es una opción que permite facilitar la interpretación de los resultados de manera eficiente.

Definición 1.2.5 — Cuadro de Mando o Dashboard. Un **dashboard**, o cuadro de mandos en español, es una representación gráfica de las principales métricas que intervienen en la consecución de los objetivos de una estrategia de una organización, un departamento, un sistema o algún organismo. Esta herramienta permite visualizar el problema y favorecer la toma de decisiones orientada a mejorar los posibles errores que se podrían estar cometiendo. El fin último es transformar los datos en información útil para orientar esta estrategia hacia la consecución de los objetivos planteados.

Un ejemplo de dashboard puede encontrarse en la figura 1.3.

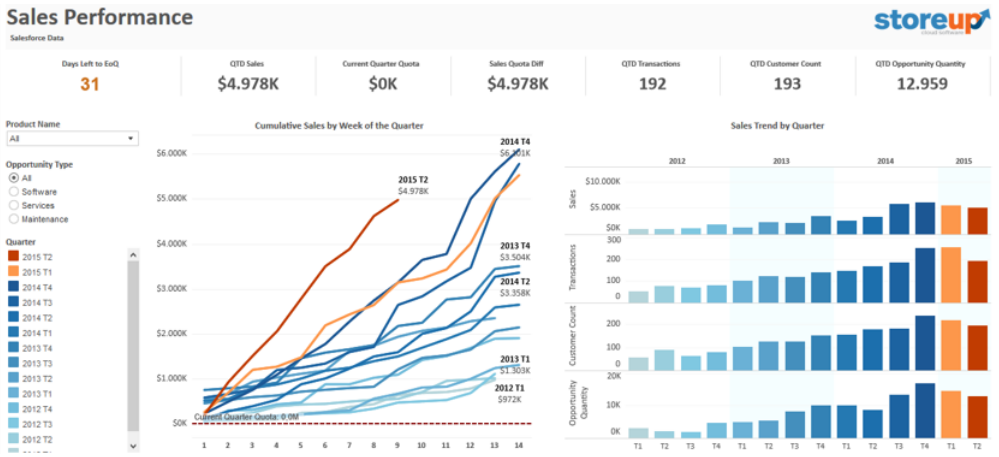


Figura 1.3: Ejemplo de dashboard creado con Tableau y disponible en el siguiente enlace: `https://tabsoft.co/37zMjzz`

Definición 1.2.6 — Infografía. Una **infografía** es una representación visual multiseccional destinada a comunicar uno o varios mensajes específicos. Las infografías están hechas de una mezcla de gráficos, mapas, ilustraciones y texto (o sonido) que proporcionan explicación y contexto.

Un ejemplo de infografía puede encontrarse en la figura 1.4.

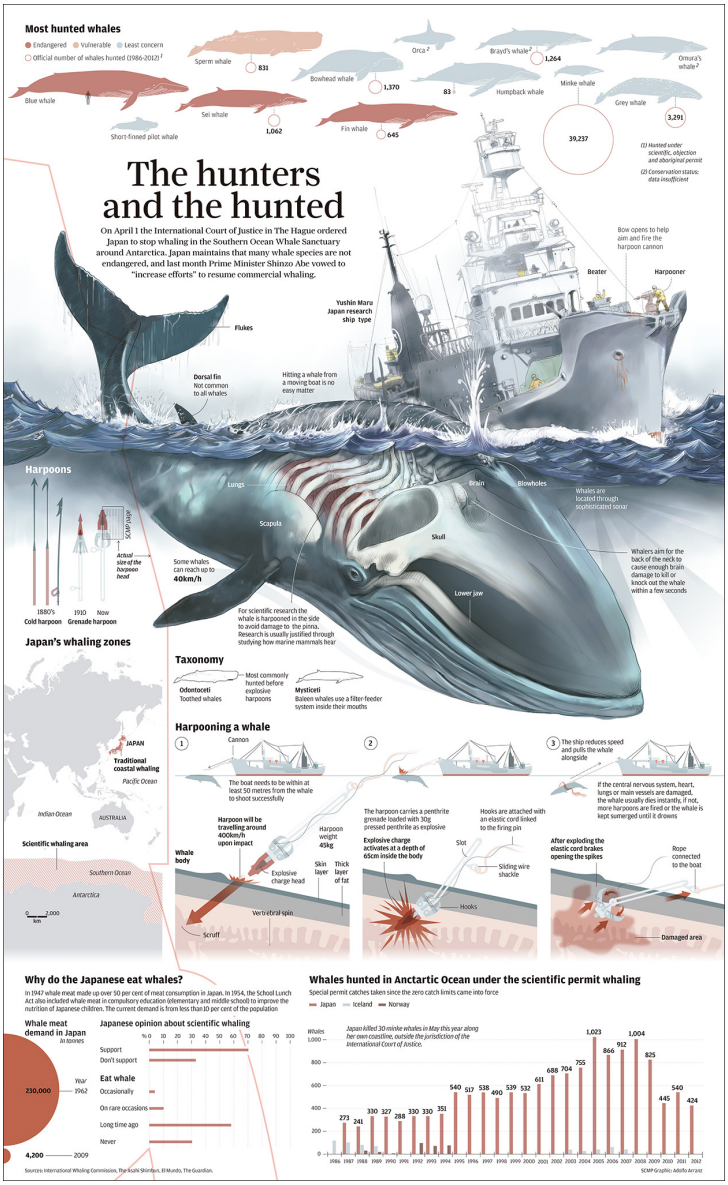


Figura 1.4: Infografía de Adolfo Arranz para el periódico South China Morning Post. Encontrado en [**cairo16**]

1.3 Necesidad de la visualización de datos

El volumen de datos creciente que tenemos a nuestra disposición con la tecnología digital es actualmente un problema. Las frases "parálisis por análisis", "morir de éxito" o "los árboles no nos dejan ver el bosque" tienen vigencia también en la era de la tecnología digital. Necesitamos herramientas que nos faciliten el manejo de los grandes volúmenes de datos/información que manejamos habitualmente. Si tenemos en cuenta los anchos de banda de los distintos sentidos, el sentido de la vista es sin lugar a dudas el que es capaz de manejar un volumen de información significativamente mayor.

La representación textual es una representación lineal, muy flexible a la hora de describir matices pero poco eficiente a la hora de presentar grandes volúmenes de información. Sin embargo, las imágenes permiten presentar en paralelo distintos tipos de información (jerarquías, distribuciones, relaciones de distintos tipos como causales, espaciales, temporales, . . .). Esto es así no solamente por

la multidimensionalidad de la imagen, sino porque nosotros, los humanos, estamos genéticamente preparados para interpretar esta información a través del órgano de la vista.

Por tanto, organizando los datos convenientemente, podemos representar visualmente la información y aprovechar así la capacidad del sistema de percepción visual humana para establecer asociaciones entre los elementos presentes en la imagen que faciliten el análisis de grandes volúmenes de información de manera instintiva e instantánea.

Organizar convenientemente los datos significa encontrar la representación abstracta (formal) que permite manejarlos de manera sencilla. Esta representación abstracta es una representación formal, matemática, que le confiere una serie de propiedades que facilitan su manipulación simbólica y por tanto su tratamiento informatizado. La visualización es el último paso, que consiste en la conversión de los símbolos matemáticos en símbolos visuales de acuerdo a las posibilidades y limitaciones de la percepción humana.

1.4 La visualización en el proceso de análisis de información

1.4.1 El proceso de análisis de información

Si consideramos todas las fases del procesado de la información, veremos que la visualización de datos/información se puede aplicar en todas ellas con distintos objetivos (fig. 1.5). En general, la visualización de información se puede utilizar para la gestión de grandes volúmenes de datos, la selección o filtrado de subconjuntos relevantes para una tarea, el análisis de los datos utilizando las capacidades de visualización humanas o la presentación de las conclusiones de manera más resumida y eficiente.

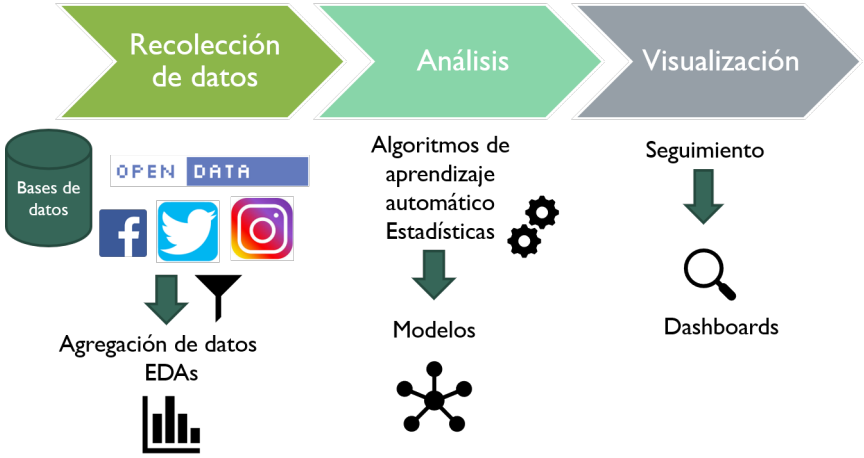


Figura 1.5: Uso de la visualización a lo largo de un proceso de análisis de información

A continuación esbozamos la utilidad de la visualización en las distintas fases de un estudio:

- En la fase de preprocesado, la visualización puede facilitar la interacción con el usuario, ayudando en la generación de herramientas semiautomáticas que simplifiquen y aceleren las fases de adquisición y anotación manual de grandes conjuntos de datos.
- En la fase de análisis: el análisis visual de los datos facilita principalmente detectar correlaciones, relaciones espaciales y temporales, tendencias, etc., entre los datos. Esto se puede aplicar tanto a casos concretos (relaciones entre casos concretos o instancias) como a grandes volúmenes de datos acumulados en representaciones que muestran la distribución de los casos (mostrando mapas de frecuencia de relaciones entre casos, lo que permite, por ejemplo, localizar fácilmente relaciones frecuentes y/o casos especiales). Si añadimos la capacidad de

interaccionar con los datos durante el análisis visual, podemos simplificar extraordinariamente la tarea de análisis de los datos, creando entornos semiautomáticos e interactivos en los que el usuario decide sobre qué datos quiere trabajar y qué operación quiere realizar en cada momento.

- En la fase de presentación, simplemente se deberá seleccionar de entre las representaciones utilizadas en el análisis, aquellas que resumen las conclusiones del análisis y que son de interés para un tercero.

1.4.2 La creación de una visualización

Las preguntas clave a las que tenemos que dar respuesta en todo estudio visual son 1) ¿Qué queremos representar? y 2) ¿cómo lo representamos?. La primera pregunta depende del objetivo del estudio. Más adelante nos centraremos en la segunda, en la representación más adecuada, es decir, en el análisis de cómo codificar la información de manera que podamos acceder fácilmente a ella.



Figura 1.6: Marco global que organiza los conceptos necesarios que debemos abordar a la hora de realizar una visualización

La figura 1.6 resume este marco global que organiza los conceptos iniciales con los que tenemos que tratar a la hora de realizar un estudio que implique información visual. Partimos siempre de que el objetivo de una visualización puede definirse a través de dos elementos: la razón que conlleva la creación de la visualización y el efecto esperado por la visualización. En el caso del primero, se trata de reconocer el detonante detrás del proyecto o el origen de donde surgió: nos han encargado la visualización o es un proyecto personal. Esto nos da una idea del alcance y el contexto del proyecto, cuánto control creativo se puede tener, si se nos ha animado a seguir una dirección creativa particular y qué ideas se han formado ya.

En cuanto al efecto podemos encontrarnos con diferentes intenciones: aprendizaje, jugar con los datos, contextualizar los datos, modificar opinión, motivos estéticos, argumentar, monitorizar señales, realizar un análisis, cuestiones/respuestas, localizar patrones, experimentación, ... Como vemos existen diferentes expresiones que evidencian diferentes dimensiones de intención. Luego se debe identificar el efecto deseado. En otras palabras, decidir que se pretende conseguir y cómo se va a conseguir. Sin embargo, para lograr nuestra intención debemos conocer detalladamente nuestra audiencia. Tener claro un perfil de la audiencia nos permite establecer un contexto necesario

para una visualización. La claridad de qué y quién es su público objetivo ayudará a dar forma a su intención y a partir de esto seremos capaces de definir dos dimensiones muy importantes: la función y el tono de su proyecto de visualización.

El estilo de la narrativa (tono) y la función de una visualización nos permite desarrollar la historia. La historia tendrá una parte narrativa, de explicación del contexto, de las suposiciones de partida, de los objetivos, etc., y unas representaciones visuales de apoyo a la narrativa que permitan mostrar información o interaccionar con el usuario. Pues bien, en este curso nos centraremos en la parte de cómo generar estas representaciones visuales de apoyo (representación visual de la información). Aunque también se abordará la parte la necesidad de la narrativa del estudio (o qué es necesario contar una historia) apoyados en imágenes.

Además, no debemos olvidarnos de otros factores del contexto en el que se realiza el proyecto de la visualización que pueden tener cierto impacto en las decisiones que se tomen como las presiones del cliente, el formato necesario para realizar la visualización, la existencia de plazos de entrega, capacidades técnicas necesarias para la realización del proyecto, ...

Tanto el objetivo como la intención nos permiten seleccionar los datos de interés de entre los datos disponibles y la estructura de datos más adecuada (ver fig. 1.7). Obviamente, si no se dispone de los datos de interés, habrá que generarlos, bien mediante transformaciones a partir de los datos existentes, bien adquiriendo nuevos datos relacionados con el objetivo. A continuación, el número de variables y sus tipos (estructura) condicionan las representaciones visuales posibles. Y de éstas, los objetivos incluyen una serie de preferencias que ayudan también en la selección de la visualización más adecuada.

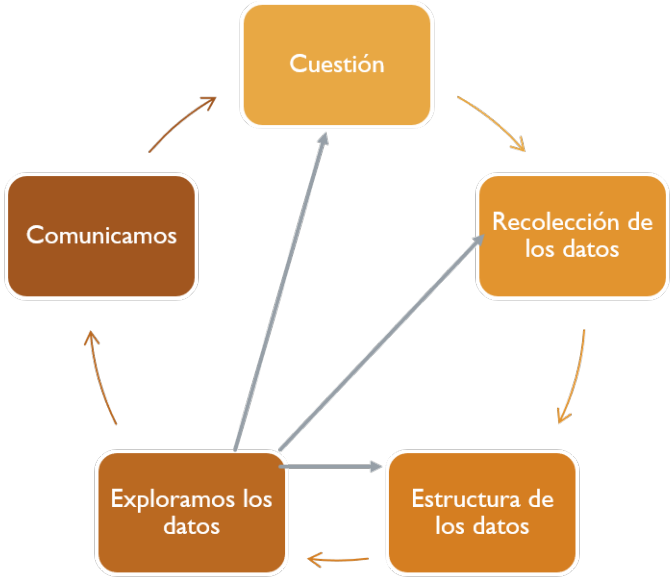


Figura 1.7: Proceso para abordar una visualización

Una vez seleccionada la visualización, podemos aplicarla a los datos existentes y analizar el resultado. Debemos tener muy claro que, normalmente, el resultado deseado no se obtendrá a la primera, bien porque los datos de entrada contienen ruido, porque representan situaciones que no se habían previsto o porque no se hayan elegido bien los parámetros de configuración del gráfico. Por tanto, lo más habitual es que haya que editar los datos para subsanar las deficiencias detectadas y obtener el resultado deseado. Este proceso habrá de repetirse cuantas veces sea necesario hasta obtener los resultados deseados.

1.4.3 Roles en el proceso de la visualización

Una vez hemos comprendido el proceso que conlleva la creación de una visualización, debemos tener en cuenta que es un proceso que generalmente involucra a más de una persona. De forma que podemos describir una serie de roles o puntos de vista relacionados con el proceso de creación de una visualización:

- El **iniciador** es el líder, la persona que busca una solución a la tarea según un encargo o bien por su propia curiosidad. El principal proceso visual que lleva a cabo es la *exploración*. Buscan explorar datos y diferentes vías de diseño para encontrar respuestas a problemas o pruebas que sirvan a su mentalidad de investigador. Establecerá la dirección funcional y tonal de un proyecto de visualización, así como identificará y perfilará la audiencia objetivo. El iniciador también definirá otros parámetros, como el formato/plataforma previsto para la solución y algunas de las cuestiones tecnológicas clave.
- El **científico de datos** se caracteriza por ser un minero de datos. Es el responsable de la obtención, adquisición, gestión y preparación de los datos. Esto significa demostrar las habilidades técnicas para trabajar con conjuntos de datos grandes y pequeños así como con gran variedad de tipos de datos diferentes. Una vez adquiridos, el científico de datos es responsable de examinarlos preliminarmente y preparar los datos. En este modelo de conjunto de habilidades propuesto, es el científico de datos quien tendrá el conocimiento estadístico y matemático clave y lo aplicará para llevar a cabo un análisis visual exploratorio para aprender sobre los patrones, relaciones y propiedades descriptivas de los datos.
- El **periodista** es un narrador, la persona que establece el enfoque narrativo del contexto del problema abordado en la visualización. Trabajando con el científico de datos y el iniciador, es capaz de establecer las historias clave y los ángulos con los que limitar el análisis. Trabajará en la formulación de las preguntas sobre los datos que ayudarán a mantener el enfoque del proyecto en su camino previsto. Basándose en las ideas preliminares del iniciador, el periodista desarrollará una línea de investigación más profunda para explorar realmente las oportunidades analíticas.
- El **informático** es el ejecutor, la persona que da vida al proyecto. Es en última instancia el encargado de construir la solución mediante la aplicación de sus capacidades técnicas. También reforzará al científico de datos con sus conocimientos técnicos para manejar de la manera más eficaz y eficiente las actividades de recopilación, manipulación y visualización de datos. Los conocimientos de programación y el uso de diversas herramientas software orientadas a la visualización tendrán una gran influencia en la dirección y sofisticación de la solución de visualización de datos.
- El **diseñador** es el creativo, el que, en armonía con el informático, desarrollarán la solución. Tiene el ojo para el detalle visual, un don para la innovación y el estilo y aprecia plenamente las posibilidades potenciales que existen. Su responsabilidad fundamental es también ser capaz de garantizar la armonía de la solución entre su forma y su función, asegurándose de que sea estéticamente atractiva para atraer al lector y, al mismo tiempo, transmitir fundamentalmente el mensaje deseado y comunicado.
- El **científico cognitivo** aporta los conocimientos necesarios en la ciencia detrás de la eficacia visual del proyecto. Tienen el conocimiento de la percepción visual sobre cómo el ojo y el cerebro funcionan más efectiva y eficientemente. También tienen un profundo conocimiento sobre conceptos como las leyes de la Gestalt, las teorías de la comunicación, las teorías del color y los principios de la interacción hombre-computadora. Además, es capaz de informar el proceso de diseño en relación con las complejidades de cómo funciona la mente en términos de memoria, atención, toma de decisiones y cambio de comportamiento.
- El **comunicador** es evidentemente el encargado de la comunicación del proyecto. Actuará como negociador y presentador, operando en el portal usuario-cliente-diseñador, ayudando a

informar a todos los involucrados sobre el progreso, requerimientos, problemas y soluciones. El comunicador tiene que estar cerca de todas las etapas del proceso, comprendiendo los requisitos, detectando las restricciones, reconociendo las posibilidades y, en última instancia, dando a conocer y exhibiendo el trabajo final. Es vital la capacidad de articular y explicar las cuestiones relacionadas a diferentes roles y características de los participantes, técnicas y no técnicas, y ser capaz de manejar las expectativas y las relaciones.

- El **coordinador** gestiona el proceso del proyecto y su progreso, asegurándose de que sea cohesivo, a tiempo y con un mensaje. Comprenden el informe e identifican/gestionan todos los factores clave que rodean el proyecto. En última instancia, esta función es necesaria para asegurar que las cosas se terminen, por lo que necesitan ser detallistas, comprometidos y pacientes para comprobar todo y también deben preocuparse por las cuestiones de integridad en torno a la ética de la visualización.

1.4.4 Algunos consejos sobre la visualización

Una de las primeras cuestiones que debemos abordar al realizar una visualización es mantener un equilibrio entre la aproximación estética (la forma del gráfico) frente a una aproximación práctica (la función del gráfico). Inicialmente, al menos en las primeras aproximaciones a la visualización, es recomendable centrarse en garantizar los aspectos funcionales de su visualización. En primer lugar, tratar de lograr una base que proporciona la información adecuada -que funciona- antes de explorar las formas de mejorar su forma. La analogía más simple sería construir la casa antes de decorarla. Aunque no debemos olvidar que ambos procesos están intrínsecamente ligados. Con el tiempo y la experiencia, será mucho más fácil abordar ambas perspectivas de forma armoniosa.

Además, cualquier decisión durante el diseño de la visualización debe estar justificada. De forma que desde los primeros instantes en que abordamos una visualización, debemos identificar y ser conscientes de la información que se encuentra a nuestro alcance, para garantizar que cualquier objetivo que nos marquemos a partir de esas premisas apoya nuestro trabajo y el resultado que esperamos para nuestros usuarios. Luego debemos plantearnos la idea de diseño deliberado, lo que significa que la inclusión, exclusión y creación de cada marca, característica y rasgo de diseño se hace por una razón. También es importante asegurarse de que cualquier propiedad visual que se incluya, pero que no represente datos, como el sombreado, las etiquetas, los colores y los ejes entre otras propiedades, sólo se incluya para ayudar al proceso de percepción visual, no para obstaculizarlo.

Las visualizaciones abarrotadas con gran cantidad de elementos de interactividad pueden convertirse en una trampa en la que es fácil caer y que conduce a proyectos que se ven bien o que son impresionantes técnicamente pero que no cumplen con su propósito. En cambio, interfieren en la eficiencia y eficacia del intercambio de información, demostrando así la incapacidad de sintetizar forma y función.

Cuando se crea una visualización, se integra el diseño visual con la información que conoce un usuario. Desde el diseño visual llegamos al intercambio de información, donde el diseño y la ejecución de esta comunicación lo que permite acceder a la información. Pero es importante crear una distinción entre accesibilidad e inmediatez. La velocidad con la que se puede leer o interpretar una visualización debe estar determinada por la complejidad del tema y el propósito del proyecto, no por la ineficacia del diseño. A veces los temas son fundamentalmente sencillos y la representación de los datos es directa e intuitiva. Esto a su vez significa que la tarea del lector de interpretar los datos debe ser relativamente fácil.

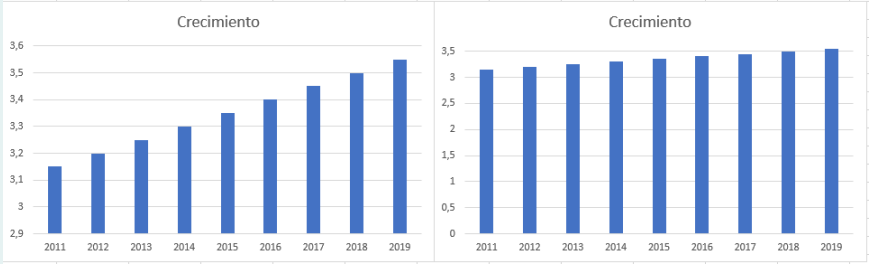
Pero, en otras ocasiones, un conjunto de datos puede ser más complejo. El reto que hemos abordar será respetar la complejidad y evitar simplificar, diluir o reducir la esencia de este tema. Esto podría conllevar con una representación que no es inmediatamente fácil de interpretar. Algunas visualizaciones requerirán un esfuerzo adicional por parte del lector, que le obligará a realizar un

procesamiento cognitivo adicional para conseguir la interpretación correcta de la visualización. Debemos asegurarnos de que los esfuerzos necesarios del lector o usuario para entender cómo usar e interpretar una visualización se vean recompensados en última instancia con la cantidad de información obtenida.

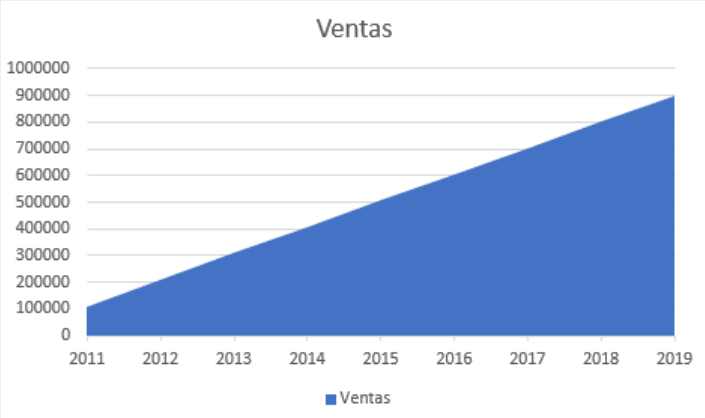
Y por último, debemos contar con cierta ética de la visualización. En este caso nos referimos al posible engaño que puede crearse, intencionadamente o no, a partir de una representación ineficaz e inapropiada de los datos. A veces puede ser por una simple falta de comprensión de la percepción visual, como por ejemplo que el usuario final no sepa interpretar correctamente el gráfico. En otras ocasiones, sin embargo, la manipulación de ciertos elementos de un gráfico serán los que induzcan a una errónea lectura.

■ **Ejemplo 1.3** Vamos a repasar dos ejemplos de visualización donde se crea cierto engaño en la interpretación de los datos al cometer ciertos errores a la hora de representar los datos.

En este primer ejemplo, el principal problema de la visualización es el hecho de no informar al usuario de que los ejes no comienzan en cero o bien no comenzar los ejes de representación en cero conlleva a una posible interpretación de los datos errónea y percepción incorrecta. Si nos fijamos en el gráfico de la izquierda vemos que existe un crecimiento meteórico a lo largo de los años. Sin embargo, en el gráfico de la derecha vemos un crecimiento moderado. Ambos gráficos se han realizado sobre el mismo conjunto de datos. Sólo se ha cambiado el inicio de la escala del eje de las Y.

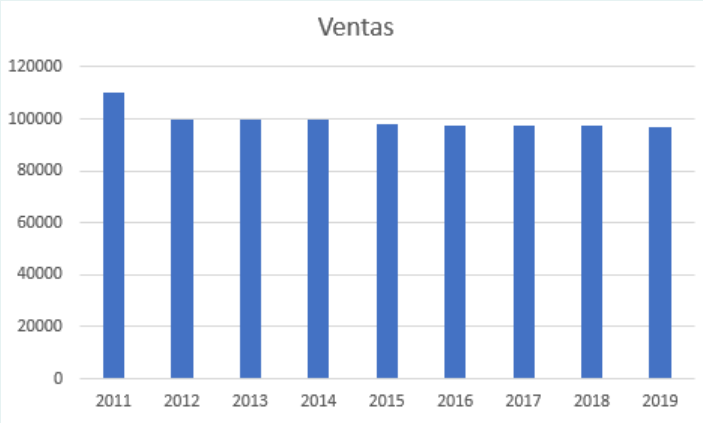


En este segundo ejemplo, usamos un gráfico acumulado en un contexto que puede llevar a error, como es el de las ventas.



Si nos fijamos en el gráfico directamente sin una clara interpretación, podríamos creer que las ventas crecen constantemente todos los años. Ya que el gráfico ofrece ese efecto al acumular los datos de los años anteriores. Sin embargo, si usamos un gráfico más correcto, como sería un gráfico de barras, vemos que ese efecto de crecimiento no es tal. Incluso es posible detectar

un ligero descenso de las ventas. Como vemos, la selección del tipo de gráfico también puede influir en la interpretación del público destinatario de la presentación y modificar su percepción.



Obedecer la ética de la visualización es claramente un objetivo para cualquier proyecto. Debemos plantearnos de que es una idea básica: seguir las buenas prácticas, respetar a los usuarios y prestar atención a los detalles. ■

1.5 "Presentación de información" frente a "análisis de información"

Aunque ya hemos hablado de la visualización de forma más amplia, nos queda acotar el uso de la visualización dentro del campo de la ingeniería de datos. Se han identificado dos grandes líneas, con objetivos distintos, a la hora de hablar del papel de la visualización de la información dentro de la ingeniería de datos en este caso, la presentación y gestión de la información y el análisis de la información.

La presentación de información tiene el único objetivo de facilitar el manejo de la gran cantidad de información disponible con la idea de que el analista la utilice de manera eficiente en el desarrollo de su labor o la transmita a los demás. Las características principales (necesidades) que tenemos que valorar a la hora de comparar distintos entornos son las facilidades que nos ofrecen a la hora de: presentar toda la información asociada a casos concretos, interaccionar con ellos, realizar zoom in/ zoom out, navegar por los casos, visualizar la información desde múltiples puntos de vista simultáneamente, incorporar información del contexto, facilidades de filtrado y selección casos, tipos de visualizaciones, etc.

En el análisis de la información, por su lado, no solamente se requieren facilidades para presentar la información y ser capaces de manipularla (gestionarla), sino que son necesarias herramientas para que el analista analice esa información y pueda sacar conclusiones de manera más eficiente, considerando un conjunto de datos más amplio. En este caso, son necesarias facilidades para seleccionar/filtrar/estructurar casos (basado en conocimiento o basado en los datos), realizar agrupaciones de casos por características comunes, analizar distribuciones (funciones de normalización, caracterización, validación), establecer relaciones, etc.

1.6 Ejercicios

Ejercicio 1.1 Visualiza la charla de Alberto Cairo titulada "How We Lie to Ourselves With Charts" en la pasada conferencia PyData Miami 2019 que puedes encontrar en el siguiente enlace `https://youtu.be/3QYsc48zzgs`. Tras la visualización contesta las siguientes preguntas:

1. ¿Cuáles son las principales ventajas de la visualización de datos?

2. Durante la charla, ¿se aborda principalmente el rol de “presentación de la información” o el de “análisis de la información” de acuerdo con la descripción de este capítulo?
3. ¿Cuáles son los principales problemas a los se enfrenta un usuario frente a un gráfico?
4. ¿Cómo crees que se pueden evitar esos problemas desde el punto de vista de los creadores de visualizaciones?

■

Ejercicio 1.2 Siguiendo la figura 1.7, describa un ejemplo de proyecto de análisis de datos como base al caso práctico planteado en la asignatura e indique las subtareas relacionadas con cada una de las etapas indicadas. Indique cómo podría mejorar el proceso el uso de herramientas de visualización de información. ■



2. Representación de la información

Durante el proceso de visualización de datos se parte de datos en crudo que se van convirtiendo, de forma sistemática y lógica, a otros formatos más informativos y finalmente a elementos visuales para formar el gráfico final. Por tanto, podemos decir que en una visualización vamos a tener en cuenta los siguientes dos elementos:

1. **Los datos** que contienen la información que queremos mostrar.
2. **La representación gráfica,** relativa a los elementos y estructura del gráfico.

En este capítulo nos vamos a centrar en lo relativo a los datos, explorando lo necesario para poder conocer la estructura de nuestros datos y así decidir qué queremos representar y cómo podemos preparar dichos datos para realizar una mejor visualización.

2.1 Representación de datos: Tipos de variables de datos y su estructura

En cualquier representación se distinguen dos partes:

1. la estructura o modelo que nos servirá para realizar la representación
2. los elementos concretos que hay que representar en un problema concreto.

Esta distinción es clave, pues separamos desde el principio la parte formal (estructura o modelo) de la parte dependiente del problema concreto (las instancias o elementos concretos). Dicho de otro modo, distinguimos la definición de los tipos de contenedores que vamos a utilizar del contenido que metamos en un problema concreto. En esta sección nos centramos en cómo generar la estructura formal o tipos de contenedores.

Debe quedar claro que, aunque existirán múltiples maneras de formalizar un cierto problema, cuanto más simple resulte esta estructura formal, más fácil resultará el análisis posterior. También se debe de tener en cuenta que todo modelo está orientado a resolver un determinado problema, por lo que la información que se debe modelar dependerá del objetivo perseguido.

En primer lugar, analizaremos la representación de información desde el punto de vista de la **teoría de sistemas**. Básicamente, en un sistema se distinguen objetos y relaciones entre objetos. La

idea es que tenemos que identificar los objetos/entidades y las relaciones de nuestro problema (objetivos, preferencias, entradas, salidas, resultados y operaciones intermedias, ...) como si formaran parte de un sistema. Cuantas más relaciones y tipos de objetos encontremos, más se complicará su manipulación, por lo que tenderemos a abstraer categorías que permitan agrupar estos objetos y facilitar así su manipulación. A continuación, veremos las estructuras de datos elementales y las propiedades que tienen interés a la hora de visualizarlas. Finalmente, veremos cómo podemos representar formalmente la información y la conversión entre distintas estructuras de datos.

2.1.1 Introducción a la teoría de sistemas

A la pregunta *¿qué queremos representar?* se responde utilizando la teoría de sistemas, que trata de conciliar las dos aproximaciones a la descripción de la realidad que existen:

- la *analítica*, basada en operaciones de reducción,
- y la *sistémica*, basada en operaciones de composición.

En la teoría de sistemas se trata de describir todos los objetos y relaciones que existen en un determinado escenario, de manera que si simuláramos el comportamiento de estos objetos, como si fuera un mundo virtual, pudiéramos obtener el mismo resultado, con el margen de error que consideremos admisible, que el que obtendríamos en la realidad. La teoría reduccionista es viable ante sistemas sencillos donde es posible encontrar variables descriptivas de la situación. Por ejemplo, prácticamente todos los problemas relacionados con la mecánica del movimiento se pueden modelar con las tres leyes de Newton, la clave está en la abstracción tanto de los objetos como de sus relaciones a un conjunto mínimo. Pero ante un sistema complejo, con multitud de tipos de objetos y de comportamientos, es más viable organizar la información utilizando el paradigma orientado a objetos.

De manera muy resumida, sin pretender ser exhaustivos en las definiciones, distinguiremos entre objetos y relaciones de la siguiente manera:

- **Objetos**: son las entidades (tangibles o abstractas) que se van a relacionar dentro del mundo virtual/abstracto definido. Los objetos pueden pertenecer a distintos niveles de abstracción o tener distinto nivel de complejidad, y las combinaciones de éstos mediante relaciones de abstracción y de composición permiten describir nuevos objetos. Por ejemplo, un objeto podría ser una persona, un coche, un mueble, etc.
- **Relaciones**: se distinguen los siguientes tipos:
  - las **relaciones intra-objeto** o **atributos**, que describen propiedades de los objetos. Por ejemplo, una persona tiene un nombre, unos apellidos, una edad, etc.
  - las **relaciones inter-objeto** representan conexiones entre los objetos del sistema. Por ejemplo, una persona (objeto 1) se compone (relación 1) de cabeza (objeto 2), cuerpo (objeto 3) y extremidades (objeto 4). A su vez, se distinguen (relación 1) las extremidades superiores e inferiores (objetos 5 y 6). Obsérvese que la relación *se compone* y la relación *se distinguen* pueden ser tratadas de la misma forma (relación de composición), aunque también la relación *se distinguen* se podría haber interpretado como una relación de abstracción, pues las extremidades inferiores y las superiores *son dos tipos de* extremidades. La Figura 2.1 muestra un esquema de esta organización[1].

Las relaciones también pueden ser tratadas como objetos, con relaciones y atributos propios (se habla entonces de relaciones reificadas). Otro tipo de relaciones son aquellas que emergen de la interacción entre los objetos descritos. Por ejemplo, en los sistemas multiagente se habla mucho de propiedades y abstracciones emergentes, donde una sociedad (objeto abstracto) emerge de la interacción entre agentes y se puede tratar como un nuevo objeto con atributos y relaciones. La

[1] A su vez, la cabeza tiene un tamaño, un peso, una posición, etc. que son atributos.

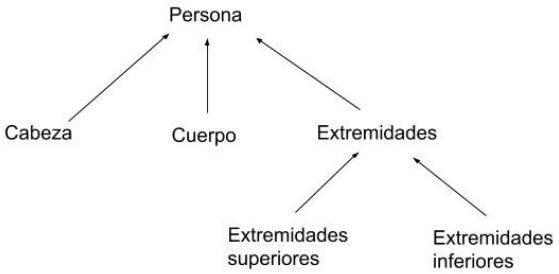


Figura 2.1: Relaciones de composición para describir el objeto persona a partir de sus partes (objetos) constituyentes.

sociedad *X* se relaciona con la sociedad *Y*, la sociedad *X* regula el comportamiento de los agentes inmersos en esa sociedad, etc. Obsérvese que, si no se define la entidad sociedad, parecería que las propiedades emergen de la interacción pero, si se define, entonces serían propiedades/atributos de la entidad.

2.1.2 Representación de objetos y relaciones

Una vez que sabemos lo que deseamos representar, debemos decidir cómo representar esos objetos y relaciones. Siguiendo el paradigma de la programación orientada a objetos, podemos encapsular todo lo característico de cada objeto dentro de un marco[2] y las relaciones entre objetos como enlaces entre esos marcos.

La Figura 2.2 muestra un ejemplo de representación del objeto persona de la Figura 2.1 con algunos atributos añadidos. En esta estructura se aprecian claramente las relaciones de composición como submarcos contenidos en un marco mayor (por ejemplo, la cabeza y el cuerpo son submarcos del marco persona) y los atributos como propiedades internas de los marcos (por ejemplo, los atributos nombre, altura, etc), tanto del marco global persona, como de alguna de sus partes. Los atributos, a su vez, pueden ser variables simples o compuestas. Por ejemplo, en la cabeza se representa el peso mediante una variable simple, pero las dimensiones se representan como un vector de tres componentes (altura, anchura, profundidad).

Por otro lado, la Figura 2.3 muestra un ejemplo de relación entre personas, la relación de parentesco. Cada relación se representa por un enlace distinto que conecta distintos objetos, Por ejemplo, el objeto *María* está conectado con el objeto *Juan* mediante la relación *hijo de*.

El resultado final que se obtiene al usar este enfoque es una representación organizada y jerárquica en la que todas las entidades y relaciones existentes en un cierto contexto se van descomponiendo en entidades más simples hasta llegar a entidades mínimas que se pueden representar mediante variables simples. Obsérvese que las entidades más simples de la descomposición marcan el grano más fino de detalle con el que se pueden analizar los datos. Por ejemplo, la variable *peso* puede almacenar un único valor (el peso actual), pero si quisiéramos llevar un control de la evolución del peso de una persona, necesitaríamos almacenar el peso en distintos instantes de tiempo, *peso(t)*, y necesitaríamos un vector para hacerlo.

2.1.3 Tipos de variables

Una variable es un contenedor de información. Como tal, existen varios criterios para clasificar las variables, por ejemplo, atendiendo a su naturaleza (estadísticas vs deterministas), a su dimensionalidad (1D, 2D, 3D, ..., nD), a su papel en un problema (dependientes vs independientes), simple

[2]Un marco es una estructura donde incluimos el conjunto de propiedades que caracterizan un concepto

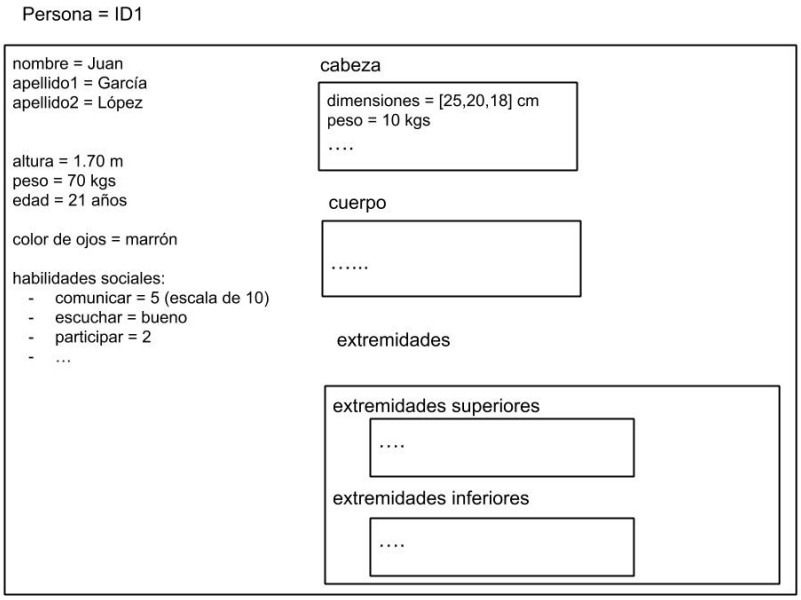


Figura 2.2: Marco conceptual para la descripción de una persona.

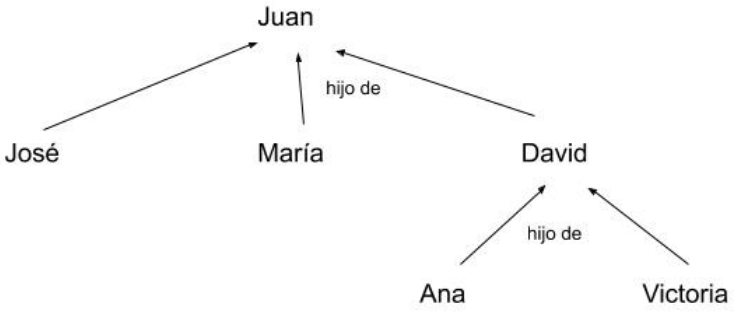


Figura 2.3: Relación de parentesco entre personas.

vs compleja (recursivas, estructuradas, etc.). Sin embardo, la clasificación que aquí más nos interesa atiende al tipo de dato simple que pueden almacenar (variables cualitativas vs cuantitativas) porque sus características inciden directamente en la manera de representarlas y visualizarlas. En la Figura 2.4 mostramos la jerarquía de variables cualitativas y cuantitativas.

Las variables **cualitativas** (también llamadas categóricas) permiten almacenar clases, etiquetas, nombres, etc. Dentro de este tipo de variables distinguimos entre variables **nominales** y **ordinales**. La principal característica de las primeras, las nominales, es que no existe una relación de orden entre sus posibles valores, pudiendo intercambiar sus posiciones en una representación sin perder información. Por ejemplo, la nacionalidad de una persona se puede modelar como una clase: francés, chino, indio, etc. Las principales características de esta enumeración son que:

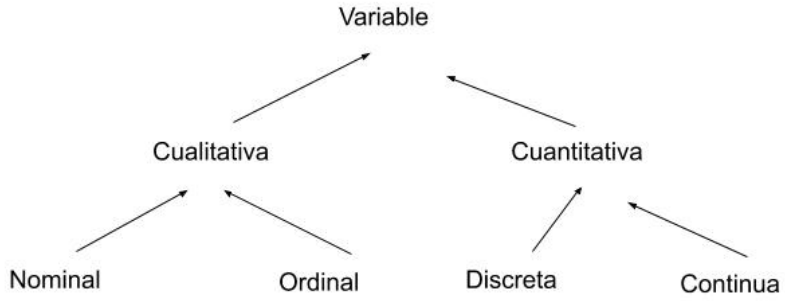


Figura 2.4: Tipos de variables.

1. puede ser exhaustiva si se detallan todas las clases posibles;
2. puede ser exclusiva si no hay solape entre las clases. Es decir, si una instancia concreta no puede pertenecer a dos clases a la vez.

Por otro lado, las observaciones son cada uno de los datos que hemos recogido para cada una de las variables. De modo que con todas las observaciones construimos un dataset sobre el que trabajaremos. En python, las variables cualitativas se suelen almacenar como cadenas de texto que sirven para representar distintos rasgos de las observaciones sobre las que se trabaja.

La relación de jerarquía entre clases realmente se produce en las fases iniciales del modelado, cuando las variables todavía no están bien definidas y se mezclan clases de distinto nivel de abstracción. Se producen solapes, por lo que las clases no son exclusivas, etc. La solución es separar distintos subconjuntos y definir variables distintas para cada uno de ellos. Por ejemplo, supongamos que tenemos el siguiente conjunto de clases en un problema:

- Partes del cuerpo humano = cabeza, cuerpo, extremidades, ojos, brazos, corazón, cerebro

Este conjunto de clases es correcto ya que todas son partes del cuerpo humano, pero las clases no son exclusivas (el corazón de una persona concreta pertenecerá simultáneamente a la clase corazón y a la clase cuerpo, por ejemplo). En realidad lo que hay son dos grupos de clases con distinto nivel de detalle con una relación de abstracción entre ellas:

- Partes del cuerpo humano 1 = {cabeza, cuerpo, extremidades}
- Partes del cuerpo humano 2 = {ojos, brazos, corazón, cerebro}
- Relaciones de pertenencia:
  - ojos pertenecen-a cabeza
  - cerebro pertenece-a cabeza
  - brazos pertenecen-a extremidades
  - corazón pertenecen-a cuerpo

En cambio, las variables **ordinales** son variables no numéricas en las que sí se establece una ordenación de los valores posibles. Por ejemplo, una persona puede ser {baja, normal, alta, muy alta} o el grado de acuerdo con una afirmación puede ser {muy en desacuerdo, en desacuerdo, indiferente, de acuerdo, muy de acuerdo}. Obsérvese que existe una ordenación de los valores, pero no se cuantifica cuándo se pasa de un valor a otro (sigue siendo subjetivo).

Las variables **cuantitativas** almacenan datos en los que existe una relación de orden cuantitativa (los números asociados tienen un sentido cuantificado, una escala conocida). Se distingue entre variables **discretas** y **continuas** dependiendo de si los valores posibles son puntos aislados o

continuos respectivamente. Como ejemplo, consideremos la variable tiempo. Esta variable se puede tratar como una variable discreta si sólo consideramos el año (1999, 2000, 2001, ...), o como una variable continua si consideramos divisiones más pequeñas (1999.1, 1999.55, ...). Las variables continuas tienen un número infinito de valores entre cualesquiera dos valores.

En python, se suelen utilizar los tipos entero (int) y decimal (float) para guardar variables cuantitativas.

Por otro lado, para su visualización, nos interesará conocer las propiedades de las variables:

- Rango de valores posibles (dentro del universo de discurso)
- Rango de valores presentes (dentro del estudio)
- Si existe un orden y si éste es necesario (si aporta información)
- Si el conjunto es exclusivo (si no hay solape entre los subconjuntos)
- Si el conjunto es exhaustivo (si se definen todas las clases posibles)

Obsérvese que hemos ido añadiendo restricciones a las variables para pasar de las primeras (las clases, subjetivas, sin relación de orden y sin estructura) a las últimas (variable continua), por lo que si obviamos algunas de estas propiedades en las variables que presentan más restricciones, siempre podremos tratarlas como variables de los grupos previos. Esto es muy importante, pues muchos gráficos se basan en este hecho.

2.1.4 Estructuras formales de representación de datos

En el apartado anterior decíamos que una variable simple puede almacenar un valor y distinguíamos distintos tipos de variables en función del tipo de valor que pueden almacenar. Hablemos ahora de las estructuras que permiten organizar varios valores del mismo tipo en una única estructura de datos.

La organización de varios valores de una variable atiende a otra dimensión, la cual le confiere un cierto orden. Por ejemplo, los valores del peso de una persona a lo largo de un año (ordenados según la variable tiempo) o la altitud de cada punto en un mapa (ordenados/organizados según su posición espacial).

Vemos que existen dos variables de especial interés por su amplia aplicación para modelar los acontecimientos que nos rodean en cualquier dominio: las que nos permiten modelar las dimensiones espacio-tiempo. Tanto la variable tiempo como la variable distancia en 1D, espacio/superficie en 2D, o volumen en 3D pueden tratarse como variables continuas o discretas y se pueden utilizar para indexar otras variables.

Si queremos almacenar más de un valor para una variable, podemos hacer uso de arrays o de listas.

2.1.5 Conversión entre estructuras de datos

Es evidente que una misma información se puede representar formalmente mediante distintas estructuras de datos. Cada estructura tiene sus ventajas e inconvenientes, y los lenguajes y los sistemas automáticos que las manipulan hacen uso de estas propiedades para optimizar el tiempo de cómputo, la expresividad del lenguaje o la facilidad de manipulación. Un caso paradigmático es la propia tecnología digital, que a partir de únicamente dos símbolos (0 y 1, verdadero/falso) sirve para abordar problemas complejos en todos los ámbitos de nuestro alrededor. Pero eso no se aborda trabajando en binario y hablando código máquina, sino interponiendo representaciones intermedias (que utilizan lenguajes distintos) que facilitan la representación y la interacción a costa de un mayor coste computacional.

La estructura más sencilla para representar información es el formato de tabla, en el que cada fila representa los datos de una instancia (las observaciones) y cada columna representa los distintos atributos que caracterizan las instancias (cada variable). Este formato facilita el manejo

y la visualización de información para un número de datos pequeño, pero presenta los siguientes inconvenientes a la hora de su manejo:

- no es práctico cuando el número de instancias es grande
- no es práctico cuando el número de atributos es grande
- no es flexible para representar objetos con características dependientes del tipo de objeto
- no es flexible a la hora de generar nuevos atributos que no dependan únicamente de características del propio objeto
- las características espaciales y volumétricas se representan de manera poco intuitiva

Una manera de evitar estos problemas es usar bases de datos, que consisten en múltiples tablas relacionadas mediante campos clave (identificadores unívocos). En este caso, para obtener los datos de interés para un determinado objetivo habrá que lanzar una consulta que permita obtener una vista de la base de datos con la información de interés, esto es, una tabla. Otra opción es encapsular toda la información en los objetos que forman parte del sistema y, mediante programación, extraer la información de interés.

Además de la organización global de la información disponible, es interesante saber que una variable se puede convertir a otra de otro tipo más general sin perder información. Por ejemplo, una variable entera se puede tratar como variable continua si no se realizan operaciones no permitidas en el espacio origen. Una variable categórica se puede presentar como una variable numérica y establecer interpolaciones ficticias, etc.

Cuando en el apartado anterior se habló de tipos de datos, se dijo que al pasar desde variables categóricas a variables continuas se añadían restricciones de orden y de escala, este es el caso contrario, se eliminan estas restricciones, por lo que hay que tener mucho cuidado y estudiar cada uso concreto para no realizar representaciones erróneas.

En python se suele usar el formato basado en tabla para almacenar datos cuando se tienen varias variables y observaciones. Para ello, se usa la estructura denominada *DataFrame* del paquete *pandas*. Este paquete ofrece varios métodos que permiten la exploración y manejo de las tablas con el fin de poder analizar los datos que contienen. Más adelante vamos a mostrar algunos de estos métodos.

2.2 Proceso de análisis de datos

Dado un conjunto de datos (dataset) que es una muestra representativa de un cierto proceso o situación, el análisis de datos consiste en encontrar las similitudes y las diferencias presentes en el dataset. Esto es, en identificar los modelos o patrones que permiten describir los datos de manera sencilla. Normalmente, los datos crudos no tienen el formato ni el nivel de detalle necesario para obtener directamente la visualización objetivo. El preprocesado de los datos es una tarea muy importante y que normalmente conlleva más trabajo y recursos que el análisis final.

El análisis de los datos se suele realizar de manera incremental, siguiendo la metodología en espiral (ver Figura 2.5). Tras determinar el problema, se comienza con la selección de los datos, la identificación de las condiciones de contexto y la manera de abordar el problema. Esta es la fase de preprocesado y transformación inicial de los datos. A continuación se realiza el estudio planificado, el procesado de los datos, obteniendo los resultados objetivo de acuerdo con las hipótesis planteadas. Estos resultados hay que evaluarlos, bien para comprobar las hipótesis planteadas, bien para generar nuevas hipótesis. Tanto la generación de nuevas hipótesis, como la no consecución de los objetivos esperados dan lugar a críticas sobre el conjunto de datos utilizado y/o sobre el proceso de análisis, lo que da lugar a un nuevo ciclo de análisis hasta que los resultados conseguidos concuerdan con los esperados, en cuyo caso se puede generar el informe final.

A pesar de esta diferenciación entre preprocesado y análisis de datos, hay que reconocer que la línea que las diferencia es muy fina, pues se trata en muchas ocasiones de las mismas operaciones.

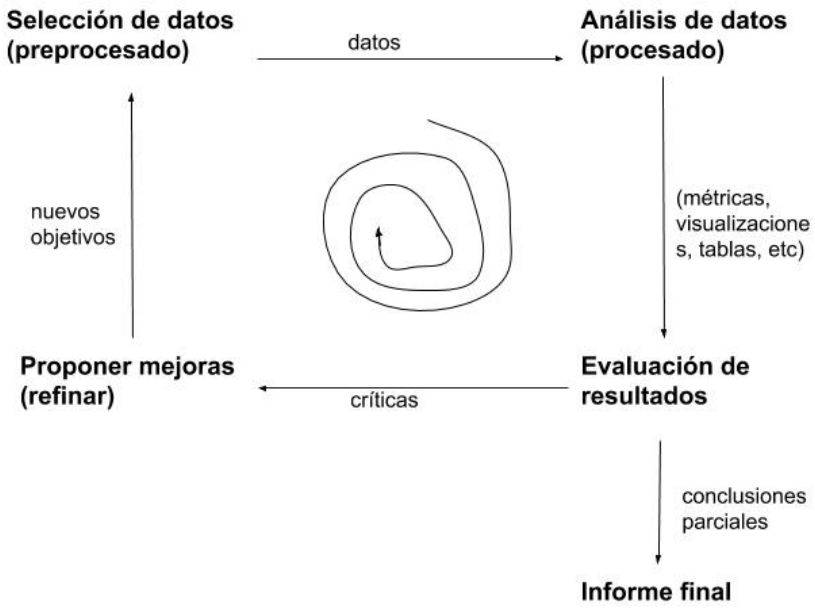


Figura 2.5: Proceso incremental de análisis de datos

La diferencia es el matiz de si se considera que los datos obtenidos son parte del análisis o son pasos previos necesarios para el análisis.

2.2.1 Preprocesado de datos

Las tareas más habituales en el preprocesado son las siguientes:

La limpieza de datos

La limpieza de datos, también conocida como data cleaning o data scrubbing, es el acto de descubrimiento, corrección o eliminación de datos erróneos en un dataset. Este proceso afecta a datos incompletos, vacíos, incorrectos, inexactos, no pertinentes, etc. La limpieza de datos es muy importante ya que facilita el uso posterior de algoritmos, como por ejemplo de aprendizaje automático. Un caso en el que es importante el proceso de limpieza de datos es cuando se van a usar algoritmos que no pueden trabajar con valores nulos, de modo que tendríamos que eliminar dichos valores nulos.

Los valores nulos pueden ser consecuencia de que un usuario no haya rellenado un campo o que el dato se haya perdido antes de llegar a nosotros. En python, podemos consultar los valores nulos de un DataFrame llamado df ejecutando *df.isnull().sum()*. Como salida, obtendremos el número de valores nulos por columna del DataFrame. Por ejemplo, en la Figura 2.6 mostramos un código donde creamos una tabla con valores nulos para las variables Altura y Peso. En ambos casos, indicamos los nulos mediante el valor *np.nan* (not a number). El contenido del DataFrame lo podemos ver en la Figura 2.7. Cuando ejecutamos la última línea, obtenemos la salida de la Figura 2.8, donde podemos ver que hay dos valores nulos en total.

En caso de que no queramos trabajar con valores nulos, tenemos dos alternativas:

- Sustituir cada valor nulo por un valor predeterminado, como por ejemplo 0, un valor mínimo, la media de nuestros valores, etc. Podemos hacer esto a través del método *fillna()*. Por ejemplo, en el DataFrame anterior podríamos hacer algo como *df = df.fillna(0)*. Existen

```
import pandas as pd
import numpy as np


diccionario = {"Nombre":["Juan", "Maria", "Laura", "David", "Marta"],
     "Altura(cm)":[175 , 165, 173, np.nan, 182],
     "Peso(kg)":[70, np.nan, 84, 62, 73]}

#creamos el DataFrame a partir del diccionario
df = pd.DataFrame(diccionario)

df.isnull().sum()
```

Figura 2.6: Ejemplo con valores nulos

	Nombre	Altura(cm)	Peso(kg)
0	Juan	175.0	70.0
1	Maria	165.0	NaN
2	Laura	173.0	84.0
3	David	NaN	62.0
4	Marta	182.0	73.0

Figura 2.7: Contenido del DataFrame

```
Nombre        0
Altura(cm)    1
Peso(kg)      1
dtype: int64
```

Figura 2.8: Valores nulos del DataFrame

métodos más elaborados para realizar la sustitución de datos tratando de inferir el valor a partir de las otras variables. Se les conoce como métodos de imputación de datos.

- Eliminar las filas que contienen nulos usando el método *dropna()*. Por ejemplo, en el DataFrame anterior podríamos ejecutar *df= df.dropna()*. Hay que tener en cuenta que usando esta opción, reducimos el tamaño de nuestro dataset.

El filtrado/selección de variables y/o instancias

El filtrado es el proceso de selección para un análisis concreto del subconjunto de datos de interés dentro del dataset completo. Normalmente el dataset contiene variables e instancias irrelevantes para un estudio concreto, con lo que eliminarlos cuanto antes simplifica el procesado posterior. Seleccionar y filtrar son acciones complementarias. La primera tiene por objetivo localizar las instancias y variables de interés, para quedarnos con ellas, mientras que la segunda, filtrar, selecciona los datos que se desea rechazar. Estos términos actualmente se usan indistintamente, pues su efecto se deduce por el contexto.

El filtrado nos puede servir también para reducir el espacio que ocupan nuestros datos, puesto

que eliminamos los que no son relevantes. Además, al trabajar con menos datos, se reduce el tiempo de procesamiento.

Podemos eliminar columnas (variables) de un DataFrame usando el método *drop()* y una lista con los nombres de las columnas que deseamos eliminar. A continuación mostramos un ejemplo de código donde eliminamos las columnas *Nombre* y *Apellidos*. El atributo *inplace* se poner a *True* para hacer los cambios directamente sobre el DataFrame. El atributo *axis* vale 1 cuando queremos eliminar columnas y 0 cuando queremos eliminar filas (en este caso tenemos que indicar una lista con los valores del índice de las filas a eliminar).

```
columnas_a_borrar = ["Nombre","Apellidos"]

df.drop(columnas_a_borrar , inplace=True , axis = 1)
```

Transformar variables

El proceso de transformación conlleva el cambio de los valores de una variable o la generación de nuevas variables a partir de variables ya existentes. Por ejemplo, se pueden cambiar los valores de una variable para realizar un cambio de escala o del sistema de referencia.

Por otro lado, se puede crear, por ejemplo, una nueva variable categórica a partir de la información de otra variable no categórica. Por ejemplo, supongamos un listado de pacientes a los que se les ha medido la temperatura. Podemos generar una nueva variable *tiene-fiebre* a partir del valor de la variable *temperatura* (la transformación genera una nueva variable o un nuevo atributo). Supongamos ahora que el listado de pacientes contiene los datos de todas las poblaciones españolas y queremos analizar si existe alguna relación entre la temperatura corporal y las características geográficas y meteorológicas de las poblaciones. Entonces, la transformación debe generar, a partir de los datos de los pacientes de cada población, un valor para cada población, como por ejemplo la temperatura media. Obsérvese que en este caso se pasa de un listado de pacientes con un atributo *temperatura* a otro listado de poblaciones con un atributo de *temperatura-media* en el que concentramos todos los datos de los pacientes de cada población.

Otro ejemplo podría ser un DataFrame con una columna que contiene los precios sin iva de unos determinados productos. Podemos crear una nueva columna, *precioConIva*, que contenga el precio tras aplicar el valor de iva almacenado en otra variable. A continuación vemos un ejemplo sobre cómo añadir la nueva columna:

```
df["precioConIva"] = df["precioSinIva)"] * (1 + (iva / 100))
```

2.2.2 Tareas de procesado

Durante el procesado se realizan las siguientes operaciones:

- **Ordenar**: Teniendo en cuenta los principios de la gestalt (y las capacidades humanas), para que una visualización sea efectiva debe presentar unidos los elementos relacionados, de manera que podamos agruparlos fácilmente. La ordenación correcta de una lista de categorías puede ser la diferencia entre un resultado coherente o incomprensible.
- **Agrupar (clustering)**: Esta es una tarea típica de análisis, la cual trata de encontrar agrupaciones de interés dentro de un espacio de entrada. Con el clustering se trata de agrupar de manera automática. Es decir, se trata de considerar dentro de la misma categoría aquellas instancias que tienen características comunes. En el campo de la minería de datos existen multitud de algoritmos para realizar clustering. Desde el punto de vista de la visualización, los dendrogramas son una forma bastante habitual de representar la jerarquía de agrupaciones

obtenidas de manera automática. Por ejemplo, podemos obtener el dendograma de la Figura 2.9 a partir del código de la Figura 2.10.

- **Correlacionar**: Correlacionar es el proceso de análisis que trata de estudiar la relación entre distintas variables. Normalmente se habla de correlaciones positivas o negativas, lineales o no lineales, etc., porque son fácilmente computables, pero mediante visualizaciones podemos detectar muchos más tipos de correlaciones entre variables. No confundir la correlación entre variables con la existencia de una relación causal entre las mismas. Una relación causal entre dos eventos existe si la ocurrencia del primero causa el segundo. El primer evento es llamado la causa y el segundo evento el efecto. La correlación entre dos variables no implica causalidad, sin embargo, si hay una relación causal entre dos variables, éstas deben estar correlacionadas. Otra operación que analiza la relación entre eventos es la coocurrencia. En la Figura 2.11 se puede ver un heatMap (gráfico de calor) que muestra la coocurrencia de una serie de valores aleatorios que calculamos a través del código de la Figura 2.12. Se puede ver en cada casilla el valor de correlación, de modo que con que mayor es este valor, más cálido es color que se usa.
- **Combinar información**: En ocasiones no interesará analizar separadamente todas las instancias del dataset, sino que se crearán representaciones intermedias que agrupen o integren conjuntos de instancias en entidades más abstractas. En este caso, el análisis visual se realizará sobre las nuevas entidades creadas. Este es el caso comentado anteriormente en el apartado de preprocesado en el que se obtenía un listado de poblaciones con atributos obtenidos de la combinación de información de pacientes pertenecientes a cada población.
- **Normalizar**: Normalizar tiene dos acepciones. Por una lado, en estadística, con normalizar nos referimos al proceso de transformación de una variable aleatoria con una determinada distribución en una variable aleatoria con distribución normal de media 0 y varianza 1. Por otro lado, cuando se habla de normalizar una variable, realmente nos referimos a estandarizar, esto es, a llevar los datos a un espacio común, estándar, donde pueden ser comparados con otros datos, con otras variables. Por ejemplo, cuando usamos porcentajes, estamos utilizando un valor normalizado (estandarizado) en el espacio [0,100]. Otra normalización habitual es el paso o transformación de un histograma a una función de densidad.
- **Escalar**: Cambiar la escala de una variable puede mejorar la visualización y resaltar las diferencias que realmente son significativas. También se usa habitualmente en sentido contrario para presentar diferencias que no son realmente significativas.

2.2.3 Evaluación

Una vez realizado el procesado se deben comprobar los resultados, es decir, se debe responder a la pregunta: ¿el resultado obtenido es congruente y se corresponde con lo esperado completamente o se han encontrado algunas críticas que es necesario resolver?

En esta fase se debe comprobar visualmente que los resultados obtenidos corresponden con los esperados. Se trata de analizar los resultados para confirmar que son congruentes con las previsiones. Si se detectaran resultados inesperados, es posible que se deban a situaciones no previstas de antemano o a errores en los datos de entrada. En el primer caso, habrá que analizar si los casos inesperados se corresponden con el modelo, y por tanto el análisis es válido, o si es necesario un análisis posterior para mejorar el modelo. En el segundo caso, se trata de observaciones excepcionales que no corresponden a datos válidos, sino a errores en los datos de entrada. En este caso, habrá que corregir los errores y repetir el proceso.

2.2.4 Mejorar

A partir de la evaluación previa y de las críticas detectadas, podremos realizar dos acciones principales:

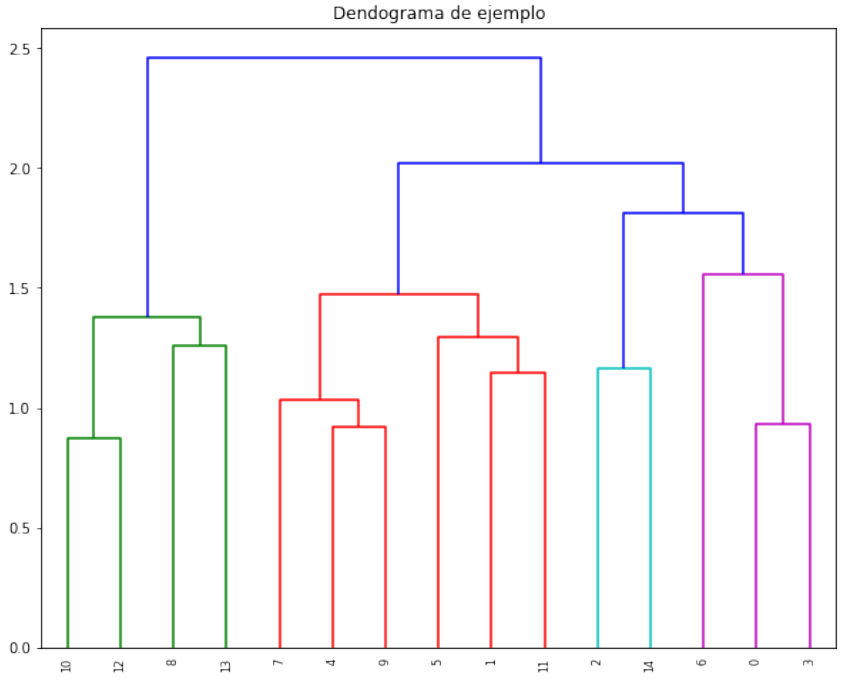


Figura 2.9: Ejemplo de dendograma.

- **Proponer nuevas hipótesis/objetivos**: la visualización de un determinado análisis puede llevar a proponer nuevas hipótesis para refinar las conclusiones del estudio. Por ejemplo, puede llevar a centrarse en un subconjunto de los datos, analizar los datos a otro nivel, etc.
- **Proponer mejoras en la visualización**: la visualización de un determinado análisis también puede llevar a proponer mejoras en la visualización. Por ejemplo, un cambio de colores para que todos estén en la misma gama o que sean complementarios y presenten un contraste más alto, un cambio de escala para que la visualización represente la realidad con el nivel adecuado de detalle, cambiar de posición las leyendas, las etiquetas y demás accesorios del gráfico para mejorar la estética del gráfico, etc.

2.3 Caso práctico

Después de lo estudiado en este tema, vamos a ver un caso práctico relativo al trabajo inicial que podemos realizar con un dataset y cómo obtener sencillas visualizaciones del mismo. En nuestro ejemplo vamos a trabajar con el famoso dataset de flor iris [3]. Este dataset contiene observaciones de tres especies de la flor iris y es un clásico de la ciencia de datos, ya que se usa para visualización, análisis de datos y aprendizaje automático. Para estos ejemplos vamos a usar la librería de gráficos *seaborn*, que utiliza por debajo *matplotlib*.

Para empezar, cargamos los paquetes necesarios y el dataset a través del siguiente código:

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt

iris = sns.load_dataset("iris")
```

[3] https://es.wikipedia.org/wiki/Conjunto_de_datos_flor_iris

```
from matplotlib import pyplot as plt
from scipy.cluster.hierarchy import dendrogram, linkage

import numpy as np


X = np.random.rand(15, 12)

Z = linkage(X, 'ward')

plt.figure(figsize=(10, 8))
plt.title('Dendograma de ejemplo')
dendrogram(
        Z,
        leaf_rotation=90.,
        leaf_font_size=8.,
        show_contracted=True
    )

plt.show()
```

Figura 2.10: Código de ejemplo para obtener un dendograma

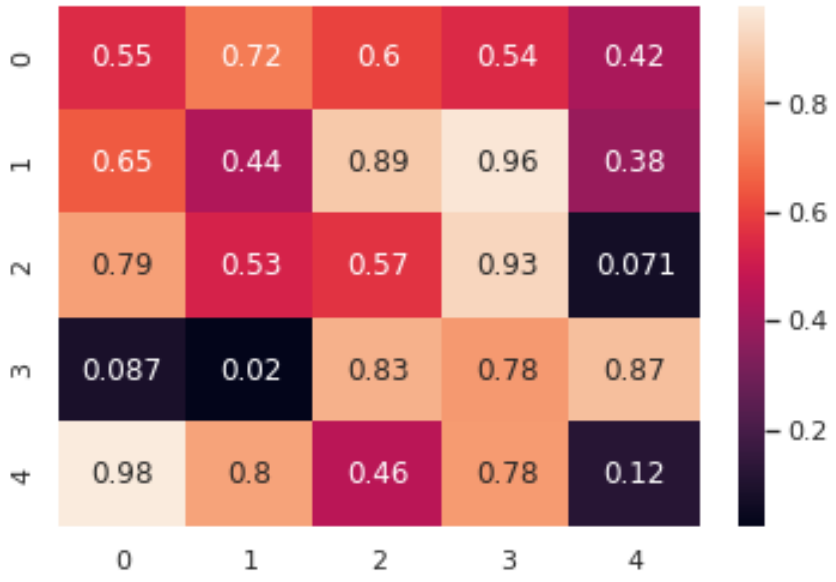


Figura 2.11: Ejemplo de heatMap para ver la correlación entre dos variables

El dataset se ofrece dentro de un DataFrame. Antes de comenzar con las tareas de visualización, conviene explorar el dataset para comprobar su contenido, las variables que tiene, su tipo, etc. Para empezar la exploración del mismo, miramos el aspecto de las primeras líneas mediante el siguiente código, obteniendo el resultado de la Figura 2.13:

```
import numpy as np
#fijamos la semilla para tener los mismos valores
np.random.seed(0)
import seaborn as sns
sns.set()
datos = np.random.rand(5, 5)
x = sns.heatmap(datos,annot=True)
```

Figura 2.12: Código de ejemplo para un heatMap

```
iris.head()
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Figura 2.13: Primeras líneas del dataset iris

Podemos ver que el dataset tiene cinco variables, cuatro de ellas numéricas. Realizamos una exploración más detallada sobre el número de observaciones que tiene y el tipo concreto de cada variable con el siguiente código:

```
iris.info()
```

Como salida obtenemos:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
sepal_length    150 non-null float64
sepal_width     150 non-null float64
petal_length    150 non-null float64
petal_width     150 non-null float64
species         150 non-null object
dtypes: float64(4), object(1)
memory usage: 5.9+ KB
```

Podemos ver que el dataset contiene 150 observaciones y ninguna de ellas es nula. Las cuatro variables numéricas (*sepal_length*, *sepal_width*, *petal_length* y *petal_width*) son de tipo real (float de 64 bits) y la variable *species* es una variable categórica (que vamos a explorar más abajo).

Si queremos tener una descripción más detallada de cada variable numérica, ejecutamos el siguiente código, cuyo resultado podemos ver en la Figura 2.14:

	sepal_length	sepal_width	petal_length	petal_width
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

Figura 2.14: Descripción de las variables numéricas del dataset iris.

```
iris.describe()
```

Como resultado del método *describe()* podemos ver para cada variable el número de elementos, la media, desviación estándar, mínimo, cuartiles (25 %, 50 %, que coincide con la mediana y 75 %) y el máximo de las observaciones. A través de esta información podríamos decidir si aplicar algún proceso de escalado o de normalización para tener todas las variables en el mismo rango. En este ejemplo, vamos a continuar sin aplicar ninguna variación al dataset.

Tras observar las variables numéricas, nos interesa obtener información sobre la variable categórica *species*. En concreto queremos conocer qué valores contiene y cuántas observaciones hay por cada posible valor. A través del siguiente código podemos obtenerlo:

```
iris["species"].value_counts()
```

Obteniendo como resultado:

```
versicolor    50
setosa        50
virginica     50
Name: species, dtype: int64
```

Por tanto, tenemos tres posibles valores (*versicolor*, *setosa* y *virginica*) y el mismo número de observaciones (50) para cada valor.

Una vez hemos realizado este proceso inicial de exploración del dataset, podemos empezar con la exploración visual. Para ello tendremos que seleccionar el tipo de gráfico a utilizar y la variable o variables a explorar. Sin embargo, podemos comenzar con una exploración visual comparando todas las variables dos a dos. Es decir, observar cómo varía cada variable en función de cada una de las demás. De este modo, podemos ver de forma sencilla cómo afecta una variable a las demás. El paquete *seaborn* permite realizar esta exploración de forma sencilla usando el siguiente código, cuyo resultado podemos ver en la Figura 2.15:

```
sns.pairplot(iris)
```

Se puede ver que el resultado contiene 16 gráficos, resultado de emparejar dos a dos las variables numéricas. En la diagonal que comienza en el gráfico de arriba a la izquierda se presentan cada uno

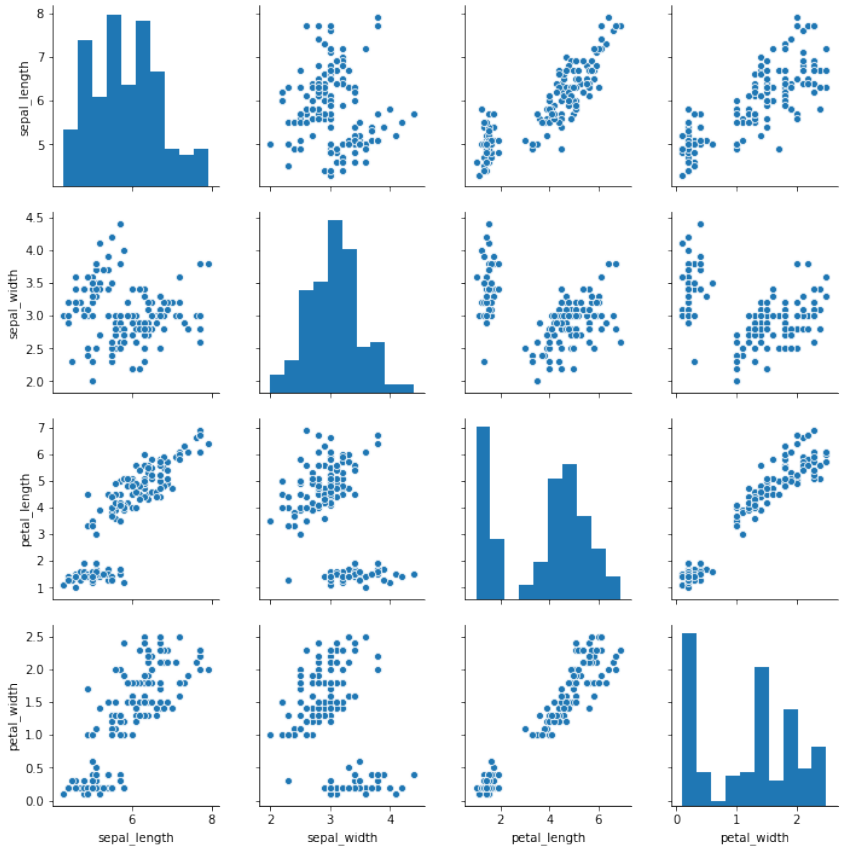


Figura 2.15: Visualización de las relaciones entre las variables del dataset iris.

de los histogramas que muestran la distribución de los valores de cada variable. Por ejemplo, el gráfico de la primera fila y la primera columna muestra el histograma de la variable *sepal_length*.En el resto de gráficos podemos ver de forma gráfica la relación que existe entre cada par de variables. Por ejemplo, en el gráfico de la cuarta fila y la tercera columna se puede observar que según aumentan los valores de *petal_length*, aumentan los valores de *petal_width*, lo que nos puede hacer pensar que hay una relación entre la longitud y el ancho de los pétalos.

Si queremos añadir a los gráficos información relativa a una variable categórica (en nuestro dataset la variable *species*), debemos de indicarlo a través del atributo *hue*, de modo que en cada gráfico se mostrarán los puntos diferenciados (usando distintos colores) por cada categoría de dicha variable. En nuestro ejemplo usaríamos el siguiente código, cuyo resultado podemos observar en la Figura 2.16.

```
sns.pairplot(iris , hue="species")
```

En esta nueva versión se puede observar que en cada gráfico además de comparar dos variables (la del eje x y la del eje y), añadimos una tercera variable relativa a la especie usando distintos colores. Por ejemplo, en la tercera columna podemos observar que las flores de la variedad *setosa* tienen una menor longitud de pétalo.

Tras haber realizado este primer análisis exploratorio de nuestros datos, podemos proceder a centrarnos en determinadas variables u observaciones y realizar gráficos sobre ellos, formular nuevas hipótesis y comprobarlas, etc.

Como último ejemplo de este caso práctico, vamos a centrarnos en crear solamente un gráfico que nos permita ver la relación entre dos variables del dataset iris. Por ejemplo, vamos a ver cómo

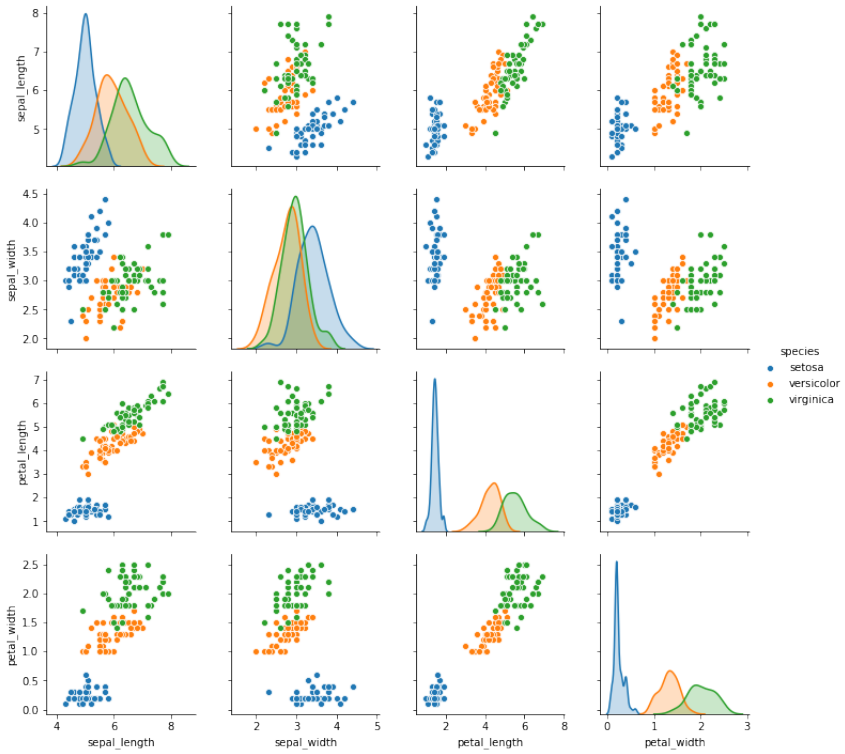


Figura 2.16: Visualización de las relaciones entre las variables del dataset iris diferenciadas por especies.

cambia la variable *petal_width* en función de la variable *sepal_width* usando el siguiente código, cuyo resultado mostramos en la Figura 2.17:

```
sns.scatterplot(x="sepal_width", y="petal_width", data=iris)
```

En el gráfico no se ve una relación clara ya que hay casos en los que parece que para anchos mayores de sépalo, disminuye el ancho de pétalo. Sin embargo, esta observación no se cumple siempre. Por tanto, añadimos más información al incluir la especie con el siguiente código, que genera el gráfico de la Figura 2.18:

```
sns.scatterplot(x="sepal_width", y="petal_width" ,
                hue="species", data=iris)
```

Al añadir información sobre la especie sí que podemos observar algunas relaciones. En primer lugar, vemos que el ancho de pétalo varía en función de la especie, mientras que el ancho de sépalo no varía tanto, salvo para los mayores tamaños, que se corresponden con la especie *setosa*. En cuando a la relación entre anchos de pétalo y sépalo, en las especies *versicolor* y *virginica* parece que aumenta el ancho de pétalo al aumentar el ancho de sépalo. Sin embargo, no se observa este comportamiento con la especie *setosa*. Posteriormente tendríamos que aplicar los métodos adecuados para comprobar estas relaciones, pero ya hemos podido realizar una primera observación que nos hace intuir que existen algunas relaciones en el dataset con el que estamos trabajando.

2.4 Ejercicios

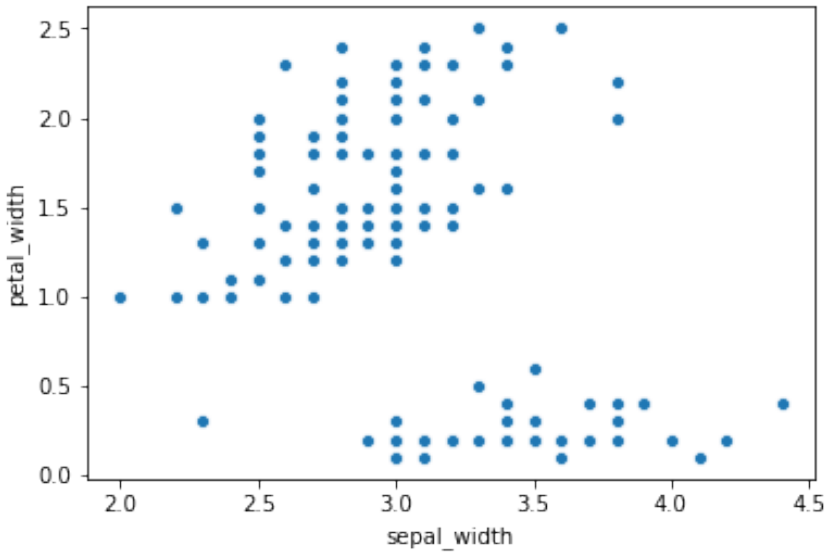


Figura 2.17: Gráfico de puntos que muestra la relación entre *petal_width* y *sepal_width*

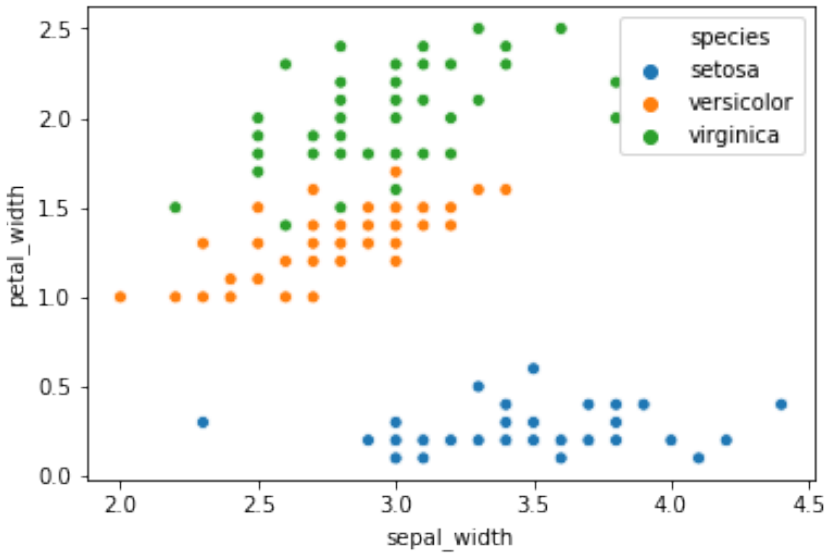


Figura 2.18: Gráfico de puntos que muestra la relación entre *petal_width* y *sepal_width* considerando *species*

Ejercicio 2.1 Cargar el dataset *diamonds* y realizar un análisis inicial del mismo incluyendo al menos lo siguiente:

1. Comprobar el número de observaciones, variables y el tipo de cada una de ellas. ¿Existen valores nulos?
2. Comprobar los valores de cada variable categórica.
3. Comparar distintas variables entre si y tratar de obtener algunas intuiciones sobre las relaciones entre ellas.

La colección se puede cargar ejecutando el siguiente comando:

```
coleccion = sns.load_dataset("diamonds")
```

Ejercicio 2.2 Cargar el dataset *titanic* relativo a los pasajeros del Titanic y realizar un análisis inicial del mismo incluyendo al menos lo siguiente:

1. Comprobar el número de observaciones, variables y el tipo de cada una de ellas. ¿Existen valores nulos?
2. Comprobar los valores de cada variable categórica.
3. Comparar distintas variables entre si y tratar de obtener algunas intuiciones sobre las relaciones entre ellas.

La colección se puede cargar ejecutando el siguiente comando:

```
coleccion = sns.load_dataset("titanic")
```

2.5 Cuestiones

Pregunta 2.1 ¿Con qué tipo de variable representarías los destinos a los que vuela una compañía de aviones? ¿Por qué?

Pregunta 2.2 ¿Con qué tipo de variable representarías los precios de los productos de un supermercado? ¿Por qué?

2.6 Glosario

Vocabulario 2.1 — Variable. Contenedor de información.

Vocabulario 2.2 — Variable cualitativa. Variables que permiten almacenar clases, etiquetas, nombres, etc. Es decir, permiten almacenar información no numérica. Por ejemplo, usaríamos una variable cualitativa para guardar nombres de colores .

Vocabulario 2.3 — Variable cuantitativa. Variables que permiten almacenar valores numéricos. Por ejemplo, la edad se guardaría en una variable cualitativa.

Vocabulario 2.4 — Limpieza de datos. Es el proceso durante el que se buscan y eliminan, o corrigen, datos erróneos.



3. Análisis visual de la información

De acuerdo con Dondis [**Dondis**, **1973**], durante mucho tiempo, la información se almacenó y transmitió fundamentalmente a través del lenguaje, y la sociedad consideró al artista como el único individuo capaz de comunicarse visualmente. La alfabetidad verbal universal se convirtió en esencial y la inteligencia visual ignorada en gran parte. Sin embargo, durante el siglo pasado, con la "democratización" del uso de la cámara fotográfica y de vídeo y la mejora de las tecnologías de edición digitales, se ha producido un crecimiento espectacular de los canales de comunicación visual, lo cual ha producido un cambio muy importante en la manera de comunicarnos.

Para la correcta comprensión y uso de estos canales visuales, se requiere el desarrollo de la "inteligencia visual", para lo que es necesaria una alfabetización visual que promueva el conocimiento de nuestras capacidades visuales básicas y, a partir de éstas, el desarrollo de un sistema estructural y una metodología para aprender a expresar e interpretar visualmente las ideas. Dicho de otro modo, de manera equivalente a la alfabetización por medio del lenguaje (alfabetización verbal), en la que hemos establecido una serie de normas que nos permiten expresarnos por medio del lenguaje y entender lo que otro ha escrito o dicho, debemos tender hacia una alfabetización visual que permita sustituir la intuición y el azar por reglas y líneas generales para la construcción de composiciones visuales.

En este capítulo nos centraremos en la visualización de datos con el objetivo de contar una historia, lo cual está relacionado no solo con proponer las mejores técnicas para la visualización conjunta de una serie de datos, sino con el proceso, en cierto modo artístico, de buscar una composición impactante y orientada al objetivo.

En primer lugar, una vez vistos los distintos tipos de variables y estructuras de datos que nos encontraremos para la representación de la información en el mundo digital, pensemos cómo representarlas gráficamente, visualmente. En este capítulo analizaremos qué elementos gráficos podemos utilizar, cómo organizarlos para representar información de manera implícita en la estructura y hasta qué punto podemos aumentar la cantidad de información sin saturar la capacidad de percepción humana.

Este análisis tiene tanto connotaciones fisiológicas como psicológicas. Gracias a la neurociencia y la psicología, nuestro conocimiento del funcionamiento del cerebro y de las capacidades y

limitaciones humanas ha aumentado de manera significativa en las últimas décadas. Actualmente, no se discute que la percepción humana es el resultado de la reacción fisiológica a los estímulos sensoriales o, dicho de otro modo, la información no está en los propios estímulos sino en nuestras reacciones fisiológicas a éstos. Aquí realizaremos un análisis funcional de nuestras capacidades y limitaciones perceptivas, sin entrar en su justificación fisiológica.

Si embargo, conocer nuestras capacidades y limitaciones no es suficiente. Al final, lo que deseamos es transmitir un mensaje, una idea, y para ello es necesario convertir los datos en información. Para transmitir una idea de manera efectiva, para que cale y consiga su propósito, no es suficiente con poner una enorme cantidad de datos encima de la mesa y decir "ahí tienen los datos, engáñense por su ojo", sino que es preciso contar una historia que les de sentido y guíe el proceso de interpretación. Contar una historia es todo un arte y requiere tener en cuenta no solo la propia idea que se quiere transmitir, sino también otros elementos como el contexto en el que se transmite, el público al que va dirigida o el impacto que se quiere producir. Además, la historia tiene que ser "bonita" y llamativa para que cale en el observador.

Tómese este capítulo como una guía donde se ponen en contexto distintos conceptos relacionados con el análisis de la información visual y el diseño de visualizaciones de datos efectivas. Para profundizar en cada uno de los temas tratados, se aconseja al lector realizar las actividades que se proponen y seguir las referencias indicadas en el texto.

3.1 Características visuales que facilitan el análisis de la información

Vamos a comenzar por describir los elementos básicos que componen una representación visual. Estos elementos básicos tienen una serie de atributos con los que podremos jugar a la hora de transmitir información y, por tanto, nos permitirá distinguir distintos canales de información visual.

Seguidamente analizaremos la efectividad de estos canales visuales, lo que nos permitirá distinguir cuales percibimos con mayor facilidad y cuales transportan información con mayor precisión, de manera que podamos optimizar nuestro diseño visual para maximizar su efecto. Para ello analizaremos nuestra respuesta a los distintos canales de información visual.

3.1.1 Elementos gráficos y canales de información visual

Analicemos los elementos gráficos que podemos utilizar para representar información visualmente, los cuales son ampliamente conocidos en arte y diseño gráfico [**Kandinski**, **1991**] [**Arheim**, **1980**] [**Malamed**, **2015**] [**Mazza**, **2009**] [**Gonnela**, **2015**].

Los más básicos son el punto, la línea, la superficie y el volumen, y cada uno se forma a partir de los anteriores:

- **Punto**: El punto es una coordenada en el espacio, sin dimensión ni área, que permite focalizar la atención del observador. Es el elemento más básico en sí mismo y, a la vez, el bloque básico de construcción para todo lo demás. El punto puede ser pequeño en tamaño (contener información puntual), pero también puede ser más grande y agrupar información semejante que después se puede expandir haciendo zoom. Si los puntos están muy próximos, se produce una direccionalidad que da lugar a un nuevo elemento, la línea.
- **Línea**: Las líneas se pueden interpretar como series de puntos adyacentes o también como puntos en movimiento. Si los puntos eran focos de atención, las líneas indican movimiento y dirección.
- **Superficie/Forma**: Las Superficies / Formas tienen 2 dimensiones. Son objetos sin profundidad, no tienen masa pero empezamos a ver una masa visual o peso en objetos bidimensionales. Todos los objetos se componen de formas. Para construirlas, el diseñador utiliza líneas, variaciones en intensidad, color y/o textura.
- **Volúmen**: Los Volúmenes tienen 3 dimensiones. En la imagen trabajamos únicamente con

2 dimensiones, por lo que sólo es posible representar la forma. Sin embargo, mediante combinaciones de formas, podemos representar volúmenes.

Estos elementos básicos tienen sus propias características visuales, con las que podemos jugar para llamar la atención sobre aquellos que contienen información relevante, haciéndoles destacar sobre los demás. Estas características visuales son los canales de información visual:

- **Color** - Por el color se transmiten gran cantidad de valores psicológicos y sociales. Además, es una de las propiedades en las que se percibe más rápidamente la variación si se utilizan colores complementarios. En la figura 3.1 se muestra la rueda de colores, donde las parejas de colores complementarios son diametralmente opuestas y los tríos forman un triángulo equilátero.
  Dentro del color se distinguen varias sub-características visuales: el **tono** representa el color que percibimos, la **saturación** indica lo puro que es el tono (inversamente proporcional a su nivel de gris) y la **intensidad** indica el valor de la luminosidad. Existe toda una teoría del color para conseguir el efecto deseado sobre el observador (sobre cómo llamar su atención o influir en su estado de ánimo). Como introducción, consultar [**color-wiki**] [**Cannon**, **2012**] [**Malamed2015**].

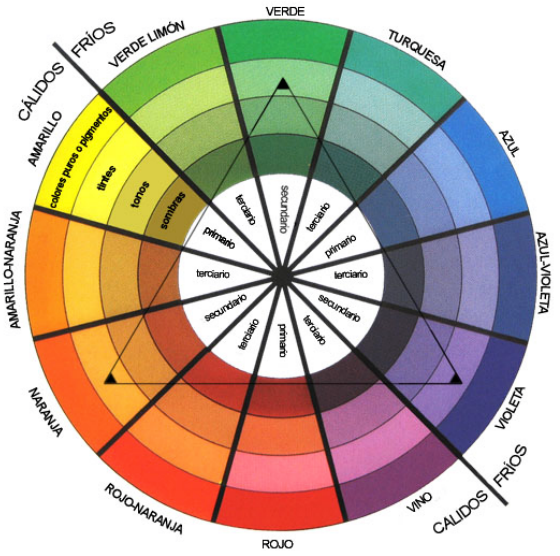


Figura 3.1: Rueda de colores [http://www.ecured.cu/index.php/Archivo:DisGraf7.JPG]

- **Tamaño / Escala**: La escala corresponde al tamaño relativo y la proporción de los diferentes elementos existentes en la imagen. La variación en tamaño de los elementos permite transmitir diferentes mensajes y resaltar (organizar/secuenciar) unos sobre otros.
- **Forma**: los elementos puntuales pueden diferenciarse unos de otros por su forma. La forma puede ser más o menos elemental. Cuanto más simple, más rápida es la percepción de la misma (menor es tiempo de respuesta).
- **Orientación**: Los elementos lineales pueden diferenciarse por su orientación. También en esta propiedad el ser humano detecta rápidamente la variación si ésta es significativa.
- **Textura**: La textura está relacionada con cómo se percibe una cierta superficie al tacto (tacto visual). Cuando dos o más elementos se colocan en un diseño, se crea una estructura entre ellos que percibimos como patrones. A medida que estos patrones empiezan a formar sus propias composiciones se convierten en texturas.

Pero el uso descontrolado de los elementos visuales puede crear una imagen caótica si no existen unas leyes superiores que los organicen. Desgraciada o afortunadamente, no existe un

sistema unificado y definitivo de relaciones mutuas entre los elementos visuales, sino únicamente unos principios que nos ayudan a estructurar la información visual y facilitan la interpretación de la representación globalmente. Estos principios, desarrollados por la Gestalt al inicio del siglo XX, se basan en la idea de que el todo que experimentamos es más que la suma de las partes que lo constituyen y ayudan al agrupamiento de los elementos visuales en entidades de interés. Sin embargo, tienen un carácter primario, pues no son suficientes para explicar de manera unívoca el resultado final. También lo podemos interpretar como que no somos capaces de tratar de manera independiente con un número de objetos relativamente pequeño (pongamos 10?) por lo que tendemos a agrupar los elementos visibles en la escena en un número de grupos relativamente pequeño. Las investigaciones más recientes han ampliado esta lista para cubrir una amplia gama de características de imagen, pero también han enfatizado la importancia del aprendizaje y otros factores que no pertenecen a la propia imagen [**Wagemans**, **2015**]. Los principios más importantes utilizados para realizar esta agrupación son los siguientes [**gestalt-wiki**]:

- **Figura-Fondo**: Cuando percibimos, vamos diferenciando entre aquello que es de interés y que relacionamos con otros elementos, la figura, y el resto, el fondo. El fondo suele rodear a la figura y se le presta muy poca atención (tiende a ser omitido).
- **Buena Continuación/Buena forma/Pregnancia**: el campo perceptual se organizará a lo largo de líneas de flujo ininterrumpido. Tenderemos a organizar los elementos en figuras lo más simples posible (simétricas, regulares y estables).
- **Proximidad**: Los elementos visuales que se encuentran en las proximidades se agrupan fácilmente (proximidad espacial y/o temporal).
- **Similitud**: Los elementos visuales de características similares se pueden observar como un grupo.
- **Destino común**: Los elementos visuales que se mueven con la misma velocidad y dirección tienden a ser agrupados fácilmente.
- **Cierre**: en lo posible, los elementos serán agrupados para que aparezcan como unidades encerradas en sí mismas.
- **Juego de objetivos**: Las agrupaciones de elementos se verán afectados por una secuencia precedente de eventos sensoriales.

Al no existir una teoría clara, es muy habitual ver mezclados en los libros de diseño gráfico todos estos conceptos como elementos y principios básicos de diseño.

Actividad 3.1 Busque en [**Gonnela**, **2015**] ejemplos de uso de los elementos visuales y principios de composición. ■

Actividad 3.2 El color es un factor capaz de condicionar el comportamiento humano. Busque en la bibliografía e internet y construya una tabla con potenciales influencias psicológicas asociadas al color. Relacione color (o grupo de colores) y efecto para distintos grupos poblacionales. Comience por estas fuentes: [**Malamed**, **2015**]-capítulo 7, [**Gonnela**, **2015**]-capítulo 5. ■

Actividad 3.3 Lea estos dos artículos sobre los principios de la gestalt aplicados a la visualización de datos:
Gestalt, parte 1: `https://www.nature.com/articles/nmeth1110-863` Gestalt, parte 2: `https://www.nature.com/articles/nmeth1210-941` ■

3.1.2 Efectividad de los canales de información visual

Como ya hemos comentado, la interpretación visual de la información se basa en las capacidades humanas para analizar los estímulos percibidos a través de la vista. Los humanos somos buenos a

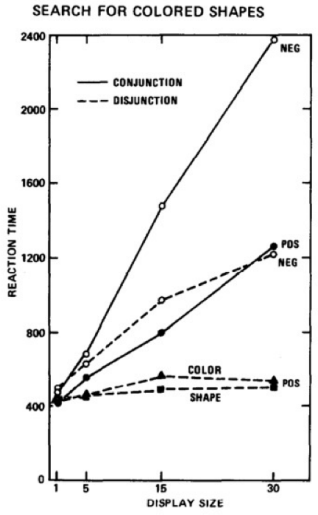


FIG. 1. Search times in Experiment I.

Linear Regressions of Reaction Times on Display Size in Experiment I

		Slope	Intercept	Percentage variance with display size which is due to linearity
Conjunction	Positives	28.7	398	99.7
	Negatives	67.1	397	99.6
Feature mean	Positives	3.1	448	67.9[a]
	Negatives	25.1	514	96.6
Feature color	Positive	3.8	455	61.0[a]
Feature shape	Positive	2.5	441	78.5

Figura 3.2: Comparativa de velocidades de procesado de los canales de información visual color y forma (tomada de [**Treisman**, **1980**]).

la hora de detectar cambios o irregularidades en los estímulos (contrastes), por lo que, a la hora de representar información, podemos aprovechar esta facilidad para codificar los datos de manera que aquellos que poseen información relevante presenten un cambio en el estímulo mientras que el resto (datos no relevantes) puedan pasar desapercibidos (como si pertenecieran al fondo de la imagen). Valoraremos principalmente dos parámetros a la hora de representar la información: la precisión de la representación y la velocidad de proceso.

Por un lado, interesa saber qué características de los elementos visuales son más precisas, es decir, en qué características el ser humano detecta con mayor precisión pequeños cambios. Existirán aplicaciones en las que una representación aproximada será suficiente para permitir al observador realizar una interpretación cualitativa de la visualización, mientras que en otras desearemos mayor precisión porque la diferencia cuantitativa sea importante para el análisis.

Por otro, la velocidad de proceso es importante para captar la atención del observador y también para el desarrollo de interfaces en los que se desea una alta velocidad de respuesta. Treisman y Gelade presentaron en 1980 su teoría de la atención basada en integración de características [**Treisman**, **1980**]. Según esta teoría, existen dos niveles de procesamiento neuronal, un nivel pre-atencional, donde distintos canales analizan de manera independiente la información procedente de distintas características (color, orientación, frecuencia espacial, movimiento, etc.) y otro nivel atencional, donde se combinan todos estos canales y se produce una respuesta coordinada. El primer nivel actúa de manera independiente y en paralelo, por lo que su procesamiento es muy rápido. En cambio, el segundo nivel requiere un procesamiento secuencial, en el que se combinan las características procedentes de cada canal objeto a objeto, por tanto, más lento. Esto justifica que las propiedades simples de los objetos se capturen fácil y rápidamente, mientras que otras más complejas o combinación de las más simples requieran un mayor procesado (figuras 3.2 y 3.3).

Como toda teoría, ésta no explica el modo en que se fija la atención en todos los casos. Otras teorías, por ejemplo, hipotetizan que los estímulos compiten por los recursos neuronales y que, por tanto, si se presentan más estímulos, éstos se representarán más débilmente en el cerebro porque hay que repartir los recursos (más detalles en [**Torralbo**, **2008**]).

En cualquier caso, el resultado experimental es que sobrecargar de información al sistema visual repercute en el tiempo de respuesta y en su capacidad de apreciar de manera no consciente aquellos detalles que contienen información, que diferencian el objeto de interés del fondo. Por

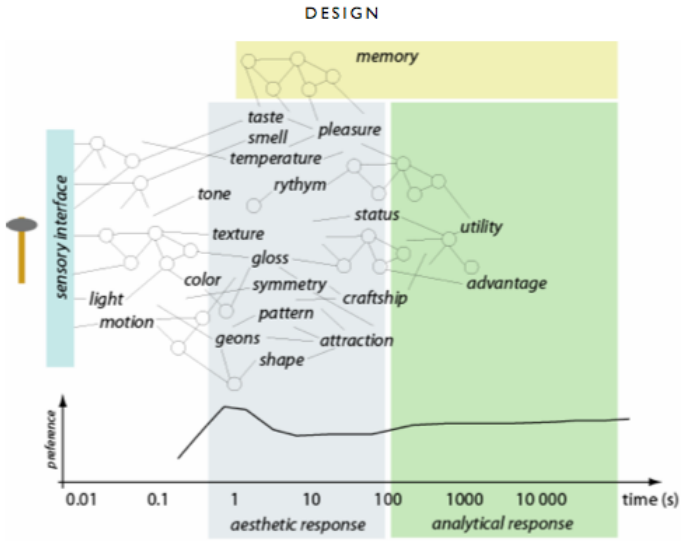


Exhibit RESPONSE. Schematic illustration of human cognitive response to an artifact.

Figura 3.3: Tiempo de respuesta humana a un evento visual (tomada de [**Ulrich**, **2006**]).

tanto, para la representación visual de la información se debe aprovechar la capacidad humana de procesamiento de características básicas y no sobrecargar al sistema para que el resultado sea óptimo. En [**Healey**, **2012**] se realiza un estudio detallado de la atención y la percepción visual centrado en el análisis visual de información.

> Actividad 3.4 Lea [**Healey**, **2012**] centrándose en la atención visual (Secciones 1 a 3). Analice el tiempo que tarda en detectar el elemento diference, el que contrasta, en cada una de las características visuales ejemplificadas en la Fig. 2 de dicho artículo. ■

En cuanto a la precisión de la representación, en la figura 3.4 se ordenan los distintos canales o características visuales. El color y la textura son características menos precisas (los humanos no detectamos fácilmente pequeñas variaciones en el color o la textura), mientras que la orientación, la longitud o la posición relativa son características muy precisas. De la figura se desprende también que velocidad y precisión son características contrapuestas, pues un incremento en una conlleva un decremento en la otra y viceversa. Por tanto, ante un problema de representación visual concreto, deberemos seleccionar aquella característica o conjunto de características que optimice conjuntamente ambas variables de acuerdo con los requisitos de la tarea objetivo.

3.2 Elección de la representación más adecuada. Visual mapping

Una vez que hemos identificado las propiedades de los elementos visuales que podemos utilizar para representar la información (color, forma, posición, tamaño, área, longitud, dirección,... del objeto o combinaciones de los anteriores), así como las limitaciones de las capacidades perceptuales humanas. Ahora nos centraremos en qué factores influyen a la hora de seleccionar la representación más adecuada.

La elección de la representación más adecuada para una determinada tarea, obviamente, es función tanto de los datos de entrada como del objetivo de la representación. Por tanto, nos deberemos fijar en los siguientes aspectos de nuestro proyecto de visualización:

1. **Percepción-Acción**: Lo primero que tenemos que decidir es si deseamos que la representación sea solo "perceptible" (con el objetivo de comunicar) o que se pueda interactuar con ella

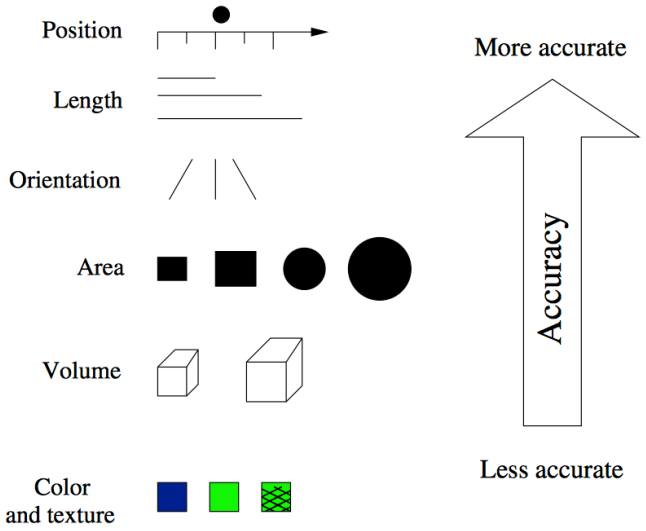


Fig. 2.4 Accuracy in the perception of quantitative values for some graphical and spatial elements.

Figura 3.4: Precisión en la percepción de distintas características visuales de los elementos gráficos (Tomada de [**Mazza**, **2009**])

(con el objetivo de seleccionar, explorar, organizar, filtrar, ampliar, ...). En el primer caso, tendremos más flexibilidad, menos restricciones, pues lo que se muestra es lo que hay en un instante dado, no hace falta guardar más información. En cambio, si el usuario debe poder interaccionar con la representación, se abren muchas más posibilidades pero, a la vez, se complica la organización de la información necesaria para que esta interacción sea fluida, sencilla, intuitiva y amigable.

2. **Número de variables y sus dimensiones**: A continuación, deberemos valorar cuántas variables queremos representar de manera simultánea. Por ejemplo, sin entrar a distinguir el tipo de variables (cualitativas o cuantitativas), espacialmente podemos representar hasta 3 dimensiones (3D); si le añadimos el tiempo, podremos representar una dimensión más (4D); y luego podremos jugar con los elementos visuales (forma, color, textura, dirección, ... de los objetos) para representar distintas dimensiones. Cuantas más variables queramos representar, más se sobrecargará el gráfico y más difícil será de interpretar, así que lo más práctico es limitar la visualización a lo que es relevante para la tarea objetivo.
3. **Número de instancias**: Deberemos valorar también cuántas instancias (casos) tenemos que representar. Si son pocos, se pueden representar todos individualmente, pero si son muchos, tendremos que recurrir a algún mecanismo de reducción para no sobrecargar el gráfico. Si se sobrecarga el gráfico, puede, por un lado, haber problemas para visualizarlo convenientemente porque se superpongan los elementos y se cree una amalgama ininteligible, y por otro, aumentar en exceso el tiempo de renderizado (tiempo de generación del gráfico), lo que no es conveniente sobre todo en visualizaciones dinámicas interactivas. En la era del big data, este tipo de problemas se dan cada vez con más frecuencia.
   Como mecanismos de reducción, podremos recurrir a 1) una organización jerárquica que muestre únicamente las clases más abstractas que agrupan la información final, 2) tomar una muestra representativa de todos los datos, o 3) calcular una serie de parámetros estadísticos que describan al conjunto de datos y permitan representar el conjunto de instancias mediante variables o atributos de un único objeto.
4. **Tipo de variables**: La tabla 3.1 muestra las características de los elementos visuales que pueden ser utilizadas para representar los tipos básicos de variables: cualitativas (categóricas y

ordinales) y cuantitativas. En este punto, hay que tener en cuenta que podremos, con todas las precauciones del mundo, transformar un tipo de variable en otro y utilizar las características de éstas para representarlas. "Todas las precauciones del mundo" quedarán implícitas en la definición del espacio de representación (ver el concepto de espacio de representación a continuación).

5. **Relaciones entre instancias**: Por último, deberemos analizar qué relaciones entre distintas instancias queremos mostrar. Estas relaciones son a su vez nuevas variables (una relación puede venir indicada por su tipo (clase), por una variable binaria (existe o no existe tal relación) o por una relación de orden cualitativa o cuantitativa (grado de la relación = poca, normal, mucha ó valor numérico de la relación = “5”).

Selección del espacio de representación: Del análisis de los puntos anteriores se establecen las características del espacio de representación, lo que nos define una gramática para la representación en la que se establecen una serie de reglas o restricciones consensuadas que nos permiten representar información adicional de manera implícita. Si no conocemos el funcionamiento del espacio de representación, no seremos capaces de interpretar toda la información representada.

Esto se verá más claro con un sencillo ejemplo: supongamos que el espacio de representación es un mapa a escala sin distorsiones, entonces, la distancia entre dos puntos del mapa representa la distancia entre esos dos puntos en la realidad. Esa distancia no aparece ("pintada") en el mapa de ninguna manera, por lo que únicamente si asumimos que el mapa está a escala podremos interpretar que la separación entre esos dos puntos es significativa y calcular su distancia. Obsérvese, como ejemplo, la evolución de la representación del mapa de la red metro de la ciudad de Madrid a lo largo de los años (figuras 3.5, 3.6 y 3.7). En el mapa de la figura 3.5, y de manera aproximada en el de la figura 3.6, se podía calcular la distancia entre estaciones por superficie, de manera que a veces, para llegar a un punto objetivo, resultaba más cómodo y rápido salir en una estación cercana y andar un poco que cambiar de línea para llegar a la estación más cercana. Ahora, con la nueva representación, no tenemos esta información, por lo que nos arriesgaríamos a tener que andar un largo trecho -afortunadamente, ahora esta información la tenemos por otros medios-. Por tanto, inicialmente la representación (cartográfica) correspondía aproximadamente con la posición espacial de las estaciones, mientras que en la actual (esquemática), al tener que incluir más estaciones por el crecimiento de la red de metro, se ha perdido dicha relación espacial. Ahora, la única relación espacial es topológica, "conexión entre estaciones de la misma línea", y está marcada explícitamente por las líneas de colores. Se ha perdido completamente la representación espacial de la posición y de la distancia.

Existen espacios de representación ya consensuados, como los sistemas de ejes de coordenadas (lineales o no lineales) de los espacios 1D, 2D ó 3D, un mapa de carreteras, un mapa topográfico, un diagrama de barras, una diagrama de tarta, etc., pero continuamente se están inventando nuevos espacios de representación para favorecer la visualización de cierto tipo de información, aunque normalmente en detrimento de otro, como vimos en el caso del mapa del metro de Madrid.

Las instancias se suelen representar como objetos (puntos o formas más complejas) en el espacio y sus características visuales o su posición relativa nos describirán sus propiedades y nos permitirán diferenciarlas unas de otras. Dependiendo del objetivo de la visualización, del compromiso entre capacidad de procesamiento y precisión de la representación, deberemos seleccionar qué características de los elementos visuales vamos a utilizar para representar visualmente la información. La figura 3.8 muestra un modelo para la selección de los componentes a la hora de construir la representación visual más adecuada.

Actividad 3.5 Lea el artículo [**Rodrigues**, **2006**] e interprete la tabla 1. ■

Attribute	Quantitative	Ordinal	Categorical
Color			
Hue	×	×	✓
Intensity	–	✓	×
Form			
Orientation	–	–	×
Length	✓	–	×
Width	–	–	×
Size	–	–	×
Collinearity	×	×	×
Curvature	–	–	×
Spatial grouping	×	×	×
Added marks	×	×	✓
Shape	×	×	✓
Numerosity	✓	✓	×
Spatial position			
2D position	✓	✓	–
Stereoscopic depth	×	×	×
Concavity/convexity	–	–	×
Movement			
Flicker	×	×	–
Motion	–	–	×

Table 3.2 Encoding quantitative, ordinal, and categorical data with different preattentive attributes.
✓ indicates that the attribute is suitable for the data type. – indicates a limited suitability.
× indicates that the attribute does not work well with that data type.

Cuadro 3.1: Representación visual de distintos tipos de variables (tomada de [**Mazza**, **2009**]).



Figura 3.5: Plano cartográfico de la red de metro de Madrid (tomada de http://www.espormadrid.es/2010/07/la-historia-de-la-red-de-metro-de.html)



Figura 3.6: Plano esquemático de la red de metro de Madrid: manteniendo significado cierta información espacial (tomada de http://www.espormadrid.es/2010/07/la-historia-de-la-red-de-metro-de.html)



Figura 3.7: Plano esquemático de la red de metro de Madrid en 2009: sin significado espacial para poder incluir un mayor número de estaciones en menos espacio (tomada de http://www.espormadrid.es/2010/07/la-historia-de-la-red-de-metro-de.html)

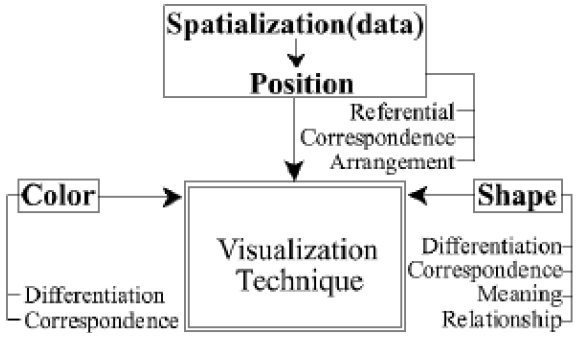


Figura 3.8: Componentes de cualquier técnica de visualización. (Tomada de [**Rodrigues**, **2006**])

3.3 Del análisis visual a la comunicación visual. Storytelling

El objetivo final de la comunicación visual es transmitir un mensaje a través de la visualización. Para ello, en la mayoría de los casos, un solo gráfico no es suficiente para representar toda la información asociada al mensaje. Para interpretar los resultados de un proyecto, explicar cómo se va a realizar una tarea, contar una historia, etc.. es necesario crear una estructura superior que permita organizar múltiples gráficos (múltiples imágenes, vídeo, etc).

El objetivo final de la comunicación visual es guiar al espectador por la imagen para que se fije en aquello que queremos resaltar y pase de largo por lo prescindible, bien porque no nos interesa, bien porque pueda despistarlo. Lo contrario es una comunicación visual plana, en la que se muestra la información y se le dice al espectador algo así como "engáñese por su ojo". Algún espectador avispado entenderá el mensaje que se desea transmitir, pero es muy probable que otros realicen interpretaciones distintas a la deseada.

Por ello, además de los principios que nos permiten analizar un elemento concreto, también es clave comprender los principios que rigen la organización de la **composición** (dibujo, interfaz, entorno, etc.). Estos principios, que son ampliamente estudiados en diseño gráfico con el objetivo de conseguir presentaciones orientadas a un objetivo (llamativas, elegantes, chocantes pero no hirientes, organizadas, estables, etc.), se resumen a continuación (para un análisis más detallado, consultar [**Dondis**, **1973**][**Malamed**, **2015**]):

- **Unidad**: Todos los elementos en una vista deben estar relacionados (unidos) visualmente y conceptualmente. El diseño visual es un balance entre unidad (para no ser estridente y caótico) y variedad (para no ser aburrido).
- **Gestalt**: respetar los principios de la Gestalt para ver el diseño como un todo, no como un colaje de elementos inconexos.
- **Espacio**: la organización del espacio es importante para mejorar la legibilidad.
- **Jerarquía**: la organización jerárquica permite estructurar ítems de distinto nivel dentro del mismo esquema. Los marcos, los colores, el tamaño de los textos o su posición son recursos que se utilizan normalmente para este fin.
- **Balance**: La composición dentro del cuadro debe estar compensada. Existen distintos criterios para balancear la distribución de la información en el diseño, el más simple es la simetría o equilibrio axial, pero hay otras maneras de conseguir el equilibrio. También es interesante conocer que hay zonas más estables (la base) o que son más importantes (regla de los tercios y puntos fuertes, preferencia por el ángulo inferior izquierdo, diferencia de peso arriba-abajo e izquierda-derecha, etc.).
- **Contraste**: el contraste es una variación significativa en alguna cualidad visual que hace destacar unos elementos sobre otros. El contraste se puede obtener por diferencias en color, tamaño, dirección, etc. Lo contrario del contraste es la armonía.

- **Escala**: la escala se debe mantener homogénea entre los distintos ítems a no ser que se desee llamar la atención sobre algún ítem concreto.
- **Dominancia**: permite focalizar la atención en un elemento. La dominancia se obtiene por contraste o por escala.
- **Similaridad**: permite crear continuidad por repetitividad de la estructura del escenario pero presentando información distinta.

En las siguientes actividades se profundiza en estos puntos.

Actividad 3.6 Lea este documento dedicado al anális de los principios de la composición visual. Martín Arrillaga, J.(2008). Fundamentos de la composición visual. Recuperado de `https://comp osicionarqdatos.files.wordpress.com/2008/09/fundamentos-de-la-composicion-visual_javier-martin-arrillaga.pdf` ■

Actividad 3.7 Analice distintas maneras de organizar el espacio en una infografía ([**Malamed**, **2015**]-capítulo 4: Organizing Graphic Space). ■

Actividad 3.8 Analice distintas maneras de guiar al lector por una infografía (Principle 2: Direct the eyes, Visual Language for Designers. Connie Malamed. Rockport Publishers. 2009. `https://learning.oreilly.com/library/view/visual-language-for/9781592535156/`) `https://learning.oreilly.com/library/view/visual-language-for/9781592535156/xhtml/ch02.html`) ■

Pero no solamente hay que prestar atención al formato de la presentación, también al contenido. Stikeleather lo describe muy bien en su artículo "How to Tell a Story with Data" [**Stikeleather**, **2013**]. En la bibliografía este tema se denomina "story telling" [**Nussbaumer**, **2015**] [**Krum**, **2013**] [**Lazauskas**, **2018**]

- **Encuentra una narrativa convincente y apasionante**: además de contar los hechos, no seas aburrido. Si no tienes una historia que contar, al menos es posible que la visualización permita una exploración visual de los datos.
- **Piensa en quién es tu audiencia**: la visualización debe orientarse hacia el nivel de información que la audiencia maneja. Audiencias posibles: novato, generalista, manager, experto, ejecutivo.
- **Sé objetivo**: incluso cuando se pretende influir, uno debe basarse en los datos. Tufte denomina "Lie Factor" al valor que describe la relación entre el efecto mostrado en un gráfico y el efecto que los datos tienen en sí mismos; (en internet encontraréis un montón de referencias de "cómo mentir con ..." o en inglés "How to lie with ..."). Hay maneras simples de mostrar objetividad, como etiquetar correctamente los datos y los ejes para evitar ambigüedad, utilizar unidades estándar, visualizar los datos desde distintas perspectivas (varios gráficos) para evitar malentendidos, etc. Es importante que la presentación sea consistente, pues si ésta se pierde y es detectada, se perderá la confianza y la credibilidad, sin importar lo bien que se cuente la historia.
- **No censures los datos**: no elimines los datos que no cuadran con la historia. Si se detecta, también se perderá la confianza. Es mejor dejarlos y tener una explicación para ello.
- **Y, finalmente, edita, edita, edita**: trata de explicar los datos, no de decorarlos. No caigas en la trampa del "suena bien", "es bonito", si pierdes más tiempo en editar y mejorar la visualización que en crearla, es que estás haciéndolo bien.

Actividad 3.9 El siguiente video es un ejemplo paradigmático de cómo contar una historia con datos de manera que cale en el expectador (¡¡¡tiene más de 14M de reproducciones!!!). Visualícelo y analícelo desde el punto de vista de la comunicación visual.
`https://www.ted.com/talks/hans_rosling_the_best_stats_you_ve_ever_seen`
■

Actividad 3.10 Realice una tabla resumen con los errores más comunes a la hora de crear una infografía. Consulte los siguientes enlaces:
`https://www.codeconquest.com/blog/12-bad-data-visualization-examples-explained/`
`https://visme.co/blog/bad-infographics/`
`https://www.dummies.com/programming/big-data/big-data-visualization/data-visualization-examples-of-the-good-and-the-bad/` ■

3.4 Ejercicios

Ejercicio 3.1 Defina los conceptos de "elemento visual", "propiedad de elemento visual" y "canal de información". ■

Ejercicio 3.2 Establezca un sistema de niveles de descripción de una representación visual y distribuya los siguientes términos: unidad, contraste, escala, textura, orientación, color, intensidad, forma, jerarquía, variedad, punto, historia, punto de vista, simetría, cierre, proximidad, semejanza, pregnancia, línea. ■

Ejercicio 3.3 Reflexione sobre el contenido del siguiente artículo: Nick Chater, 2018. "You See Less Than You Think" The Wall Street Journal. https://www.wsj.com/articles/you-see-less-than-you-think-1533914846 ■

Ejercicio 3.4 Busque en alguna de las referencias indicadas, o en internet directamente, figuras que describan los principios de la gestalt enunciados en el apartado 3.1.1. ■

Ejercicio 3.5 Indique las características visuales más apropiadas para representar visualmente la velocidad instantánea de un coche con dos niveles de precisión distintos: a) en km/h; b) dentro de una de las clases baja, normal, elevada. ■

Ejercicio 3.6 Siendo términos contradictorios, ¿por qué es importante que una representación visual tenga unidad y variedad? ■

Ejercicio 3.7 Existen distintas formas de conseguir el equilibrio (balance) en una composición. Ponga ejemplos de equilibrio simétrico, asimétrico y axial. Los diseños de equilibrio axial son fáciles de realizar y de entender, pues en ellos se emplea la formulación menos complicada del contrapeso. ¿Cuándo cree que deben utilizarse este tipo de diseños y cuándo no? ■

Ejercicio 3.8 Cuando hacemos una fotografía, lo hacemos con criterios artísticos, teniendo en

cuenta los principios de una buena composición. Compruébelo: tome una fotografía y analice los criterios que ha utilizado. ■

Ejercicio 3.9 En un gráfico en el que ya se marcan los puntos asociados a los valores de cada variable con distintos colores, ¿qué interés puede tener unir además estos puntos con una línea? Responda a la pregunta y muéstrelo con ejemplos visuales. ■

Ejercicio 3.10 Comente las dos imágenes de la figura 3.9, las cuales fueron diseñadas con el mismo objetivo. ■



Figura 3.9: Ways to improve health. (fig. 9.2 de [**Malamed**, **2015**])

Ejercicio 3.11 La aplicación gapminder tiene cargados gran candidad de datos socio-económicos de todos los paises del mundo. Utilice la aplicación para comparar la evolución de la esperanza de vida en España con respecto a otros paises (uno de nuestro entorno, uno más rico y otro más pobre).

Descargar la aplicación Gapminder: `https://www.gapminder.org/tools-offline/` ■

Ejercicio 3.12 ¿Es posible "mentir" con gráficos?

1. Lea las siguientes referencias:
   `http://evalblog.com/tag/how-to-lie-with-statistics/`
   `http://www.datavis.ca/gallery/`
2. Comente los gráficos o parejas de gráficos mostrados en las figuras 3.10 a 3.14.

■

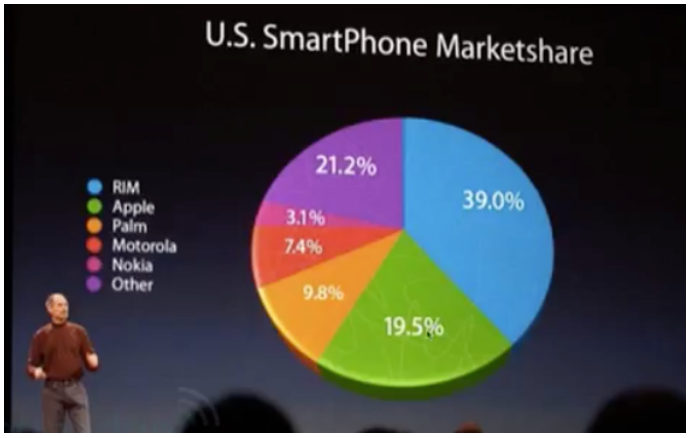


Figura 3.10: Gráfico 1

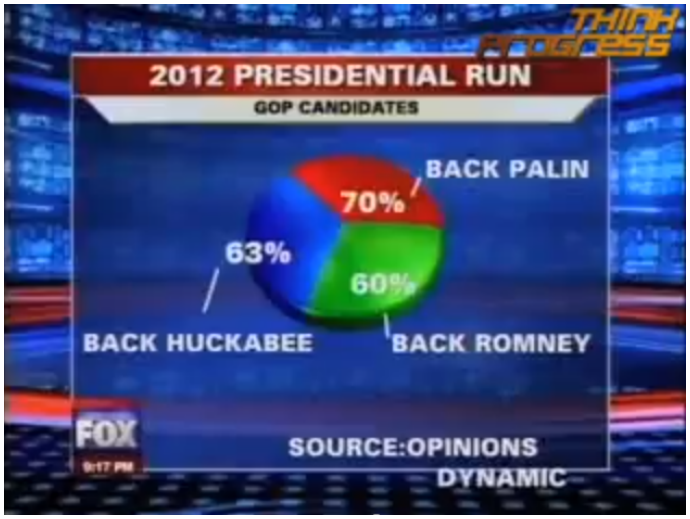


Figura 3.11: Gráfico 2

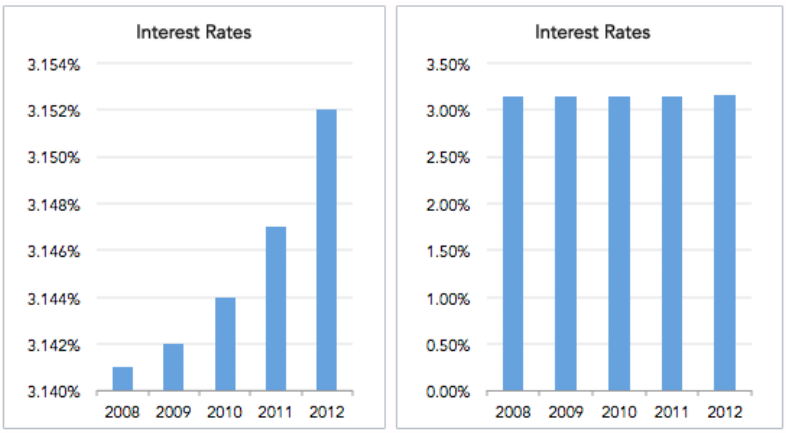


Figura 3.12: Gráfico 3

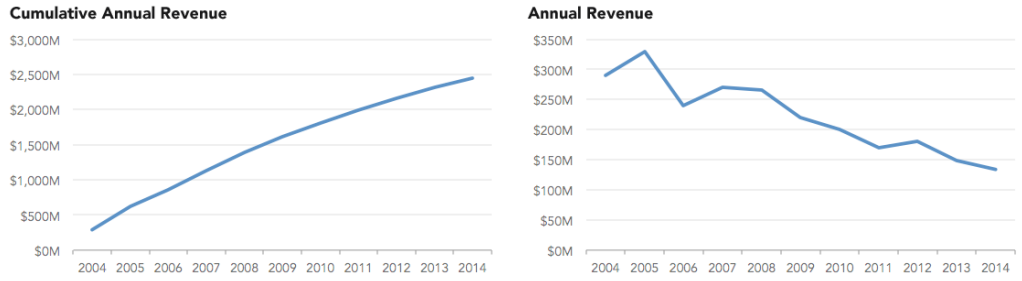


Figura 3.13: Gráfico 4

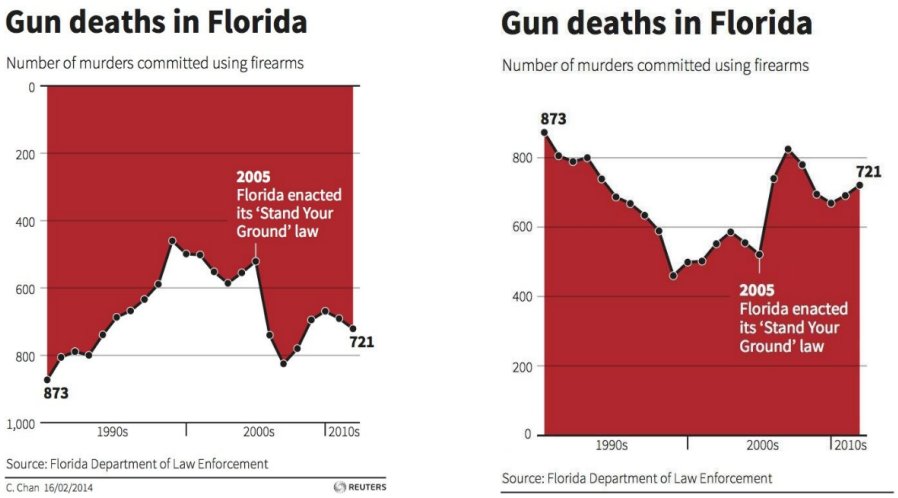


Figura 3.14: Gráfico 5

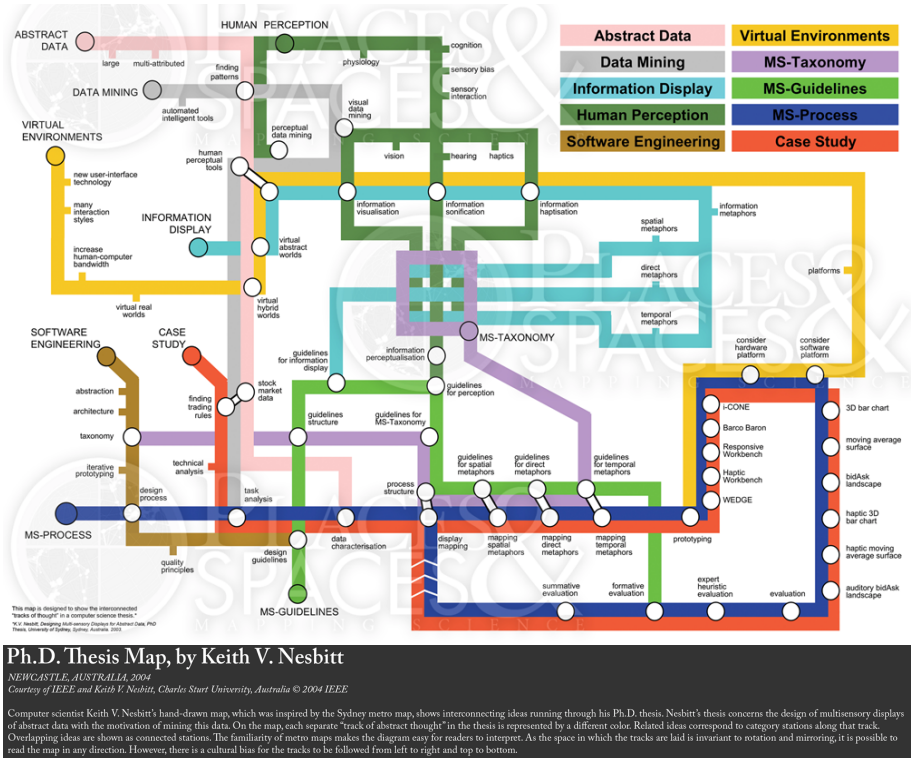
Ejercicio 3.13 Comente el gráfico de la figura 3.15 en función de los siguientes términos:

- Variables representadas, indicando sus tipos
- Elementos gráficos
- Características visuales
- Principios organizativos. Describa la estructura de acuerdo con los principios organizativos de la gestalt
- Objetivo de la presentación
- Comente otros aspectos que considere relevantes

■

Ejercicio 3.14 Analice una noticia de actualidad presentada en un medio de comunicación (un periódico, por ejemplo) en la que se intente justificar, por medio de un análisis visual de los datos, una postura que no se ajuste a los datos del estudio. ■

Ejercicio 3.15 El siguiente enlace, `http://www.usability.gov/what-and-why/visual-design.html`, se análiza el uso de los principios de diseño en una página web. Navegue por la red y elija dos páginas web, una que considere bien diseñada y otra que no, y coméntelas. ■



Ph.D. Thesis Map, by Keith V. Nesbitt

NEWCASTLE, AUSTRALIA, 2004

Courtesy of IEEE and Keith V. Nesbitt, Charles Sturt University, Australia © 2004 IEEE

Computer scientist Keith V. Nesbitt's hand-drawn map, which was inspired by the Sydney metro map, shows interconnecting ideas running through his Ph.D. thesis. Nesbitt's thesis concerns the design of multisensory displays of abstract data with the motivation of mining this data. On the map, each separate "track of abstract thought" in the thesis is represented by a different color. Related ideas correspond to category stations along that track. Overlapping ideas are shown as connected stations. The familiarity of metro maps makes the diagram easy for readers to interpret. As the space in which the tracks are laid is invariant to rotation and mirroring, it is possible to read the map in any direction. However, there is a cultural bias for the tracks to be followed from left to right and top to bottom.

Figura 3.15: Interconnecting ideas (inicialmente obtenido de `http://www.scimaps.org/maps/map/phd_thesis_map_94/detail` Actualmente: Getting to more Abstract Places using the Metro Map Metaphor. 2004. DOI: 10.1109/IV.2004.1320189. `https://www.researchgate.net/publication/221360882_Getting_to_more_Abstract_Places_using_the_Metro_Map_Metaphor`
)

Ejercicio 3.16 Realizar una representación gráfica que describa de manera sencilla y esquemática los temas abordados en el presente capítulo y las relaciones entre ellos. Indicando de alguna manera su importancia en el contexto de la visualización de datos con el objetivo de contar una historia. ■



Bibliografía

[1] Arnheim R. (1980). *Arte y percepción visual*. Alianza Forma, Madrid, 1980.

[2] Dondis, D.A. (1973). *A primer of Visual Literacy*. The Massachussets Institute of Technology, 1973.

[3] Kandinsky W. (1991). *Punto y línea sobre el plano: contribución al análisis de los elementos pictóricos*. Barcelona:Labor

[4] Wikipedia. *Teoría del Color*. http://es.wikipedia.org/wiki/Teor%C3%ADa_del_color

[5] Cannon T. (2012). *An Introduction to Color Theory for Web Designers* http://webdesign.tutsplus.com/articles/an-introduction-to-color-theory-for-web-designers--webdesign-1437

[6] *Psicología de la Gestalt*. Wikipedia. https://es.wikipedia.org/wiki/Psicolog

[7] Gonnella R., Navetta C., & Friedman M. (2015). *Design Fundamentals: Notes on Visual Elements and Principles of Composition*. Peachpit Press, USA.ISBN:9780133930290 https://learning.oreilly.com/library/view/design-fundamentals-notes/9780133930290/

[8] Christopher G. Healey, & James. T. (2012). *Attention and Visual Memory in Visualization and Computer Graphics*. IEEE trans. on Visualization and Computer Grphics, No.07-July (2012 vol.18) 1170-1188.

[9] Kandinsky W. (1991). *Punto y línea sobre el plano: contribución al análisis de los elementos pictóricos*. Barcelona:Labor.

[10] Krum R. (2013). *Cool Infographics: Effective Communication with Data Visualization and Design*. Wiley. ISBN: 9781118582305. https://learning.oreilly.com/library/view/cool-infographics-effective/9781118582305/

[11] Lazauskas J. and Snow S. (2018). *The Storytelling Edge*. Wiley. ISBN:9781119483359. https://learning.oreilly.com/library/view/the-storytelling-edge/9781119483359/

[12] Malamed C. (2015). *Visual Design Solutions: Principles and Creative Inspiration for Learning Professionals*. Wiley. ISBN: 9781118863565 https://learning.oreilly.com/library/view/visual-design-solutions/9781118864043/

[13] Mazza R. (2009). *Introduction to Information Visualization*. Springer. 2009.

[14] Nussbaumer C. (2015). *Storytelling with Data: A Data Visualization Guide for Business Professionals*. Wiley. ISBN: 9781119002253 https://learning.oreilly.com/library/view/storytelling-with-data/9781119002253/

[15] Puhalla D. (2011). *Design Elements, Form & Space: A Graphic Style Manual for Understanding Structure and Design*. Rockport Publishers. ISBN 1592537006, 9781592537006.

[16] Rodrigues J.F. et al. (2006). *Reviewing data visualization: an analytical taxonomical study*. In IEEE 10th International Conference on Information Visualization, pages 713–720. 2006. http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.386.8571&rep=rep1&type=pdf

[17] Stikeleather J. (2013). *How to Tell a Story with Data*. https://hbr.org/2013/04/how-to-tell-a-story-with-data/

[18] Treisman A.M. & Gelade G. (1980). *A Feature-Integration Theory of attention*. COGNITIVE PSYCHOLOGY 12, 97-136. http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.296.3400&rep=rep1&type=pdf http://www.cs.utah.edu/~miriah/uncertainty/FeatureIntegrationTheoryOfAttention.pdf

[19] Torralbo A. (2008). *Más no siempre es mejor: procesamiento de estímulos visuales y límites de capacidad*. Ciencia Cognitiva: Revista Electrónica de Divulgación, 2:2, 59-61. http://www.cienciacognitiva.org/files/2008-10.pdf ó http://medina-psicologia.ugr.es/~cienciacognitiva/files/2008-10.pdf

[20] Ulrich K.T. (2006). *Design: Creation of Artifacts in Society*. Pontifica Press. http://opim.wharton.upenn.edu/~ulrich/documents/ulrich-aesthetics.pdf

[21] Wagemans J. & Brooks J. (2015). *Traditional and new principles of perceptual grouping*. In The Oxford Handbook of Perceptual Organization. : Oxford University Press. Retrieved 24 Jan. 2020, from https://www.oxfordhandbooks.com/view/10.1093/oxfordhb/9780199686858.001.0001/oxfordhb-9780199686858-e-060.

[22] Ware C.(2012). *Information Visualization. Perception for Design*. Morgan Kaufmann. eBook ISBN:9780123814654. https://learning.oreilly.com/library/view/information-visualization-3rd/9780123814647/

Material adicional

Otras referencias de interés, tanto en español como en inglés:

- Elementos visuales y principios de diseño:
  http://www.merca20.com/24-elementos-del-diseno-grafico-explicados-en-40-segundos/
  https://inkscape.org/en/doc/tutorials/elements/tutorial-elements.es.html
  https://learning.oreilly.com/library/view/the-non-designers-design/9780133966350
  https://learning.oreilly.com/library/view/visual-language-for/9781592535156/
  https://www.slideshare.net/rociomaribel/3-elementos-del-diseo-34364705
  http://www.slideshare.net/mbelprieto/1-el-diseo-y-sus-elementos-14677343
  http://www.ecured.cu/index.php/Elementos_bÃąsicos_del_DiseÃśo_GrÃąfico
  http://www.slideshare.net/percynegrete/leyes-de-la-gestalt-12293125
  http://mooldesign.blogspot.com.es/2010/10/principios-de-organizacion-de-la.html
  http://www.guillermoleone.com.ar/leyes.htm
  http://www.biblioteca.uma.es/bbldoc/tesisuma/16279074.pdf
  https://prezi.com/9kpt5lkhpyho/leyes-de-la-gestalt-aplicadas-al-diseno-de-interaccion-e-interfaces/



4. Técnicas de representación visual

En el capítulo anterior se llevó a cabo el análisis visual de la información, estudiando las principales características visuales, la elección de la representación más adecuada y aspectos relacionados con la comunicación visual. En este tema ahondaremos en las técnicas de representación visual más relevantes, tanto estáticas como dinámicas, en base a los objetivos deseados. También se aprenderá a obtener interpretaciones y conclusiones válidas sobre los datos de estudio dependiendo del objetivo de la visualización a construir.

4.1 Elementos formales

Una representación visual debe mostrar aquello que deseamos destacar de la manera más intuitiva posible, es decir, el objetivo de la visualización en cuestión. Las preguntas claves que debemos formularnos son las siguientes:

- ¿ Qué elementos deseo mostrar dependiendo del objetivo de la visualización?
- ¿ Cómo deseo mostrar el objetivo en la visualización a construir?
- ¿ Cual es el tipo de audiencia objetivo de la visualización?

Por otra parte, a la hora de realizar una presentación mediante gráficos formales, deberían seguirse unas pautas que partan de las preguntas anteriormente mencionados. En el sitio web `https://presentastico.com/2011/09/26/7-consejos-para-usar-estadisticas-en-tus-presentaciones/` se proporcionan un conjunto de consejos.

En capítulos anteriores ya se han introducido algunos de esas preguntas, pero ahora es necesario formalizar que tipo de gráficos y técnicas tenemos a nuestra disposición, una vez tenemos claras las preguntas anteriores.

4.1.1 El objetivo de una representación visual

En este apartado analizaremos cuál es el objetivo de la representación y llegaremos a las visualizaciones más adecuadas para alcanzarlo. Como se verá, algunas visualizaciones pueden servir a varios objetivos, lo importante es que el diseñador sea consciente del objetivo que persigue y de que la visualización elegida se corresponde con éste objetivo.

En primer lugar, podemos desear representar los atributos de instancias concretas, o casos. El objetivo es simplemente la descripción de la instancia, representando los valores de los atributos/variables que la describen. Si son pocas variables, se pueden utilizar los gráficos habituales de ejes de coordenadas, donde cada eje representa un atributo y la posición espacial del punto describe la instancia concreta. Podemos añadir más atributos jugando con los atributos visuales de color, textura, forma, escala, dirección, etc. Cuando son muchos los atributos que se desean representar, se suele utilizar también otras visualizaciones como los gráficos en estrella, que permiten codificar los atributos como variaciones en los radios de la estrella o en las características de una forma básica. Por ejemplo, la percepción sobre un emoticono puede variar sustancialmente dependiendo de la variación del estado de la boca. Para que este tipo de gráficos tenga sentido, lo importante es que los cambios en las formas del gráfico intuitivamente se asocien las variaciones en las características de interés. En el ejemplo anterior de la boca, una sonrisa puede equivaler a una satisfacción por parte de un cliente en una compra o reflejar un consumo eficiente, etc.

Ahora bien, normalmente, lo que nos va a interesar es representar conjuntos de instancias, bien para establecer diferencias, bien para extraer características comunes. Distinguiremos si las instancias que deseamos representar son independientes (no presentan, a priori, relaciones conocidas entre ellas) o están relacionadas (y esta relación es clave en la representación).

Para instancias independientes, podemos querer describir una variable visualizando su distribución respecto a sí misma, esto es, la composición de una variable. Ejemplos de visualizaciones que describen la composición o distribución de una variable son los diagramas de barras, las tartas, los histogramas o las funciones de distribución. Una vez seleccionado el tipo de gráfico, deberemos seleccionar si deseamos una escala de referencia absoluta (número de instancias) o relativa (porcentual).

4.1.2 Métodos de selección de gráficos

El principal interés a la hora de seleccionar un gráfico no está en los colores sino en su estructura, esto es, en la claridad de su organización y conceptualización que la hagan sumamente intuitiva y refleje elegantemente lo que se puede o se quiere reflejar en un gráfico.

Con el paso de los años van apareciendo nuevas formas de representación visual que permiten la visualización en problemas en los que hay un gran número de variables o permiten una visualización interactiva a partir de una organización jerárquica de la información. En el presente capítulo se verán las más típicas, además de relevantes.

Para lograr este objetivo, es necesario llevar a cabo una clasificación inicial o agrupación de los distintos tipos de gráficos que comparten características similares, aunque algunos pueden ser adecuados en varias de las agrupaciones. Se trata de comenzar el viaje hacia la identificación de la forma más adecuada para responder a un objetivo, cómo se va a construir, el tipo de audiencia, etc.

A continuación, se muestra una clasificación inicial de tipos de representaciones visuales, tal y como se detalla en [**Oetting2018**]:

1. *Comparación de categorías*. Facilitan la comparación de valores categóricos, tanto de manera absoluta como relativa. El ejemplo clásico sería el gráfico de columnas o barras. También pueden utilizarse áreas, líneas, puntos, histogramas, etc.
2. *Jerarquías*. El propósito es establecer un desglose de valores categóricos en su relación con una población de valores, o bien elementos pertenecientes a estructuras jerárquicas. El ejemplo aquí sería el gráfico circular. Otros tipos de gráficos podrían ser las barras apiladas, árboles, etc.
3. *Evolución a lo largo del tiempo*. Son útiles para explotar datos temporales y mostrar las tendencias y patrones de valores cambiantes en un marco de tiempo continuo. Un ejemplo típico es el gráfico de líneas simples o compuestas, dispersión, etc.
4. *Conexiones y relaciones*. En este punto, estas representaciones se utilizan para evaluar

asociaciones, distribuciones y patrones. Se suelen utilizar en análisis exploratorios de datos. Un ejemplo puede ser un diagrama de dispersión. Por ejemplo, para comprobar la relación entre dos grupos de datos se pueden utilizar gráficos de dispersión, burbujas, o incluso líneas.

5. *Mapas geoespaciales*. Como su propio nombre indicada se utilizan para representar datos geoespaciales.

También se ha de tener en cuenta que una visualización puede estar compuesta por varios gráficos, conocidos como dashboards, tal y como se verá al final de este capítulo. Se puede encontrar información adicional sobre los métodos de representación visual y representaciones adicionales en [**Kirk2012**].

4.2 Representación estática

En el presente apartado se especificará la representación estática de objetos cuando se representa la información de manera visual, la distribución espacial de la información, su distribución por categorías, series temporales que nos permitan ver la evolución visual de la información a lo largo del tiempo, relaciones jerárquicas y mapas conceptuales.

4.2.1 Gráfico de columnas/barras

Los gráficos de columnas permiten comparar varios elementos entre si. Puede representarse incluso una evolución general, tal y como se muestra en la Fig. 4.1. Para este tipo de gráficos es recomendable utilizar colores consistentes, resaltando con color los cambios y utilizar etiquetas horizontales que faciliten la lectura. También se debería iniciar el eje Y en 0 para que la gráfica refleje correctamente los valores representados. En caso contrario, las proporciones podrían no reflejar la realidad. Además, se debe evitar el desorden cuando una etiqueta de datos es larga o si tiene más de 10 elementos para comparar.



Figura 4.1: Ejemplo de gráfico de columnas

Actividad 4.1 Interpreta la representación gráfica de la Fig. 4.1 y describe que mejoras sencillas introducirías para dicha visualización. ■

Por su parte, los gráficos de barras, son muy similares con una orientación diferente (ver Fig. 4.2). Este tipo de visualización también se puede usar para mostrar números negativos. Las

recomendaciones que podríamos ofrecer a estos tipos de gráficos son muy similares a los gráficos de columnas.



Figura 4.2: Ejemplo de gráfico de barras

Actividad 4.2 Compara las representaciones gráficas de las Figs. 4.1 y 4.2, ¿cual de ellas representa mejor los datos presentados? ■

4.2.2 Gráfico de líneas

Un gráfico de líneas revela las tendencias o el progreso en relación a otras variable (como por ejemplo, el tiempo). Se puede usar para mostrar muchas categorías diferentes de datos. El conjunto de datos es continuo. En caso de ser discreto habría que ir uniendo los puntos generados. Para este tipo de gráficos se recomienda utilizar únicamente líneas sólidas, no mostrar más de cuatro líneas para evitar distracciones y utilizar a altura adecuada (2/3 de la altura del eje Y). Un ejemplo se muestra en la Fig. 4.3.

Actividad 4.3 ¿Un gráfico de líneas es adecuado para medir la evolución de la temperatura a lo largo del tiempo? Realiza un ejemplo relacionado con la medición de temperatura o cualquier otro parámetro con la librería matplotlib de python. Más información sobre la librería en: `https://matplotlib.org/stable/users/index.html`. ■

Un gráfico un poco más complejo que el anterior podría ser el de dos ejes para representar 3 variables. En este caso se combinaría dos tipos de gráficos, como por ejemplo una gráfica de columnas y de ejes en el mismo lugar, compartiendo el mismo eje horizontal a comparar. Como recomendaciones tenemos la utilización del eje Y en el lado izquierdo para la variable principal porque estamos naturalmente inclinados a mirar primero a la izquierda, además de elegir colores contrarios para diferenciar los dos conjuntos de datos.

4.2.3 Gráfico de área

Un gráfico de área tiene la intención de mostrar relaciones de una parte a la otra, como por ejemplo mostrar la contribución de los representantes de ventas individuales a las ventas totales

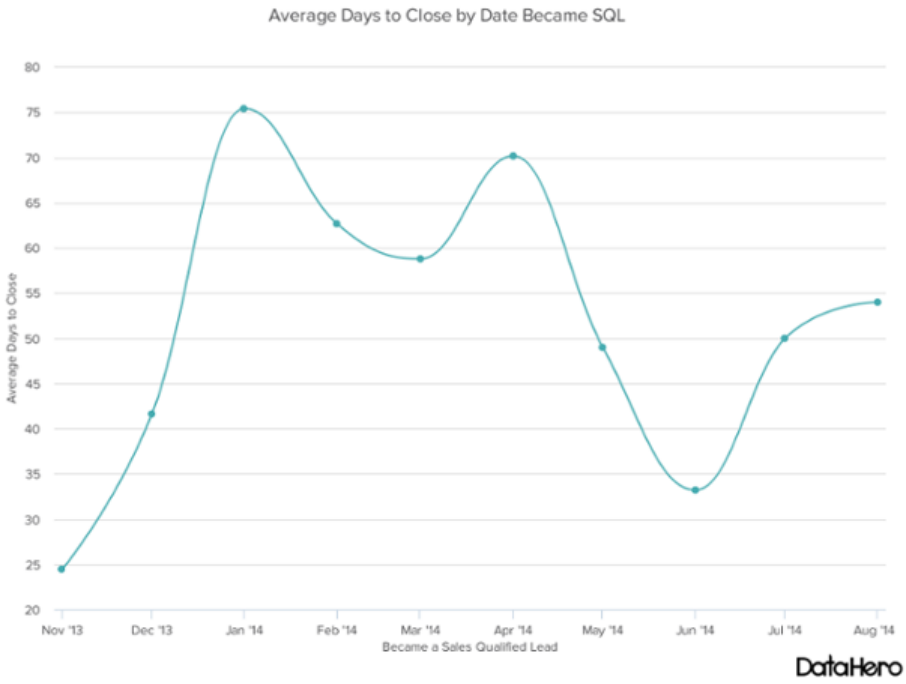


Figura 4.3: Ejemplo de gráfico de líneas

durante un año, tal y como se muestra en la Fig. 4.4. El objetivos principal de este tipo de gráfico es analizar la información de tendencias tanto general como individual.

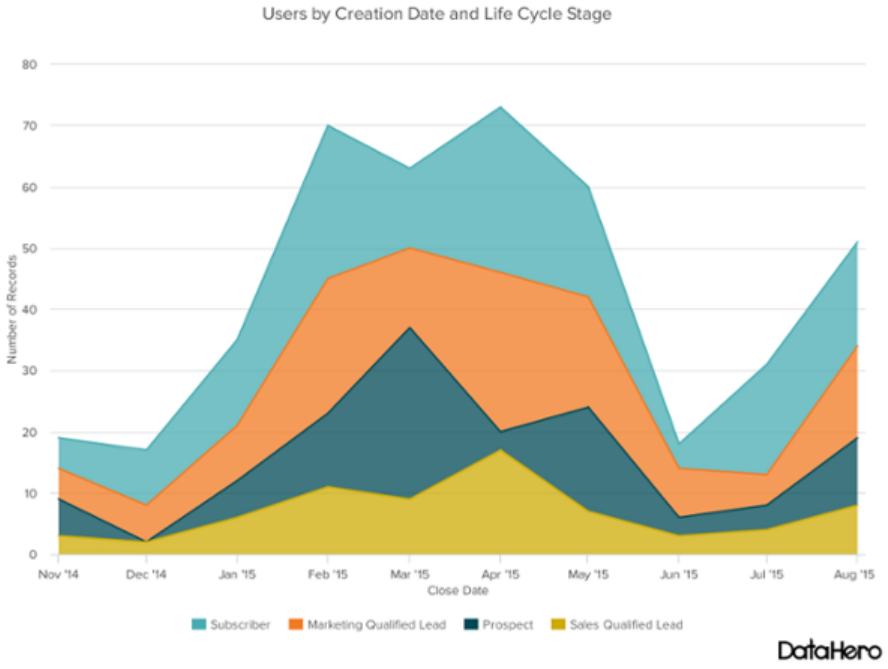


Figura 4.4: Ejemplo de gráfico de área (gráfico obtenido de [**Oetting2018**])

Actividad 4.4 Realiza un gráfico de área con la librería matplotlib de python. Más información sobre la librería en: `https://matplotlib.org/stable/users/index.html`. ■

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:

- Usar colores transparentes para que la información no se oculte en el fondo.
- No usar más de cuatro categorías para evitar el desorden.
- Organizar los datos altamente variables en la parte superior del cuadro para facilitar la lectura.

4.2.4 Gráfico de barras apiladas

Un gráfico de barra apiladas tiene como objetivo principal el comparar muchos elementos diferentes y mostrar la composición de cada elemento que se compara, tal y como se muestra en la Fig. 4.5. Es un buen tipo de gráfico para ilustrar relaciones de una parte a la otra.

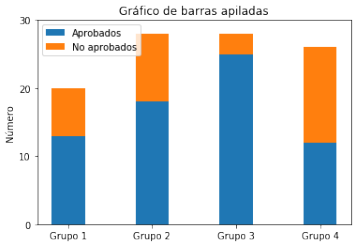


Figura 4.5: Ejemplo de gráfico de barras apiladas

Actividad 4.5 Realiza un gráfico de barras apiladas con la librería matplotlib de python. Más información sobre la librería en: `https://matplotlib.org/stable/users/index.html`. ■

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:

- Se deben utilizar colores que resalten la información para mayor claridad.
- Hay que usar una escala de gráfico lo suficientemente grande como para ver los tamaños de un grupo en relación con el otro.

4.2.5 Grafico circular

Un gráfico circular muestra un número estático y cómo las categorías representan parte de un todo: la composición de algo. Los números en porcentajes, y la suma total de todos los segmentos debe ser igual al 100 %. Puede verse un ejemplo en la Fig. 4.6.

Actividad 4.6 Realiza un gráfico circular con la librería matplotlib de python. Más información sobre la librería en: `https://matplotlib.org/stable/users/index.html`. ■

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:

- No añadir demasiadas categorías para garantizar la diferenciación entre sectores.
- Asegúrese de que los valores de corte sumen hasta 100 %.
- Ordenar los sectores acorde a su tamaño.

4.2.6 Gráfico de dispersión

Para instancias independientes, también podemos querer representar la dispersión dentro de una muestra de datos. Este tipo de gráfico muestra la relación entre dos variables diferentes o puede revelar las tendencias de distribución. Por ejemplo, en la Fig. 4.7 se pueden observar muchos puntos de instancias distintas, con la intención de resaltar similitudes o disimilitudes en el conjunto de

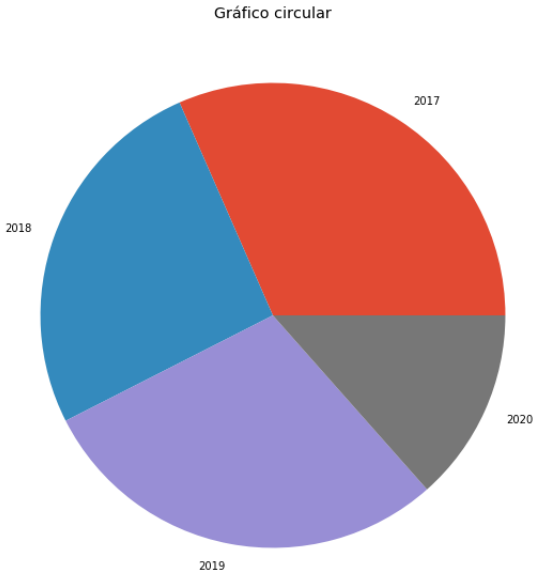


Figura 4.6: Ejemplo de gráfico circular

datos. Se buscan valores atípicos o comprender la distribución de sus datos. Se pueden incluir más variables, como diferentes tamaños, para incorporar más datos.



Figura 4.7: Ejemplo de gráfico de dispersión (gráfico obtenido de [**Oetting2018**])

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:

- Comenzar el eje Y en 0 para representar datos con precisión.
- Si se incluyen líneas de tendencia, solo usar un máximo de dos para que el diagrama sea fácil de entender.

Actividad 4.7 Realiza un gráfico de dispersión con la librería matplotlib de python. Más información sobre la librería en: `https://matplotlib.org/stable/users/index.html`. ■

Como casos especiales de este tipo de gráficos tenemos los gráficos en los que los ejes represen-

tan el espacio o el tiempo, o sea, los mapas y las líneas temporales. Un ejemplo de esto es cuando por ejemplo buscamos en Google Maps hoteles en una ciudad concreta. En este caso, no se fija un origen de referencia porque las coordenadas absolutas no son de interés. Para encontrar ejemplos de gráficos de línea temporal, podemos buscar "Gráficos 1D, 2D, 3D, . . . " en imágenes de Google o de cualquier otro buscador.

4.2.7 Gráfico de burbujas

Los gráficos de burbujas son similares a los de dispersión en el sentido de que puede mostrar distribución o relación. En este caso se tiene un conjunto de datos adicional que se indica por el tamaño de la burbuja o círculo. Se puede observar un ejemplo en la Fig. 4.8. En relación con este tipo de gráficos, en la Fig. 2.18 del Capítulo 2 ya utilizó un gráfico de este estilo para representar la relación entre anchos de pétalo y sépalo para varias especies de hojas.

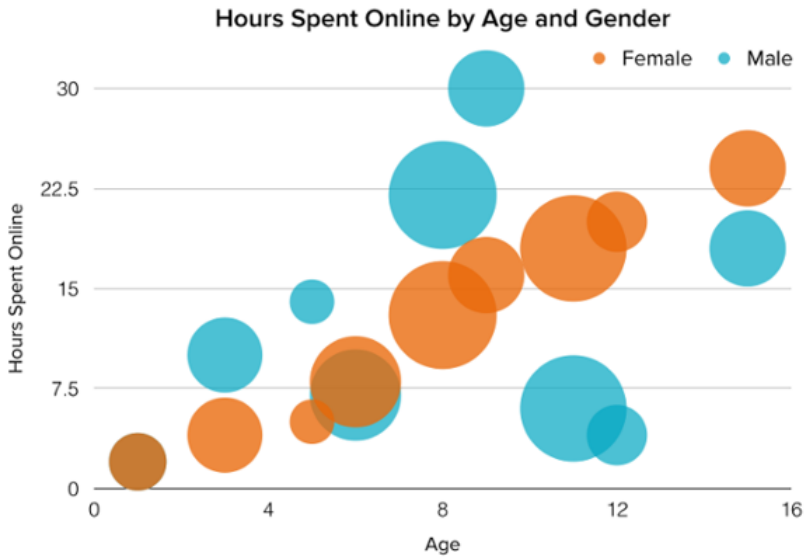


Figura 4.8: Ejemplo de gráfico de burbujas (gráfico obtenido de [**Oetting2018**])

Actividad 4.8 Analiza e interpreta el gráfico de la Fig. 4.8. ■

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:
- Asegurarse que las etiquetas sean claras y visibles.
- Escalar las burbujas según el área, no el diámetro.
- Usar formas circulares solamente.

4.2.8 Gráfico en cascada

Un gráfico en cascada tiene como objetivo principal mostrar un valor inicial que se ve afectado por valores intermedios, ya sean positivos o negativos, y que como resultado final tenga un valor. Un ejemplo puede verse en la Fig. 4.9, donde se revela la composición de un valor.

Actividad 4.9 Analiza e interpreta el gráfico de la Fig. 4.9. ■

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:
- Utilizar colores destacados para resaltar las diferencias en los conjuntos de datos.
- Seleccionar colores cálidos para indicar aumentos y colores fríos para indicar disminuciones.

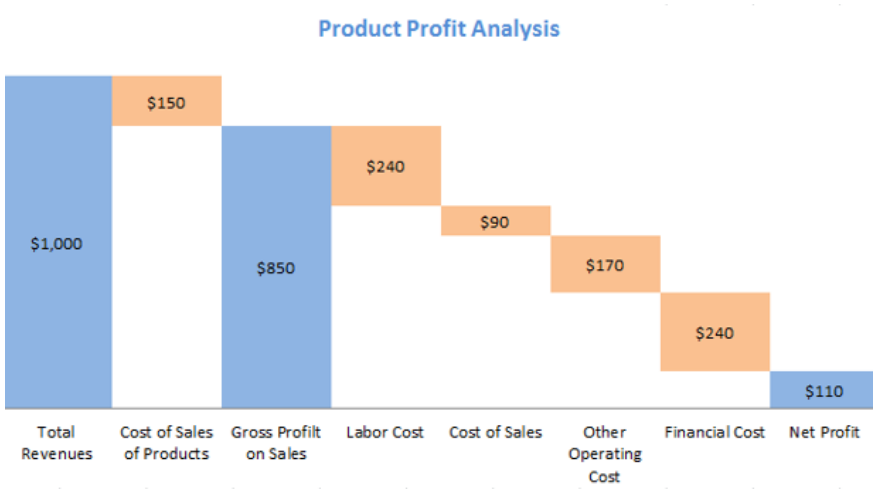


Figura 4.9: Ejemplo de gráfico en cascada (gráfico obtenido de [**Oetting2018**])

4.2.9 Mapa de calor

Los mapas de calor muestran la relación entre dos elementos y proporciona información de clasificación, como alta a baja o de baja a excelente. Por tanto, se suelen utilizar colores variados o saturación para clasificar la información, tal y como se muestra en la Fig. 4.10. Para gráficos con valores continuos la variación de colores se podría mostrar mediante degradados de color, tonalidades, etc.

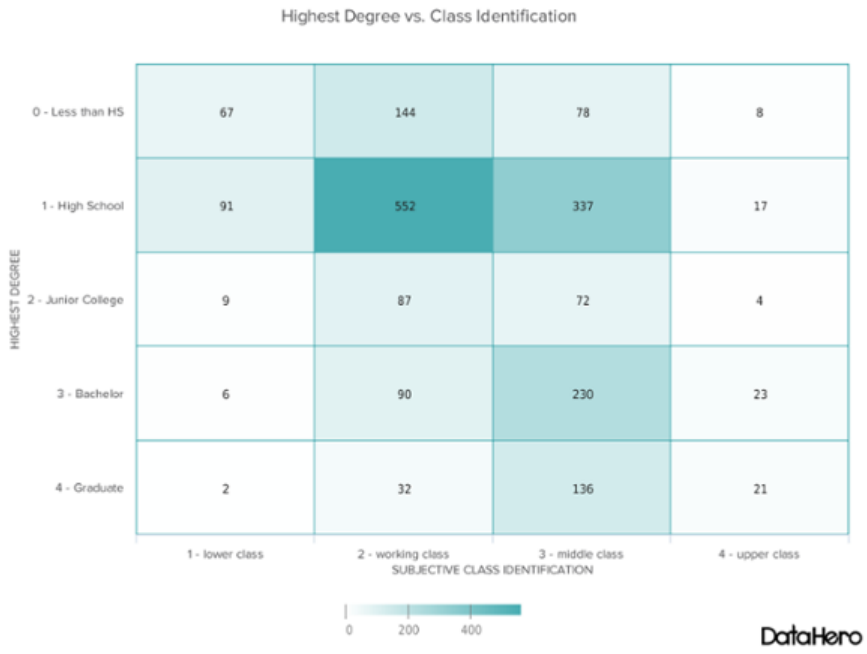


Figura 4.10: Ejemplo de mapa de calor (gráfico obtenido de [**Oetting2018**])

Actividad 4.10 Analiza e interpreta el gráfico de la Fig. 4.10. ■

Como recomendaciones de buenas prácticas tenemos lo siguiente para este tipo de gráfico:

- Usar un esquema de mapa básico y claro para evitar distraerse de los datos.

- Usar un solo color en diferentes tonos para mostrar los cambios en los datos.
- Evitar la utilización de patrones múltiples.

4.2.10 Grafos

Otro grupo de visualizaciones muy interesantes son aquellas que reflejan las relaciones entre las instancias. Se trata de distintas variaciones del concepto de "grafos" en el que las instancias se representan mediante nodos y las relaciones entre nodos mediante enlaces (cada tipo de enlace representa un tipo de relación distinto). Se puede observar un ejemplo sencillo de representación de grafo en la Fig. 4.11 en el cual existen varios grupos de elementos relacionados entre ellos.

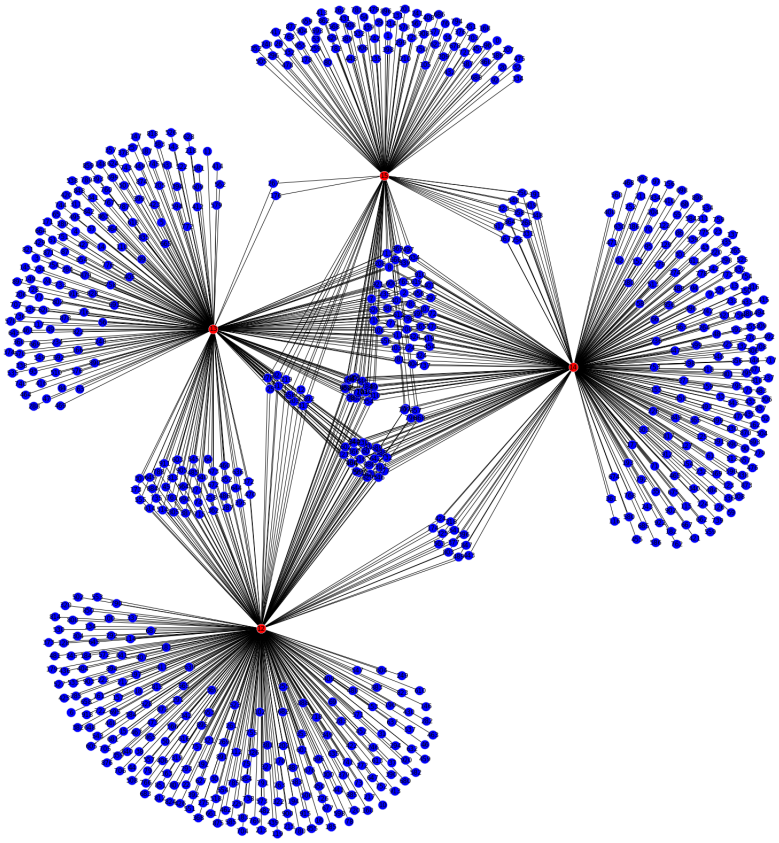


Figura 4.11: Ejemplo sencillo de grafo [**Robles2016**]

Actividad 4.11 ¿Cómo interpretarías el grafo representado en la Fig. 4.11?¿es necesaria información adicional? ■

Llegados a este punto, distinguiremos dos tipos de grafos en función de los tipos de enlaces que se manejan, 1) aquellos diseñados para que la visualización sea interpretada por humanos, en los que se mezclan distintos tipos de enlace porque el humano es capaz de navegar por ellos fácilmente y 2) aquellos que se utilizan como mecanismo de representación de grandes volúmenes de información y que permiten el análisis automático utilizando teoría de grafos, que se basan en un único tipo de enlace.

Por ejemplo, mediante teoría de grafos, es posible detectar islas (nodos no enlazados con el resto), puentes y repartidores (hubs) que hacen de conexión entre grupos, componentes conectados, subredes, la centralidad de la red, el prestigio de un nodo, puntos débiles de la red, el camino más

corto entre dos nodos, etc. La herramienta interactiva Gephi (`http://gephi.github.io`) permite realizar fácilmente análisis de redes.

Por ejemplo, si analizamos con detalle la Fig. 4.12, que muestra relaciones complejas, vemos que hay distintas agrupaciones (mostradas con colores diferentes). Se pueden crear grafos dinámicos muy útiles para analizar redes sociales con la librería NetworkX (`https://networkx.github.io/`) en python, aunque este se sale de los objetivos base de este manual.

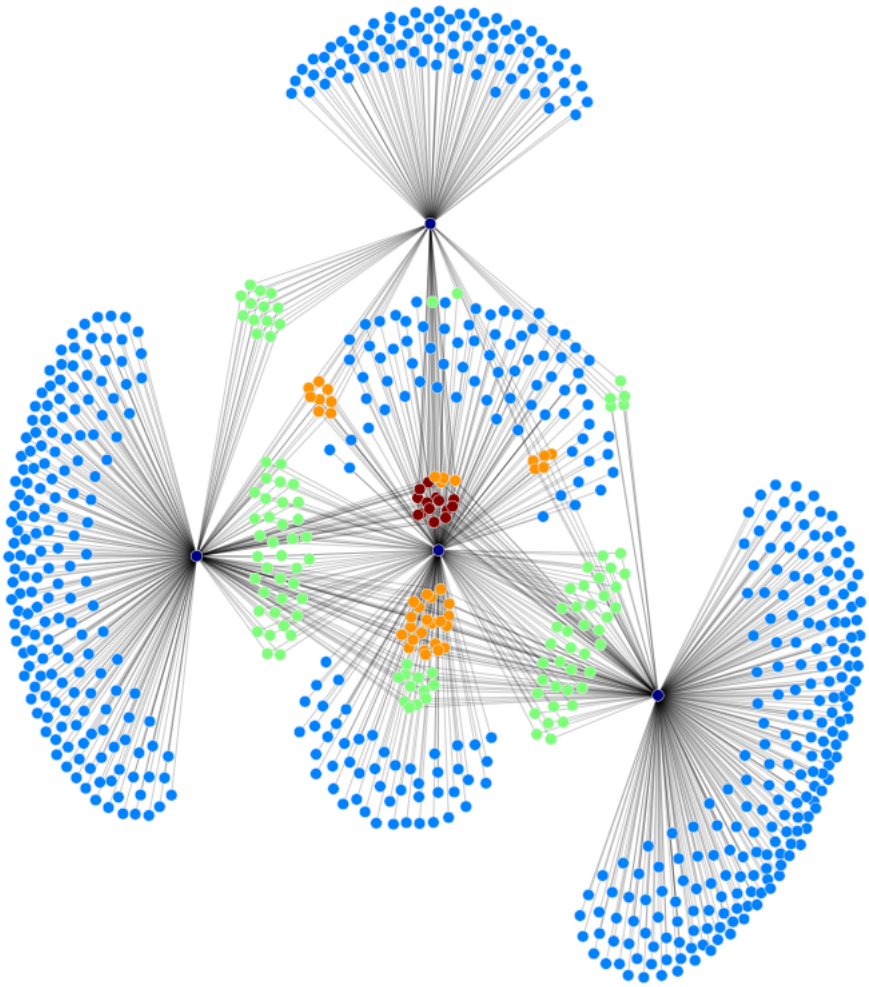


Figura 4.12: Ejemplo complejo de grafo [**Robles2016**]

Actividad 4.12 Lee el artículo [**Robles2016**], publicado en el Digital Humanities 2016 (DH 2016), sobre un estudio realizado sobre los mensajes de blog del día de las humanidades digitales desde el año 2009 al 2015. Una vez leído, interpreta y describe el grafo mostrado en dicho artículo. ■

Finalmente, otro tipo de grafos interesantes son los árboles genealógicos, que pueden ser considerados grafos dirigidos sin ciclos. Un ejemplo de este tipo de grafo y su proceso de realización puede encontrarse en: `https://es.slideshare.net/davilamaestra/ejemplo-de-rbol-genealgico`. Los mapas conceptuales son otro tipo de representaciones de este tipo.

4.2.11 Visualización de textos

Un caso especial, y aplicable también cuando el número de posibles valores de una variable categórica es elevado, mapa de etiquetas, en los que las clases se distinguen por posición, orientación, color, etc., y la distribución se indica por el tamaño. Esto permite comparaciones relativas entre clases, pero se pierde la idea del total de la distribución. En el siguiente sitio web se pueden generar nubes de palabras: `https://www.nubedepalabras.es/`. También se puede hacer de forma programática con cualquier lenguaje de programación.

Por ejemplo, se puede representar una nube de con la palabras más relevantes, en término de frecuencia de aparición en los mismos. La Fig. 4.13 muestra una nube de palabras con distintas frecuencia de aparición en un conjunto de textos. En este caso concreto, los tópicos de interés en los mensajes escritos en un blog. Para ello, se ha tenido que extraer las palabras más relevantes, filtrar (quitar las stopwords), calcular su frecuencia de aparición, y ordenarlos con respecto a un criterio. En el caso concreto que nos ocupa, cuanto más grande es la frecuencia de aparición, mayor es el tamaño de la palabra en la representación gráfica.



Figura 4.13: Ejemplo de nube de palabras [**Robles2016**]

Actividad 4.13 En la nube de palabras mostrada en la Fig. 4.13, ¿cuales crees que son las palabras más frecuentes? ■

Siguiendo con el análisis de textos, se pueden llevar a cabo otro tipo de representaciones, distintos a los mapas de etiquetas, como puede ser el análisis de la polaridad en los textos mediante un gráfico de dispersión (u otro tipo de representación). Esto es, comprobar si los mensajes son positivos o negativos. En la Fig. 4.14 se muestra un gráfico de dispersión que muestra un ejemplo de polaridad de cada mensaje escrito por un usuario. Esto es un ejemplo sencillo, y se podría añadir gran complejidad al análisis de cada mensaje, incluyendo emociones o sentimientos mucho más complejos. Se podrían incluso aplicar técnicas de Machine Learning (ML) para analizar el discurso en redes sociales [**Elinas2019b**].

Actividad 4.14 Revisa las representaciones visuales de cada tipo de gráfico que se hizo en la presentación del artículo [**Robles2016**]. Analiza cada una de las gráficas presentadas, haciendo especial hincapié en las que tienen que ver con el análisis de textos. Dicha presentación puedes encontrarla en: `https://es.slideshare.net/UnedLaboratoriodeInn/researchers-perceptions-of-dh-trends-and-topics-64286054` ■

Por otra parte, tenemos los mapas de árboles, que es un tipo de visualización que permite aumentar el número de categorías que forman parte de la distribución total. El tamaño de cada categoría, su área respecto al total, representa su porcentaje en la distribución total. Además, utilizando el color o el grosor de las líneas, es posible establecer distintos niveles de detalle dentro del mismo gráfico. En el enlace web `https://mappa.mundi.net/maps/maps_009/` puede verse

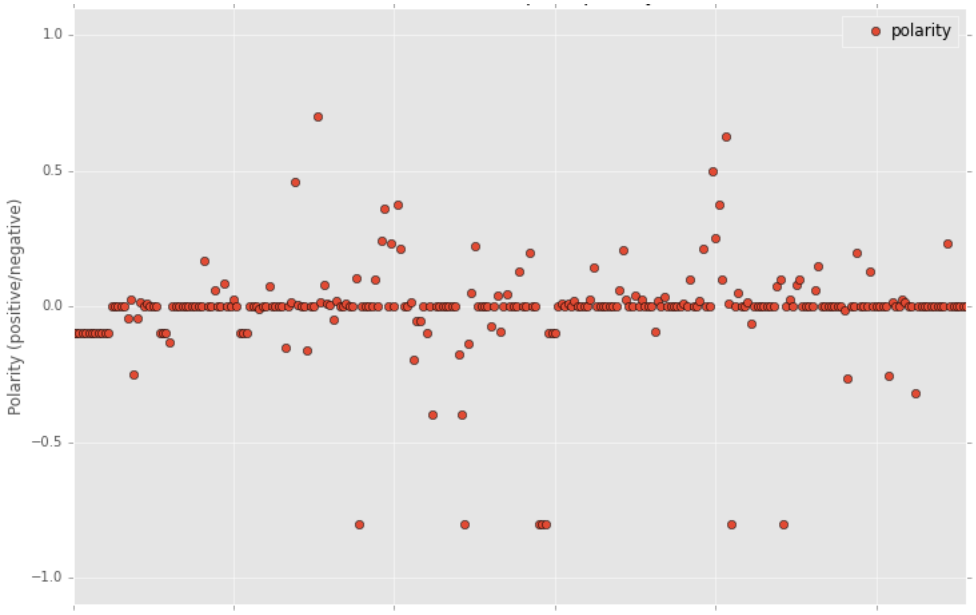


Figura 4.14: Ejemplo de gráfico de dispersión sobre polaridad [**Robles2016**]

un ejemplo de este tipo de visualización.

Para tener en cuenta el contexto en el que se utiliza una palabra, se pueden utilizar los árboles de palabras. Un ejemplo de análisis de los discursos de Obama se puede encontrar en: `https://www.juanosborne.com/2011/11/in-obamas-words/`.

Finalmente, en el capítulo 2, se ha hecho referencia a los dendrogramas. En el siguiente enlace se muy un ejemplo de dendrograma complejo: `https://bl.ocks.org/mbostock/4339607`

Actividad 4.15 Visualiza e interpreta el dendrograma que se acaba de referenciar. ■

4.3 Representación dinámica

En ocasiones, una visualización no está orientada al análisis directo de los datos, sino simplemente a facilitar la navegación por los datos para poder acceder fácilmente al subconjunto de datos de interés mediante operaciones de selección, clasificación, filtrado, etc. en sistemas interactivos. La forma más habitual de presentar grandes volúmenes de información es mediante estructuras, en las que se presentan y se tiene acceso a unas pocas categorías abstractas, bajo las cuales se encuentran nuevas subcategorías hasta llegar a las instancias concretas. Obsérvese que sólo estamos interesados en representar la estructura de la representación del conjunto de instancias, sin hacer ninguna referencia a la cantidad de éstas dentro de cada categoría.

4.3.1 Dashboards

Llegado este punto, vamos a abordar los dashboards, o paneles de control para la representación dinámica de información. Ya se han introducido en el capítulo 1. Básicamente, es un conjunto de gráficos, interactivos o no, y que pueden llegar a ser controlados y/o actualizados mediante un conjunto de paneles. Los paneles de control representan de manera gráfica los principales indicadores (KPI) que intervienen en la consecución de los objetivos (en distintos ámbitos de actuación), y que está orientada a la toma de decisiones para optimizar la estrategia de la organización o institución correspondiente.

A la hora de construir un dashboard debemos realizarnos un conjunto de preguntas:

- ¿Cuál es el problema o la cuestión que este dashboard intenta solucionar/responder?
- ¿Esta es la mejor manera de representar la información?
- ¿Todos los elementos o componentes son necesarios y tienen sentido?
- ¿Hay interactividad funcional?
- ¿Existen etiquetas y son claras?

Esto es, tal y como se muestra en la Fig. 4.15, se debe generar una información representable a partir de unos datos obtenidos (y filtrados), tal y como se ha detallado en capítulos anteriores. A partir de las visualizaciones generadas y los análisis llevados a cabo, se generará un nuevo conocimiento que depende del tipo de audiencia destinataria.



Figura 4.15: Flujo: Datos-Información-Conocimiento

Por tanto, algunos consejos básicos que pueden ayudarnos a elaborar un dashboard son los siguientes:

- Utilizar el tipo de gráfico adecuado para cada indicador.
- Comparar varios tipos de gráficos si tenemos dudas a la hora de realizar un tipo de representación.
- Relacionar varias fuentes de datos en una sola visualización o diferentes visualizaciones para una sola fuente de datos. Es decir, conectar puntos en principio no relacionados.
- Permitir a los usuarios contestar sus preguntas. Esto es, utilizar el tipo adecuado de interactividad y probar diversas opciones.
- Usar encabezados, etiquetas y ayuda contextual para añadir contexto, sin ser excesivos.
- Dedicarle tiempo, no conformarnos con la primera versión.

A partir de todo lo aprendido en el presente capítulo y los anteriores, se pueden crear buenos dashboards con visualizaciones interactivas. Es decir, en algunas de ellas, existen varios controles que nos permiten actualizar la información presentada al usuario de manera dinámica. En la Fig. **??** se presenta un ejemplo de dashboard creado con Tableau y que puede ser manejado desde la url correspondiente, al estar publicado en la utilidad de Tableau Public.

Para finalizar, en la Fig. 4.17 se muestra de manera comparativa la utilidad (o no) de un dashboard. En resumen, sirven para identificar datos relevantes, haciendo especial énfasis en los KPIs necesarios para en conjunto de visualizaciones, debiendo reflejar el cumplimiento de unos objetivos específicos. En cambio, de cara a un informe con una audiencia destino no sirven para analizar las razones de algo al cruzar datos y/o es estudio de problemas asociados. De cara a realizar un análisis inicial y exploratorio de datos de manera interna serían útiles, y una vez fijado el objetivo, mejorarlos con los objetivos específicos propuestos.

4.3.2 Actividades sobre cuadros de mandos

Actividad 4.16 Visualiza e interpreta el ejemplo proporcionado en la Fig. 4.16, ¿cómo está organizado dicho dashboard? ¿qué información obtenemos? ■

Actividad 4.17 Visualiza e interpreta todas las visualizaciones presentadas en el enlace web: `https://public.tableau.com/profile/mirandali#!/vizhome/ExecutiveSalesforce/SalesPerformance`. Si te fijas, verás que existen varias pestañas con un dashboard distinto, ¿qué



Figura 4.16: Ejemplo de dashboard creado con Tableau y obtenido del siguiente enlace: `https://public.tableau.com/profile/mirandali#!/vizhome/ExecutiveSalesforce/SalesPerformance/`



Figura 4.17: Ejemplo de

significa? ■

Actividad 4.18 Analiza las explicaciones sobre las visualizaciones del siguiente enlace web: `https://www.tableau.com/about/blog/2015/9/top-metrics-every-sales-executive-cant-live-without-43746`, ¿qué conclusiones obtienes? Elabora un informe imaginando que la audiencia destino son los jefes de una organización. ■

4.4 Ejercicios

Ejercicio 4.1 Lee e interpreta las visualizaciones presentadas en la referencia [**Stodder2013**], ¿que conclusiones obtienes? ¿cuales son las recomendaciones que harías? ■

Ejercicio 4.2 Realiza un representación gráfica de líneas para comparar dos variables a lo largo del tiempo con la librería matplotlib de python, u otra más avanzada que se apoye sobre esta (como puede ser Bokeh, por ejemplo). Más información sobre la librería en: `https://matplotlib.org/stable/gallery/index.html`. ■

Ejercicio 4.3 Lee el artículo [**Robles2016**], publicado en el Digital Humanities 2016 (DH 2016), sobre un estudio realizado sobre los mensajes de blog del día de las humanidades digitales desde el año 2009 al 2015. Una vez leído, interpreta y describe las nubes de palabras mostradas en dicho artículo. ■

Ejercicio 4.4 Lee el artículo [**Heer2010**] e interpreta las visualizaciones expuestas en el mismo. Concluye que se quiere representar en cada una de ellas. ■

Ejercicio 4.5 Lee el artículo [**Elinas2019a**] e interpreta las visualizaciones de grafos expuestas en el mismo. ■

Ejercicio 4.6 Visualiza e interpreta todas las visualizaciones presentadas en el enlace web: `https://public.tableau.com/views/SoberingeffectsofDrinkingandDrivingiPad/Dashboard?%3Aembed=y&%3AshowVizHome=no`. Elabora un informe sobre dichas representaciones visuales. ■



Bibliografía

[1] F.J. Anscombe, "Graphs in Statistical Analysis,.ᴬmerican Statistician, 27 (febrero de 1973), 17-21.

[2] Alberto Cairo. 2016. The Truthful Art: Data, Charts, and Maps for Communication (1st. ed.). New Riders Publishing, USA.

[3] Pantelis Elinas, Anna Leontjeva, Yuriy Tyshetskiy. Knowing Your Neighbours: Machine Learning on Graphs. Medium blog, 2019. URL: https://medium.com/stellargraph/knowing-your-neighbours-machine-learning-on-graphs-9b7c3d0d5896.

[4] Pantelis Elinas. Can graph machine learning identify hate speech in online social networks? A use-case study for Twitter users. Medium blog, 2019. URL: https://medium.com/stellargraph/can-graph-machine-learning-identify-hate-speech-in-online-social-networks-58e3b80c9f7e.

[5] Jeffrey Heer, Michael Bostock, Vadim Ogievetsky. A Tour through the Visualization Zoo: A survey of powerful visualization techniques, from the obvious to the obscure. Stanford University, 2010. URL: https://queue.acm.org/detail.cfm?id=1805128

[6] Jami Oetting. Data Visualization 101: How to Choose the Right Chart or Graph for Your Data, 2018. URL: https://blog.hubspot.com/marketing/data-visualization-choosing-chart.

[7] Antonio Robles-Gómez, Elena González-Blanco, Salvador Ros, Gimena del Rio Riande, Roberto Hernández, Llanos Tobarra, Agustín C. Caminero, Rafael Pastor. Researchers' perceptions of DH trends and topics in the English and Spanishspeaking community: DayofDH data as a case study. Digital Humanities 2016 conference, 2016. URL: https://pdfs.semanticscholar.org/2744/54105bdcbee3e0b91b5e096d684e5a0b4f98.pdf?_ga=2.238575363.2070726760.1580377895-1263694069.1575829003.

[8] David Stodder. Data Visualization and Discovery for Better Business Decisions. TDWI Best Practices Report, 2013. URL: http://solutiondesignteam.com/wp-content/uploads/data-visualization-discovery-better-business-decisions-106672.pdf.



Índice alfabético

C

Cuestiones 41

E

Ejercicios 20, 39, 57, 81

V

Vocabulario 41